

**PERANCANGAN SISTEM *BUSINESS*
INTELLIGENCE BERBASIS *RULE-BASED*
CHATBOT DENGAN *TIME SERIES*
FORECASTING DAN TEKNOLOGI BAHASA
ALAMI UNTUK ANALISIS DAN PREDIKSI
KINERJA BISNIS**

Laporan Tugas Akhir

Oleh

**Thalita Zahra Sutejo
18222023**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Juni 2026**

LEMBAR PENGESAHAN

PERANCANGAN SISTEM *BUSINESS INTELLIGENCE* BERBASIS *RULE-BASED CHATBOT* DENGAN *TIME SERIES* *FORECASTING* DAN TEKNOLOGI BAHASA ALAMI UNTUK ANALISIS DAN PREDIKSI KINERJA BISNIS

Laporan Tugas Akhir

Oleh

Thalita Zahra Sutejo
18222023

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 8 Juni 2026

Pembimbing



Dr. Ir. Dimitri Mahayana, M.Eng.

NIP. 196808091991021001

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 8 Juni 2026



Thalita Zahra Sutejo
NIM: 18222023

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Gemini	Menengah	Bab III – Bab VI (<i>refine</i> teks)
2	Pembuatan teks	Gemini	Menengah	Bab III – Bab VI (<i>refine</i> teks)
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	ChatGPT	Rendah	Seluruh bab
5	Penyusunan bahan diskusi	Tidak ada	Tidak ada	Tidak ada
6	Penyusunan kode program	Claude	Menengah	Kode <i>frontend</i> , <i>backend</i> , dan layanan ML
7	Penyusunan formula atau perhitungan matematis	Tidak ada	Tidak ada	Tidak ada
8	Penyusunan konsep desain atau algoritma	Gemini	Rendah	Bab IV Perancangan
9	Penyusunan analisis data	Gemini	Rendah	Bab VI Evaluasi
10	Penyusunan kesimpulan atau rekomendasi	Tidak ada	Tidak ada	Tidak ada

Bandung, 8 Juni 2026



Thalita Zahra Sutejo

NIM: 18222023

ABSTRAK

Perancangan Sistem *Business Intelligence* Berbasis *Rule-Based Chatbot* dengan *Time Series Forecasting* dan Teknologi Bahasa Alami untuk Analisis dan Prediksi Kinerja Bisnis

oleh

Thalita Zahra Sutejo

18222023

Sistem *Business Intelligence* di lingkungan internal perusahaan umumnya masih bergantung pada pelaporan manual dan kemampuan teknis dalam menggunakan bahasa kueri untuk memperoleh *insight* dari data. Ketergantungan tersebut menyulitkan pengguna nonteknis, seperti manajer dan analis bisnis, dalam mengakses informasi secara mandiri dan tepat waktu. Sebagai solusi atas permasalahan tersebut, dilakukan perancangan dan implementasi sistem *Business Intelligence* berbasis *chatbot* yang memungkinkan pengguna internal melakukan analisis dan prediksi kinerja bisnis melalui antarmuka percakapan berbahasa Indonesia. Sistem ini menggunakan pendekatan *rule-based* untuk memahami pertanyaan pengguna, kemudian menghasilkan keluaran analitik dalam bentuk narasi bahasa Indonesia melalui modul *Natural Language Generation* berbasis templat. Selain kemampuan analitik, sistem juga dilengkapi dengan model peramalan deret waktu untuk mendukung prediksi kinerja bisnis pada periode berikutnya. Dengan menggunakan data dari *Enterprise Data Warehouse* internal perusahaan serta beberapa variasi model peramalan, dilakukan implementasi sistem yang mencakup proses klasifikasi maksud, eksekusi aturan analitik, pembangkitan narasi, dan peramalan deret waktu. Setelah implementasi, dilakukan evaluasi terhadap kemampuan analitik dan prediktif sistem. Evaluasi analitik menunjukkan bahwa sistem mampu menghasilkan narasi dengan akurasi faktual 100% berdasarkan aturan yang telah didefinisikan. Sementara itu, evaluasi prediktif dilakukan dengan membandingkan model GRU (*Gated Recurrent Unit*) dan LSTM (*Long Short-Term Memory*) terhadap model statistik ARIMA dan *Prophet* menggunakan metode *walk-forward validation* pada enam tingkat wilayah. Hasil evaluasi menunjukkan bahwa model GRU memberikan kinerja paling stabil, dengan lima wilayah berstatus lulus berdasarkan nilai sMAPE di bawah 30% dan satu wilayah berstatus lulus dengan catatan. Sementara itu, *Prophet* menunjukkan kinerja paling rendah dengan nilai sMAPE di atas 100% pada seluruh wilayah akibat ketidaksesuaian asumsi model terhadap karakteristik data operasional. Secara keseluruhan, sistem yang dikembangkan mampu membantu pengguna nonteknis memperoleh informasi analitik dan prediktif secara lebih cepat, mandiri, dan terstruktur untuk mendukung pengambilan keputusan bisnis internal.

Kata kunci: *Business Intelligence, Chatbot, Rule-Based, Natural Language Gene-*

ration, Time Series Forecasting, GRU, LSTM, ARIMA, Prophet.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala limpahan rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan Laporan Tugas Akhir yang berjudul “Perancangan Sistem *Business Intelligence* Berbasis *Rule-Based Chatbot* dengan *Time Series Forecasting* dan Teknologi Bahasa Alami untuk Analisis dan Prediksi Kinerja Bisnis”. Laporan ini disusun sebagai salah satu persyaratan untuk memperoleh gelar sarjana pada Program Studi Sistem dan Teknologi Informasi, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung. Penyusunan tugas akhir ini tidak terlepas dari bantuan, arahan, dan dukungan dari berbagai pihak. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Bapak Dr. Ir. Dimitri Mahayana, M.Eng., selaku dosen pembimbing tugas akhir, yang telah memberikan arahan, bimbingan, serta masukan yang sangat berarti bagi penulis selama proses pengerjaan tugas akhir ini.
2. Kak Naufal Pandu Irsyadi, selaku asisten dosen pembimbing, yang telah memberikan bantuan, pandangan, dan saran teknis yang mendukung proses penyusunan tugas akhir.
3. Bapak Renno Rifaldo, selaku *Data Specialist* di Telkom Indonesia, dan Bapak Purwanto, selaku *Manager Data Management* di Telkom Indonesia, yang telah memberikan kesempatan, pendampingan, serta dukungan kepada penulis selama pelaksanaan penelitian.
4. Bapak I Gusti Bagus Baskara Nugraha, S.T., M.T., Ph.D., selaku Ketua Program Studi Sistem dan Teknologi Informasi Institut Teknologi Bandung, yang telah memberikan dukungan dalam penyelenggaraan kegiatan akademik dan pelaksanaan tugas akhir.
5. Orang tua dan keluarga penulis yang senantiasa memberikan doa, kasih sayang, dorongan, serta dukungan baik secara moral maupun material selama penulis menempuh pendidikan hingga menyelesaikan tugas akhir ini.
6. Sahabat-sahabat penulis selama menjalani perkuliahan di Institut Teknologi Bandung yang telah menjadi tempat berbagi cerita, memberikan semangat, serta menemani penulis dalam berbagai proses selama masa studi.
7. Teman-teman Program Studi Sistem dan Teknologi Informasi angkatan 2022 serta teman-teman BYTE HMIF yang telah menjadi bagian dari perjalanan akademik penulis dan memberikan dukungan selama masa perkuliahan.

Penulis menyadari bahwa laporan tugas akhir ini masih belum sempurna. Oleh ka-

rena itu, penulis terbuka terhadap kritik dan saran yang membangun sebagai bahan perbaikan di masa mendatang. Akhir kata, penulis berharap laporan ini dapat memberikan manfaat bagi pembaca serta memberikan kontribusi bagi pengembangan ilmu pengetahuan, khususnya pada bidang *Business Intelligence*, kecerdasan buatan, dan peramalan deret waktu.

Bandung, 8 Juni 2026



Thalita Zahra Sutejo

DAFTAR ISI

LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN PENGGUNAAN AI	vii
ABSTRAK	ix
KATA PENGANTAR	xi
DAFTAR ISI	xiii
DAFTAR GAMBAR	xxi
DAFTAR TABEL	xxiii
DAFTAR PERSAMAAN	xxvii
DAFTAR ALGORITMA	xxix
DAFTAR <i>LISTING</i>	xxxix
DAFTAR SIMBOL	xxxiii
DAFTAR SINGKATAN	xxxv
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan	4
I.4 Batasan Masalah	5
I.5 Metodologi	6
I.5.1 Tahapan Investigasi dan Pengumpulan Fakta	6
I.5.2 Studi Literatur	7
I.5.3 Perancangan Sistem	7
I.5.4 Implementasi Sistem	8
I.5.5 Pengujian dan Evaluasi	8
I.5.6 Dokumentasi dan Penyusunan Laporan	9
I.5.7 Sistematika Penulisan	9
II STUDI LITERATUR	11
II.1 <i>Business Intelligence</i> dan Arsitektur Sistem	11
II.1.1 Konsep <i>Business Intelligence</i>	11
II.1.2 Arsitektur <i>Business Intelligence</i> Hibrida	12
II.1.3 <i>Semantic Layer</i> dalam <i>Business Intelligence</i>	12
II.1.3.1 Komponen Inti <i>Semantic Layer</i>	13
II.2 <i>Rule-Based Query</i> dan Implementasinya pada <i>Chatbot</i>	13
II.2.1 Konsep <i>Rule-Based Query</i> dalam Sistem Basis Data	14
II.2.2 <i>Chatbot</i> Berbasis Aturan dan Pencocokan Pola	14
II.2.3 Integrasi <i>Rule-Based Query</i> dalam Arsitektur <i>Chatbot BI</i>	15
II.3 <i>Pattern-Based Intent Classification</i> dengan <i>Confidence Level</i>	16
II.3.1 Konsep <i>Intent Classification</i>	16
II.3.2 Pertimbangan Alternatif: Klasifikasi <i>Intent</i> Berbasis <i>Transformer</i>	17
II.3.3 <i>Pattern Matching</i> untuk <i>Intent Classification</i>	17
II.3.4 <i>Confidence Score</i> dalam <i>Intent Classification</i>	18

II.3.4.1	<i>Confidence Threshold</i>	18
II.3.5	Evaluasi Performa <i>Intent Classification</i>	19
II.3.5.1	Metrik Evaluasi Klasifikasi <i>Intent</i> Multi-Kelas	19
II.3.5.2	<i>Confusion Matrix</i> dan <i>Confidence Score Analysis</i>	23
II.3.5.3	Target Performa <i>Intent Classification</i>	23
II.4	<i>Template-Based Natural Language Generation</i>	23
II.4.1	Konsep <i>Natural Language Generation</i>	24
II.4.2	<i>Template-Based Natural Language Generation</i>	24
II.4.3	<i>Template Rewriting</i> dengan <i>Pre-trained Language Models</i>	25
II.4.4	Keamanan dan Privasi Data dalam NLG Internal	25
II.4.4.1	<i>Differential Privacy</i> untuk NLG	25
II.4.4.2	Strategi Keamanan Data dalam NLG	26
II.4.4.3	Mitigasi Risiko dalam NLG Internal	26
II.4.5	Evaluasi Kualitas <i>Natural Language Generation</i>	27
II.4.5.1	Metrik Otomatis untuk Evaluasi NLG	27
II.4.5.2	Evaluasi Subjektif Berbasis Pengguna	28
II.4.5.3	Kriteria Performa NLG dalam Literatur	29
II.5	<i>Time Series Forecasting</i>	31
II.5.1	Konsep <i>Time Series</i> dan Peramalan	31
II.5.2	Model Peramalan Statistik Klasik sebagai <i>Baseline</i>	31
II.5.2.1	ARIMA dan SARIMA	32
II.5.2.2	Prophet	32
II.5.2.3	Keterbatasan Model Statistik dan Motivasi Penggunaan <i>Deep Learning</i>	33
II.5.3	Model Peramalan Deret Waktu Berbasis <i>Deep Learning</i>	33
II.5.3.1	LSTM (<i>Long Short-Term Memory</i>) untuk Peramalan Deret Waktu	34
II.5.3.2	GRU (<i>Gated Recurrent Unit</i>) sebagai Alternatif LSTM	35
II.5.3.3	<i>Temporal Fusion Transformer</i> (TFT) untuk Data Multivariat	35
II.5.3.4	Model Hibrida dan <i>Ensemble</i>	36
II.5.3.5	Perbandingan Karakteristik Model Peramalan <i>Deep Learning</i>	36
II.5.3.6	Pemilihan Model dalam Konteks Penelitian	43
II.5.4	Evaluasi Performa <i>Time Series Forecasting</i>	44
II.5.4.1	Metrik Evaluasi <i>Forecasting</i>	44
II.5.4.2	<i>Skill Score</i> terhadap Garis Dasar	45
II.5.4.3	Pelaporan per Horizon dan per Entitas Prioritas	46
II.5.4.4	<i>Residual Analysis</i>	46
II.5.4.5	<i>Time Series Cross-Validation</i>	47
II.5.4.6	Target Performa <i>Forecasting</i>	47
II.6	Integrasi Sistem dan Penelitian Terkait	48
II.6.1	Arsitektur <i>Chatbot</i> Hibrida	48
II.6.2	Integrasi Klasifikasi <i>Intent</i> dan Mesin Kueri	49
II.6.3	Integrasi Pembangkitan Bahasa Alami Berbasis Templat	49

II.6.4	Integrasi Peramalan Deret Waktu	49
II.6.5	Integrasi Prediksi <i>Customer Churn</i>	49
II.7	Tinjauan Penelitian Terdahulu	50
II.8	Celah Penelitian dan Kontribusi	52
III	ANALISIS MASALAH	55
III.1	Analisis Kondisi Saat Ini	55
III.1.1	Pemahaman Bisnis (<i>Business Understanding</i>)	55
III.2	Analisis Kebutuhan	57
III.2.1	Identifikasi Masalah Pengguna	58
III.2.2	Kebutuhan Fungsional	60
III.2.3	Kebutuhan Nonfungsional	63
III.3	Analisis Pemilihan Solusi	67
III.3.1	Alternatif Solusi	68
III.3.2	Analisis Penentuan Solusi	74
III.3.2.1	Solusi 1: <i>Chatbot</i> Berbasis Aturan Sederhana	75
III.3.2.2	Solusi 2: <i>Chatbot</i> BI dengan Klasifikasi Maksud Berbasis Pola, Pembangkitan Bahasa Alami Berbasis Templat, dan Peramalan Deret Waktu	76
III.3.2.3	Solusi 3: Dasbor BI Interaktif Tradisional dengan Peningkatan	80
III.3.2.4	Solusi 4: <i>Chatbot</i> BI Berbasis Model Bahasa Besar (<i>Large Language Model</i>)	83
III.3.2.5	Matriks Perbandingan <i>Balanced Scorecard</i>	86
III.3.2.6	Kesimpulan Pemilihan Solusi	88
III.4	Pemahaman dan Analisis Data (<i>Data Understanding</i>)	90
III.4.1	Sumber Data dan Arsitektur Penyimpanan	91
III.4.1.1	Asal-Usul Data dan Izin Pemakaian	91
III.4.1.2	Domain SALES	93
III.4.1.3	Domain REVENUE	94
III.4.1.4	Domain DATA_PROSES	94
III.4.1.5	Domain TARGET	95
III.4.1.6	Domain CT0	96
III.4.2	Analisis Kualitas Data	96
III.4.2.1	Kelengkapan dan Konsistensi Data	96
III.4.2.2	Analisis Struktur Temporal	97
III.4.2.3	Analisis Relevansi Fitur	98
III.4.3	Atribut Relasional Antar-Domain	98
III.5	Persiapan Data (<i>Data Preparation</i>)	99
III.5.1	Pembersihan Data	99
III.5.1.1	Penanganan Nilai Hilang	99
III.5.1.2	Penghapusan Duplikasi	100
III.5.1.3	Deteksi dan Penanganan <i>Outlier</i>	100
III.5.2	Transformasi Data	100
III.5.2.1	Normalisasi dan Standardisasi	100
III.5.2.2	Transformasi Logaritmik	101

III.5.2.3	Pengkodean Fitur Kategorikal	101
III.5.3	Rekayasa Fitur untuk Peramalan Deret Waktu	101
III.5.3.1	Fitur Temporal	101
III.5.3.2	Fitur <i>Lag</i> dan <i>Rolling Statistics</i>	102
III.5.3.3	Fitur Agregat per Entitas	103
III.5.4	Pembagian Data untuk Pelatihan dan Evaluasi	103
III.5.5	Penyimpanan <i>Dataset</i> Final	104
III.6	Pemodelan Data (<i>Data Modelling</i>)	104
III.6.1	Arsitektur Model Peramalan Deret Waktu	104
III.6.1.1	Model <i>Baseline</i> Statistik: ARIMA dan Prophet	104
III.6.1.2	Model LSTM (<i>Long Short-Term Memory</i>)	105
III.6.1.3	Model GRU (<i>Gated Recurrent Unit</i>)	105
III.6.1.4	Perbandingan Karakteristik Model	106
III.6.2	Konfigurasi <i>Hyperparameter</i>	107
III.6.3	Strategi Pelatihan Model	107
III.6.3.1	<i>Early Stopping</i>	107
III.6.3.2	Regularisasi	108
III.6.3.3	Fungsi Kerugian	108
III.6.4	Model Klasifikasi <i>Intent</i> Berbasis Pola	108
III.6.5	Model Pembangkitan Bahasa Alami Berbasis Templat	109
III.6.6	Integrasi Model dalam Arsitektur Sistem	109
IV	PERANCANGAN SISTEM <i>BUSINESS INTELLIGENCE CHATBOT</i>	111
IV.1	Alur Proses Bisnis Sistem Analitik Saat Ini (<i>As-Is</i>)	112
IV.2	Alur Proses Bisnis Sistem Analitik dengan Chatbot BI (<i>To-Be</i>)	113
IV.3	Perbandingan Sistem Saat Ini (<i>As-Is</i>) dan Sistem Baru (<i>To-Be</i>)	114
IV.4	Rancangan Solusi Keseluruhan	116
IV.4.1	Komponen-Komponen Utama Arsitektur	116
IV.4.2	Arsitektur Sistem dan Aliran Data	117
IV.5	Kebutuhan Perangkat dan Lingkungan Sistem	119
IV.5.1	Perangkat Lunak dan Teknologi	119
IV.5.2	Kebutuhan Sumber Daya Komputasi	122
IV.6	Desain Pengujian dan Evaluasi	123
IV.6.1	Evaluasi Klasifikasi Maksud Berbasis Pola	123
IV.6.1.1	Metrik Evaluasi Klasifikasi <i>Intent</i>	123
IV.6.1.2	Analisis Nilai Keyakinan (<i>Confidence Score</i>)	124
IV.6.2	Evaluasi Pembangkitan Bahasa Alami Berbasis Templat	124
IV.6.2.1	Akurasi Faktual	124
IV.6.2.2	Evaluasi Subjektif Berbasis Pengguna	124
IV.6.3	Evaluasi Peramalan Deret Waktu	125
V	IMPLEMENTASI SISTEM <i>BUSINESS INTELLIGENCE CHATBOT</i>	127
V.1	Arsitektur Sistem Terimplementasi	127
V.2	Implementasi <i>Backend</i> (Node.js/Express)	128
V.2.1	Struktur Proyek <i>Backend</i>	128
V.2.2	Konfigurasi <i>Middleware</i> Keamanan	128
V.2.3	Koneksi Oracle Database	129

	V.2.4 Rute API (<i>API Routes</i>)	129
V.3	Implementasi Mesin Aturan (<i>Rule Engine</i>)	130
	V.3.1 Arsitektur Mesin Aturan	130
	V.3.2 Struktur Definisi Aturan	131
	V.3.3 Injeksi Filter Geografis	132
	V.3.4 Mekanisme <i>Caching</i>	135
V.4	Implementasi Klasifikasi Maksud (<i>Intent Classification</i>)	135
	V.4.1 Arsitektur Klasifikasi	135
	V.4.2 Algoritma Perhitungan Skor	136
V.5	Implementasi Pembangkitan Bahasa Alami (<i>NLG</i>)	137
	V.5.1 Alur Pembangkitan Respons	137
	V.5.2 Peta Subjek Aturan	139
	V.5.3 Format Keluaran	139
V.6	Implementasi Layanan <i>Machine Learning</i>	140
	V.6.1 Struktur Proyek Layanan ML	141
	V.6.2 Implementasi Model GRU dan LSTM	141
	V.6.3 <i>Pipeline</i> Pelatihan	144
	V.6.3.1 Penyesuaian Otomatis Ukuran Jendela (<i>Auto-Tune Window Size</i>)	146
	V.6.3.2 Validasi <i>Walk-Forward</i>	146
	V.6.3.3 Mekanisme <i>Benchmark</i> terhadap Model Sebelumnya	147
	V.6.3.4 Deteksi Data Parsial	147
	V.6.3.5 Tata Kelola Reprodusibilitas	148
	V.6.3.5.1 Keterbatasan.	148
	V.6.4 Praolah Data	148
	V.6.5 Implementasi Model <i>Baseline</i> Statistik (ARIMA dan <i>Prophet</i>)	149
	V.6.5.1 ARIMA (<i>Auto-Regressive Integrated Moving Average</i>)	149
	V.6.5.2 <i>Prophet</i>	149
	V.6.6 Metrik Evaluasi Terimplementasi	149
V.7	Implementasi <i>Frontend</i> (React.js)	150
V.8	Implementasi Autentikasi dan Keamanan	151
	V.8.1 Autentikasi Berbasis JWT	151
	V.8.2 Validasi Masukan	151
V.9	Ringkasan Implementasi	151
	V.9.1 Antarmuka Pengguna	151
	V.9.1.1 Halaman Masuk (<i>Login</i>)	152
	V.9.1.2 Halaman Registrasi	152
	V.9.1.3 Halaman Utama <i>Chatbot</i>	153
	V.9.1.4 Halaman Profil	154
	V.9.1.5 Halaman Pengaturan	155
	V.9.1.6 Tampilan Tema Terang (<i>Light Mode</i>)	155
	V.9.1.7 Detail Respons <i>Rule-Based Query</i>	156
	V.9.1.8 Detail Respons Peramalan Deret Waktu	157
	V.9.2 Selisih antara Rancangan dan Implementasi	157

VI EVALUASI	159
VI.1 Evaluasi Klasifikasi Maksud (<i>Intent Classification</i>)	159
VI.1.1 Cakupan <i>Intent</i>	159
VI.1.2 Metodologi Evaluasi Klasifikasi	159
VI.1.3 Cakupan Evaluasi Klasifikasi	160
VI.1.4 Hasil Evaluasi Pencocokan Aturan	161
VI.1.5 Analisis Keyakinan dan Cakupan	162
VI.1.6 Analisis Mekanisme Disambiguasi	163
VI.1.7 Evaluasi terhadap Target Performa	163
VI.1.8 Mekanisme <i>Fallback</i>	164
VI.2 Evaluasi Pembangkitan Bahasa Alami (<i>NLG</i>)	164
VI.2.1 Akurasi Faktual	164
VI.2.2 Evaluasi Subjektif oleh Pengguna Internal	164
VI.2.3 Karakteristik Teknis Modul NLG	165
VI.3 Evaluasi Peramalan Deret Waktu (<i>Time Series Forecasting</i>)	165
VI.3.1 Protokol Evaluasi	166
VI.3.2 Metrik Evaluasi	166
VI.3.3 Hasil Evaluasi per Metrik Bisnis	167
VI.3.3.1 Peramalan Rata-rata Hari Instalasi (<i>Avg Install Days</i>)	167
VI.3.3.2 Peramalan Volume Pesanan (<i>Order HSI</i>)	169
VI.3.3.3 Peramalan Volume <i>Churn</i> (<i>Churn HSI</i>)	170
VI.3.3.4 Peramalan Realisasi Target (<i>Realisasi HSI</i>)	171
VI.3.3.5 Ringkasan Lintas Metrik	173
VI.3.4 Analisis Komparatif Antar-Model	173
VI.3.4.1 Kinerja Model GRU	174
VI.3.4.2 Kinerja Model LSTM	174
VI.3.4.3 Kinerja Model ARIMA	174
VI.3.4.4 Kegagalan Model <i>Prophet</i>	174
VI.3.4.5 Kesimpulan Perbandingan Model	175
VI.3.4.6 Catatan Metodologis: Sifat Perbandingan	175
VI.3.5 Mekanisme Perbandingan Model	176
VI.4 Evaluasi Sistem Terintegrasi	176
VI.4.1 Pengujian Alur Lengkap	176
VI.4.2 Pengujian Waktu Respons	176
VI.4.3 Pengujian Manajemen Sesi dan Riwayat	177
VI.5 Validasi oleh Pengguna Internal	177
VI.5.1 Ruang Lingkup Validasi	177
VI.5.2 Temuan Validasi	177
VI.6 Umpan Balik Pengguna Internal	178
VI.6.1 Profil Responden dan Metodologi	178
VI.6.2 Hasil Penilaian Kuantitatif	178
VI.6.3 Umpan Balik Kualitatif	178
VI.6.4 Masukan dan Saran Perbaikan	179
VI.6.5 Rekap Umpan Balik per Aspek	180
VI.6.6 Contoh Kueri yang Diujikan	180
VI.7 Pembahasan Hasil Evaluasi	182

VI.7.1 Ancaman terhadap Validitas	183
VII PENUTUP	185
VII.1 Kesimpulan	185
VII.2 Saran	186
Lampiran A HASIL WAWANCARA	199
Lampiran B HASIL FORMULIR EVALUASI HASIL SISTEM BRI- GHTAI (INTERNAL)	203
Lampiran C TAUTAN REPOSITORY KODE SUMBER	205

DAFTAR GAMBAR

I.1	Metodologi <i>CRISP-DM</i>	6
II.1	Bahasa Kueri untuk Penemuan Aturan dalam Basis Data	14
II.2	<i>Pattern-Based Intent Classification</i>	16
II.3	<i>Natural Language Generation</i>	24
II.4	<i>Time Series Forecasting</i>	30
III.1	Detail <i>Rule-Based</i> yang Telah Ada	93
IV.1	BPMN Sistem <i>As-Is</i>	113
IV.2	BPMN Sistem <i>To-Be</i>	115
IV.3	Diagram Arsitektur Sistem Baru Secara Keseluruhan	118
V.1	Halaman Masuk (<i>Login</i>) Sistem BrightAI	153
V.2	Halaman Registrasi Pengguna Baru	153
V.3	Halaman Utama <i>Chatbot</i> BrightAI	154
V.4	Halaman Profil Pengguna	154
V.5	Halaman Pengaturan Sistem	155
V.6	Tampilan Antarmuka <i>Chatbot</i> dalam Tema Terang (<i>Light Mode</i>)	156
V.7	Contoh Respons <i>Rule-Based Query</i> dengan Narasi NLG dan Tabel Data	156
V.8	Contoh Hasil Peramalan Deret Waktu melalui Panel <i>Forecast</i>	157
B.1	Tangkapan Layar Formulir Pertanyaan Evaluasi Sistem BrightAI	204
B.2	Tangkapan Layar Hasil Jawaban Evaluasi Internal (<i>Officer Data Management</i>)	204

DAFTAR TABEL

II.1 Perbandingan Karakteristik Model Peramalan Deret Waktu	37
II.2 Tinjauan Penelitian Terdahulu	50
III.1 Kebutuhan Fungsional Sistem <i>Chatbot</i> BI	60
III.2 Kebutuhan Nonfungsional Sistem <i>Chatbot</i> BI	64
III.3 Perbandingan Alternatif Solusi Teknologi	69
III.4 Analisis <i>Balanced Scorecard</i> untuk Aturan Sederhana	75
III.5 Analisis <i>Balanced Scorecard</i> untuk BI Komprehensif	77
III.6 Analisis <i>Balanced Scorecard</i> untuk BI Tradisional	81
III.7 Analisis <i>Balanced Scorecard</i> untuk LLM	83
III.8 Perbandingan <i>Balanced Scorecard</i> Alternatif Solusi	87
III.9 Ringkasan Domain Data pada Skema DWH_M0IS	92
III.10Spesifikasi Domain Data Sales	94
III.11Spesifikasi Domain Data Revenue	94
III.12Spesifikasi Domain Data Proses	95
III.13Spesifikasi Domain Data Target	95
III.14Spesifikasi Domain Data Churn	96
III.15Hasil Profiling Data Deret Waktu per Metrik (Level Nasional)	97
III.16Atribut Utama Relasional Antar-Domain	98
III.17Teknik Penanganan Nilai Hilang per Jenis Atribut	99
III.18Teknik Penskalaan per Kategori Fitur	100
III.19Teknik Pengkodean Fitur Kategorikal	101
III.20Fitur Temporal yang Dihasilkan	102
III.21Fitur Lag dan Statistik Bergulir	102
III.22Fitur Agregat per Entitas	103
III.23Pembagian Data untuk Pelatihan dan Evaluasi	103
III.24Komponen Gerbang pada Arsitektur LSTM	105
III.25Komponen Gerbang pada Arsitektur GRU	106
III.26Perbandingan Karakteristik Model Peramalan	106
III.27Konfigurasi <i>Hyperparameter</i> Model (Berkas <i>config.py</i>)	107
III.28Fungsi Kerugian untuk Setiap Jenis Prediksi	108

III.29 Integrasi Model dalam Arsitektur Sistem	110
IV.1 Perbandingan Sistem <i>As-Is</i> dan <i>To-Be</i>	115
IV.2 Perangkat Lunak dan Teknologi Implementasi Sistem	120
V.1 Struktur Direktori Proyek <i>Backend</i>	128
V.2 Konfigurasi <i>Connection Pool</i> Oracle Database	129
V.3 Rute API Sistem BrightAI	129
V.4 Komponen Struktur Definisi Aturan	131
V.5 Daftar <i>Intent</i> yang Diimplementasikan	135
V.6 Contoh Pemetaan Subjek Aturan	139
V.7 Struktur Direktori Layanan <i>Machine Learning</i>	142
V.8 Konfigurasi <i>Hyperparameter</i> Model Terimplementasi	144
V.9 Target KPI Metrik Evaluasi Terimplementasi	150
V.10 Komponen Utama <i>Frontend</i>	150
V.11 Ringkasan Komponen Sistem yang Terimplementasi	152
V.12 Selisih antara Rancangan dan Implementasi	158
VI.1 Cakupan Kata Kunci per <i>Intent</i>	160
VI.2 Distribusi Aturan Bisnis per Domain Basis Data	161
VI.3 Ringkasan Metrik Evaluasi Pencocokan Aturan	162
VI.4 Statistik Keyakinan dan Cakupan Klasifikasi	162
VI.5 Perbandingan Hasil Evaluasi Pencocokan Aturan dengan Target Per- forma	163
VI.6 Metrik Evaluasi yang Digunakan	167
VI.7 Perbandingan Hasil Evaluasi Model Peramalan pada Metrik <i>Avg In-</i> <i>stall Days</i>	168
VI.8 Perbandingan Hasil Evaluasi Model Peramalan pada Metrik <i>Order</i> <i>HSI</i>	169
VI.9 Perbandingan Hasil Evaluasi Model Peramalan pada Metrik <i>Churn</i> <i>HSI</i>	170
VI.10 Perbandingan Hasil Evaluasi Model Peramalan pada Metrik <i>Real-</i> <i>sasi HSI</i>	172
VI.11 Ringkasan Kinerja Model Terbaik per Metrik Bisnis (Tingkat Nasio- nal)	173
VI.12 Skor Penilaian Kualitas Sistem BrightAI oleh Pengguna Internal . .	179
VI.13 Rekap Umpan Balik Kualitatif Pengguna Internal	180
VI.14 Contoh Kueri Uji dan Evaluasi Respons Sistem (Data Ilustratif) . .	181

A.1	Hasil Wawancara dengan Bapak Purwanto	199
A.2	Hasil Wawancara dengan Mas Renno Rifaldo	200

DAFTAR PERSAMAAN

II.3	Makro-Rata Presisi, Daya Ingat, dan Skor-F1	20
II.5	Mikro-Rata Presisi dan Daya Ingat	20
II.6	Dekomposisi Aditif Deret Waktu (<i>Prophet</i>)	32
II.12	Persamaan Gerbang LSTM	34
II.16	Persamaan Gerbang GRU	35
II.17	<i>Mean Absolute Error</i> (MAE)	44
II.18	<i>Root Mean Square Error</i> (RMSE)	44
II.19	<i>Symmetric Mean Absolute Percentage Error</i> (sMAPE)	45
II.20	<i>Mean Absolute Scaled Error</i> (MASE)	45
II.21	<i>Skill Score</i> terhadap Garis Dasar	45
IV.1	Presisi Makro	123
IV.2	Daya Ingat Makro	123
IV.3	Skor-F1 Makro	124
IV.4	sMAPE	125
IV.5	MASE	125
IV.6	<i>Skill Score</i>	125

DAFTAR ALGORITMA

V.1	Injeksi Filter Geografis ke dalam Kueri SQL (Bagian 1)	133
V.2	Injeksi Filter Geografis ke dalam Kueri SQL (Bagian 2)	134
V.3	Klasifikasi Maksud Berbasis Pencocokan Pola Kata Kunci Berbobot	138
V.4	Pembangkitan Respons Berbasis Templat (<i>Template-Based NLG</i>) . .	141
V.5	Pelatihan GRU/LSTM dengan <i>Early Stopping</i> dan <i>Learning Rate Scheduling</i>	145
V.6	Penyesuaian Otomatis Ukuran Jendela (<i>Auto-Tune Window Size</i>) . .	146
V.7	<i>Walk-Forward Validation</i> untuk Evaluasi Model Peramalan	147

DAFTAR *LISTING*

V.1	Contoh Struktur Definisi Aturan Analitik	131
V.2	Pencocokan Aturan pada <i>Query Processor</i>	136
V.3	Fungsi Pembangkitan Respons NLG	139
V.4	Implementasi Arsitektur Model GRU	142
V.5	Implementasi Arsitektur Model LSTM	143

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
ϵ	Konstanta kecil untuk mencegah pembagian dengan nol pada sMAPE	26
$\sum$	Operator penjumlahan	20
$\min$	Nilai minimum dari suatu himpunan	136
$ x $	Nilai absolut dari x	44
t	Indeks waktu (<i>timestep</i>) pada data deret waktu	32
y_t	Nilai aktual observasi pada waktu ke- t	44
$\hat{y}_t$	Nilai prediksi/ramalan (<i>forecast</i>) pada waktu ke- t	44
x_t	Vektor masukan (<i>input</i>) pada waktu ke- t	34
h_t	<i>Hidden state</i> pada sel berulang (GRU/LSTM) waktu ke- t	34
c_t	<i>Cell state</i> pada sel LSTM waktu ke- t	34
m	Periode musiman (<i>seasonality period</i> , e.g. 12 untuk data bulanan)	32
n	Jumlah sampel atau <i>horizon</i> prediksi	44
K	Jumlah kelas <i>intent</i> dalam sistem klasifikasi	123
W	Matriks bobot (<i>weight matrix</i>) pada lapisan <i>neural network</i>	34
b	Vektor bias (<i>bias vector</i>) pada lapisan <i>neural network</i>	34
p, d, q	Parameter orde model ARIMA (autoregresif, diferensiasi, rata-rata bergerak)	32
P, D, Q	Parameter orde musiman model SARIMA	32
$T(t)$	Komponen tren pada model Prophet	32
$S(t)$	Komponen musiman pada model Prophet	32

$H(t)$	Komponen efek hari raya (<i>holiday</i>) pada model Prophet	32
$\sigma(x)$	Fungsi aktivasi <i>sigmoid</i>	34
$\tanh(x)$	Fungsi aktivasi <i>hyperbolic tangent</i>	34
i_t	<i>Input gate</i> pada sel LSTM	34
f_t	<i>Forget gate</i> pada sel LSTM	34
o_t	<i>Output gate</i> pada sel LSTM	34
r_t	<i>Reset gate</i> pada sel GRU	35
z_t	<i>Update gate</i> pada sel GRU	35
MAE	<i>Mean Absolute Error</i>	44
$RMSE$	<i>Root Mean Squared Error</i>	44
$MAPE$	<i>Mean Absolute Percentage Error</i>	45
$sMAPE$	<i>symmetric Mean Absolute Percentage Error</i>	44
$MASE$	<i>Mean Absolute Scaled Error</i>	45
SS	<i>Skill Score</i>	45

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	<i>Artificial Intelligence</i>	1
API	<i>Application Programming Interface</i>	8
ARIMA	<i>Autoregressive Integrated Moving Average</i>	5
BI	<i>Business Intelligence</i>	1
BLEU	<i>Bilingual Evaluation Understudy</i>	27
CAGR	<i>Compound Annual Growth Rate</i>	1
CORS	<i>Cross-Origin Resource Sharing</i>	129
CRISP-DM	<i>Cross-Industry Standard Process for Data Mining</i>	6
DWH	<i>Data Warehouse</i>	127
EDW	<i>Enterprise Data Warehouse</i>	91
ERP	<i>Enterprise Resource Planning</i>	5
ETL	<i>Extract, Transform, Load</i>	8
GPU	<i>Graphics Processing Unit</i>	17
GRU	<i>Gated Recurrent Unit</i>	5
JWT	<i>JSON Web Token</i>	151
KPI	<i>Key Performance Indicator</i>	18
LLM	<i>Large Language Model</i>	83
LSTM	<i>Long Short-Term Memory</i>	5
MAE	<i>Mean Absolute Error</i>	9
MAPE	<i>Mean Absolute Percentage Error</i>	45
MASE	<i>Mean Absolute Scaled Error</i>	9
ML	<i>Machine Learning</i>	141
NLG	<i>Natural Language Generation</i>	4
NLP	<i>Natural Language Processing</i>	2
NLU	<i>Natural Language Understanding</i>	16
RNN	<i>Recurrent Neural Network</i>	34
RMSE	<i>Root Mean Squared Error</i>	9
ROUGE	<i>Recall-Oriented Understudy for Gisting Evaluation</i>	27
SARIMA	<i>Seasonal Autoregressive Integrated Moving Average</i>	31
sMAPE	<i>symmetric Mean Absolute Percentage Error</i>	9

SQL	<i>Structured Query Language</i>	1
TFT	<i>Temporal Fusion Transformer</i>	5

BAB I

PENDAHULUAN

I.1 Latar Belakang

Transformasi digital di sektor bisnis telah mengubah cara perusahaan menganalisis dan memanfaatkan data untuk pengambilan keputusan strategis. *Business Intelligence* (BI) kini menjadi tulang punggung operasional organisasi modern yang ingin tetap kompetitif di pasar global. Pasar global *Business Intelligence* diproyeksikan mencapai USD 36,82 miliar pada tahun 2025 dan tumbuh menjadi USD 116,25 miliar pada tahun 2033, dengan tingkat pertumbuhan tahunan gabungan (CAGR) sebesar 14,98% (Straits Research 2024). Pertumbuhan ini menunjukkan bahwa organisasi di seluruh dunia semakin menyadari nilai strategis sistem analitik berbasis data untuk meningkatkan efisiensi operasional dan daya saing.

Di Indonesia, adopsi teknologi kecerdasan buatan (*Artificial Intelligence/AI*) dan digitalisasi juga mengalami akselerasi signifikan. Laporan industri mencatat bahwa tingkat adopsi AI di kalangan pelaku bisnis Indonesia terus meningkat, meskipun sebagian besar masih pada tahap pemanfaatan dasar untuk efisiensi operasional (East Ventures July 2025). Tren ini sejalan dengan temuan global bahwa organisasi yang mengadopsi pengambilan keputusan berbasis data memperoleh keunggulan produktivitas yang terukur dibandingkan organisasi yang belum mengadopsinya (Gul dan Al-Faryan 2023).

Salah satu tantangan utama dalam implementasi BI adalah kompleksitas akses dan interpretasi data bagi pengguna nonteknis. Sistem BI konvensional sering memerlukan keahlian khusus dalam bahasa kueri (seperti SQL) dan pemahaman mendalam tentang struktur basis data sehingga menjadi hambatan bagi manajer dan staf operasional yang membutuhkan *insight* cepat untuk keputusan harian. Dalam mengatasi hal tersebut, teknologi *Conversational AI* berbasis *chatbot* muncul sebagai solusi yang menjanjikan. Pasar *Conversational AI* global diperkirakan mencapai USD 49,7 miliar pada tahun 2025 dan tumbuh dengan CAGR sekitar 23,6% hingga 2032 (Qaltivate 2025).

Implementasi *chatbot* dalam konteks layanan pelanggan dan operasional internal telah menunjukkan hasil yang positif. Penelitian menunjukkan bahwa *chatbot* berbasis AI mampu menangani sebagian besar pertanyaan rutin pelanggan secara otomatis, mempercepat waktu respons, dan mengurangi beban kerja agen manusia secara signifikan (Adam, Wessel, dan Benlian 2021). Dalam konteks BI, *chatbot* berfungsi sebagai antarmuka percakapan yang memungkinkan pengguna internal, seperti manajer penjualan, tim layanan pelanggan, dan analis bisnis, mengakses data analitik, laporan, dan prediksi melalui kueri bahasa alami tanpa keahlian teknis. Studi (Iqbal, Ahmad, dan Khan 2021) menunjukkan bahwa penerapan *natural language processing* (NLP) pada *chatbot* meningkatkan efisiensi dan akurasi pelayanan pelanggan secara signifikan.

Teknologi NLP menjadi fondasi yang memungkinkan sistem memahami dan merespons kueri pengguna dalam bahasa alami. Pasar NLP global diproyeksikan tumbuh dari USD 35,43 miliar pada tahun 2024 menjadi USD 438,08 miliar pada tahun 2034, dengan CAGR sekitar 28,6% (Precedence Research 2025). Dalam aplikasi BI, NLP memungkinkan sistem menginterpretasikan *intent* pengguna, mengekstraksi entitas penting dari kueri, dan menghasilkan respons relevan berdasarkan konteks percakapan, baik melalui pendekatan *rule-based* untuk kueri terstruktur maupun melalui model pembelajaran mesin untuk kueri yang lebih kompleks.

Selain kemampuan analisis deskriptif dan diagnostik, kebutuhan akan kemampuan prediktif dalam BI juga meningkat. Analisis prediktif memungkinkan organisasi mengantisipasi permintaan layanan pelanggan, merencanakan alokasi sumber daya, dan mengidentifikasi potensi *churn* sebelum terjadi. Dalam konteks ini, permintaan layanan pelanggan didefinisikan sebagai minat, pesanan, dan kebutuhan pelanggan terhadap produk atau layanan yang ditawarkan perusahaan, yang dapat diukur melalui data pemesanan, target penjualan, tingkat *churn*, dan pendapatan pelanggan. Pasar *time series forecasting* secara global diperkirakan tumbuh dari sekitar USD 11,17 miliar (2024) menjadi USD 36,9 miliar pada 2032, dengan CAGR $\sim 16,12\%$ (WiseGuy Reports 2024).

Metode *forecasting* yang lazim meliputi model statistik dan model *deep learning* untuk menangkap pola temporal. Pada kasus prediksi *customer churn* di industri telekomunikasi, baik Random Forest maupun LSTM efektif dalam prediksi *churn*, tetapi kegunaannya bergantung pada sifat data dan batasan bisnis. LSTM lebih baik bila interaksi pelanggan historis dan tren kepuasan menjadi kunci dalam pengambilan keputusan (Mena dkk. 2024).

Integrasi tiga komponen utama, *Rule-Based Query*, *Natural Language Generation*, dan *Time Series Forecasting*, ke dalam satu sistem BI berbasis *chatbot* menawarkan solusi komprehensif bagi kebutuhan analisis dan prediksi di lingkungan bisnis modern. Sistem demikian berpotensi memperkuat pengambilan keputusan proaktif berbasis data serta meningkatkan efisiensi operasional internal perusahaan.

I.2 Rumusan Masalah

Sebagian besar sistem *Business Intelligence* untuk analisis indikator permintaan terkait pelanggan di lingkungan internal perusahaan pada saat ini masih mengandalkan pelaporan manual, belum terintegrasi dengan antarmuka percakapan berbasis *chatbot*, dan minim pemanfaatan kecerdasan buatan untuk analisis prediktif serta interaksi berbasis bahasa alami. Kondisi ini memunculkan sejumlah permasalahan sebagai berikut.

1. Keterbatasan akses analitik berbasis percakapan
Tidak tersedia sistem yang mampu memproses dan memahami permintaan data serta analisis bisnis secara otomatis dari pengguna internal melalui percakapan dalam bahasa alami. Hal ini menyebabkan pegawai mengalami kendala dalam memperoleh *insight* terkait pesanan (*order*), pencapaian target penjualan, *churn* pelanggan, serta pendapatan secara cepat dan intuitif untuk mendukung pengambilan keputusan harian.
2. Ketiadaan fitur prediksi yang mudah diakses pengguna nonteknis
Belum terdapat fitur prediksi indikator utama bisnis terkait pelanggan, seperti peramalan jumlah pesanan, *churn* pelanggan, dan target pendapatan berbasis pembelajaran mesin atau peramalan deret waktu yang dapat diakses oleh pengguna nonteknis. Keadaan ini menyebabkan perencanaan kapasitas, evaluasi target, dan penetapan strategi bisnis perusahaan menjadi kurang responsif terhadap tren serta dinamika bisnis pada masa yang akan datang.
3. Minimnya integrasi *rule-based query* dan *natural language generation*
Integrasi *rule-based query* dan pemrosesan bahasa alami (*natural language generation*) dalam sistem BI internal masih sangat terbatas sehingga proses pencarian data, penyaringan metrik utama, serta penyusunan laporan kinerja bisnis masih harus dilakukan secara manual dan berulang. Keadaan tersebut menimbulkan keterlambatan pengambilan keputusan serta penyajian data yang kurang selaras dengan kebutuhan analisis oleh manajemen.

Bagaimana merancang dan mengembangkan sistem *Business Intelligence* berbasis *chatbot* yang terintegrasi dengan teknologi *rule-based query*, pemrosesan bahasa alami dengan (*natural language generation*), dan algoritma peramalan deret waktu sehingga seluruh pengguna internal perusahaan dapat menganalisis, memantau, dan

memprediksi indikator bisnis pelanggan, seperti pesanan, target, *churn*, dan pendapatan melalui antarmuka percakapan, serta memperoleh *insight* berbasis data yang akurat, efisien, dan relevan untuk mendukung pengambilan keputusan bisnis dan perencanaan strategis perusahaan?

I.3 Tujuan

Tujuan utama tugas akhir ini adalah merancang dan mengembangkan sistem *Business Intelligence* berbasis *chatbot* yang terintegrasi dengan teknologi *rule-based query*, pemrosesan bahasa alami (*Natural Language Generation/NLG*), dan algoritma peramalan deret waktu (*time series forecasting*) untuk memfasilitasi pengguna internal perusahaan dalam menganalisis dan memprediksi indikator bisnis pelanggan.

Secara terperinci, tujuan yang hendak dicapai dalam tugas akhir ini adalah sebagai berikut.

1. Merancang arsitektur sistem *Business Intelligence* berbasis *chatbot* yang mampu memproses permintaan analisis data dan memberikan *insight* berbasis data kepada pengguna internal perusahaan secara otomatis.
2. Mengimplementasikan modul pemrosesan bahasa alami sehingga pengguna internal dapat mengajukan pertanyaan dan permintaan analisis bisnis menggunakan bahasa alami melalui antarmuka *chatbot*.
3. Mengimplementasikan modul mekanisme *rule-based query* untuk menangani permintaan data yang bersifat terstruktur dan berulang dengan respons yang cepat dan konsisten.
4. Mengintegrasikan model peramalan deret waktu (*time series forecasting*) terpilih ke dalam sistem dengan membandingkan model *deep learning* (GRU dan LSTM) terhadap *baseline* statistik (ARIMA dan *Prophet*) untuk menghasilkan prediksi terhadap indikator bisnis pelanggan, seperti volume pesanan, pencapaian target penjualan, volume *churn* pelanggan agregat bulanan, dan kualitas layanan operasional. Prediksi *churn* dalam konteks ini merujuk pada peramalan jumlah total pelanggan yang berhenti berlangganan per periode, bukan klasifikasi biner per pelanggan individual.
5. Mengintegrasikan modul pembangkitan bahasa alami berbasis templat (*template-based Natural Language Generation*) untuk menghasilkan narasi deskriptif dalam bahasa Indonesia dari data terstruktur hasil kueri basis data.
6. Merancang dan mengimplementasikan antarmuka percakapan berbasis web yang mendukung interaksi bahasa alami dan alur terpandu (*guided flow*) bagi pengguna internal.

I.4 Batasan Masalah


Dalam memfokuskan ruang lingkup penelitian dan memastikan kelayakan pelaksanaan tugas akhir, batasan-batasan penelitian ditetapkan sebagai berikut.

1. Sistem dirancang khusus untuk pengguna internal perusahaan (manajer, analis bisnis, dan staf operasional), bukan untuk pelanggan eksternal.
2. Sistem *chatbot* hanya mendukung interaksi dalam Bahasa Indonesia.
3. Sistem menggunakan data yang terbatas pada data historis pelanggan yang mencakup informasi pesanan (*order*), target penjualan, tingkat *churn*, dan pendapatan dalam kurun waktu minimal dua tahun terakhir.
4. Sistem hanya menangani permintaan terkait analisis deskriptif, diagnostik, dan prediktif terhadap indikator bisnis pelanggan. Sistem tidak mencakup fungsi transaksional atau modifikasi data.
5. Sistem menggunakan metode peramalan deret waktu yang mencakup model *deep learning* berupa LSTM (*Long Short-Term Memory*) dan GRU (*Gated Recurrent Unit*), serta model statistik berupa ARIMA (*Autoregressive Integrated Moving Average*) dan Prophet sebagai *baseline* pembanding. Perbandingan antara model statistik dan model *deep learning* dilakukan untuk menentukan pendekatan yang paling tepat sesuai dengan karakteristik data. Model TFT (*Temporal Fusion Transformer*) **tidak termasuk** dalam cakupan implementasi penelitian ini; TFT hanya dikaji dalam studi literatur sebagai rekomendasi pengembangan di masa mendatang.
6. Klasifikasi maksud pengguna (*intent*) diimplementasikan dalam tujuh kategori utama (*quantity, trend, comparison, location, performance, detail, reason*) beserta satu kategori cadangan (*general/fallback*). Setiap *intent* dikombinasikan dengan delapan kategori fokus analisis dan dipetakan ke 38 aturan bisnis (*business rules*) yang mencakup lima domain data.
7. Sistem yang dikembangkan merupakan purwarupa mandiri (*standalone*) dan belum terintegrasi secara penuh dengan sistem ERP (*Enterprise Resource Planning*) atau CRM (*Customer Relationship Management*) yang ada di perusahaan.
8. Sistem diimplementasikan pada platform berbasis *web* dengan menggunakan *framework* yang umum untuk pengembangan *chatbot*.
9. Sistem dievaluasi melalui pengujian fungsional, pengukuran akurasi prediksi, analisis waktu respons, serta pengukuran kepuasan perwakilan divisi untuk pengguna internal. Evaluasi klasifikasi difokuskan pada level pencocokan aturan (*rule matching*) terhadap 38 kelas aturan bisnis, bukan pada level klasifikasi *intent* (7+1 kategori) karena taksonomi *intent* dirancang bersifat saling

eksklusif secara semantik sehingga klasifikasi pada level tersebut bersifat deterministik.

10. Sistem mengimplementasikan fitur keamanan dan privasi data dibatasi pada tingkat dasar, seperti autentikasi pengguna dan enkripsi koneksi, tanpa mencakup standar keamanan tingkat *enterprise* seperti ISO 27001.

I.5 Metodologi



Gambar I.1 Metodologi *CRISP-DM*

Metodologi pelaksanaan tugas akhir ini mengadopsi kerangka kerja CRISP-DM (*Cross-Industry Standard Process for Data Mining*) (lihat Gambar I.1) untuk tahapan pengolahan data dan analitik. Pendekatan ini dipilih agar proses penelitian berjalan secara iteratif, fleksibel, dan tetap sistematis dalam menyelesaikan permasalahan yang telah dirumuskan.

CRISP-DM (*Cross-Industry Standard Process for Data Mining*) adalah metodologi standar lintas industri untuk penambangan data yang menyediakan pendekatan terstruktur dalam enam fase utama, yaitu pemahaman bisnis (*business understanding*), pemahaman data (*data understanding*), persiapan data (*data preparation*), pemodelan (*modeling*), evaluasi (*evaluation*), dan penyebaran (*deployment*) (DataScience-PM, 2024). Metodologi ini bersifat iteratif, yang memungkinkan pengulangan fase jika diperlukan untuk meningkatkan kualitas hasil. Dalam penelitian ini, **CRISP-DM digunakan** untuk mengelola aspek penambangan data dan analitik prediktif.

I.5.1 Tahapan Investigasi dan Pengumpulan Fakta

Tahapan ini bertujuan untuk mengumpulkan data dan informasi faktual sebagai landasan perumusan masalah. Kegiatan yang dilakukan meliputi:

- a. Observasi sistem yang ada, yaitu pengamatan terhadap sistem yang saat ini di-

gunakan organisasi untuk mengidentifikasi keterbatasan dan kebutuhan pengguna internal.

- b. Wawancara dengan pemangku kepentingan, dilakukan secara terstruktur dengan perwakilan pemangku kepentingan internal untuk menggali kebutuhan fungsional dan ekspektasi terhadap sistem baru.
- c. Analisis data historis, dilakukan untuk menelaah volume dan tren permintaan, pola musiman, serta kelengkapan dan kualitas data yang tersedia.
- d. Dokumentasi temuan, mengompilasi seluruh hasil observasi, wawancara, dan analisis dalam bentuk laporan yang akan dilampirkan.

I.5.2 Studi Literatur

Tahapan ini bertujuan untuk mengumpulkan, mengelompokkan, dan menyaring literatur yang relevan dengan topik penelitian. Proses yang dilakukan meliputi:

- a. Pencarian literatur sistematis pada basis data akademik (IEEE Xplore, ScienceDirect, SpringerLink, ACM Digital Library, Google Scholar) menggunakan kata kunci terkait *business intelligence*, *chatbot*, *natural language generation*, dan *time series forecasting*.
- b. Pengelompokan literatur berdasarkan tema utama, yaitu konsep *Business Intelligence*, teknologi *chatbot* dan *conversational AI*, pemrosesan bahasa alami, metode peramalan deret waktu, integrasi sistem, dan studi kasus implementasi.
- c. Penapisan dan analisis kualitas literatur berdasarkan faktor dampak, jumlah sitasi, metodologi, dan relevansi terhadap penelitian.
- d. Sintesis literatur untuk membangun kerangka teoretis, mengidentifikasi praktik terbaik dan teknologi terkini, serta menyusun tinjauan pustaka pada Bab II.
- e. Dokumentasi proses dalam bentuk peninjauan penelitian terdahulu yang ditemukan dan membuat celah penelitian dan kontribusi besar yang ditawarkan penelitian ini.

I.5.3 Perancangan Sistem

Tahapan ini meliputi perancangan arsitektur dan komponen sistem secara terperinci, mencakup:

- a. Perancangan arsitektur sistem, yaitu penyusunan arsitektur berlapis yang mengintegrasikan *chatbot*, pemrosesan bahasa alami, mesin *rule-based query*, dan peramalan deret waktu, serta penentuan teknologi dan kerangka kerja yang akan digunakan.
- b. Perancangan modul *chatbot*, meliputi komponen pemahaman bahasa alami

(*Natural Language Understanding*), manajemen dialog (*Dialogue Management*), pembangkitan bahasa alami (*Natural Language Generation*), serta pen-
definisian *intent* dan entitas yang akan dikenali.

- c. Pengimplementasian *rule-based query*, yaitu pendefinisian aturan untuk kueri terstruktur dan berulang serta pemetaan antara *intent* dengan templat kueri.
- d. Perancangan model peramalan deret waktu, meliputi penentuan variabel target, perancangan praolah data, pemilihan arsitektur model (ARIMA, Prophet, LSTM, dan GRU), perbandingan model statistik dengan model *deep learning*, dan strategi evaluasi model.
- e. Perancangan basis data dan gudang data, yaitu perancangan skema basis data untuk menyimpan data pelanggan, hasil prediksi, dan data pelatihan NLP, serta perancangan proses ETL (*Extract, Transform, Load*).
- f. Perancangan antarmuka pengguna, meliputi pembuatan *wireframe* dan *mockup* untuk antarmuka *chatbot*.

I.5.4 Implementasi Sistem

Tahapan ini meliputi pengembangan sistem berdasarkan rancangan yang telah ditetapkan, mencakup:

- a. Pengembangan *backend*, yaitu implementasi mesin *rule-based query*, model NLP untuk klasifikasi *intent* dan pengenalan entitas, model peramalan deret waktu, serta penyediaan API *backend*.
- b. Pengembangan *frontend*, meliputi implementasi antarmuka *chatbot*.
- c. Pengembangan basis data, yaitu implementasi skema basis data, proses ETL untuk integrasi data, dan *data pipeline* untuk pemrosesan data.
- d. Integrasi komponen, meliputi integrasi *chatbot* dengan mesin *rule-based query* dan NLP, integrasi model peramalan dengan sistem BI, serta implementasi mekanisme tembolok (*caching*) untuk performa.

I.5.5 Pengujian dan Evaluasi

Tahapan ini bertujuan menilai kinerja sistem secara menyeluruh, mencakup aspek fungsionalitas, akurasi, performa, dan kebergunaan.

- a. Evaluasi pencocokan aturan (*rule matching*), yaitu evaluasi menggunakan *confusion matrix* serta menghitung nilai akurasi, presisi, daya ingat (*recall*), dan skor-F1 (*F1-score*) per kelas yang kemudian diagregasi secara makro (*macro*) dan mikro (*micro*) pada sampel kueri uji. Turut dilakukan pula analisis nilai keyakinan (*confidence score*) dan tingkat cakupan (*coverage rate*).
- b. Evaluasi model peramalan deret waktu, yaitu evaluasi menggunakan protokol *walk-forward validation* dengan *seasonal naive* sebagai garis dasar. Kinerja

model diukur menggunakan *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), *symmetric Mean Absolute Percentage Error* (sMAPE), dan *Mean Absolute Scaled Error* (MASE), dilengkapi *skill score* terhadap garis dasar untuk kategorisasi status kelulusan model.

- c. Evaluasi kinerja implementasi *Natural Language Generation* (NLG), yaitu evaluasi terhadap teks yang dihasilkan sistem yang mencakup dua aspek utama: akurasi faktual terhadap nilai perhitungan matematis pada *backend*, serta evaluasi subjektif berbasis pengguna (*human evaluation*) untuk menilai kelengkapan informasi, kemudahan pemahaman, kesesuaian narasi, dan kualitas tata bahasa.

I.5.6 Dokumentasi dan Penyusunan Laporan

Tahapan akhir meliputi dokumentasi dan penyusunan laporan tugas akhir, mencakup:

- a. Dokumentasi teknis, yaitu penyusunan dokumentasi API, dokumentasi kode, panduan pengguna (*user manual*), dan panduan penyebaran (*deployment guide*).
- b. Penyusunan laporan tugas akhir, meliputi penulisan laporan sesuai format yang ditetapkan dengan penyuntingan dan pemeriksaan kelengkapan.
- c. Persiapan presentasi, meliputi pembuatan *slide* presentasi, penyusunan skenario demonstrasi sistem, dan kurasi materi pendukung.
- d. Revisi dan finalisasi, yaitu revisi berdasarkan masukan pembimbing, finalisasi laporan dan sistem, serta persiapan sidang tugas akhir.

Seluruh proses metodologi ini akan didokumentasikan dengan baik untuk keterbukaan, kemampuan direproduksi, dan akuntabilitas penelitian.

I.5.7 Sistematika Penulisan

Laporan tugas akhir ini disusun dengan sistematika sebagai berikut.

1. Bab I Pendahuluan: Berisi latar belakang, rumusan masalah, tujuan, batasan masalah, metodologi, dan sistematika penulisan laporan tugas akhir.
2. Bab II Studi Literatur: Berisi kajian pustaka yang relevan dengan topik tugas akhir, mencakup teori dan konsep *Business Intelligence*, *chatbot* berbasis aturan, pemrosesan bahasa alami, pembangkitan bahasa alami, serta metode peramalan deret waktu.
3. Bab III Analisis Masalah: Berisi analisis kondisi sistem *Business Intelligence* saat ini, identifikasi masalah pengguna, kebutuhan fungsional dan nonfungsional sistem, serta analisis pemilihan solusi teknologi yang paling tepat.
4. Bab IV Perancangan Sistem *Business Intelligence Chatbot*: Berisi perancang-

an arsitektur sistem, perancangan layanan antarmuka percakapan (klasifikasi *intent* dan mesin aturan), model peramalan deret waktu, modul pembangkitan bahasa alami (NLG), rancangan antarmuka pengguna, dan rancangan basis data.

5. Bab V Implementasi Sistem *Business Intelligence Chatbot*: Berisi penjelasan tentang proses implementasi komponen sistem, termasuk sistem *frontend*, *backend*, layanan *machine learning* (peramalan deret waktu), klasifikasi maksud pengguna, mesin aturan, pembangkitan bahasa alami, serta keamanan sistem.
6. Bab VI Evaluasi: Berisi hasil pengujian fungsional sistem, evaluasi performa modul pencocokan aturan (*rule matching*), evaluasi kinerja model peramalan deret waktu, serta evaluasi kualitas pembangkitan bahasa alami.
7. Bab VII Penutup: Berisi kesimpulan dari hasil pelaksanaan tugas akhir dan saran untuk pengembangan lebih lanjut.
8. Daftar Pustaka: Berisi daftar referensi yang digunakan dalam penyusunan laporan tugas akhir.
9. Lampiran: Berisi dokumen pendukung seperti hasil wawancara, transkrip formulir evaluasi, dan tautan repositori kode sumber.

BAB II

STUDI LITERATUR

Bab ini menyajikan kajian teoretis dan tinjauan pustaka yang relevan dengan topik penelitian. Pembahasan meliputi konsep *Business Intelligence*, teknologi *chatbot* dan *Conversational AI*, klasifikasi *intent* berbasis pola, pembangkitan bahasa alami berbasis templat, serta peramalan deret waktu yang mendukung analisis dan prediksi permintaan layanan pelanggan. Kajian literatur ini disusun secara sistematis untuk memberikan landasan teoretis yang kuat bagi pengembangan sistem yang diusulkan, dengan fokus pada integrasi *pattern-based intent classification*, *template-based natural language generation*, dan *time series forecasting* dalam satu platform terintegrasi.

II.1 *Business Intelligence* dan Arsitektur Sistem

Bagian ini membahas konsep dasar *Business Intelligence*, evolusinya, serta arsitektur sistem yang mendukung implementasi BI modern. Pembahasan mencakup komponen-komponen utama arsitektur BI dan peran *semantic layer* dalam menjembatani kesenjangan antara data teknis dan kebutuhan bisnis. Pemahaman yang komprehensif tentang arsitektur BI menjadi fondasi penting dalam merancang sistem yang mampu mengintegrasikan berbagai komponen teknologi secara efektif.

II.1.1 Konsep *Business Intelligence*

Business Intelligence (BI) merupakan sistem teknologi yang mengumpulkan, mengorganisasi, dan menganalisis data dari berbagai sumber dalam suatu bisnis untuk membantu perusahaan mengubah data mentah menjadi wawasan yang berguna sehingga mereka dapat membuat keputusan yang lebih baik (Sorour 2020). Evolusi BI dari sistem berbasis aturan tradisional ke platform berbasis kecerdasan buatan telah meningkatkan secara signifikan analitik prediktif, otomatisasi, dan kemampuan pengambilan keputusan waktu nyata di seluruh industri (Khaddam dan Alzghoul 2025).

Implementasi BI di institusi pendidikan tinggi telah menunjukkan kemampuan untuk memantau aktivitas jaminan kualitas dan mendukung pengambilan keputusan

strategis (Sorour 2020). Penelitian empiris menunjukkan bahwa organisasi yang mengadopsi pengambilan keputusan berbasis data secara sistematis memperoleh keunggulan produktivitas yang signifikan dibandingkan organisasi yang belum mengadopsinya (Gul dan Al-Faryan 2023). Pasar BI global terus menunjukkan pertumbuhan yang signifikan, dengan proyeksi mencapai USD 116,25 miliar pada tahun 2033 dari USD 36,82 miliar pada tahun 2025, dengan CAGR sebesar 14,98% (Straits Research 2024). Pertumbuhan ini menunjukkan relevansi dan kebutuhan akan solusi BI yang inovatif dalam menghadapi kompleksitas data bisnis modern.

II.1.2 Arsitektur *Business Intelligence* Hibrida

Arsitektur BI hibrida mengintegrasikan sistem BI tradisional dengan kemampuan kecerdasan buatan untuk meningkatkan pengambilan keputusan, analitik prediktif, dan efisiensi operasional. Pendekatan ini menyajikan struktur yang memanfaatkan model pembelajaran mesin bersama pelaporan BI tradisional untuk menjembatani kesenjangan antara analisis historis dan wawasan berbasis data waktu nyata (Sahoo dkk. 2023).

Komponen utama arsitektur BI hibrida mencakup beberapa lapisan yang saling terintegrasi (Sahoo dkk. 2023). Lapisan sumber data mencakup sumber internal seperti sistem CRM dan perangkat lunak keuangan, serta sumber eksternal seperti data media sosial dan laporan pasar. Gudang data berfungsi sebagai fasilitas penyimpanan terpusat untuk data yang terorganisasi dan siap digunakan untuk pelaporan. Mesin analitik bertanggung jawab untuk pengenalan pola dan analisis tren, memberikan wawasan prediktif untuk perencanaan strategis.

Penelitian empiris berskala besar menunjukkan bahwa organisasi yang mengadopsi pengambilan keputusan berbasis data (*data-driven decision-making*) memiliki produktivitas 5–6% lebih tinggi dibandingkan organisasi yang belum mengadopsinya (Gul dan Al-Faryan 2023). Studi lain mengonfirmasi bahwa kapabilitas *Business Intelligence* dan analitik berdampak positif terhadap kinerja organisasi melalui peningkatan kemampuan perubahan proses bisnis (Sahoo dkk. 2023). Integrasi komponen-komponen ini membentuk fondasi yang kuat untuk sistem BI modern yang responsif dan dapat diandalkan.

II.1.3 *Semantic Layer* dalam *Business Intelligence*

Semantic layer adalah antarmuka berorientasi bisnis yang menjembatani kesenjangan antara model data yang kompleks dan pengguna bisnis, bertindak sebagai lapisan abstraksi yang menerjemahkan struktur data teknis ke dalam istilah dan konsep bisnis yang familiar (Databricks 2025b). Lapisan semantik menyediakan pandangan

bisnis terpadu terhadap data di seluruh organisasi, terlepas dari lokasi data atau bagaimana secara teknis terstruktur.

Lapisan semantik menyederhanakan konsep dan teknis data untuk pengguna bisnis sehingga mereka tidak perlu mengubah data bisnis yang mendasarinya untuk bekerja dengan cara baru (AtScale 2025). Lapisan ini memungkinkan pengguna bisnis untuk berinteraksi dengan data menggunakan terminologi yang mereka pahami tanpa perlu memahami struktur teknis basis data yang mendasarinya. Kemampuan ini sangat penting dalam konteks sistem *chatbot* BI, dengan memfasilitasi interpretasi kueri bahasa alami menjadi operasi basis data yang sesuai.

II.1.3.1 Komponen Inti *Semantic Layer*


Lapisan semantik memiliki lima komponen inti yang bertindak sebagai fondasi struktural dan teknis (Labs 2024). Komponen pertama adalah definisi model semantik yang menciptakan representasi logis dari domain bisnis, memetakan struktur basis data teknis ke konsep bisnis. Alih-alih bekerja dengan tabel mentah seperti `usr_tbl` atau `trx_hist`, entitas seperti *Customer* atau *Order* didefinisikan untuk merangkum kompleksitas yang mendasarinya.

Komponen kedua adalah manajemen metadata yang menangani informasi tentang data, seperti deskripsi bidang, garis keturunan data (*data lineage*), frekuensi pembaruan, dan metrik kualitas. Lapisan logika bisnis sebagai komponen ketiga berisi aturan perhitungan spesifik untuk metrik bisnis. Komponen keempat adalah lapisan akses data yang menerjemahkan permintaan bisnis menjadi kueri basis data yang dioptimalkan, menerapkan filter keamanan yang diperlukan. Komponen terakhir adalah mekanisme *caching* yang memeriksa apakah hasil perhitungan sudah tersedia dalam tembolok sebelum menjalankan kueri.

Implementasi *semantic layer* yang efektif memungkinkan organisasi untuk mencapai konsistensi dalam pelaporan dan analisis, sekaligus mengurangi kompleksitas teknis yang dihadapi oleh pengguna bisnis. Pemahaman tentang *semantic layer* ini menjadi dasar penting dalam merancang sistem klasifikasi *intent* yang akan dibahas pada bagian selanjutnya.

II.2 Rule-Based Query dan Implementasinya pada Chatbot

Arsitektur tersebut mengilustrasikan bagaimana manipulasi basis data bertransisi dari penulisan sintaks deklaratif statis menjadi orkestrasi dinamis yang memadukan komputasi probabilistik LLM dan integrasi aplikasi kustom.



Gambar II.1 Bahasa Kueri untuk Penemuan Aturan dalam Basis Data

II.2.1 Konsep *Rule-Based Query* dalam Sistem Basis Data

Secara historis, optimisasi kueri pada sistem manajemen basis data relasional banyak mengandalkan pendekatan berbasis aturan (*rule-based*) dan berbasis biaya (*cost-based*) untuk memilih rencana eksekusi kueri yang efisien (Yang dkk. 2024; Shah 2025). Pendekatan *rule-based* menggunakan seperangkat aturan heuristik yang ditetapkan pakar (seperti yang diilustrasikan pada Gambar II.1), seperti urutan penerapan seleksi dan proyeksi, penggunaan indeks, atau restrukturisasi *join*, untuk menyederhanakan dan mengoptimalkan kueri tanpa melakukan estimasi biaya numerik yang rinci (Yang dkk. 2024). Aturan-aturan tersebut, misalnya, dapat mengharuskan operator seleksi ditempatkan sedekat mungkin dengan sumber data atau menganjurkan penggunaan indeks ketika kondisi penyaringan sesuai sehingga mengurangi jumlah baris yang harus diproses pada tahap-tahap berikutnya.

Meskipun perkembangan terkini banyak mengarah pada optimisasi kueri berbasis kecerdasan buatan, sejumlah kajian menegaskan bahwa teknik berbasis aturan masih relevan dan sering digunakan sebagai fondasi, terutama untuk pola kueri yang berulang dan terstruktur dengan baik (Shah 2025; Lubis dkk. 2025). Dalam konteks sistem *Business Intelligence*, aturan-aturan kueri dapat dirancang untuk memetakan permintaan bisnis yang sering muncul (misalnya, “total penjualan per bulan per segmen pelanggan”) ke pola kueri yang terstandarisasi terhadap gudang data sehingga mempercepat proses pengambilan data dan menjaga konsistensi hasil analisis.

II.2.2 *Chatbot* Berbasis Aturan dan Pencocokan Pola

Pada ranah *chatbot*, pendekatan berbasis aturan (*rule-based chatbot*) merupakan salah satu arsitektur paling awal dan masih banyak digunakan untuk skenario tugas-terarah (*task-oriented*) dengan ruang lingkup percakapan yang terbatas (Singh dkk. 2025; Ouali dkk. 2024). *Chatbot* berbasis aturan umumnya bekerja dengan mencocokkan masukan pengguna terhadap pola-pola teks yang telah didefinisikan sebelumnya menggunakan teknik pencocokan pola (*pattern matching*), pencarian kata kunci, atau ekspresi reguler. Ketika suatu pola terpenuhi, sistem akan mengeksekusi-

si aturan yang terkait, baik berupa pemilihan respons templat maupun pemanggilan prosedur tertentu di *backend*.


Kajian sistematis mengenai *chatbot* berbahasa Arab menunjukkan bahwa pendekatan *pre-scripted rules* memetakan ujaran pengguna ke aturan atau pola yang telah dipersiapkan, kemudian memilih respons dari himpunan jawaban yang sudah tersedia (Ouali dkk. 2024). Pendekatan ini juga digunakan pada berbagai *chatbot* klasik seperti ELIZA dan ALICE, serta pada bahasa skrip khusus seperti AIML (*Artificial Intelligence Markup Language*) yang memungkinkan pengembang mendefinisikan pola masukan dan templat keluaran secara eksplisit (Singh dkk. 2025). Keunggulan utama pendekatan berbasis aturan terletak pada kontrol penuh terhadap perilaku sistem, kemudahan untuk menjamin bahwa respons tidak keluar dari batas pengetahuan yang diizinkan, serta kesesuaian untuk domain yang sangat terstruktur.

Penelitian terbaru di Indonesia juga mengimplementasikan pendekatan pencocokan pola berbasis aturan untuk mengembangkan *chatbot* layanan informasi internal. Misalnya, pengembangan aplikasi Sido *chatbot* menggunakan pola aturan dan pencocokan pola untuk menjawab pertanyaan umum pengguna, disertai pengujian keberhasilan respons melalui uji fungsional dan kuesioner pengguna (Ananta dkk. 2025). Studi lain mengimplementasikan kerangka kerja Rasa untuk membangun sistem *FAQ bot* yang menggabungkan pemetaan intent dengan aturan dialog dan integrasi ke platform pesan seperti Telegram, menunjukkan bahwa arsitektur hibrida berbasis aturan dan pembelajaran mesin dapat memberikan fleksibilitas sekaligus menjaga struktur dialog yang terkontrol (Talenggoran dkk. 2025).

II.2.3 Integrasi Rule-Based Query dalam Arsitektur Chatbot BI

Dalam konteks *Business Intelligence*, beberapa kajian mengusulkan penggunaan *chatbot* sebagai antarmuka percakapan untuk eksplorasi data dan kolaborasi analitik, dengan komponen percakapan (*conversational agent*) bekerja berdampingan dengan agen eksplorasi data dan agen rekomendasi (Cherednichenko dkk. 2023). Pendekatan ini sering kali memanfaatkan arsitektur berbasis aturan untuk menerjemahkan permintaan dalam bahasa alami menjadi perintah atau kueri terstruktur terhadap sistem BI dan gudang data. Aturan-aturan tersebut dapat mencakup pemetaan intent tertentu ke templat kueri, pengisian parameter kueri dari entitas yang diekstraksi, serta penentuan agregasi dan dimensi pelaporan berdasarkan frasa waktu atau hierarki bisnis yang disebutkan pengguna.

Chatbot berbasis aturan memerlukan basis pengetahuan yang menyimpan aturan-aturan yang dirancang secara manual untuk menjamin kekokohan dan konsistensi



Gambar II.2 *Pattern-Based Intent Classification*

perilaku sistem (Singh dkk. 2025). Dalam kerangka *chatbot* BI, basis pengetahuan ini tidak hanya berisi pasangan pola–jawaban, tetapi juga aturan pemetaan ke *rule-based query engine* yang mengakses gudang data. Studi-studi tersebut mendukung pendekatan yang digunakan dalam penelitian ini, yaitu menggabungkan klasifikasi intent berbasis pola dengan *rule-based query* yang terdokumentasi dengan baik sehingga sistem dapat menjawab pertanyaan bisnis terstruktur secara andal dan transparan, sembari tetap membuka ruang pengembangan lebih lanjut untuk integrasi teknik pembelajaran mesin yang lebih canggih jika cakupan intent dan kompleksitas kebutuhan analitik meningkat.

II.3 *Pattern-Based Intent Classification dengan Confidence Level*

Bagian ini membahas pendekatan klasifikasi *intent* berbasis pola untuk sistem *chatbot* (seperti yang ditunjukkan pada Gambar II.2), dengan fokus pada mekanisme pencocokan pola, penggunaan *confidence score*, dan evaluasi performa. Klasifikasi *intent* merupakan komponen kritis dalam memahami maksud pengguna dari kueri bahasa alami dan menentukan respons yang sesuai berdasarkan data internal perusahaan.

II.3.1 *Konsep Intent Classification*

Klasifikasi *intent* adalah proses menentukan niat atau tujuan pengguna dari masukan mereka, yang merupakan tugas fundamental dalam sistem *chatbot* percakapan (Ouaddi, Benabbou, dan Sael 2025). Inti dari *chatbot* berbasis AI adalah komponen NLU yang mengklasifikasikan *intent* pengguna untuk menghasilkan respons yang sesuai. Tugas klasifikasi ini sangat penting karena menentukan alur percakapan dan tindakan yang akan diambil sistem.

Pasar *Conversational AI* global diproyeksikan mencapai USD 49,9 miliar pada tahun 2030, meningkat dari USD 10,7 miliar pada tahun 2023, dengan CAGR sebesar 25,2% (Qaltivate 2025). Pertumbuhan eksponensial ini didorong oleh meningkatnya adopsi teknologi AI dalam layanan pelanggan dan operasional bisnis. Penelitian menunjukkan bahwa *chatbot* berbasis AI mampu menangani sebagian besar pertanyaan

rutin pelanggan secara otomatis sehingga mengurangi beban kerja agen manusia dan mempercepat waktu respons secara signifikan (Adam, Wessel, dan Benlian 2021). Temuan ini menunjukkan potensi besar klasifikasi *intent* dalam meningkatkan efisiensi operasional dan kepuasan pengguna.

II.3.2 Pertimbangan Alternatif: Klasifikasi *Intent* Berbasis *Transformer*

Klasifikasi *intent* berbasis *Transformer* merupakan pendekatan modern yang memanfaatkan mekanisme perhatian diri (*self-attention*) untuk memahami konteks ujaran pengguna secara dua arah. Model-model seperti BERT, RoBERTa, dan IndoBERT telah menunjukkan kinerja unggul pada tugas klasifikasi *intent*, termasuk dalam bahasa Indonesia dengan akurasi mencapai sekitar 0,94 (Merugu dkk. 2024; Ozerova 2022; Gehweiler 2024). Namun, literatur juga menyoroti adanya kompromi antara kualitas prediksi, latensi sistem, dan konsumsi sumber daya komputasi yang signifikan (Merugu dkk. 2024; Gehweiler dkk. 2025).

Pendekatan ini tidak diimplementasikan pada prototipe sistem dalam penelitian ini dengan tiga pertimbangan utama: (1) ruang lingkup pertanyaan yang relatif terbatas pada kebutuhan analitik internal, (2) pola kueri pengguna yang cenderung berulang dan terstruktur, serta (3) prioritas efisiensi komputasi tanpa ketergantungan pada unit pemroses grafis (GPU) berbiaya tinggi (Ozerova 2022). Sebagai gantinya, penelitian ini mengadopsi pendekatan berbasis pola (*pattern matching*) dengan mekanisme nilai keyakinan yang dibahas pada subbab berikutnya, dan menjadikan pendekatan berbasis *Transformer* sebagai rekomendasi pengembangan lanjutan di masa mendatang.

II.3.3 *Pattern Matching* untuk *Intent Classification*

Pendekatan berbasis pola (*pattern matching*) dalam klasifikasi *intent* menggunakan aturan dan templat yang telah ditentukan sebelumnya untuk mencocokkan masukan pengguna dengan kategori *intent* yang sesuai. Sistem ini menyimpan pola-pola pertanyaan atau *utterances* untuk setiap *intent*, kemudian membandingkan *input* pengguna dengan pola-pola yang telah didefinisikan untuk menemukan kecocokan terbaik.

Pendekatan *pattern matching* efektif untuk menangani kueri terstruktur dan berulang dalam domain spesifik. Implementasi dapat dilakukan menggunakan ekspresi reguler, pencocokan *n-gram*, atau algoritma kesamaan string seperti *Fuzzy String Matching* (Mulyatun, Kurniawan, dan Hudaya 2021). Keuntungan utama pendekatan ini adalah kecepatan eksekusi yang tinggi, prediktabilitas hasil, dan kontrol penuh atas logika pencocokan, menjadikannya pilihan yang tepat untuk sistem yang

memerlukan respons cepat dan deterministic based pada data internal perusahaan.

II.3.4 *Confidence Score* dalam *Intent Classification*

Confidence score atau skor keyakinan adalah nilai numerik antara 0 dan 1 yang menunjukkan tingkat kepercayaan sistem terhadap prediksi klasifikasi *intent* (Khosla dkk. 2022). Skor ini dihitung berdasarkan tingkat kecocokan antara *input* pengguna dengan pola yang telah didefinisikan. Semakin tinggi kecocokan, semakin tinggi nilai *confidence score*, dan semakin besar kemungkinan respons yang diberikan adalah benar.

Sistem menghitung *confidence score* dengan membandingkan *input* pengguna terhadap semua pola *utterances* atau frasa pelatihan yang tersedia. Sistem kemudian memilih *intent* dengan skor tertinggi sebagai prediksi. Implementasi *confidence score* memungkinkan sistem untuk mengidentifikasi kapan prediksi mungkin tidak akurat dan memerlukan mekanisme *fallback* (Kuligowska dan Kowalczyk 2024).

II.3.4.1 *Confidence Threshold*

Confidence threshold adalah nilai ambang batas minimum yang harus dicapai oleh *confidence score* agar sistem memicu respons *intent* tertentu. Dalam literatur, nilai *threshold* umumnya dinyatakan sebagai angka numerik antara 0 dan 1; sebagai rujukan, nilai *default* yang lazim digunakan pada *framework* klasifikasi *intent* adalah sekitar 0,45 (Hengst dkk. 2024), sedangkan sistem yang lebih konservatif dapat menggunakan *threshold* yang lebih tinggi untuk mengurangi risiko respons yang salah. Perlu dicatat bahwa skala dan nilai ambang aktual yang digunakan pada suatu sistem bergantung pada rancangan mekanisme *scoring*-nya; konversi antara skala 0–1 dan skala 0–100 dilakukan dengan mengalikan atau membagi nilai dengan 100.

Jika *confidence score* terbaik jatuh di bawah *threshold*, sistem akan memicu interaksi *fallback*, biasanya berupa pesan yang meminta klarifikasi atau memberitahu pengguna bahwa sistem tidak memahami pertanyaan. Pengaturan *threshold* yang tepat sangat penting untuk menyeimbangkan antara tingkat otomatisasi dan akurasi respons (Cyara 2024).

Analisis *threshold* membantu menentukan pengaturan yang optimal berdasarkan *Key Performance Indicators* (KPI) bisnis. Organisasi dapat menyesuaikan *threshold* berdasarkan tiga pendekatan utama. Pendekatan pertama adalah menyesuaikan *threshold* untuk mencapai persentase target respons yang benar. Pendekatan kedua adalah membatasi persentase maksimal respons yang salah. Pendekatan ketiga adalah mengoptimalkan trade-off antara tingkat otomatisasi dan risiko kesalahan berdasarkan

toleransi bisnis (Cyara 2024; Genesys 2023).

II.3.5 Evaluasi Performa *Intent Classification*

Evaluasi performa klasifikasi *intent* dilakukan dengan mengukur beberapa metrik kunci yang mencerminkan akurasi dan keandalan sistem dalam memprediksi niat pengguna. Evaluasi yang komprehensif memastikan bahwa sistem dapat beroperasi sesuai dengan standar yang ditetapkan dan memberikan pengalaman pengguna yang optimal.

II.3.5.1 Metrik Evaluasi Klasifikasi *Intent* Multi-Kelas

Pencocokan kueri pengguna ke aturan bisnis (*business rule*) dalam penelitian ini dievaluasi menggunakan metrik standar yang disesuaikan untuk masalah klasifikasi multi-kelas. Sistem memiliki 38 aturan bisnis yang saling eksklusif—bukan 38 *intent*; jumlah *intent* (kategori maksud) adalah tujuh ditambah satu *fallback*, sedangkan 38 adalah jumlah aturan analitik yang masing-masing memiliki fungsi `calculateConfidence` tersendiri. Pendekatan evaluasi harus mengakomodasi bahwa setiap kueri pengguna hanya dapat dipetakan ke satu aturan yang benar sehingga metrik klasifikasi biner harus diperluas menggunakan strategi *one-vs-all* dan agregasi yang tepat (Grandini, Bagli, dan Visani 2020; Evidently AI 2025).

Perbedaan utama antara klasifikasi multi-kelas dan biner adalah pada interpretasi elemen matriks kebingungan (*confusion matrix*) dan agregasi metrik per-kelas. Dalam 38 aturan bisnis, matriks kebingungan berukuran 38×38 , dengan setiap baris merepresentasikan aturan hasil prediksi dan setiap kolom merepresentasikan aturan sebenarnya. Prediksi yang benar terletak pada diagonal utama, sedangkan prediksi salah tersebar pada sel off-diagonal. Pola sebaran kesalahan pada matriks kebingungan multi-kelas memberikan wawasan berharga tentang persamaan atau kebingungan antar aturan, misalnya kueri yang seharusnya dipetakan ke aturan “Total Order HSI” yang justru terpetakan ke “Tren Pertumbuhan Order” menunjukkan kesamaan semantik kata kunci yang perlu ditangani dengan pola diferensiasi yang lebih spesifik (Evidently AI 2025).

Dalam menghitung metrik per kelas- i , masalah klasifikasi multi-kelas diubah menjadi masalah biner secara virtual melalui pendekatan *one-vs-all* (Grandini, Bagli, dan Visani 2020):

- a. TP_i (*True Positive*): Jumlah sampel kelas- i yang diprediksi benar sebagai kelas- i (elemen diagonal matriks kebingungan pada baris dan kolom i)
- b. FP_i (*False Positive*): Jumlah sampel kelas selain i yang diprediksi sebagai kelas- i (jumlah seluruh baris i pada matriks kebingungan kecuali elemen dia-

gonal)

- c. FN_i (*False Negative*): Jumlah sampel kelas- i yang diprediksi salah sebagai kelas lain (jumlah seluruh kolom i pada matriks kebingungan kecuali elemen diagonal)

Dalam konteks agregasi metrik (*macro-average* dengan *micro-average*) dan adanya 38 aturan bisnis dalam sistem ini, diperlukan strategi agregasi untuk memperoleh metrik keseluruhan performa sistem. Dua pendekatan utama yang umum digunakan dalam klasifikasi multi-kelas adalah *macro-averaging* dan *micro-averaging* (Evidently AI 2025)

Pendekatan **Macro-Averaging** ini menghitung metrik (*Precision*, *Recall*, *F1-Score*) untuk setiap aturan secara individual, kemudian mengambil rata-rata aritmatik dari 38 nilai metrik tersebut. Strategi ini memberikan bobot yang sama untuk setiap kelas sehingga mengutamakan performa pada kelas minoritas dan mencegah kelas mayoritas mendominasi hasil evaluasi (Grandini, Bagli, dan Visani 2020).

$$\text{Presisi}_{\text{makro}} = \frac{1}{38} \sum_{i=1}^{38} \text{Presisi}_i \quad (\text{II.1})$$

$$\text{Daya Ingat}_{\text{makro}} = \frac{1}{38} \sum_{i=1}^{38} \text{Daya Ingat}_i \quad (\text{II.2})$$

$$\text{Skor-F1}_{\text{makro}} = \frac{1}{38} \sum_{i=1}^{38} \text{Skor-F1}_i \quad (\text{II.3})$$

Pendekatan **Micro-Averaging** menjumlahkan seluruh nilai TP, FP, dan FN dari semua kelas terlebih dahulu, kemudian menghitung metrik secara global berdasarkan jumlahan tersebut. Strategi ini memberikan bobot yang sama untuk setiap sampel sehingga metrik cenderung didominasi oleh kelas mayoritas dan mengabaikan performa pada kelas minoritas. Dalam klasifikasi multi-kelas, mikro-rata presisi = mikro-rata daya ingat = akurasi (Evidently AI 2025).

$$\text{Presisi}_{\text{mikro}} = \frac{\sum_{i=1}^{38} TP_i}{\sum_{i=1}^{38} (TP_i + FP_i)} \quad (\text{II.4})$$

$$\text{Daya Ingat}_{\text{mikro}} = \frac{\sum_{i=1}^{38} TP_i}{\sum_{i=1}^{38} (TP_i + FN_i)} \quad (\text{II.5})$$

Sebagai pendekatan komplementer, rata-rata tertimbang menghitung metrik per-kelas kemudian mengambil rata-rata yang diboboti oleh jumlah sampel di setiap kelas atau ***Weighted-Averaging***. Ini mengakomodasi keseimbangan antara kepedulian terhadap kelas minoritas dan representasi data yang ada (Grandini, Bagli, dan Visani 2020).

Sistem menggunakan mekanisme pemberian skor keyakinan (*confidence scoring*) dalam rentang 0 hingga 100 untuk setiap prediksi klasifikasi *intent*. Nilai keyakinan dihitung melalui fungsi `calculateConfidence` pada setiap aturan, yang menjumlahkan bobot kata kunci primer dan pendukung yang ditemukan dalam kueri pengguna (lihat Algoritma V.3: $c = \min(100, \max_i s_i \times 10)$). Skala 0–100 ini setara dengan skala 0–1 yang lazim dalam literatur dikalikan 100. Tingkat keyakinan tertinggi menunjukkan kelas yang diprediksi oleh sistem. Dalam menentukan apakah prediksi dapat diterima atau perlu klarifikasi, ditetapkan *threshold* pada nilai 40 (setara 0,40 pada skala 0–1) (Santosa, Nusantara, dan Imron 2025):

- a. Jika tingkat keyakinan ≥ 40 : Prediksi dianggap “positif” dan diterima untuk kelas yang diprediksi; sistem memberikan respons berdasarkan *intent* yang teridentifikasi
- b. Jika tingkat keyakinan < 40 : Prediksi dianggap “tidak cukup yakin”; sistem meminta klarifikasi kepada pengguna atau menawarkan alternatif *intent* yang mungkin

Nilai ambang 40 dipilih berdasarkan pertimbangan bahwa satu kecocokan kata kunci primer sudah menghasilkan skor ≥ 75 (lihat Subbab III.4.3), sedangkan kecocokan kata kunci pendukung saja tanpa kata kunci primer menghasilkan skor yang lebih rendah. Ambang 40 memungkinkan sistem menangkap kueri yang relevan meskipun hanya cocok pada kata kunci pendukung, sekaligus menyaring kueri yang sama sekali tidak berkaitan. Nilai ini lebih rendah daripada *default* 0,45 dalam literatur (Hengst dkk. 2024) karena sistem ini menggunakan pencocokan kata kunci deterministik (bukan probabilistik) sehingga skor rendah tetap mengindikasikan relevansi parsial yang layak diproses.

Dengan demikian, untuk setiap kelas-*i*, perhitungan TP, FP, dan FN disesuaikan sebagai berikut.

- a. TP_{*i*}: Prediksi kelas-*i* dengan tingkat keyakinan ≥ 40 yang ternyata benar
- b. FP_{*i*}: Prediksi kelas-*i* dengan tingkat keyakinan ≥ 40 yang ternyata salah
- c. FN_{*i*}: Sampel kelas-*i* yang sebenarnya tidak terprediksi dengan tingkat keyakinan ≥ 40 (termasuk prediksi kelas lain atau tingkat keyakinan rendah yang ditolak sistem)

Visualisasi matriks kebingungan untuk 38 aturan bisnis memberikan informasi penting tentang pola kesalahan pencocokan (Evidently AI 2025), yaitu diagonal utama menampilkan jumlah pencocokan benar per aturan, sementara intensitas warna pada sel off-diagonal menunjukkan aturan-aturan mana yang sering dikacaukan satu sama lain. Sebagai contoh, jika ditemukan frekuensi tinggi kesalahan antara aturan “Order per Regional” dan “Performa Order per Wilayah”, hal ini menunjukkan tumpang-tindih kata kunci primer yang perlu dibedakan dengan pola yang lebih spesifik.

Setiap kelas *intent* memiliki kepentingan strategis yang berbeda dalam konteks bisnis sehingga penelitian ini menggunakan kombinasi metrik berikut (Grandini, Bagli, dan Visani 2020):

- a. Skor-F1 Makro sebagai metrik utama: Mengutamakan performa yang merata di semua 38 aturan bisnis, memastikan bahwa aturan-aturan yang jarang dipanggil tidak terabaikan
- b. Skor-F1 Tertimbang sebagai metrik sekunder: Mempertimbangkan distribusi frekuensi kelas dalam data percobaan, mencerminkan performa yang lebih realistis terhadap data produksi
- c. Skor-F1 Mikro sebagai metrik verifikasi: Harus sama dengan akurasi keseluruhan; digunakan untuk memvalidasi perhitungan
- d. Matriks Kebingungan: Dalam analisis kualitatif pola kesalahan dan identifikasi peningkatan yang diperlukan pada aturan atau templat tertentu

Berdasarkan studi industri dan best-practices untuk sistem klasifikasi *intent* dalam *chatbot* bisnis, target performa yang ditetapkan untuk penelitian ini adalah (Santosa, Nusantara, dan Imron 2025; Ozerova 2022):

- a. Skor-F1 Makro $\geq 0,85$: Menjamin performa yang baik dan seimbang di seluruh kelas, termasuk kelas-kelas dengan sampel pelatihan yang lebih sedikit
- b. Skor-F1 Tertimbang $\geq 0,90$: Menjamin performa yang baik pada kelas-kelas mayoritas yang mewakili mayoritas pertanyaan pengguna dalam praktik
- c. Skor-F1 Mikro (Akurasi Keseluruhan) $\geq 0,88$: Target akurasi minimal untuk sistem dapat diterima dalam produksi
- d. Matriks Kebingungan: Diharapkan menunjukkan lebih dari 80% nilai prediksi berada pada diagonal utama, mengindikasikan bahwa mayoritas prediksi benar

Pencapaian target-target ini akan diverifikasi melalui pengujian pada data validasi yang terpisah dan independen dari data pelatihan model, memastikan bahwa hasil evaluasi tidak bias dan representatif terhadap performa sistem pada data baru di

lingkungan produksi.

II.3.5.2 *Confusion Matrix dan Confidence Score Analysis*

Confusion matrix menyediakan detail tentang performa klasifikasi untuk setiap kelas *intent*. Analisis *confusion matrix* memungkinkan identifikasi *intent* yang sering salah diklasifikasikan dan pola kesalahan sistematis yang dapat diperbaiki melalui penyesuaian pola atau *threshold*.

Analisis distribusi *confidence score* penting untuk memahami bagaimana sistem membedakan antara *intent* yang benar (in-domain) dan pertanyaan di luar domain (out-of-domain atau OOD). Sistem yang baik harus menghasilkan *confidence score* tinggi untuk *intent* in-domain dan score rendah untuk OOD (Khosla dkk. 2022; Yutao Zhang dkk. 2022). Masalah *overconfidence*, dengan sistem menghasilkan score tinggi bahkan untuk sampel OOD yang abnormal, perlu dimitigasi melalui kalibrasi model yang tepat.


II.3.5.3 *Target Performa Intent Classification*

Berdasarkan literatur dan praktik industri terkini, target performa yang ditetapkan untuk sistem klasifikasi *intent* berbasis pola mencakup beberapa metrik kunci (Spot Intelligence 2023; Nabiilah, Adiwijaya, dan Maharani 2025). *Accuracy* harus mencapai minimal 85%, yang berarti minimal 85% dari semua prediksi *intent* harus benar. *F1-Score* ditargetkan minimal 0,80 untuk memastikan keseimbangan antara presisi dan *recall*. *Precision* ditetapkan minimal 0,82, yang berarti minimal 82% dari *intent* yang diprediksi positif benar-benar positif. *Recall* ditargetkan minimal 0,78, yang berarti minimal 78% dari *intent* positif aktual berhasil terdeteksi.

Metrik tambahan terkait *confidence score* meliputi *Average Confidence Score* untuk prediksi benar minimal 0,75, dan *Coverage Rate* atau persentase kueri yang mencapai *threshold* minimal 80%. *Response Time* harus di bawah 100 milidetik untuk 95% kueri agar memberikan pengalaman pengguna yang responsif. Pencapaian target-target ini memastikan bahwa sistem klasifikasi *intent* dapat memberikan pengalaman pengguna yang akurat dan responsif, dengan tingkat kesalahan yang minimal dan kemampuan untuk menangani variasi pertanyaan pengguna yang luas.

II.4 *Template-Based Natural Language Generation*

Bagian ini membahas pendekatan pembangkitan bahasa alami berbasis templat untuk menghasilkan variasi respons dari data internal perusahaan. Pembahasan mencakup konsep NLG berbasis templat, keamanan data dalam implementasi NLG internal, dan evaluasi kualitas teks yang dihasilkan. Pendekatan ini memastikan bahwa



Gambar II.3 *Natural Language Generation*

respons yang dihasilkan bervariasi dan natural sembari tetap menjaga keamanan dan privasi data perusahaan.

II.4.1 Konsep *Natural Language Generation*

Natural Language Generation (NLG) (lihat ilustrasi pada Gambar II.3) adalah proses menghasilkan teks bahasa alami dari representasi data terstruktur. Dalam konteks *chatbot* Business Intelligence, NLG digunakan untuk mengubah hasil kueri basis data menjadi respons bahasa natural yang mudah dipahami pengguna (Kale dan Rastogi 2020). NLG memungkinkan sistem untuk menyajikan informasi numerik dan data terstruktur dalam format naratif yang lebih mudah dicerna.

Pasar NLP global diproyeksikan tumbuh dari USD 35,43 miliar pada tahun 2024 menjadi USD 438,08 miliar pada tahun 2034, dengan CAGR sebesar 28,6% (Precedence Research 2025). Pertumbuhan eksponensial ini didorong oleh meningkatnya adopsi teknologi AI, *cloud computing*, dan kebutuhan akan analisis data tidak terstruktur di berbagai sektor industri. Pertumbuhan pasar ini menunjukkan relevansi dan urgensi pengembangan sistem NLG untuk mendukung kebutuhan bisnis modern.

II.4.2 *Template-Based Natural Language Generation*

Sistem NLG berbasis templat memetakan *input* non-linguistik secara langsung ke struktur linguistik yang berisi "celah" atau *placeholders* yang diisi selama *output*. Pendekatan ini menggunakan templat yang telah ditentukan sebelumnya dengan slot yang dapat diisi dengan data aktual dari hasil kueri basis data.

Contoh implementasi templat sederhana mencakup struktur seperti "Penjualan pada [bulan] mencapai [nilai], meningkat [persentase]% dari bulan sebelumnya." Sistem kemudian mengisi placeholder dengan data aktual: "Penjualan pada Oktober 2025 mencapai Rp 5,2 miliar, meningkat 15% dari bulan sebelumnya." (Kale dan Rastogi 2020).

Keuntungan utama pendekatan berbasis templat adalah kontrol penuh atas output, kecepatan generasi yang tinggi, tidak memerlukan *dataset* pelatihan besar, dan kemudahan maintenance dan modifikasi. Sistem dapat menghasilkan variasi output dengan mendefinisikan multiple templat untuk skenario yang sama, menghindari respons yang monoton (Kapoor dan Shetty 2023).

II.4.3 *Template Rewriting* dengan *Pre-trained Language Models*

Pendekatan lanjutan dalam NLG berbasis templat melibatkan penggunaan model bahasa pre-trained untuk menulis ulang templat sederhana menjadi teks yang lebih koheren dan natural. Metode ini menggabungkan keuntungan templat dengan fleksibilitas model bahasa neural (Kale dan Rastogi 2020; Rebuffel dkk. 2020).

Arsitektur sistem mencakup tiga tahapan utama. Tahap pertama adalah modul kebijakan menghasilkan sekumpulan tindakan berdasarkan konteks. Tahap kedua adalah templat sederhana mengkonversi setiap tindakan menjadi *utterance* bahasa alami. Tahap ketiga adalah model *encoder-decoder* seperti T5 menulis ulang gabungan *utterances* menjadi respons percakapan yang koheren (Kale dan Rastogi 2020).

Pendekatan ini memungkinkan sistem untuk menghasilkan respons yang secara semantik benar dari templat, kemudian model bahasa memperbaiki koherensi dan kealamian teks. Metode *template rewriting* telah menunjukkan peningkatan sample efficiency yang signifikan dibandingkan metode end-to-end, dengan jumlah templat yang tumbuh linear terhadap jumlah slot dibandingkan pertumbuhan kombinatorial (Rebuffel dkk. 2020).

II.4.4 Keamanan dan Privasi Data dalam NLG Internal

Implementasi NLG dalam lingkungan perusahaan memerlukan pertimbangan keamanan yang ketat untuk melindungi data sensitif dan mencegah kebocoran informasi. Sistem NLG internal harus dirancang dengan prinsip *privacy-by-design* untuk memastikan data perusahaan tetap aman.

II.4.4.1 *Differential Privacy* untuk NLG

Differential Privacy (DP) adalah kerangka kerja yang memberikan jaminan privasi secara matematis, memastikan bahwa kontribusi individu dalam *dataset* dibatasi (Feyisetan dkk. 2022; Mireshghallah dkk. 2022). Dalam konteks NLG, DP dapat diterapkan melalui dua pendekatan utama. Pendekatan pertama adalah pelatihan model dengan DP-SGD yang menambahkan noise pada gradien selama pelatihan. Pendekatan kedua adalah perturbasi representasi teks yang menambahkan noise pada *embedding* sebelum generasi.

Parameter privasi ϵ mengontrol tingkat privasi yang diberikan, dengan nilai ϵ yang lebih kecil memberikan privasi yang lebih kuat tetapi dapat mengurangi utility model. Implementasi DP dalam NLG memerlukan trade-off yang cermat antara privasi dan kualitas output (Luo dan Liu 2024).

II.4.4.2 Strategi Keamanan Data dalam NLG

Implementasi NLG internal yang aman memerlukan beberapa strategi keamanan berlapis (IT Convergence 2024). Strategi pertama adalah enkripsi data dengan mengenkripsi data saat transit menggunakan TLS/SSL dan saat istirahat untuk melindungi data sensitif. Strategi kedua adalah kontrol akses yang ketat dengan menerapkan autentikasi dan otorisasi yang robust, menggunakan prinsip *least privilege*. Strategi ketiga adalah data minimization dengan hanya menggunakan data minimum yang diperlukan untuk generasi respons. Strategi keempat adalah *template-based approach* yang membatasi generasi hanya pada templat yang telah diverifikasi, mencegah generasi teks bebas yang dapat membocorkan informasi sensitif.

Strategi kelima adalah audit dan monitoring dengan mencatat semua aktivitas NLG untuk deteksi anomali dan audit keamanan. Strategi terakhir adalah *secure deployment environment* dengan mengamankan infrastruktur server, firewall, dan menjaga software tetap terbaru (IT Convergence 2024; Amazon Web Services 2024).

II.4.4.3 Mitigasi Risiko dalam NLG Internal

Risiko utama dalam implementasi NLG internal mencakup kebocoran data sensitif melalui output yang dihasilkan, *prompt injection* yang dapat memanipulasi model untuk menghasilkan output tidak diinginkan, dan *data tampering* yang dapat menyebabkan respons AI yang salah. Mitigasi risiko ini memerlukan pendekatan multi-layer (Fujitsu - PostgreSQL Fastware 2024).

Teknik mitigasi mencakup pemfilteran output untuk memeriksa dan menyensor informasi sensitif sebelum ditampilkan ke pengguna. *Input validation* digunakan untuk memvalidasi semua *input* dan menolak pola yang mencurigakan. *Template whitelisting* membatasi generasi hanya pada templat yang telah disetujui. Implementasi *role-based access control* (RBAC) memastikan pengguna hanya dapat mengakses data sesuai peran mereka. Regular security assessment dilakukan untuk menguji kerentanan sistem secara berkala (European Data Protection Board 2025; Velotix 2025).

II.4.5 Evaluasi Kualitas *Natural Language Generation*

Evaluasi kualitas keluaran *Natural Language Generation* (NLG) merupakan aspek penting untuk memastikan bahwa teks yang dihasilkan tidak hanya benar secara faktual, tetapi juga mudah dipahami, wajar, dan bermanfaat bagi pengguna. Dalam konteks penelitian ini, fungsi utama modul NLG adalah menyajikan hasil analisis dan prediksi dalam bentuk jawaban yang lebih ramah pengguna sehingga penilaian kualitas dari sudut pandang pengguna menjadi sangat sentral. Meskipun demikian, sejumlah penelitian terdahulu menunjukkan bahwa kombinasi antara metrik evaluasi otomatis dan penilaian manusia (subjektif) memberikan gambaran yang lebih komprehensif mengenai kualitas keluaran NLG (Celikyilmaz, Clark, dan Gao 2020; Sai, Mohankumar, dan Khapra 2020; Lee dkk. 2021).

II.4.5.1 Metrik Otomatis untuk Evaluasi NLG

Berbagai survei mengenai evaluasi NLG mengelompokkan metrik otomatis ke dalam beberapa kategori utama, seperti metrik berbasis kecocokan permukaan (*string-matching*), metrik berbasis pemetaan vektor (*embedding-based*), dan metrik berbasis model pembelajaran mesin (Celikyilmaz, Clark, dan Gao 2020; Sai, Mohankumar, dan Khapra 2020; Gao dkk. 2025).

Kategori pertama adalah metrik berbasis referensi yang membandingkan keluaran sistem dengan satu atau beberapa teks rujukan yang ditulis manusia. Contoh yang paling banyak digunakan adalah BLEU (*Bilingual Evaluation Understudy*) yang mengukur kecocokan *n-gram* antara keluaran dan teks rujukan, dengan rumus umum (Sai, Mohankumar, dan Khapra 2020):

$$\text{BLEU (Bilingual Evaluation Understudy)} = BP \times \exp \left(\sum_{n=1}^N w_n \log p_n \right)$$

dengan p_n menyatakan presisi *n-gram* dan BP adalah faktor penalti panjang (*brevity penalty*). Metrik lain seperti METEOR (*Metric for Evaluation of Translation with Explicit Ordering*) memasukkan faktor sinonim dan *stemming*, sedangkan ROUGE (*Recall-Oriented Understudy for Gisting Evaluation*) berfokus pada daya ingat (*recall*) dan banyak digunakan untuk evaluasi peringkasan teks (Celikyilmaz, Clark, dan Gao 2020; Sai, Mohankumar, dan Khapra 2020).

Kategori kedua adalah metrik berbasis penyajian vektor (*embedding-based*), yang menggunakan representasi neural untuk mengukur kesamaan semantik, bukan hanya kesamaan permukaan. Contohnya adalah BERTScore yang memanfaatkan *embedding* BERT untuk menghitung kesamaan kontekstual antara token keluaran dan

token rujukan. Metrik ini umumnya menunjukkan korelasi yang lebih baik dengan penilaian manusia dibandingkan metrik *string-matching* murni, terutama ketika terdapat banyak cara wajar untuk mengekspresikan makna yang sama (Celikyilmaz, Clark, dan Gao 2020; Gao dkk. 2025).

Meskipun berguna untuk perbandingan model secara cepat dan konsisten, berbagai studi meta-evaluasi menegaskan bahwa metrik otomatis ini hanya menangkap sebagian aspek kualitas dan sering kali berkorelasi sedang atau bahkan rendah dengan penilaian manusia, terutama pada tugas dialog dan percakapan yang bersifat terbuka (Celikyilmaz, Clark, dan Gao 2020; Sai, Mohankumar, dan Khapra 2020; Xiao dkk. 2023). Oleh karena itu, metrik otomatis umumnya direkomendasikan sebagai pelengkap, bukan pengganti, evaluasi subjektif oleh manusia.

II.4.5.2 Evaluasi Subjektif Berbasis Pengguna

Sejumlah survei dan studi empiris menegaskan bahwa evaluasi manusia tetap dianggap sebagai standar emas (*gold standard*) dalam penilaian kualitas keluaran NLG, khususnya untuk aspek yang bersifat kualitatif seperti kewajaran bahasa, keterpahaman, dan kegunaan bagi pengguna akhir (Lee dkk. 2021; Celikyilmaz, Clark, dan Gao 2020; Morrison dkk. 2021). Evaluasi subjektif ini umumnya dilakukan dengan meminta penilai manusia memberikan skor pada skala Likert (biasanya 1–5 atau 1–7) terhadap beberapa dimensi kualitas teks.

Praktik evaluasi manusia yang umum pada sistem NLG dan sejumlah dimensi yang sering digunakan, antara lain (Lee dkk. 2021):

- a. Kewajaran/*Naturalness*: Sejauh mana teks terdengar wajar seperti ditulis penutur asli dan tidak tampak kaku atau *robotik*.
- b. Kelancaran/*Fluency*: Sejauh mana teks bebas dari kesalahan tata bahasa dan struktur kalimat yang janggal.
- c. Kecukupan/*Adequacy* atau *Informativeness*: Sejauh mana teks menyampaikan informasi yang tepat dan memadai terkait masukan.
- d. Koherensi/*Coherence*: Sejauh mana kalimat-kalimat dalam teks saling tersambung secara logis dan membentuk alur yang mudah diikuti.

Kerangka evaluasi seperti ConSiDERS dan panduan evaluasi subjektif yang dapat direproduksi menekankan pentingnya perancangan instruksi penilaian yang jelas, pemilihan skala yang konsisten, dan penggunaan beberapa penilai untuk meningkatkan reliabilitas (Elangovan dkk. 2023; Morrison dkk. 2021). Dalam surveinya juga digarisbawahi bahwa untuk banyak tugas NLG, korelasi antara metrik otomatis dan penilaian manusia tidak cukup tinggi sehingga penilaian manusia tetap diper-

lukan, terutama ketika tujuan utama sistem adalah meningkatkan mutu pengalaman pengguna, bukan mengoptimalkan skor metrik otomatis tertentu (Sai, Mohankumar, dan Khapra 2020).

Dalam konteks *chatbot* berbasis AI, sejumlah penelitian di bidang kualitas layanan dan pengalaman pengguna mengaitkan kualitas percakapan alami dengan dimensi seperti *friendliness*, *usefulness*, kejelasan jawaban, serta persepsi kemudahan penggunaan. Studi tentang kualitas layanan AI-*chatbot* menunjukkan bahwa kemampuan percakapan yang wajar, relevansi informasi, dan kecepatan respons berkontribusi signifikan terhadap kepuasan, kepercayaan, dan niat pengguna untuk terus menggunakan layanan tersebut (Syarifudin dkk. 2024; Hsu dan Lin 2023). Hal ini sejalan dengan fokus penelitian ini, dengan fungsi utama modul NLG adalah membuat jawaban sistem lebih ramah pengguna dan mudah dipahami, bukan menghasilkan variasi bahasa yang kreatif tanpa batas.

Dengan demikian, evaluasi subjektif dalam konteks *chatbot* BI dapat difokuskan pada beberapa dimensi utama berikut.


- a. Kewajaran Bahasa: Apakah jawaban terdengar alami dan tidak kaku.
- b. Kejelasan dan Keterpahaman: Apakah isi jawaban mudah dipahami oleh pengguna nonteknis.
- c. Kegunaan/*Usefulness*: Apakah jawaban benar-benar membantu pengguna menjawab pertanyaan bisnis yang diajukan.
- d. Kenyamanan Interaksi: Sejauh mana gaya bahasa dan struktur jawaban mendukung pengalaman percakapan yang menyenangkan.

Dimensi-dimensi tersebut dapat diukur menggunakan skala Likert oleh sejumlah penilai internal pada tahap pengujian sistem, mengikuti praktik yang direkomendasikan dalam literatur evaluasi NLG dan kualitas *chatbot* (Lee dkk. 2021; Syarifudin dkk. 2024).

II.4.5.3 Kriteria Performa NLG dalam Literatur

Survei-survei terkini mengenai evaluasi NLG menekankan bahwa tidak ada satu nilai ambang (*threshold*) numerik yang bersifat universal untuk menyatakan bahwa suatu sistem “cukup baik” karena nilai metrik sangat bergantung pada tugas, data, dan desain sistem yang dievaluasi (Celikyilmaz, Clark, dan Gao 2020; Sai, Mohankumar, dan Khapra 2020; Gao dkk. 2025). Oleh karena itu, karya-karya ilmiah umumnya:

- a. Membandingkan metrik otomatis (seperti BLEU, ROUGE, BERTScore) relatif terhadap model dasar atau pendekatan lain pada tugas yang sama, dan



Gambar II.4 *Time Series Forecasting*

- b. Menggunakan penilaian manusia sebagai landasan utama, dengan rata-rata skor pada skala 1–5 atau 1–7 untuk dimensi seperti kewajaran, kelancaran, dan kecukupan, dengan skor rata-rata yang mendekati ujung atas skala lazim dipandang sebagai indikasi kualitas tinggi (Lee dkk. 2021; Celikyilmaz, Clark, dan Gao 2020).

Dalam studi-studi dialog dan percakapan, sistem yang dianggap berkualitas baik biasanya menunjukkan:

- a. Peningkatan signifikan pada metrik otomatis dibandingkan model dasar, *namun* penulis tetap menekankan bahwa korelasi metrik otomatis dengan penilaian manusia terbatas dan konteks spesifik harus diperhatikan (Sai, Mohankumar, dan Khapra 2020; Xiao dkk. 2023),
- b. Rata-rata skor penilaian manusia yang tinggi untuk dimensi kewajaran, kelancaran, dan relevansi, serta
- c. Indikator kepuasan dan persepsi kualitas layanan yang positif pada studi pengguna, seperti peningkatan kepercayaan, kenyamanan interaksi, dan niat untuk terus menggunakan *chatbot* (Syarifudin dkk. 2024; Hsu dan Lin 2023).

Berdasarkan informasi tersebut, literatur menyarankan bahwa pemilihan metrik evaluasi NLG hendaknya disesuaikan dengan tujuan dan karakteristik sistem. Dalam sistem *Business Intelligence* berbasis *chatbot* yang memanfaatkan NLG berbasis templat untuk menyajikan data terstruktur dalam bentuk narasi yang mudah dipahami, metrik subjektif yang berfokus pada persepsi pengguna (ketepatan, kejelasan, relevansi, dan kemudahan penggunaan) merupakan indikator utama kualitas keluaran. Metrik otomatis berbasis *n-gram* seperti BLEU dan ROUGE kurang sesuai untuk NLG berbasis templat karena dirancang untuk mengevaluasi sistem generatif dan rentan menghasilkan skor artifisial rendah ketika keluaran mengandung nilai numerik spesifik serta format terstruktur yang tidak terdapat pada teks referensi (Celikyilmaz, Clark, dan Gao 2020; Lee dkk. 2021).

II.5 *Time Series Forecasting*

Peramalan deret waktu (*Time Series Forecasting*) (diilustrasikan pada Gambar II.4) adalah proses memprediksi nilai masa depan dari suatu variabel berdasarkan observasi nilai-nilai masa lalu dari variabel yang sama secara berurutan waktu. Dalam domain bisnis, metodologi ini fundamental untuk memproyeksikan metrik utama, seperti volume penjualan, permintaan layanan pelanggan, atau tingkat retensi pengguna sehingga memungkinkan organisasi mengambil langkah antisipatif dan menyusun strategi berbasis data.

Bagian ini membahas konsep peramalan deret waktu, model-model statistik dan pembelajaran mendalam yang digunakan, serta evaluasi performa yang komprehensif. Pembahasan mencakup ARIMA, SARIMA, LSTM, serta perbandingan karakteristik dan performa masing-masing metode. Pemahaman yang mendalam tentang berbagai pendekatan peramalan ini menjadi fondasi penting dalam memilih dan mengimplementasikan model yang sesuai dengan karakteristik data dan kebutuhan aplikasi.

II.5.1 Konsep *Time Series* dan Peramalan

Time series adalah serangkaian titik data yang diindeks dalam urutan waktu, dan peramalan deret waktu adalah proses menggunakan model untuk memprediksi nilai masa depan berdasarkan nilai yang diamati sebelumnya. Peramalan akurat sangat penting untuk perencanaan strategis dan pengambilan keputusan di berbagai domain bisnis.

Pasar *time series forecasting* global mencapai USD 9,62 miliar pada tahun 2023 dan diperkirakan tumbuh menjadi USD 36,9 miliar pada tahun 2032 dengan CAGR sebesar 16,12% (WiseGuy Reports 2024). Pertumbuhan ini menunjukkan meningkatnya adopsi teknik peramalan deret waktu di berbagai industri untuk mendukung pengambilan keputusan berbasis data, termasuk peramalan permintaan layanan pelanggan, prediksi penjualan, dan analisis tren bisnis. Proyeksi pertumbuhan pasar ini mengindikasikan relevansi dan urgensi pengembangan sistem peramalan yang akurat dan dapat diandalkan.

II.5.2 Model Peramalan Statistik Klasik sebagai *Baseline*

Sebelum membahas model berbasis pembelajaran mendalam, penting untuk memahami model statistik klasik yang digunakan sebagai *baseline* dalam penelitian ini. Model statistik seperti ARIMA dan Prophet merupakan tolok ukur yang lazim digunakan dalam evaluasi peramalan deret waktu karena sifatnya yang dapat diinterpre-

tasikan, tidak memerlukan data dalam jumlah sangat besar, dan relatif cepat untuk dilatih. Perbandingan terhadap *baseline* statistik ini memungkinkan penilaian yang objektif mengenai apakah model *deep learning* yang lebih kompleks benar-benar memberikan keunggulan yang sepadan dengan biaya komputasi yang lebih tinggi.

II.5.2.1 ARIMA dan SARIMA

ARIMA (*Autoregressive Integrated Moving Average*) adalah model peramalan deret waktu statistik yang menggabungkan tiga komponen utama: komponen autoregresif (AR) yang memodelkan pengaruh nilai masa lalu terhadap nilai saat ini, komponen diferensiasi (I) yang mengubah deret waktu menjadi stasioner melalui operasi selisih, dan komponen rata-rata bergerak (MA) yang memodelkan pengaruh kesalahan masa lalu. Model ARIMA dinotasikan sebagai $ARIMA(p, d, q)$ dengan p adalah orde autoregresif, d adalah derajat diferensiasi, dan q adalah orde rata-rata bergerak (Petropoulos dkk. 2022; Spiliotis, Makridakis, dan Petropoulos 2020).

Data yang mengandung pola musiman menggunakan model SARIMA (*Seasonal ARIMA*) yang dinotasikan sebagai $SARIMA(p, d, q)(P, D, Q)_m$ dengan P, D, Q adalah parameter musiman dan m adalah periode musiman (misalnya $m = 12$ untuk data bulanan). SARIMA mampu menangkap pola musiman berulang yang lazim ditemukan pada data bisnis seperti penjualan dan *churn* pelanggan (Petropoulos dkk. 2022).

Keunggulan utama ARIMA dan SARIMA terletak pada interpretabilitas tinggi, kebutuhan data yang relatif sedikit, dan efisiensi komputasi. Namun, model ini mengasumsikan linearitas dalam hubungan temporal dan memerlukan pemilihan parameter (p, d, q) yang cermat melalui analisis fungsi autokorelasi (ACF) dan autokorelasi parsial (PACF) (Petropoulos dkk. 2022; Spiliotis, Makridakis, dan Petropoulos 2020).

II.5.2.2 Prophet

Prophet adalah model peramalan deret waktu yang dikembangkan oleh Meta (Facebook) dan dirancang untuk bekerja dengan baik pada data bisnis yang memiliki tren kuat, efek musiman yang jelas, dan *outlier* yang umum (Tuncer dan Peker 2023; Masini, Medeiros, dan Mendes 2023). Prophet menggunakan pendekatan dekomposisi aditif yang memisahkan deret waktu menjadi komponen tren $T(t)$, musiman $S(t)$, efek hari raya $H(t)$, dan kesalahan residual ϵ_t :

$$y(t) = T(t) + S(t) + H(t) + \epsilon_t \quad (\text{II.6})$$

Komponen tren dimodelkan menggunakan fungsi pertumbuhan linier atau logistik yang dapat menangkap titik perubahan (*change points*) secara otomatis. Komponen musiman dimodelkan menggunakan deret Fourier untuk menangkap pola musiman harian, mingguan, dan tahunan secara fleksibel.

Keunggulan Prophet adalah kemudahan penggunaan, kemampuan menangani nilai hilang (*missing values*) dan *outlier* secara otomatis, serta dukungan untuk variabel regresor eksternal. Namun, Prophet cenderung kurang optimal untuk pola temporal yang sangat kompleks dan non-linear jika dibandingkan dengan model *deep learning* (Tuncer dan Peker 2023; Masini, Medeiros, dan Mendes 2023).

II.5.2.3 Keterbatasan Model Statistik dan Motivasi Penggunaan *Deep Learning*

Meskipun model statistik seperti ARIMA dan Prophet unggul dalam hal interpretabilitas dan efisiensi komputasi, terdapat sejumlah keterbatasan yang memotivasi penggunaan model *deep learning* dalam penelitian ini. Pertama, ARIMA dan SARIMA mengasumsikan linearitas sehingga kurang mampu menangkap hubungan temporal yang kompleks dan non-linear yang umum dalam data bisnis (Petropoulos dkk. 2022; Spiliotis, Makridakis, dan Petropoulos 2020). Kedua, model statistik univariat seperti ARIMA tidak secara langsung memanfaatkan informasi dari variabel-variabel lain yang berkorelasi sehingga kurang optimal untuk data multivariat (Masini, Medeiros, dan Mendes 2023). Ketiga, studi empiris pada data *e-commerce* dan telekomunikasi menunjukkan bahwa model LSTM dan GRU konsisten mengungguli ARIMA dengan pengurangan *error* sekitar 12–18% pada data dengan pola musiman dan ketergantungan temporal yang kompleks (Sunendar dan Rianto 2025; Tuncer dan Peker 2023).

Dengan demikian, pendekatan dalam penelitian ini adalah menggunakan ARIMA dan Prophet sebagai *baseline* yang terukur, kemudian membandingkannya dengan model *deep learning* (LSTM dan GRU) untuk memvalidasi bahwa kompleksitas tambahan dari model *deep learning* benar-benar memberikan peningkatan akurasi yang signifikan dalam konteks data indikator bisnis yang digunakan.

II.5.3 Model Peramalan Deret Waktu Berbasis *Deep Learning*

Sistem peramalan dalam penelitian ini memanfaatkan pendekatan berbasis pembelajaran mendalam (*deep learning*) yang dirancang khusus untuk menangani data deret waktu multivariat (*multivariate time series*) dengan pola temporal yang kompleks. Sistem mengimplementasikan dua arsitektur utama, yaitu LSTM dan GRU, untuk memaksimalkan akurasi prediksi terhadap indikator kinerja bisnis seperti vo-

lume pesanan, tingkat *churn* pelanggan, dan proyeksi pendapatan (Yunita dkk. 2025; Yun Zhang dkk. 2024). Arsitektur *Temporal Fusion Transformer* (TFT) dikaji sebagai referensi teoretis namun tidak diimplementasikan pada purwarupa ini (lihat Subbab II.5.3.3).

II.5.3.1 LSTM (*Long Short-Term Memory*) untuk Peramalan Deret Waktu

LSTM adalah jenis jaringan saraf berulang (*Recurrent Neural Network*, RNN) yang dirancang untuk mengatasi masalah gradien menghilang (*vanishing gradient*) pada RNN tradisional dan mampu mempelajari dependensi jangka panjang dalam data sekuens (Yunita dkk. 2025). Arsitektur LSTM terdiri dari sel memori dan tiga gerbang utama: gerbang lupa (*forget gate*) yang menentukan informasi apa dari sel memori yang harus dibuang, gerbang masukan (*input gate*) yang menentukan informasi baru apa yang akan disimpan, dan gerbang keluaran (*output gate*) yang menentukan bagian mana dari sel memori yang akan menjadi keluaran.

Persamaan matematis LSTM dapat ditulis sebagai berikut (Yunita dkk. 2025):

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{II.7})$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{II.8})$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (\text{II.9})$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (\text{II.10})$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (\text{II.11})$$

$$h_t = o_t * \tanh(C_t) \quad (\text{II.12})$$

Dalam persamaan ini, f_t adalah gerbang lupa, i_t adalah gerbang masukan, o_t adalah gerbang keluaran, C_t adalah keadaan sel (*cell state*), h_t adalah keadaan tersembunyi (*hidden state*), σ adalah fungsi sigmoid, serta W dan b adalah matriks bobot dan vektor bias yang dipelajari selama pelatihan.

LSTM unggul dalam menangani data deret waktu yang kompleks dengan dependensi jangka panjang dan pola non-linear. Kemampuan model untuk mengingat informasi relevan dari masa lalu yang jauh menjadikannya sangat efektif untuk aplikasi seperti peramalan permintaan atau tingkat *churn* pelanggan yang dipengaruhi oleh berbagai faktor temporal yang kompleks (Yunita dkk. 2025).

II.5.3.2 GRU (*Gated Recurrent Unit*) sebagai Alternatif LSTM

GRU adalah varian yang lebih sederhana dari LSTM, menawarkan performa yang sebanding dengan menggunakan arsitektur yang lebih ringkas dan parameter yang lebih sedikit (Yunita dkk. 2025; Yun Zhang dkk. 2024). GRU memiliki dua gerbang utama: gerbang reset (*reset gate*) dan gerbang pembaruan (*update gate*), menggabungkan fungsi gerbang lupa dan gerbang masukan LSTM menjadi satu gerbang pembaruan.

Persamaan matematis GRU dapat ditulis sebagai (Yunita dkk. 2025):

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \quad (\text{II.13})$$

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad (\text{II.14})$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t] + b) \quad (\text{II.15})$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t \quad (\text{II.16})$$

Dalam persamaan ini, r_t adalah gerbang reset, z_t adalah gerbang pembaruan, dan $\tilde{h}_t$ adalah calon keadaan tersembunyi. Studi empiris menunjukkan bahwa GRU sering memberikan hasil yang setara atau bahkan lebih baik daripada LSTM pada berbagai tugas peramalan deret waktu, dengan keuntungan pelatihan yang lebih cepat dan kebutuhan komputasi yang lebih rendah (Yunita dkk. 2025; Jeaab dkk. 2024).

II.5.3.3 *Temporal Fusion Transformer* (TFT) untuk Data Multivariat

Temporal Fusion Transformer (TFT) adalah arsitektur berbasis perhatian (*attention-based*) yang dirancang khusus untuk peramalan deret waktu multi-horizon pada data multivariat yang kompleks (Lim dkk. 2021; Yun Zhang dkk. 2024). TFT menggabungkan kekuatan mekanisme perhatian diri (*self-attention*) Transformer dengan lapisan berulang untuk pemrosesan lokal, memungkinkan model menangkap ketergantungan temporal pada berbagai skala waktu.

Arsitektur TFT terdiri dari beberapa komponen utama (Lim dkk. 2021; Hartanto dkk. 2024):

- a. Variabel *Input Tipe-Campuran*: TFT menangani masukan eksogen tergantung waktu (*time-dependent exogenous features*) yang terdiri dari masukan yang tidak diketahui sebelumnya dan masukan yang diketahui, serta kovariat statis yang memberikan konteks tentang entitas yang diukur.
- b. Jaringan Pemilihan Variabel (*Variable Selection Network*): Komponen ini secara adaptif memilih fitur yang paling relevan dari antara semua masukan,

meningkatkan interpretabilitas dan mengurangi kebisingan dari fitur yang tidak relevan (Lim dkk. 2021).

- c. Lapisan Gerbang Residu (*Gated Residual Networks*): Lapisan ini menerapkan mekanisme gerbang untuk menekan komponen yang tidak perlu, meningkatkan kemampuan model untuk fokus pada pola penting (Lim dkk. 2021).
- d. Mekanisme *Multi-Head Attention*: Mekanisme perhatian diri memungkinkan model menangkap hubungan jangka panjang dan pola kompleks dalam data, memberikan ketepatan prediksi yang tinggi pada berbagai horizon waktu (Hartanto dkk. 2024).

Berbeda dengan RNN yang memproses data secara sekuensial, TFT dapat memproses seluruh urutan masukan secara paralel, menghasilkan pelatihan yang lebih cepat. Penelitian menunjukkan bahwa TFT unggul dalam menangani skenario peramalan multivariat yang kompleks dengan banyak fitur yang saling berinteraksi, seperti kasus prediksi kinerja bisnis yang melibatkan banyak indikator yang saling terkait (Hartanto dkk. 2024; Cheng dkk. 2025).

II.5.3.4 Model Hibrida dan *Ensemble*

Penelitian terkini menunjukkan bahwa kombinasi hibrida dari arsitektur yang berbeda sering memberikan hasil yang lebih baik daripada model tunggal karena setiap arsitektur menangkap aspek berbeda dari pola temporal dalam data (Yunita dkk. 2025; Yun Zhang dkk. 2024).

Model hibrida **GRU-LSTM** menggabungkan keunggulan komplementer dari kedua arsitektur berulang. Studi pada prediksi suhu harian menunjukkan bahwa model hibrida GRU-LSTM mencapai RMSE sebesar 0,07499 dan MAE sebesar 0,0578 pada skenario masukan 15 hari, dengan R^2 mendekati 1 (0,9937), menunjukkan performa yang sangat baik (Diqi dkk. 2023). Keuntungan pendekatan hibrida terletak pada fleksibilitas untuk memanfaatkan kapabilitas pemrosesan lokal GRU yang efisien sekaligus pembelajaran dependensi jangka panjang yang kuat dari LSTM.

Pendekatan ensemble yang menggabungkan keluaran dari multiple model (misalnya LSTM, GRU, dan TFT) juga terbukti meningkatkan robustness dan ketepatan prediksi, terutama dalam menangani variabilitas dan ketidakpastian dalam data bisnis real-world (Yun Zhang dkk. 2024; Yunita dkk. 2025).

II.5.3.5 Perbandingan Karakteristik Model Peramalan *Deep Learning*

Berbagai penelitian empiris telah membandingkan kinerja LSTM, GRU, dan TFT pada berbagai skenario peramalan deret waktu. Tabel II.1 menyajikan perbandingan karakteristik utama dari ketiga arsitektur berdasarkan sintesis dari penelitian-

penelitian terdahulu.

Tabel II.1 Perbandingan Karakteristik Model Peramalan Deret Waktu

Metode	Kelebihan	Kekurangan	Karakteristik
LSTM	1. Menangkap de- pendensi jangka panjang hingga ratusan langkah waktu 2. Mengatasi ma- salah <i>vanishing gradient</i> melalui gerbang-gerbang adaptif 3. Fleksibel un- tuk menangani pola temporal kompleks dan <i>non-linear</i> 4. Mampu mem- pelajari urutan masukan dengan panjang variabel	1. Memerlukan volu- me data historis be- sar (minimal ribuan sampel) 2. Waktu pelatihan panjang, terutama pada <i>dataset</i> besar atau GPU terbatas 3. Sulit untuk interp- retasi internal (ber- sifat <i>black-box</i>) 4. Proses <i>inference</i> sekuensial, tidak dapat diparalelisasi secara efisien 5. Sensitif terha- dap inisialisasi <i>hyperparameter</i>	1. MAPE tipikal: 8–12% 2. Cocok untuk: data besar, pola kompleks 3. Kompleksitas model: ting- gi (jutaan parameter) 4. Parameter: ra- tusan ribu

Bersambung ke halaman berikutnya

Tabel II.1 – Perbandingan Model Peramalan Deret Waktu (lanjutan)

Metode	Kelebihan	Kekurangan	Karakteristik
GRU	1. Arsitektur lebih sederhana dibanding LSTM (hanya dua gerbang) 2. Waktu pelatihan 15–20% lebih cepat dari LSTM pada data sama 3. Jumlah parameter 20–30% lebih sedikit, mengurangi risiko <i>overfitting</i> 4. Performa sebanding atau lebih baik dari LSTM pada banyak tugas 5. Kebutuhan memori lebih rendah	1. Tetap memerlukan data historis dalam jumlah besar 2. Juga sulit untuk interpretasi internal (<i>black-box</i>) 3. Literatur dan <i>best-practices</i> lebih terbatas dibanding LSTM 4. Performa terkadang sedikit lebih rendah pada skenario dengan ketergantungan ultra-jangka-panjang 5. <i>Inference</i> masih sekuensial	1. MAPE tipikal: 10–13% 2. Cocok untuk: data besar, komputasi terbatas 3. Kompleksitas model: sedang–tinggi 4. Parameter: 20–30% lebih sedikit dari LSTM

Bersambung ke halaman berikutnya

Tabel II.1 – Perbandingan Model Peramalan Deret Waktu (lanjutan)

Metode	Kelebihan	Kekurangan	Karakteristik
TFT	1. Dirancang khusus untuk data multivariat dengan banyak fitur terkait 2. Interpretabilitas lebih baik: mekanisme <i>attention</i> menunjukkan fitur/waktu penting 3. Paralelisasi efisien: seluruh urutan diproses sekaligus, bukan sekuensial 4. <i>Multi-horizon forecasting</i>: dapat memprediksi beberapa langkah ke depan sekaligus 5. Seleksi variabel otomatis mengurangi pengaruh fitur yang tidak relevan	1. Kompleksitas arsitektur tinggi (6–7 <i>submodule</i> berbeda) 2. Memerlukan penyetelan (<i>tuning</i>) <i>hyperparameter</i> lanjut 3. Data historis dalam jumlah sangat besar optimal untuk performa terbaik 4. Biaya komputasi (<i>computational cost</i>) tinggi (GPU umumnya diperlukan) 5. Waktu <i>training</i> lebih lama dari LS-TM/GRU karena kompleksitas 6. Memerlukan keahlian teknis lebih tinggi untuk implementasi	1. MAPE tipikal: 7–11% 2. Cocok untuk: data multivariat, fitur banyak, <i>budget</i> komputasi tinggi 3. Kompleksitas model: sangat tinggi 4. Parameter: jutaan (tergantung konfigurasi) 5. Paralelisasi: baik

Bersambung ke halaman berikutnya

Tabel II.1 – Perbandingan Model Peramalan Deret Waktu (lanjutan)

Metode	Kelebihan	Kekurangan	Karakteristik
Hibrida (GRU-LSTM)	1. Menggabungkan kekuatan dua arsitektur: efisiensi GRU dan pembelajaran jangka panjang <i>LSTM</i> 2. Hasil prediksi lebih <i>robust</i> terhadap variasi dalam data (<i>ensemble effect</i>) 3. Efisiensi komputasi baik: kompromi antara akurasi dan kecepatan 4. Fleksibilitas desain: dapat dikonfigurasi sesuai karakteristik <i>dataset</i> 5. Mengurangi risiko model bias terhadap pola tertentu	1. Desain dan implementasi lebih kompleks 2. Jumlah <i>hyperparameter</i> lebih banyak sehingga <i>tuning</i> lebih sulit 3. Risiko <i>overfitting</i> lebih tinggi jika tidak dikendalikan 4. Waktu <i>training</i> lebih lama dibanding model tunggal 5. Interpretasi model lebih sulit karena kombinasi dua arsitektur 6. Memerlukan validasi silang (<i>cross-validation</i>) yang cermat	1. MAPE tipikal: 7–10% 2. Cocok untuk: data multivariat, pola campuran, GPU menengah 3. Kompleksitas model: tinggi–sangat tinggi 4. Parameter: ratusan ribu hingga jutaan 5. <i>Trade-off</i>: akurasi vs efisiensi

Bersambung ke halaman berikutnya

Tabel II.1 – Perbandingan Model Peramalan Deret Waktu (lanjutan)

Metode	Kelebihan	Kekurangan	Karakteristik
ARIMA / SARIMA (<i>Baseline</i>)	1. Sangat interpretatif: parameter memiliki makna statistik yang jelas 2. Efisiensi komputasi sangat tinggi, tidak memerlukan GPU 3. Cocok untuk seri univariat dengan stasioneritas yang dapat diuji 4. Didukung teori statistik yang matang dan terdokumentasi	1. Mengasumsikan linearitas, kurang mampu menangkap pola non-linear 2. Tidak secara langsung menangani data multivariat tanpa ekstensi 3. Memerlukan pemilihan parameter (p, d, q) yang cermat via analisis ACF/PACF 4. Performa menurun pada data dengan tren atau musiman yang berubah	1. MAPE tipikal: 15–25% 2. Cocok untuk: data univariat, interpretabilitas tinggi 3. Kompleksitas model: rendah 4. Peran: <i>baseline</i> statistik

Bersambung ke halaman berikutnya

Tabel II.1 – Perbandingan Model Peramalan Deret Waktu (lanjutan)

Metode	Kelebihan	Kekurangan	Karakteristik
Prophet (<i>Baseline</i>)	1. Mudah digunakan dan tahan terhadap <i>outlier</i> serta nilai hilang 2. Menangani tren dan musiman yang kompleks secara otomatis 3. Mendukung variabel regresor eksternal 4. Dapat mendeteksi titik perubahan tren (<i>changepoints</i>) secara otomatis	1. Masih berdasarkan model aditif yang mengasumsikan dekomposisi linier 2. Kurang optimal untuk pola temporal yang sangat kompleks dan non-linear 3. Proses <i>fitting</i> lebih lambat dibanding ARIMA untuk data sederhana 4. Interpretabilitas parameter lebih terbatas dibanding ARIMA	1. MAPE tipikal: 12–20% 2. Cocok untuk: data bisnis dengan tren dan musiman kuat 3. Kompleksitas model: rendah–sedang 4. Peran: <i>baseline</i> statistik

Studi empiris menunjukkan bahwa pada data yang mengandung pola musiman kuat dan dependensi temporal kompleks, seperti data penjualan atau *churn* pelanggan bisnis, model LSTM dan GRU mengungguli metode statistik tradisional seperti ARIMA dengan pengurangan *error* sekitar 12–18% (Sunendar dan Rianto 2025). Penelitian pada prediksi stok Indonesia menunjukkan GRU mengungguli LSTM dengan peningkatan R^2 sebesar 10,7% dan pengurangan MAPE sebesar 18,5%, menunjukkan bahwa pada *dataset* tertentu, GRU dapat memberikan hasil lebih efisien (Sabila dkk. 2025).

Model TFT menunjukkan performa tertinggi pada data multivariat, dengan MAPE yang mencapai 0,22% (0,0022) pada prediksi harga saham Indonesia ketika dikombinasikan dengan rekayasa fitur yang tepat (Hartanto dkk. 2024). Keunggulan TFT dalam interpretabilitas juga membuatnya menarik untuk aplikasi bisnis dengan transparansi model menjadi penting bagi *stakeholder*.

II.5.3.6 Pemilihan Model dalam Konteks Penelitian

Proses pemilihan model dalam penelitian ini dimulai dari evaluasi model statistik klasik sebagai *baseline*, kemudian dibandingkan dengan model *deep learning* untuk menentukan pendekatan yang paling tepat berdasarkan data indikator bisnis yang digunakan.

Tahap 1: Evaluasi *Baseline* Statistik. Model ARIMA dan Prophet digunakan sebagai *baseline* awal karena keduanya merupakan standar industri yang umum digunakan dan mudah diinterpretasikan. ARIMA dipilih untuk seri waktu yang bersifat univariat dengan pola musiman yang teridentifikasi secara statistik, sedangkan Prophet dipilih untuk data bisnis yang memiliki tren kuat dan efek musiman majemuk. Evaluasi *baseline* ini memberikan tolok ukur yang terukur sebelum mempertimbangkan model yang lebih kompleks.

Tahap 2: Justifikasi Penggunaan LSTM dan GRU. Berdasarkan karakteristik data indikator bisnis dalam penelitian ini yang mencakup data multivariat dengan ketergantungan temporal yang kompleks dan pola non-linear, LSTM dan GRU dipilih sebagai model utama dengan alasan berikut. Pertama, data volume pesanan, tingkat *churn*, dan pendapatan menunjukkan hubungan non-linear yang sulit ditangkap oleh model ARIMA yang bersifat linear. Kedua, tersedianya fitur-fitur multivariat dari berbagai domain data (penjualan, pendapatan, target, dan lainnya) memungkinkan model LSTM dan GRU memanfaatkan korelasi antar-variabel yang tidak dapat dilakukan oleh model univariat seperti ARIMA. Ketiga, studi empiris menunjukkan bahwa LSTM dan GRU secara konsisten mengungguli ARIMA pada data deret waktu bisnis yang kompleks dengan pengurangan kesalahan sekitar 12–18% (Sunendar dan Rianto 2025). Keempat, GRU dipilih sebagai alternatif LSTM karena arsitekturnya yang lebih sederhana memberikan efisiensi komputasi 15–20% lebih baik dengan akurasi yang sebanding (Yunita dkk. 2025).

Tahap 3: Potensi Pengembangan Lanjutan. Arsitektur lanjutan seperti TFT (*Temporal Fusion Transformer*) yang dibahas pada Subbab II.5.3.3 dapat menjadi kandidat pengembangan di masa depan, khususnya untuk skenario yang melibatkan banyak fitur eksogen atau ketika interpretabilitas model menjadi prioritas. Namun, TFT memerlukan data dalam jumlah lebih besar dan biaya komputasi yang lebih tinggi sehingga tidak termasuk dalam lingkup implementasi penelitian ini.

Dengan demikian, sistem mengimplementasikan LSTM dan GRU sebagai model utama dengan performa yang telah divalidasi, serta menggunakan ARIMA dan Pro-

phet sebagai *baseline* pembandingan. Evaluasi empiris pada data historis internal menggunakan metrik sMAPE, MASE, dan *Skill Score* dilakukan untuk memvalidasi pilihan model ini secara kuantitatif (Yunita dkk. 2025; Petropoulos dkk. 2023).

II.5.4 Evaluasi Performa *Time Series Forecasting*

Evaluasi performa model peramalan deret waktu merupakan langkah kritis untuk memastikan bahwa prediksi yang dihasilkan memiliki akurasi yang memadai untuk mendukung pengambilan keputusan bisnis. Evaluasi yang komprehensif mencakup berbagai metrik dan teknik analisis yang saling melengkapi untuk memberikan gambaran menyeluruh tentang kualitas model.

II.5.4.1 Metrik Evaluasi *Forecasting*

Model peramalan deret waktu multivariat dievaluasi menggunakan empat metrik utama yang komprehensif: *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), *Symmetric Mean Absolute Percentage Error* (sMAPE), dan *Mean Absolute Scaled Error* (MASE) (Petropoulos dkk. 2023). Setiap metrik memberikan perspektif berbeda terhadap akurasi prediksi sehingga kombinasinya menghasilkan penilaian yang lebih robust dan komprehensif.

Mean Absolute Error (MAE) mengukur rata-rata nilai absolut kesalahan prediksi:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (\text{II.17})$$

MAE mudah diinterpretasikan karena berada dalam satuan yang sama dengan data asli, dan *robust* terhadap *outliers*. Namun, MAE tidak memberikan penalti tambahan pada kesalahan yang sangat besar (Petropoulos dkk. 2023).

Root Mean Square Error (RMSE) mengukur akar kuadrat dari rata-rata kesalahan kuadrat:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (\text{II.18})$$

RMSE memberikan penalti yang lebih besar untuk kesalahan yang lebih besar, menjadikannya lebih sensitif terhadap *outliers* dibandingkan MAE. Metrik ini berguna ketika kesalahan besar sangat tidak diinginkan dalam konteks bisnis (Petropoulos dkk. 2023).

Symmetric Mean Absolute Percentage Error (sMAPE) mengukur persentase kesa-

lahan secara simetris:

$$\text{sMAPE} = \frac{100\%}{n} \sum_{i=1}^n \frac{2|y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|} \quad (\text{II.19})$$

sMAPE lebih stabil daripada MAPE (*Mean Absolute Percentage Error*) ketika nilai aktual mendekati nol karena pembagi mencakup baik nilai aktual maupun nilai prediksi. Hal ini membuat sMAPE lebih cocok untuk data multivariat dengan skala dan nilai yang bervariasi (Petropoulos dkk. 2023).

Mean Absolute Scaled Error (MASE) menormalkan kesalahan terhadap model referensi sederhana:

$$\text{MASE} = \frac{\text{MAE}}{\text{MAE}_{\text{baseline}}} \quad (\text{II.20})$$

MASE memudahkan perbandingan antar-deret waktu yang berbeda skala dan antar-model yang berbeda karena kesalahan dinormalkan relatif terhadap garis dasar (*baseline*). MASE bernilai kurang dari 1 menunjukkan bahwa model mengungguli garis dasar, sedangkan nilai lebih dari 1 menunjukkan performa yang lebih buruk (Petropoulos dkk. 2023).

Dalam formula-formula di atas, y_i adalah nilai aktual, $\hat{y}_i$ adalah nilai prediksi, dan n adalah jumlah observasi.

II.5.4.2 *Skill Score* terhadap Garis Dasar

Selain metrik kesalahan mentah, sistem juga menghitung *skill score* yang membandingkan performa model terhadap garis dasar (*baseline*) sederhana, seperti model *naive* (prediksi nilai sebelumnya) atau *random walk* (Petropoulos dkk. 2023). *Skill score* didefinisikan sebagai:

$$\text{Skill Score} = 1 - \frac{\text{Metrik}_{\text{model}}}{\text{Metrik}_{\text{baseline}}} \quad (\text{II.21})$$

Skill score positif menunjukkan bahwa model yang diusulkan mengungguli garis dasar, sedangkan nilai negatif mengindikasikan performa yang lebih buruk dari model referensi. Pendekatan ini memberikan konteks relatif tentang keberhasilan model dan memudahkan pengambilan keputusan apakah model kompleks (seperti LSTM atau GRU) justru diperlukan atau model sederhana sudah cukup (Petropoulos dkk. 2023; Spiliotis, Makridakis, dan Petropoulos 2020).

II.5.4.3 Pelaporan per Horizon dan per Entitas Prioritas

Dalam memberikan gambaran yang kaya dan terstruktur tentang kinerja model pada berbagai skenario, hasil evaluasi dilaporkan tidak hanya sebagai nilai rata-rata global, tetapi per *forecast horizon* (cakrawala peramalan) dan per entitas prioritas (*priority entity*) (Spiliotis, Makridakis, dan Petropoulos 2020).

Dalam konteks *forecast horizon*, model dievaluasi secara terpisah untuk setiap cakrawala waktu. Hal ini penting karena akurasi model umumnya menurun seiring bertambahnya jarak prediksi, dan pola degradasi akurasi ini berguna untuk memahami batas kepercayaan pada setiap horizon (Petropoulos dkk. 2023).

Dalam konteks *priority entity*, model dievaluasi secara terpisah untuk setiap entitas yang diprioritaskan. Hal ini memungkinkan identifikasi entitas mana yang memiliki akurasi tinggi dan mana yang memerlukan penyempurnaan model (Spiliotis, Makridakis, dan Petropoulos 2020).

Dalam setiap kombinasi horizon–entitas, metrik kesalahan dilaporkan menggunakan:

- a. Nilai Median (*Median*): Nilai tengah yang *robust* terhadap *outliers*, memberikan ukuran tendensi sentral yang lebih andal daripada rata-rata.
- b. Rentang Antar Kuartil (*Interquartile Range, IQR*): Selisih antara kuartil ketiga dan kuartil pertama, menunjukkan penyebaran 50% tengah dari distribusi kesalahan. IQR memberikan gambaran tentang variabilitas performa model tanpa dipengaruhi nilai ekstrem.

Pendekatan ini memungkinkan analisis distribusi performa model yang lebih robust, bukan hanya bergantung pada nilai rata-rata, dan dapat mengidentifikasi situasi atau entitas dengan model mungkin mengalami tantangan (Petropoulos dkk. 2023; Spiliotis, Makridakis, dan Petropoulos 2020).

II.5.4.4 Residual Analysis

Analisis residual merupakan komponen penting dalam evaluasi model peramalan untuk memastikan bahwa asumsi model terpenuhi dan tidak ada pola sistematis yang tersisa dalam kesalahan prediksi. Analisis ini mencakup beberapa teknik yang saling melengkapi:

- a. Plot Residual terhadap Waktu: Mendeteksi pola temporal yang mungkin tersisa dalam residual. Residual yang baik harus terdistribusi secara acak di sekitar nol tanpa tren atau pola musiman yang jelas, mengindikasikan bahwa model telah menangkap sebagian besar struktur dinamis dalam data.

- b. Uji Normalitas (*Shapiro-Wilk Test*): Menguji apakah residual mengikuti distribusi normal. Normalitas residual mengindikasikan bahwa model telah mengekstrak informasi sistem secara efektif dan kesalahan yang tersisa bersifat acak murni.
- c. Uji Autokorelasi (*Ljung-Box Test*): Mendeteksi autokorelasi dalam residual dengan uji statistik. Autokorelasi yang signifikan mengindikasikan bahwa masih ada informasi temporal yang belum ditangkap oleh model, dan model mungkin perlu diperbaiki atau divariasikan.

Ketiga teknik ini memberikan pemeriksaan komprehensif terhadap kualitas model dan asumsi yang mendasarinya (Petropoulos dkk. 2023).

II.5.4.5 Time Series Cross-Validation

Validasi silang khusus untuk deret waktu (*time series cross-validation*) menggunakan pendekatan *walk-forward validation* atau *expanding window* untuk menghindari kebocoran informasi dari masa depan ke masa lalu (Spiliotis, Makridakis, dan Petropoulos 2020). Pendekatan ini membagi data secara berurutan: pada setiap iterasi, model dilatih pada subset data historis yang terus bertambah, kemudian diminta memprediksi periode mendatang. Hal ini mensimulasikan kondisi operasional (*deployment*) aktual dengan model harus memprediksi masa depan berdasarkan data masa lalu yang diketahui.

Validasi silang deret waktu memberikan estimasi performa yang lebih realistis dibandingkan validasi silang standar (misalnya *k-fold*), yang dapat menghasilkan *overfitting* karena kebocoran informasi temporal. Dengan pendekatan *walk-forward*, estimasi akurasi model pada data uji mencerminkan performa yang dapat diharapkan dalam praktik (Petropoulos dkk. 2023).

II.5.4.6 Target Performa Forecasting

Berdasarkan literatur dan praktik industri terkini, target performa yang ditetapkan untuk model peramalan deret waktu multivariat dalam konteks *Business Intelligence* mencakup beberapa kriteria utama (Petropoulos dkk. 2023; Spiliotis, Makridakis, dan Petropoulos 2020):

- a. sMAPE: Harus mencapai maksimal 15%, yang dianggap dapat diterima untuk sebagian besar aplikasi bisnis dengan prediksi deret waktu multivariat.
- b. RMSE: Harus seminimal mungkin dan dibandingkan dengan standar deviasi (*standard deviation*) data aktual. RMSE yang kurang dari setengah standar deviasi data aktual umumnya dianggap performa yang baik.
- c. MAE: Harus seminimal mungkin dan diinterpretasikan dalam konteks skala

- data. MAE yang secara signifikan lebih kecil dari nilai rata-rata (*mean*) data aktual menunjukkan performa yang baik.
- d. MASE: Harus bernilai kurang dari 1 untuk menunjukkan bahwa model mengungguli garis dasar sederhana. Nilai MASE antara 0,5 dan 1 mengindikasikan performa yang sangat baik relatif terhadap garis dasar.
 - e. Residual: Harus lulus uji *Ljung-Box* dengan *p-value* lebih besar dari 0,05, mengindikasikan tidak ada autokorelasi signifikan yang tersisa dalam residual.
 - f. *Skill Score*: Harus positif untuk semua horizon dan entitas prioritas, menunjukkan konsistensi keunggulan model terhadap garis dasar.

Pencapaian target-target ini, diukur melalui statistik median dan IQR per horizon dan per entitas prioritas, memastikan bahwa model peramalan dapat memberikan prediksi yang akurat, andal, dan konsisten untuk mendukung perencanaan strategis dan pengambilan keputusan operasional dalam sistem *Business Intelligence* (Petropoulos dkk. 2023).

II.6 Integrasi Sistem dan Penelitian Terkait

Integrasi berbagai komponen teknologi dalam sistem *chatbot Business Intelligence* memerlukan pendekatan arsitektur yang terstruktur untuk memastikan kohesi antarkomponen. Penelitian-penelitian terdahulu telah mengeksplorasi integrasi parsial dari teknologi-teknologi ini secara terpisah, namun integrasi komprehensif yang menggabungkan klasifikasi *intent* berbasis pola, mesin kueri berbasis aturan, pembangkitan bahasa alami berbasis templat, dan peramalan deret waktu dalam satu sistem *chatbot* analitik masih terbatas.

II.6.1 Arsitektur Chatbot Hibrida

Arsitektur *chatbot* hibrida menggabungkan pendekatan berbasis aturan dengan kemampuan kecerdasan buatan untuk menciptakan keseimbangan antara kontrol deterministik dan fleksibilitas adaptif (Sharma dan Kumar 2024). Arsitektur *chatbot* modern terdiri dari lima komponen utama yang bekerja secara terintegrasi, yaitu antarmuka pengguna, modul pemahaman bahasa alami, manajemen dialog, *backend* yang terhubung dengan basis data, dan pembangkitan respons (Huang 2021). Pendekatan hibrida yang mengintegrasikan model pemrosesan bahasa alami ringan dengan pengawasan manusia telah menunjukkan akurasi 85% dalam menyelesaikan pertanyaan dan mengurangi beban kerja staf sebesar 30% (Bamurange 2025).

II.6.2 Integrasi Klasifikasi *Intent* dan Mesin Kueri

Klasifikasi *intent* berbasis pola menggunakan kombinasi pencocokan pola *regex*, pencocokan kata kunci, dan aturan berbasis konteks untuk mengidentifikasi maksud pengguna dengan kontrol penuh atas interpretasi (Sharma dan Kumar 2024). Pendekatan berbasis aturan memberikan hasil yang selalu akurat karena mengikuti logika kondisional yang telah didefinisikan sebelumnya (IBM 2025). Setelah *intent* teridentifikasi, sistem mengeksekusi kueri terstruktur terhadap *data warehouse* untuk mengambil data yang relevan. Integrasi ini memungkinkan pengguna mengajukan pertanyaan dalam bahasa alami dan sistem secara otomatis mengonversi pertanyaan tersebut menjadi kueri basis data yang dapat dieksekusi (Querio AI 2025).

II.6.3 Integrasi Pembangkitan Bahasa Alami Berbasis Templat

Pembangkitan bahasa alami berbasis templat menggunakan modul-modul teks yang ditulis oleh manusia dengan komponen linguistik yang menangani infleksi kata sehingga menghasilkan kalimat yang benar secara gramatikal (Retresco 2024). Keunggulan utama pendekatan berbasis templat dalam konteks bisnis adalah kemampuan kontrolnya yang tinggi, dengan sistem dapat menjamin tidak menghasilkan kalimat yang tidak diinginkan atau tidak sesuai (Retresco 2024). Integrasi pembangkitan bahasa alami dalam platform *Business Intelligence* memungkinkan pengguna memperoleh penjelasan tekstual dan perbandingan wawasan secara instan (Yellowfin BI 2025).

II.6.4 Integrasi Peramalan Deret Waktu

Model peramalan berbasis *deep learning* seperti *Long Short-Term Memory* dan *Gated Recurrent Unit* telah terbukti efektif dalam memodelkan hubungan temporal yang kompleks dalam data deret waktu (Priadinata dan Wijaya 2025). Kombinasi arsitektur *GRU-LSTM* dapat memberikan manfaat dari kedua model, memungkinkan penanganan rentang data masukan yang lebih luas dan mencapai akurasi yang lebih tinggi dalam prediksi (Wijaya dan Kusuma 2024). Peramalan deret waktu menjadi fondasi perencanaan sumber daya perusahaan dengan prediksi permintaan masa depan yang memandu keputusan kritis seperti jumlah unit yang harus disediakan, tenaga kerja yang diperlukan, dan investasi modal (Databricks 2025a).

II.6.5 Integrasi Prediksi *Customer Churn*

Prediksi *customer churn* menggunakan algoritma pembelajaran mesin seperti *XGBoost* dan *Random Forest* telah menunjukkan akurasi tinggi dalam mengidentifikasi pelanggan berisiko (Sam dan Okonkwo 2024). Model *XGBoost* dengan teknik *Histogram Augmentation* dan optimasi *Bayesian* mencapai akurasi 0,88 dan skor *F1*

sebesar 0,85 pada data telekomunikasi (Prasetyo dan Kusuma 2024). Integrasi prediksi *churn* ke dalam sistem *chatbot Business Intelligence* memungkinkan pengguna internal mengakses analisis risiko *churn* melalui antarmuka percakapan yang intuitif.

II.7 Tinjauan Penelitian Terdahulu

Berbagai penelitian telah mengeksplorasi komponen-komponen teknologi yang menjadi dasar pengembangan sistem *chatbot Business Intelligence*, meliputi arsitektur *chatbot* hibrida, klasifikasi *intent*, pembangkitan bahasa alami, peramalan deret waktu, dan prediksi *customer churn*. Tinjauan terhadap penelitian-penelitian terdahulu menunjukkan bahwa masing-masing komponen telah dikembangkan dan dievaluasi secara terpisah dengan hasil yang menjanjikan, namun integrasi menyeluruh dari seluruh komponen dalam satu sistem analitik berbasis percakapan masih terbatas. Tabel II.2 menyajikan ringkasan penelitian terdahulu yang relevan dengan pengembangan sistem yang diusulkan.

Tabel II.2 Tinjauan Penelitian Terdahulu

Penulis	Judul Penelitian	Temuan Utama	Metode	Teknologi
Bamurange dkk. (2025)	<i>Hybrid Chatbot dengan AI dan Human Oversight untuk Pendidikan Tinggi</i>	Akurasi 85% dalam menyelesaikan pertanyaan akademik dan pengurangan beban kerja staf sebesar 30%	Kerangka kerja hibrida dengan pohon keputusan dan pemetaan <i>intent</i>	<i>Chatbot</i> hibrida, <i>NLP</i> ringan
Lin dkk. (2024)	<i>How Chatbots Augment Human Intelligence in Customer Service</i>	<i>Chatbot</i> berbasis <i>AI</i> meningkatkan performa kerja melalui dukungan informasional dan emosional	Metode campuran kualitatif-kuantitatif dengan teori <i>affordances</i>	<i>AI-enabled chatbot</i> , <i>NLP</i> , <i>deep learning</i>

Bersambung ke halaman berikutnya

Tabel II.2 – Lanjutan dari halaman sebelumnya

Penulis	Judul Penelitian	Temuan Utama	Metode	Teknologi
Sam dkk. (2024)	<i>Customer Churn Prediction using Machine Learning Models</i>	<i>XGBoost</i> dan <i>Random Forest</i> mencapai akurasi prediksi tertinggi dibandingkan <i>KNN</i> , <i>SVM</i> , dan <i>Decision Trees</i>	Klasifikasi dan <i>clustering</i> dengan evaluasi akurasi, presisi, <i>F1-Score</i>	<i>XGBoost</i> , <i>Random Forest</i> , <i>SVM</i>
Priadinata dkk. (2025)	Analisis Komparatif <i>LSTM</i> , <i>GRU</i> , dan <i>Bi-LSTM</i> untuk Prediksi Harga	<i>LSTM</i> dan <i>GRU</i> efektif dalam menangkap dependensi sekuensial pada data deret waktu	Eksperimen komputasional dengan <i>grid search hyperparameter</i>	<i>LSTM</i> , <i>GRU</i> , <i>Bi-LSTM</i>
Retresco (2024)	<i>GPT</i> dan Model Teks Berbasis Templat dalam <i>NLG</i>	Pembangkitan teks berbasis templat memberikan kontrol lebih tinggi dan menjamin tidak menghasilkan kalimat tidak diinginkan	Perbandingan pendekatan <i>end-to-end</i> dengan berbasis templat	<i>Template-based NLG</i> , <i>GPT</i>
Querio (2025)	<i>Conversational AI Data Analyst Chatbot</i>	<i>Chatbot</i> analitik memungkinkan kueri bahasa alami tanpa keahlian <i>SQL</i>	Integrasi <i>NLP</i> dengan <i>data warehouse</i> dan lapisan tata kelola	<i>Conversational AI</i> , <i>text-to-SQL</i>

Bersambung ke halaman berikutnya

Tabel II.2 – Lanjutan dari halaman sebelumnya

Penulis	Judul Penelitian	Temuan Utama	Metode	Teknologi
Kalogianni dis dkk. (2024)	Integrasi <i>AI</i> dalam Analitik Bisnis	Integrasi <i>NLP</i> dan <i>AI</i> berdampak signifikan terhadap cara pelanggan berinteraksi dan berkomunikasi dengan <i>chatbot</i>	Survei terstruktur dengan analisis <i>SPSS</i>	<i>Chatbot</i> , <i>NLP</i> , <i>virtual assistant</i>
Zenodo (2025)	Studi Analitis <i>Chatbot</i> Berbasis <i>AI</i> dan <i>ML</i>	Integrasi <i>chatbot</i> berpengaruh positif signifikan terhadap performa teknis dan efisiensi operasional	Desain deskriptif-analitis dengan 220 responden	<i>AI chatbot</i> , <i>ML</i> , <i>decision support</i>

II.8 Celah Penelitian dan Kontribusi

Berdasarkan telaah kritis terhadap penelitian-penelitian terdahulu, teridentifikasi beberapa celah penelitian yang menjadi landasan kontribusi tugas akhir ini. Penelitian-penelitian sebelumnya cenderung mengembangkan komponen-komponen teknologi secara terpisah tanpa integrasi menyeluruh dalam satu sistem analitik berbasis percakapan.

Poin-poin pembeda utama antara tugas akhir ini dengan penelitian terdahulu adalah sebagai berikut.

1. Integrasi Empat Komponen Teknologi dalam Satu Sistem

Penelitian terdahulu umumnya mengembangkan klasifikasi *intent*, mesin kueri, pembangkitan bahasa alami, dan peramalan deret waktu sebagai komponen terpisah. Tugas akhir ini mengintegrasikan keempat komponen tersebut dalam satu arsitektur sistem *chatbot Business Intelligence* yang kohesif.

2. Fokus pada Pengguna Internal dan Indikator Bisnis Pelanggan

Sebagian besar penelitian *chatbot* berfokus pada layanan pelanggan eksternal. Tugas akhir ini secara khusus dirancang untuk pengguna internal perusahaan dengan fokus pada analisis indikator bisnis pelanggan seperti pesanan, target penjualan, *churn*, dan pendapatan.

3. Kombinasi Pendekatan Berbasis Aturan dan Pembelajaran Mendalam

Penelitian terdahulu cenderung menggunakan salah satu pendekatan secara eksklusif. Tugas akhir ini mengkombinasikan klasifikasi *intent* berbasis pola untuk kontrol dan keamanan dengan model *deep learning* untuk kemampuan prediktif.

4. Pembangkitan Bahasa Alami Berbasis Templat untuk Keamanan Data Internal

Berbeda dengan pendekatan *end-to-end* yang berisiko menghasilkan informasi tidak akurat, tugas akhir ini menggunakan pendekatan berbasis templat yang menjamin akurasi faktual dan keamanan data sensitif perusahaan.

5. Dukungan Bahasa Indonesia dalam Antarmuka Percakapan

Penelitian *chatbot Business Intelligence* yang mendukung interaksi dalam Bahasa Indonesia masih sangat terbatas. Tugas akhir ini mengembangkan sistem yang mendukung interaksi dalam Bahasa Indonesia.

Dengan demikian, penelitian ini berkontribusi dalam mengisi celah antara pengembangan komponen teknologi secara terpisah dengan kebutuhan sistem analitik terintegrasi yang dapat diakses oleh pengguna nonteknis melalui antarmuka percakapan. Kontribusi utama mencakup arsitektur integrasi yang menghubungkan klasifikasi *intent*, eksekusi kueri, pembangkitan bahasa alami, dan peramalan prediktif dalam satu alur kerja yang koheren, serta implementasi sistem yang berfokus pada konteks bisnis Indonesia dengan dukungan bahasa lokal.

BAB III

ANALISIS MASALAH

Bab ini menyajikan analisis mendalam terhadap kondisi sistem *Business Intelligence* saat ini, identifikasi masalah pengguna, kebutuhan fungsional dan nonfungsional sistem, serta analisis pemilihan solusi teknologi yang paling tepat. Pembahasan mencakup evaluasi sistem *Business Intelligence* yang ada, identifikasi tantangan dalam pengambilan keputusan berbasis data, dan justifikasi pemilihan pendekatan *chatbot* berbasis aturan kueri, pemrosesan bahasa alami, dan peramalan deret waktu sebagai solusi yang paling sesuai dengan kebutuhan organisasi modern.

III.1 Analisis Kondisi Saat Ini

Analisis permasalahan yang dikaji dalam penelitian ini menggunakan pendekatan CRISP-DM (*Cross-Industry Standard Process for Data Mining*). Metodologi ini terdiri dari enam tahapan utama, yaitu pemahaman bisnis (*business understanding*), pemahaman data (*data understanding*), penyiapan data (*data preparation*), pemodelan (*modeling*), evaluasi (*evaluation*), dan penerapan (*deployment*). Masing-masing tahapan dijelaskan lebih lanjut dalam bab ini beserta kegiatan-kegiatan yang dilakukan pada setiap fase, untuk menunjukkan bagaimana sistem dikembangkan secara terstruktur guna menjawab kebutuhan analisis dan prediksi kinerja bisnis secara otomatis dan responsif.

III.1.1 Pemahaman Bisnis (*Business Understanding*)

Permasalahan besar yang diangkat dalam penelitian ini adalah ketidakefisienan dan kurangnya responsivitas dalam proses analisis data bisnis untuk pengambilan keputusan strategis. Banyak organisasi, terutama perusahaan skala menengah dan besar, masih mengandalkan sistem *business intelligence* berbasis dasbor visual statis dan pelaporan manual yang memerlukan intervensi tim teknologi informasi atau analis data untuk setiap permintaan analisis berdasarkan kebutuhan khusus. Proses ini tidak hanya memakan waktu, tetapi juga berpotensi menimbulkan keterlambatan dalam pengambilan keputusan yang berdampak pada daya saing perusahaan dan kemampuan merespons dinamika bisnis secara proaktif.

Kekurangan dari sistem *business intelligence* konvensional ini sebagian besar bersumber dari beberapa faktor kritis. Pertama, keterbatasan akses analitik berbasis percakapan yang menyebabkan pengguna internal tidak dapat memperoleh wawasan terkait indikator bisnis pelanggan seperti pesanan, pencapaian target penjualan, tingkat kepergian pelanggan, serta pendapatan secara cepat dan intuitif. Kedua, ketiadaan fitur prediksi yang mudah diakses oleh pengguna nonteknis sehingga perencanaan kapasitas, evaluasi target, dan penetapan strategi bisnis menjadi kurang responsif terhadap tren dan dinamika masa depan. Ketiga, minimnya integrasi antara aturan kueri berbasis dan pemrosesan bahasa alami dalam sistem BI internal, yang menyebabkan proses pencarian data, penyaringan metrik utama, serta penyusunan laporan kinerja bisnis masih harus dilakukan secara manual dan berulang. Keempat, kurangnya analitik interaktif dan wawasan prediktif waktu nyata melalui antarmuka percakapan yang mudah diakses oleh seluruh pengguna internal.

Kondisi sistem saat ini dapat dijabarkan lebih rinci sebagai berikut.

1. Responsivitas Terbatas

Dasbor statis hanya menampilkan metrik yang telah didefinisikan sebelumnya dan tidak dapat menjawab pertanyaan mendadak atau spesifik dari pengguna bisnis. Pengguna harus menunggu tim teknologi informasi untuk membuat kueri khusus atau laporan baru, yang dapat memakan waktu beberapa jam hingga beberapa hari.

2. Ketergantungan pada Tim Teknis

Setiap permintaan kueri khusus atau analisis berdasarkan kebutuhan khusus harus diproses oleh tim teknologi informasi atau analis data, menciptakan kemacetan dan memperlambat waktu respons. Hal ini menghambat kemampuan organisasi untuk mengambil keputusan secara cepat dan tepat waktu.

3. Kurangnya Kemampuan Prediktif

Prediksi tren kinerja bisnis seperti volume penjualan, tingkat kepergian pelanggan, atau proyeksi pendapatan masih dilakukan secara manual menggunakan lembar sebar atau alat sederhana lainnya, tanpa memanfaatkan model peramalan yang canggih berbasis pembelajaran mesin atau peramalan deret waktu.

4. Akses yang Tidak Fleksibel

Sistem *business intelligence* umumnya hanya dapat diakses melalui komputer pribadi dengan antarmuka khusus yang memerlukan pengetahuan teknis, tidak mendukung akses perangkat genggam atau antarmuka percakapan yang intuitif bagi pengguna nonteknis.

5. Integrasi Data Terbatas

Data berasal dari berbagai sumber seperti sistem manajemen hubungan pelanggan, sistem perencanaan sumber daya perusahaan, dan basis data transaksi, namun belum terintegrasi sepenuhnya dalam satu mesin kueri terpadu dan mudah diakses melalui antarmuka bahasa alami.

6. Ketiadaan Antarmuka Percakapan

Sistem *business intelligence* saat ini tidak menyediakan antarmuka percakapan yang memungkinkan pengguna berinteraksi dengan data menggunakan bahasa wajar sehingga pengguna harus memahami struktur data dan terminologi teknis untuk dapat mengakses informasi yang dibutuhkan.

Permasalahan ini dapat diatasi melalui implementasi sistem *business intelligence* berbasis *chatbot* yang mengintegrasikan teknologi aturan kueri berbasis, pemrosesan bahasa alami, dan algoritma peramalan deret waktu. Pendekatan ini memungkinkan pengguna internal untuk mengajukan pertanyaan dalam bahasa wajar, mendapatkan respons yang cepat dan akurat, serta memperoleh prediksi tren bisnis secara otomatis tanpa memerlukan keahlian teknis khusus.

Pada penelitian ini, penulis memilih untuk mengimplementasikan klasifikasi maksud berbasis pencocokan pola dengan mekanisme nilai keyakinan untuk mengidentifikasi maksud pengguna dari kueri bahasa wajar, pembangkitan bahasa alami berbasis templat untuk menghasilkan respons naratif yang beragam namun tetap aman dan terkontrol, serta model peramalan deret waktu untuk menghasilkan prediksi terhadap indikator bisnis pelanggan seperti volume pesanan, pencapaian target penjualan, tingkat kepergian pelanggan, dan proyeksi pendapatan.

Oleh karena itu, berdasarkan rumusan masalah yang telah dijelaskan pada Bab I, penelitian ini bertujuan untuk merancang dan mengimplementasikan sebuah sistem *business intelligence* berbasis *chatbot* yang mampu memfasilitasi pengguna internal dalam menganalisis dan memprediksi indikator bisnis pelanggan secara interaktif dan waktu nyata. Sistem ini diharapkan dapat mengurangi beban kerja manual, meningkatkan responsivitas pengambilan keputusan, serta memberikan solusi terintegrasi yang siap diterapkan dalam praktik bisnis riil untuk meningkatkan daya saing organisasi di era digital.

III.2 Analisis Kebutuhan

Pada tahap awal pemahaman masalah dan solusi, analisis kebutuhan menjadi langkah dasar untuk memahami fitur dan karakteristik yang harus dimiliki oleh sistem agar dapat berfungsi sesuai tujuan. Dalam konteks tugas akhir ini, sistem dirancang untuk mengotomatisasi proses analisis dan prediksi kinerja bisnis berbasis data pe-

langgan menggunakan teknologi kecerdasan buatan, khususnya pemrosesan bahasa alami, klasifikasi maksud berbasis pola, dan peramalan deret waktu.

Analisis kebutuhan dibagi menjadi tiga kategori utama, yaitu identifikasi masalah pengguna, kebutuhan fungsional, dan kebutuhan nonfungsional. Identifikasi masalah pengguna berfokus pada pemahaman mendalam terhadap tantangan yang dihadapi oleh pengguna internal dalam mengakses dan menganalisis data bisnis. Kebutuhan fungsional berfokus pada fitur utama yang harus dimiliki sistem agar dapat menjalankan fungsinya secara efektif, seperti kemampuan memproses pertanyaan bahasa wajar, mengklasifikasikan maksud, mengeksekusi kueri ke gudang data, menghasilkan respons naratif, serta melakukan peramalan otomatis. Sementara itu, kebutuhan nonfungsional mencakup aspek teknis dan kualitas sistem, seperti keamanan data, performa, skalabilitas, ketersediaan, dan kemudahan penggunaan.

Pemahaman yang mendalam terhadap ketiga aspek kebutuhan ini menjadi fondasi penting dalam proses desain, implementasi, dan evaluasi sistem. Berikut ini adalah analisis kebutuhan yang telah disusun berdasarkan tujuan sistem dan karakteristik pengguna.

III.2.1 Identifikasi Masalah Pengguna

Pengguna dari sistem yang dikembangkan dalam penelitian ini adalah pengguna internal perusahaan, yang meliputi manajer, supervisor, analis bisnis, dan staf operasional yang terlibat dalam pengelolaan dan analisis data kinerja bisnis terkait pelanggan. Pengguna ini berasal dari berbagai departemen seperti penjualan, layanan pelanggan, pemasaran, dan manajemen strategis yang membutuhkan akses cepat terhadap wawasan bisnis untuk mendukung pengambilan keputusan harian maupun strategis.

Saat ini, mayoritas pengguna internal masih mengandalkan sistem *business intelligence* konvensional yang berbasis dasbor visual statis dan pelaporan manual. Pendekatan ini memiliki beberapa keterbatasan signifikan yang menghambat efektivitas pengambilan keputusan:

1. Keterlambatan Respons terhadap Pertanyaan Bisnis

Pengguna sering mengalami keterlambatan dalam memperoleh jawaban atas pertanyaan bisnis yang mendesak. Ketika membutuhkan wawasan spesifik yang tidak tersedia di dasbor yang ada, seperti perbandingan performa penjualan antar segmen pelanggan atau analisis tren kepergian pada periode tertentu, pengguna harus menunggu tim teknologi informasi atau analis data untuk membuat kueri khusus. Waktu tunggu ini dapat berkisar antara beberapa jam

hingga beberapa hari, tergantung pada kompleksitas pertanyaan dan beban kerja tim teknis. Keterlambatan ini mengakibatkan pengambilan keputusan menjadi terhambat dan peluang bisnis yang peka waktu dapat terlewatkan.

2. Kesulitan Mengakses Analisis Berdasarkan Kebutuhan Khusus

Banyak pertanyaan bisnis yang bersifat berdasarkan kebutuhan khusus atau unik tidak dapat dijawab oleh dasbor statis yang telah dikonfigurasi sebelumnya. Pengguna harus menjelaskan kebutuhan analisis mereka secara detail kepada tim teknologi informasi melalui surat elektronik, sistem tiket, atau komunikasi langsung, yang kemudian memerlukan waktu bagi tim teknis untuk memahami persyaratan, membuat kueri yang sesuai, dan menghasilkan laporan. Proses ini tidak efisien, memakan waktu, dan rentan terhadap kesalahpahaman antara pengguna bisnis dan tim teknis yang dapat menyebabkan hasil analisis tidak sesuai dengan kebutuhan.

3. Ketiadaan Kemampuan Prediksi Otomatis

Analisis prediktif untuk tren kinerja bisnis seperti proyeksi volume penjualan, prediksi tingkat kepergian pelanggan, atau estimasi pencapaian target pendapatan masih dilakukan secara manual menggunakan lembar sebar atau alat analisis sederhana. Pengguna harus mengunduh data historis, melakukan perhitungan manual, atau meminta tim ilmu data untuk membuat prediksi khusus. Proses ini tidak dapat diperluas, memakan waktu, dan prediksi yang dihasilkan tidak selalu terkini mengikuti perubahan data terbaru. Ketiadaan prediksi otomatis membuat organisasi kurang siap dalam mengantisipasi tren atau risiko bisnis yang dapat berdampak pada strategi dan alokasi sumber daya.

4. Akses yang Tidak Ramah Pengguna Nonteknis

Dasbor *business intelligence* yang tersedia sering kali dirancang dengan asumsi bahwa pengguna memiliki pengetahuan teknis tentang struktur data, dimensi, metrik, dan terminologi basis data. Pengguna nonteknis, seperti manajer atau staf operasional yang tidak memiliki latar belakang teknis, sering merasa kesulitan dan kewalahan dengan berbagai tapis, daftar tarik, dan opsi yang tersedia. Antarmuka tidak intuitif, tidak mendukung kueri berbasis bahasa wajar, dan memerlukan kurva pembelajaran yang tinggi. Hal ini menyebabkan banyak pengguna potensial tidak memanfaatkan sistem *business intelligence* secara optimal atau bahkan menghindari penggunaannya sama sekali.

5. Fragmentasi Akses Wawasan

Wawasan bisnis yang dibutuhkan untuk pengambilan keputusan tersebar di berbagai sistem, dasbor, laporan, dan alat yang berbeda. Pengguna harus membuka berbagai aplikasi atau modul untuk mendapatkan gambaran leng-

kap tentang kinerja bisnis, kemudian mengintegrasikan data secara manual di lembar sebar atau membuat dokumen analisis mereka sendiri. Fragmentasi ini meningkatkan risiko ketidakkonsistenan data, kesalahan manusia dalam proses konsolidasi, dan redundansi pekerjaan karena pengguna yang berbeda mungkin melakukan analisis yang sama secara terpisah tanpa berbagi hasil.

Tantangan-tantangan ini menghadirkan kebutuhan mendesak untuk mengembangkan sistem *business intelligence* yang lebih responsif, intuitif, dan terintegrasi, dengan kemampuan *chatbot* untuk antarmuka percakapan yang ramah pengguna, klasifikasi maksud yang cerdas untuk pengalihan kueri yang efisien, pembangkitan respons naratif yang beragam dan mudah dipahami, serta peramalan otomatis untuk prediksi kinerja bisnis. Sistem yang diusulkan diharapkan dapat mengatasi keterbatasan tersebut dan memberikan nilai tambah signifikan bagi organisasi dalam meningkatkan kecepatan, akurasi, dan kualitas pengambilan keputusan berbasis data.

III.2.2 Kebutuhan Fungsional

Kebutuhan fungsional menggambarkan fitur-fitur utama yang harus dimiliki oleh sistem *business intelligence* berbasis *chatbot* agar dapat memenuhi tujuan penelitian dan mengatasi masalah pengguna yang telah diidentifikasi. Setiap kebutuhan fungsional dirancang untuk mendukung proses analisis dan prediksi kinerja bisnis secara otomatis, responsif, dan mudah diakses oleh pengguna internal dengan berbagai tingkat keahlian teknis.

Berikut merupakan daftar kebutuhan fungsional yang telah disusun berdasarkan analisis mendalam terhadap proses bisnis, alur interaksi pengguna, dan arsitektur sistem yang diusulkan:

Tabel III.1 Kebutuhan Fungsional Sistem *Chatbot BI*

ID	Nama Kebutuhan	Deskripsi
FR-1	Penerimaan Pertanyaan Bahasa Alami	Tujuan: Memungkinkan pengguna mengajukan pertanyaan atau permintaan analisis dalam Bahasa Indonesia secara wajar melalui antarmuka <i>chatbot</i>. Masukan: Teks pertanyaan dari pengguna dalam bentuk bahasa wajar (contoh: "Berapa total penjualan bulan ini?" atau "Prediksi tingkat kepergian pelanggan 3 bulan ke depan").

Bersambung ke halaman berikutnya

Tabel III.1 – Kebutuhan Fungsional Sistem *Chatbot* BI (lanjutan)

ID	Nama Kebutuhan	Deskripsi
		Keluaran: Pertanyaan tersimpan dan diproses oleh sistem untuk tahap berikutnya.
FR-2	Klasifikasi Maksud dan Pemberian Nilai Keyakinan	Tujuan: Mengidentifikasi maksud utama pengguna dari pertanyaan menggunakan pencocokan pola dan menghitung nilai keyakinan untuk menentukan tingkat kepercayaan sistem. Masukan: Teks pertanyaan hasil pemrosesan awal. Keluaran: Maksud teridentifikasi beserta nilai keyakinan (0-1) dan parameter terkait (entitas, dimensi waktu, metrik).
FR-3	Pengalihan Kueri Berdasarkan Tingkat Keyakinan	Tujuan: Mengarahkan kueri ke modul pemrosesan yang sesuai berdasarkan nilai keyakinan klasifikasi maksud. Masukan: Maksud dan nilai keyakinan. Keluaran: Jika nilai keyakinan ≥ 40 (skala 0–100): kueri diteruskan ke mesin kueri berbasis aturan. Jika nilai keyakinan < 40: sistem memicu permintaan klarifikasi ke pengguna atau menawarkan alternatif <i>intent</i>.
FR-4	Eksekusi Kueri ke Gudang Data	Tujuan: Mengambil data relevan dari gudang data atau mart data internal berdasarkan maksud dan parameter yang telah diidentifikasi. Masukan: Maksud, entitas, dan parameter kueri. Keluaran: Data hasil kueri dalam format terstruktur (JSON, tabel).
FR-5	Penciptaan Respons Naratif Berbasis Templat	Tujuan: Menghasilkan respons dalam bentuk teks naratif yang mudah dipahami menggunakan pembangkitan bahasa alami berbasis templat.

Bersambung ke halaman berikutnya

Tabel III.1 – Kebutuhan Fungsional Sistem *Chatbot* BI (lanjutan)

ID	Nama Kebutuhan	Deskripsi
		Masukan: Data hasil kueri dan konteks percakapan. Keluaran: Teks respons naratif yang beragam dan wajar (contoh: "Penjualan pada bulan Oktober mencapai Rp 5,2 miliar, meningkat 15% dari bulan sebelumnya").
FR-6	Dukungan Penggalian Data dan Analisis Perbandingan	Tujuan: Memungkinkan pengguna melakukan eksplorasi data lebih dalam dari tingkat ringkasan ke tingkat detail, serta membandingkan metrik antar periode, segmen, atau dimensi. Masukan: Permintaan penggalian data atau perbandingan dari pengguna. Keluaran: Data detail atau hasil perbandingan dengan statistik perubahan (delta, persentase, tren).
FR-7	Peramalan Deret Waktu	Tujuan: Menghasilkan prediksi otomatis terhadap indikator kinerja bisnis menggunakan model <i>Time Series Forecasting</i>. Masukan: Data historis dan cakrawala prediksi yang diminta (harian, mingguan, bulanan). Keluaran: Nilai prediksi dan selang kepercayaan.
FR-8	Manajemen Riwayat Percakapan dan Sesi	Tujuan: Menyimpan riwayat percakapan pengguna untuk memudahkan pelacakan dan konteks percakapan yang berkelanjutan. Masukan: Interaksi pengguna dengan sistem. Keluaran: Riwayat percakapan tersimpan dan dapat diakses kembali oleh pengguna.

Bersambung ke halaman berikutnya

Tabel III.1 – Kebutuhan Fungsional Sistem *Chatbot* BI (lanjutan)

ID	Nama Kebutuhan	Deskripsi
FR-9	Autentikasi dan Otorisasi Pengguna	Tujuan: Memastikan hanya pengguna yang berwenang dapat mengakses sistem dan data sesuai dengan peran mereka. Masukan: Kredensial pengguna (nama pengguna, sandi). Keluaran: Akses sistem berdasarkan kendali akses berbasis peran.
FR-10	Mekanisme Pengunduran dan Penanganan Kesalahan	Tujuan: Menangani kueri yang tidak dapat dipahami atau diproses dengan memberikan respons alternatif atau permintaan klarifikasi. Masukan: Kueri dengan nilai keyakinan rendah atau kesalahan pemrosesan. Keluaran: Pesan klarifikasi, saran pertanyaan alternatif, atau eskalasi ke dukungan manusia.

Kebutuhan-kebutuhan fungsional di atas dirancang untuk menciptakan sistem yang komprehensif, responsif, dan mudah digunakan, yang mampu mengotomatisasi sebagian besar tugas analisis dan prediksi bisnis, mengurangi ketergantungan pada tim teknis, serta memberdayakan pengguna internal untuk mengakses wawasan yang mereka butuhkan dengan cepat dan efisien.

III.2.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional menggambarkan karakteristik kualitas sistem yang harus dipenuhi untuk memastikan sistem dapat beroperasi dengan baik, aman, andal, dan memberikan pengalaman pengguna yang optimal. Kebutuhan nonfungsional mencakup aspek-aspek seperti performa, keamanan, ketersediaan, skalabilitas, kemudahan penggunaan, dan pemeliharaan sistem.

Berikut merupakan daftar kebutuhan nonfungsional yang telah disusun untuk sistem *Business Intelligence* berbasis *chatbot*:

Tabel III.2 Kebutuhan Nonfungsional Sistem *Chatbot* BI

ID	Nama Kebutuhan	Deskripsi
NF-1	Keamanan Data dan Privasi	Sistem harus memastikan keamanan data internal perusahaan dengan menerapkan enkripsi data saat dalam perjalanan (TLS/SSL) dan saat penyimpanan. Sistem harus mengimplementasikan kendali akses berbasis peran yang ketat untuk memastikan pengguna hanya dapat mengakses data sesuai dengan peran dan wewenang mereka. Sistem harus mencegah kebocoran data sensitif, suntikan perintah berbahaya, atau akses tidak sah. Pencatatan dan jejak audit untuk semua aktivitas kueri dan akses data harus diimplementasikan untuk kepatuhan dan analisis forensik.
NF-2	Ketersediaan Sistem	Sistem harus memiliki tingkat ketersediaan minimal 99% agar dapat diakses kapan saja oleh pengguna internal. Sistem harus dilengkapi dengan mekanisme redundansi dan pengalihan otomatis untuk memastikan kontinuitas layanan. Jika terjadi kesalahan pada saat eksekusi kueri atau penciptaan respons, sistem harus memiliki mekanisme pengunduran yang elegan dan penanganan kesalahan yang memadai serta memberikan pesan kesalahan yang informatif kepada pengguna.

Bersambung ke halaman berikutnya

Tabel III.2 – Kebutuhan Nonfungsional Sistem *Chatbot* BI (lanjutan)

ID	Nama Kebutuhan	Deskripsi
NF-3	Performa dan Waktu Respons	Sistem harus mampu memberikan waktu respons rata-rata 15 detik untuk 95% dari kueri tipikal. Dalam kueri kompleks yang memerlukan peramalan atau analisis data besar, waktu respons rata-rata adalah 45 detik. Sistem harus dapat memproses minimal 100 kueri per menit pada kondisi beban normal dan hingga 1000 kueri per jam pada kondisi beban puncak tanpa penurunan performa yang signifikan.
NF-4	Skalabilitas	Sistem harus mampu menangani peningkatan jumlah pengguna dan volume data secara horizontal dengan menambahkan server atau simpul tambahan. Infrastruktur harus dirancang dengan arsitektur layanan mikro atau penerapan terkontainer untuk memudahkan penskalaan. Basis data dan mesin kueri harus dioptimalkan untuk menangani volume data yang besar tanpa penurunan performa.
NF-5	Kemudahan Penggunaan	Antarmuka <i>chatbot</i> harus intuitif dan mudah digunakan oleh pengguna nonteknis tanpa memerlukan pelatihan ekstensif. Sistem harus menyediakan panduan kontekstual dan saran pertanyaan untuk membantu pengguna merumuskan kueri. Riwayat percakapan dan manajemen sesi harus didukung untuk memudahkan pengguna melacak interaksi sebelumnya. Mekanisme umpan balik harus tersedia untuk perbaikan berkelanjutan berdasarkan masukan pengguna.

Bersambung ke halaman berikutnya

Tabel III.2 – Kebutuhan Nonfungsional Sistem *Chatbot* BI (lanjutan)

ID	Nama Kebutuhan	Deskripsi
NF-6	Kemudahan Pemeliharaan	Sistem harus mudah dipelihara dengan dokumentasi kode, antarmuka program aplikasi, dan arsitektur yang lengkap dan jelas. Templat, aturan berbasis pola, dan pemetaan maksud harus mudah diperbarui oleh tim tanpa memerlukan penerapan ulang sistem atau waktu henti. Sistem harus dirancang secara modular sehingga mudah untuk menambahkan maksud baru, aturan baru, atau model peramalan baru di masa depan.
NF-7	Kompatibilitas dan Aksesibilitas	Sistem harus dapat diakses dari berbagai platform (<i>web</i> , perangkat genggam, komputer pribadi) dan perangkat (ponsel pintar, tablet, komputer pribadi/laptop) dengan faktor bentuk yang berbeda. Antarmuka harus responsif dan mendukung berbagai ukuran layar. Sistem harus kompatibel dengan peramban umum seperti Chrome, Firefox, Edge, dan Safari, serta mendukung berbagai sistem operasi (Windows, macOS, Linux, iOS, Android).
NF-8	Keandalan	Sistem harus memiliki tingkat keandalan yang tinggi dengan kemampuan menangani kesalahan dan kondisi tidak normal tanpa berhenti. Sistem harus memiliki mekanisme pengulangan otomatis untuk proses yang gagal dan pencatatan komprehensif untuk analisis penyebab akar. Hasil prediksi dan analisis harus konsisten dan dapat direproduksi dengan data masukan yang sama.

Bersambung ke halaman berikutnya

Tabel III.2 – Kebutuhan Nonfungsional Sistem *Chatbot* BI (lanjutan)

ID	Nama Kebutuhan	Deskripsi
NF-9	Integritas Data	Sistem harus memastikan bahwa data yang diambil, diproses, dan disajikan kepada pengguna adalah akurat dan tidak mengalami kerusakan. Hasil ekstraksi dari gudang data tidak boleh rusak, hilang, atau berubah saat disimpan, diproses, atau diekspor. Sistem harus mengimplementasikan validasi data dan penjumlahan cek untuk memastikan integritas data di seluruh saluran pemrosesan.
NF-10	Ekstensibilitas	Sistem harus dirancang dengan arsitektur yang fleksibel dan modular untuk memungkinkan penambahan fitur baru di masa depan, seperti integrasi dengan sistem eksternal (ERP, CRM), penambahan model pembelajaran mesin baru, atau perluasan ke domain bisnis lainnya. Antarmuka program aplikasi yang terdokumentasi dengan baik harus disediakan untuk memfasilitasi integrasi dengan sistem lain.

Kebutuhan nonfungsional ini dirancang untuk memastikan bahwa sistem tidak hanya dapat menjalankan fungsi-fungsi yang diharapkan, tetapi juga memiliki kualitas teknis yang tinggi, aman, andal, dan memberikan pengalaman pengguna yang memuaskan. Pencapaian kebutuhan nonfungsional ini akan dievaluasi melalui pengujian performa, pengujian keamanan, pengujian beban, dan survei kepuasan pengguna pada tahap implementasi dan evaluasi sistem.

III.3 Analisis Pemilihan Solusi

Analisis permasalahan yang dikaji dalam penelitian ini menggunakan pendekatan kesesuaian masalah-solusi, yaitu dengan mencocokkan kebutuhan nyata yang terjadi di lapangan dengan solusi teknologi yang paling tepat guna. Pendekatan ini mempertimbangkan berbagai alternatif solusi yang tersedia, mengevaluasi kelebihan dan kekurangan masing-masing, serta memilih solusi yang paling optimal berdasarkan kriteria yang telah ditetapkan menggunakan metode *Balanced Scorecard*.

Pemilihan solusi yang tepat sangat penting untuk memastikan bahwa sistem yang dikembangkan dapat mengatasi masalah pengguna secara efektif, memberikan nilai tambah yang signifikan bagi organisasi, serta berkelanjutan untuk pengembangan jangka panjang. Analisis ini akan membantu memvalidasi bahwa solusi yang dipilih adalah yang paling sesuai dengan kondisi, kebutuhan, dan tujuan strategis organisasi.

III.3.1 Alternatif Solusi

Dalam rangka meningkatkan efisiensi analisis dan prediksi kinerja bisnis serta mengatasi keterbatasan sistem *business intelligence* konvensional, terdapat beberapa alternatif solusi teknologi yang dapat dipertimbangkan. Setiap alternatif memiliki karakteristik, kelebihan, dan kekurangan yang berbeda, yang perlu dievaluasi secara komprehensif untuk menentukan solusi yang paling optimal.

Berikut adalah empat alternatif solusi utama yang telah diidentifikasi dan dianalisis berdasarkan studi literatur, praktik industri, dan kebutuhan spesifik organisasi, sebagaimana disajikan pada Tabel III.3:

Tabel III.3 Perbandingan Alternatif Solusi Teknologi

No	Nama Solusi	Deskripsi	Kelebihan	Kekurangan
1	<i>Chatbot</i> Berbasis Aturan Sederhana	Menggunakan <i>chatbot</i> dengan pencocokan pola yang sangat kaku, hanya merespons pola kalimat yang telah ditentukan sebelumnya. Sistem hanya dapat menangani kueri terstruktur dengan format tetap, tidak mampu memahami variasi bahasa wajar yang kompleks. Tidak ada model peramalan, hanya pengambilan data dari basis data.	1. Implementasi cepat dan hemat biaya 2. Mudah dipelihara untuk aturan sederhana 3. Tidak memerlukan infrastruktur kompleks 4. Kontrol penuh atas respons sistem	1. Tidak dapat diperluas untuk kebutuhan BI modern 2. Pengguna harus menyesuaikan dengan pola tetap 3. Tidak mampu menjawab kueri kompleks 4. Tidak ada kemampuan prediktif 5. Pengalaman pengguna terbatas

Bersambung ke halaman berikutnya

Tabel III.3 – Perbandingan Alternatif Solusi Teknologi (lanjutan)

No	Nama Solusi	Deskripsi	Kelebihan	Kekurangan
2	<i>Chatbot</i> BI dengan Klasifikasi Maksud Berbasis Pola, Pembangkitan Bahasa Alami Berbasis Templat, dan Peramalan Deret Waktu	Mengimplementasikan sistem BI <i>chatbot</i> yang terintegrasi dengan tiga komponen, yaitu klasifikasi maksud berbasis pola dengan pemberian nilai keyakinan, pembangkitan bahasa alami berbasis templat untuk respons yang beragam namun aman, dan model peramalan deret waktu untuk prediksi otomatis.	1. Mampu menangani variasi bahasa wajar kompleks 2. Respons beragam dan wajar 3. Dukungan peramalan otomatis 4. Adaptif terhadap kebutuhan dinamis 5. Pengalaman pengguna unggul 6. Keamanan terjaga dengan templat 7. Dapat diperluas secara fleksibel	1. Kompleksitas implementasi lebih tinggi 2. Memerlukan usaha awal untuk desain 3. Pemeliharaan butuh keahlian berbagai bidang 4. Biaya infrastruktur lebih tinggi

Bersambung ke halaman berikutnya

Tabel III.3 – Perbandingan Alternatif Solusi Teknologi (lanjutan)

No	Nama Solusi	Deskripsi	Kelebihan	Kekurangan
3	Dasbor BI Interaktif Tradisional dengan Peningkatan	Tetap menggunakan dasbor BI visual yang sudah ada, dengan peningkatan untuk interaktivitas yang lebih baik. Pengguna dapat melakukan penggalian data, penyaringan, dan agregasi melalui kontrol antarmuka pengguna yang lebih intuitif. Menambahkan fitur analitik layanan mandiri dan aplikasi dasbor perangkat genggam.	1. Teknologi matang dan terbukti 2. Dukungan komunitas dan alat kaya 3. Tata kelola data dan keamanan mapan 4. Akrab bagi organisasi dengan alat BI tradisional	1. Tidak mendukung kueri bahasa wajar 2. Tidak ada antarmuka percakapan 3. Dukungan terbatas untuk peramalan 4. Tetap memerlukan keahlian teknis 5. Tidak dapat diperluas untuk bisnis peka waktu

Bersambung ke halaman berikutnya

Tabel III.3 – Perbandingan Alternatif Solusi Teknologi (lanjutan)

No	Nama Solusi	Deskripsi	Kelebihan	Kekurangan
4	Chatbot BI Berbasis Model Bahasa Besar (<i>Large Language Model</i>)	Mengimplementasikan chatbot BI yang memanfaatkan arsitektur Transformer penuh dengan model bahasa besar pra-latih seperti GPT, BERT, atau varian lainnya. Sistem menggunakan pembelajaran mendalam untuk pemahaman bahasa alami yang sangat canggih, mampu menangani kueri kompleks dengan konteks multiturn, dan menghasilkan respons naratif yang sangat wajar. Model dapat disetel-halus (<i>fine-tuned</i>) dengan data domain spesifik untuk meningkatkan akurasi.	1. Pemahaman bahasa alami paling canggih 2. Kemampuan konteks percakapan mendalam 3. Respons sangat wajar dan beragam 4. Dapat menangani kueri sangat kompleks 5. Adaptif terhadap variasi bahasa ekstrem 6. Pembelajaran berkelanjutan dari interaksi	1. Biaya komputasi sangat tinggi 2. Memerlukan infrastruktur GPU berkinerja tinggi 3. Risiko halusinasi dan respons tidak akurat 4. Sulit mengontrol keluaran secara deterministik 5. Potensi kebocoran data sensitif 6. Kompleksitas implementasi sangat tinggi 7. Ketergantungan pada penyedia model eksternal 8. Latensi respons lebih tinggi

Berikut adalah penjelasan empat alternatif solusi utama yang telah diidentifikasi dan dianalisis berdasarkan tabel di atas:

1. Alternatif 1: *Chatbot* Berbasis Aturan Sederhana

Solusi ini mengimplementasikan *chatbot* dengan pendekatan berbasis aturan yang sederhana, menggunakan pencocokan pola berbasis ekspresi reguler atau pencocokan langsung. Sistem hanya dapat merespons pertanyaan dengan format yang telah didefinisikan sebelumnya dan tidak memiliki kemampuan untuk memahami variasi bahasa atau konteks yang kompleks. Fitur yang tersedia terbatas pada pengambilan data sederhana dari basis data tanpa kemampuan analisis lanjutan atau prediksi. Antarmuka juga terbatas dan tidak dioptimasi untuk pengalaman pengguna yang baik pada perangkat genggam.

2. **Alternatif 2: *Chatbot* BI dengan Klasifikasi Maksud Berbasis Pola, Pembangunan Bahasa Alami Berbasis Templat, dan Peramalan Deret Waktu**

Solusi ini merupakan pendekatan komprehensif yang mengintegrasikan tiga komponen teknologi utama. Pertama, klasifikasi maksud berbasis pola dengan mekanisme pemberian nilai keyakinan untuk mengidentifikasi maksud pengguna dari kueri bahasa wajar dengan akurasi tinggi. Kedua, pembangunan bahasa alami berbasis templat untuk menghasilkan respons naratif yang variatif, wajar, dan mudah dipahami sambil menjaga keamanan data internal melalui pembatasan pada templat yang telah diverifikasi. Ketiga, model peramalan deret waktu untuk menghasilkan prediksi otomatis terhadap indikator kinerja bisnis seperti volume penjualan, tingkat kepergian pelanggan, dan proyeksi pendapatan. Sistem ini dirancang dengan arsitektur modular yang dapat diperluas dan diperbesar, mendukung akses berbagai platform (web, perangkat genggam, komputer pribadi), dan menerapkan kontrol keamanan yang ketat.

3. **Alternatif 3: Dasbor BI Interaktif Tradisional dengan Peningkatan**

Solusi ini mempertahankan pendekatan dasbor BI visual yang sudah ada dengan menambahkan peningkatan pada aspek interaktivitas dan kemudahan penggunaan. Fitur penggalan data lebih dalam, penyaringan lanjutan, dan pembuatan laporan khusus ditingkatkan dengan antarmuka yang lebih intuitif. Sistem ini juga dilengkapi dengan aplikasi dasbor perangkat genggam untuk akses data dari perangkat bergerak. Namun, solusi ini tidak menyediakan antarmuka percakapan berbasis bahasa wajar dan kemampuan prediktif yang otomatis.

4. **Alternatif 4: *Chatbot* BI Berbasis Model Bahasa Besar (*Large Language Model*)**

Berbeda dengan ketiga alternatif sebelumnya yang menggunakan pendekatan terstruktur atau semi-terstruktur, alternatif keempat ini memanfaatkan paradigma pembelajaran mesin yang sepenuhnya berbasis data dengan arsitektur

jaringan saraf tiruan yang sangat mendalam. Solusi ini mengimplementasikan *chatbot* BI yang memanfaatkan arsitektur *Transformer* penuh dengan model bahasa besar pra-latih seperti GPT, BERT, T5, atau varian lainnya. Sistem menggunakan pembelajaran mendalam untuk pemahaman bahasa alami yang sangat canggih, mampu menangani kueri kompleks dengan konteks percakapan multiturn, dan menghasilkan respons naratif yang sangat wajar menyerupai komunikasi manusia. Model dapat disetel-halus (*fine-tuned*) dengan data domain spesifik organisasi untuk meningkatkan akurasi dan relevansi respons terhadap konteks bisnis. Sistem ini memanfaatkan kemampuan pemodelan bahasa yang telah dilatih pada korpus teks masif untuk memahami nuansa, konteks implisit, dan melakukan inferensi kompleks dari pertanyaan pengguna. Namun, solusi ini memerlukan infrastruktur komputasi dengan GPU berkinerja tinggi untuk inferensi cepat, menimbulkan tantangan dalam hal kontrol deterministik terhadap keluaran, dan menghadapi risiko halusinasi dengan model dapat menghasilkan respons yang terdengar meyakinkan tetapi faktanya tidak akurat atau tidak berdasar pada data nyata. Implementasi juga memerlukan pertimbangan ketat terhadap keamanan data untuk mencegah kebocoran informasi sensitif melalui model, serta strategi mitigasi risiko untuk memastikan keandalan respons dalam konteks pengambilan keputusan bisnis kritis.

III.3.2 Analisis Penentuan Solusi

Dalam menentukan solusi terbaik untuk meningkatkan sistem *Business Intelligence* dan mengatasi masalah yang telah diidentifikasi, digunakan kerangka evaluasi *Balanced Scorecard* (BSC) untuk membandingkan setiap alternatif secara sistematis. Metode ini menilai masing-masing solusi dari empat perspektif yang saling melengkapi, yaitu *Financial*, *Customer*, *Internal Business Process*, dan *Learning and Growth* sehingga evaluasi tidak hanya berfokus pada biaya dan investasi awal, tetapi juga pada dampak terhadap kepuasan pengguna, kelancaran proses operasional, serta penguatan kapabilitas analitik dan pembelajaran organisasi. Pendekatan ini membantu memastikan bahwa solusi yang dipilih benar-benar sejalan dengan tujuan jangka panjang dan arah pengembangan sistem *Business Intelligence* di perusahaan.

Berikut adalah analisis mendalam untuk setiap solusi berdasarkan keempat perspektif *Balanced Scorecard*:

III.3.2.1 Solusi 1: *Chatbot* Berbasis Aturan Sederhana

Tabel III.4 menyajikan hasil analisis untuk alternatif Solusi 1 berdasarkan empat perspektif *Balanced Scorecard*. Pendekatan ini mengandalkan pencocokan pola statis tanpa kemampuan pemahaman konteks yang dinamis.

Tabel III.4 Analisis *Balanced Scorecard* untuk Aturan Sederhana

Perspektif	Penilaian
<i>Financial</i>	Solusi ini memerlukan investasi awal yang rendah hingga sedang karena tidak membutuhkan infrastruktur komputasi yang kompleks atau model pembelajaran mesin yang canggih. Biaya operasional juga relatif rendah karena sistem dapat dijalankan pada pelanggan sederhana. Namun, pengembalian investasi jangka panjang rendah karena sistem tidak dapat diperluas dan akan memerlukan perancangan ulang besar ketika kebutuhan bisnis berkembang. Penghematan dari otomatisasi terbatas karena sistem hanya dapat menangani kueri yang sangat terstruktur dan sederhana sehingga sebagian besar pekerjaan analisis masih memerlukan intervensi manual. Biaya peluang tinggi karena organisasi kehilangan peluang untuk mengoptimalkan pengambilan keputusan berbasis data secara cepat dan responsif.
<i>Customer</i> (Pengguna)	Solusi ini menawarkan pengalaman pengguna yang cukup terbatas. Pengguna harus menyesuaikan diri dengan format kueri yang kaku dan tidak fleksibel, yang tidak sesuai dengan cara berpikir dan berkomunikasi wajar mereka. Sistem tidak dapat memahami variasi pertanyaan atau konteks yang kompleks sehingga sering kali pengguna harus mencoba beberapa kali dengan perumusan yang berbeda untuk mendapatkan hasil yang diinginkan. Hal ini menyebabkan frustrasi dan menurunkan tingkat kepuasan pengguna. Tingkat adopsi sistem cenderung rendah karena pengguna merasa sistem tidak memberikan nilai tambah yang signifikan dibandingkan dengan metode yang sudah ada.

Bersambung ke halaman berikutnya

Tabel III.4 – Analisis *Balanced Scorecard* untuk Aturan Sederhana (lanjutan)

Perspektif	Penilaian
<i>Internal Business Process</i>	Dari perspektif proses bisnis , solusi ini hanya menawarkan otomasi minimal untuk kueri yang sangat terstruktur dan berulang. Proses analisis manual masih tetap diperlukan untuk sebagian besar pertanyaan bisnis yang bersifat khusus atau kompleks sehingga hambatan dalam alur analisis data tidak teratasi secara efektif. Waktu penyelesaian untuk mendapatkan wawasan bisnis tidak berkurang secara signifikan. Sistem juga tidak mendukung analisis lanjutan seperti penggalian data lebih dalam, perbandingan multidimensi, atau deteksi anomali sehingga kemampuan organisasi untuk melakukan analisis mendalam tetap terbatas.
<i>Learning and Growth</i>	Solusi ini memberikan kesempatan yang sangat terbatas untuk pembelajaran dan pertumbuhan organisasi. Teknologi yang digunakan relatif sederhana dan tidak mendorong tim untuk mengembangkan keahlian baru dalam bidang kecerdasan buatan, pembelajaran mesin, atau analitik lanjutan. Organisasi tidak memperoleh keunggulan kompetitif teknologi dan tidak membangun kapabilitas yang dapat menjadi pembeda di pasar. Sistem juga tidak menyediakan landasan untuk inovasi masa depan atau integrasi dengan teknologi yang lebih canggih.

III.3.2.2 Solusi 2: *Chatbot* BI dengan Klasifikasi Maksud Berbasis Pola, Pembangunan Bahasa Alami Berbasis Templat, dan Peramalan Deret Waktu

Tabel III.5 memaparkan evaluasi untuk Solusi 2 yang mengombinasikan kecerdasan buatan, pemrosesan bahasa alami, dan model prediktif. Solusi ini menjadi alternatif komprehensif dalam menjawab kebutuhan analitik otomatis.

Tabel III.5 Analisis *Balanced Scorecard* untuk BI Komprehensif

Perspektif	Penilaian
<i>Financial</i>	Solusi ini memerlukan investasi awal yang lebih tinggi, mencakup biaya untuk pengembangan sistem yang kompleks, pengadaan infrastruktur komputasi yang memadai (termasuk kemungkinan GPU untuk model peramalan), dan pelatihan model kecerdasan buatan. Namun, pengembalian investasi jangka panjang sangat tinggi karena sistem memberikan nilai tambah yang signifikan melalui beberapa jalur, yaitu pengurangan dramatis dalam waktu analisis dari jam atau hari menjadi detik yang memungkinkan pengambilan keputusan lebih cepat dan responsif, penghematan biaya tenaga kerja karena analis dan tim TI tidak perlu menghabiskan waktu untuk kueri rutin dan dapat fokus pada tugas-tugas yang lebih strategis, peningkatan kualitas keputusan bisnis berdasarkan wawasan prediktif yang akurat, yang dapat menghasilkan peningkatan pendapatan atau penghematan biaya yang signifikan, dan skalabilitas yang baik dengan biaya tambahan untuk menambahkan pengguna atau kueri baru relatif rendah setelah sistem terbangun. Sistem ini juga memberikan keunggulan kompetitif yang dapat berdampak pada posisi pasar dan profitabilitas jangka panjang organisasi.

Bersambung ke halaman berikutnya

Tabel III.5 – Analisis *Balanced Scorecard* untuk BI Komprehensif (lanjutan)

Perspektif	Penilaian
<i>Customer</i> (Pengguna)	Solusi ini menawarkan pengalaman pengguna yang sangat unggul. Antarmuka percakapan yang wajar dan akrab memungkinkan pengguna untuk mengajukan pertanyaan dengan cara yang sama seperti mereka berbicara dengan rekan manusia, tanpa perlu mempelajari tata bahasa khusus atau terminologi teknis. Sistem dapat memahami berbagai variasi pertanyaan dan konteks sehingga mengurangi frustrasi pengguna. Respons yang dihasilkan bersifat naratif, beragam, dan mudah dipahami, bukan hanya tabel angka yang kering. Kemampuan prediktif otomatis memberikan nilai tambah yang signifikan bagi pengguna, memungkinkan mereka untuk mengantisipasi tren dan membuat keputusan proaktif. Aksesibilitas berbagai platform (web, perangkat genggam, komputer pribadi) memastikan pengguna dapat mengakses wawasan setiap membutuhkannya. Tingkat kepuasan dan adopsi pengguna diperkirakan sangat tinggi karena sistem memberikan nilai nyata dan mudah digunakan.

Bersambung ke halaman berikutnya

Tabel III.5 – Analisis *Balanced Scorecard* untuk BI Komprehensif (lanjutan)

Perspektif	Penilaian
<i>Internal Business Process</i>	Dari perspektif proses bisnis, solusi ini menawarkan transformasi yang fundamental. Otomasi maksimal untuk hampir semua jenis kueri analitik, dari yang sederhana hingga yang kompleks, menghilangkan hambatan yang selama ini menghalangi alur analisis data. Proses bisnis dapat menjadi lebih lincah dan responsif terhadap perubahan kondisi pasar atau internal. Waktu penyelesaian untuk mendapatkan wawasan berkurang drastis, memungkinkan organisasi untuk mengidentifikasi masalah, peluang, atau tren lebih cepat dan mengambil tindakan yang tepat. Kemampuan peramalan otomatis mendukung perencanaan yang lebih akurat untuk alokasi sumber daya, penetapan target, dan strategi bisnis. Sistem juga memfasilitasi budaya berbasis data dengan keputusan dibuat berdasarkan wawasan objektif bukan hanya intuisi.

Bersambung ke halaman berikutnya

Tabel III.5 – Analisis *Balanced Scorecard* untuk BI Komprehensif (lanjutan)

Perspektif	Penilaian
<i>Learning and Growth</i>	Solusi ini memberikan kesempatan tertinggi untuk pembelajaran dan pertumbuhan organisasi. Implementasi teknologi kecerdasan buatan seperti pemrosesan bahasa alami, klasifikasi maksud berbasis pola, pembangkitan bahasa alami berbasis templat, dan peramalan deret waktu memungkinkan tim untuk mengembangkan keahlian baru yang sangat relevan di era digital. Organisasi membangun kapabilitas internal dalam bidang kecerdasan buatan dan pembelajaran mesin yang dapat menjadi fondasi untuk inovasi-inovasi masa depan, seperti ekspansi ke domain lain (<i>chatbot</i> layanan pelanggan, sistem rekomendasi, deteksi penipuan). Sistem menciptakan keunggulan kompetitif teknologi yang membedakan organisasi dari kompetitor. Platform yang dibangun bersifat dapat diperluas dan dapat menjadi basis untuk pengembangan solusi analitik yang lebih canggih di masa depan. Budaya inovasi dan adopsi teknologi terdorong, memposisikan organisasi sebagai pemimpin dalam transformasi digital di industrinya.

III.3.2.3 Solusi 3: Dasbor BI Interaktif Tradisional dengan Peningkatan

Tabel III.6 menunjukkan penilaian *Balanced Scorecard* untuk Solusi 3, yaitu peningkatan visual dan interaktivitas pada dasbor yang sudah ada. Pendekatan ini mempertahankan paradigma konvensional dalam penyajian wawasan bisnis.

Tabel III.6 Analisis *Balanced Scorecard* untuk BI Tradisional

Perspektif	Penilaian
<i>Financial</i>	Solusi ini memerlukan investasi yang sedang, terutama untuk meningkatkan antarmuka pengguna dan menambahkan fitur interaktivitas pada dasbor yang sudah ada. Biaya lisensi untuk alat BI komersial dapat cukup signifikan, terutama jika organisasi menggunakan platform seperti Tableau, Power BI, atau Qlik. Pengembalian investasi berada di tingkat menengah karena peningkatan efisiensi terbatas pada perbaikan antarmuka pengguna dan kemudahan akses, tanpa transformasi fundamental dalam cara pengguna berinteraksi dengan data. Penghematan biaya tenaga kerja terbatas karena pengguna masih memerlukan keahlian teknis untuk memanfaatkan fitur analitik layanan mandiri secara efektif. Tidak ada kemampuan prediktif otomatis yang dapat memberikan nilai tambah signifikan untuk perencanaan strategis.
<i>Customer</i> (Pengguna)	Solusi ini membuat pengalaman pengguna mengalami peningkatan dibandingkan dengan sistem lama, terutama dalam hal tampilan data dan kemudahan navigasi. Dasbor yang lebih interaktif dengan fitur penggalan data lebih dalam dan penyaringan lanjutan memberikan fleksibilitas lebih besar bagi pengguna untuk mengeksplorasi data. Aplikasi perangkat genggam memungkinkan akses data dari perangkat bergerak, meningkatkan kemudahan akses. Namun, solusi ini masih tidak mendukung kueri bahasa wajar atau antarmuka percakapan sehingga pengguna nonteknis tetap menghadapi kurva pembelajaran yang cukup tinggi. Sistem tidak dapat menjawab pertanyaan khusus yang kompleks tanpa konfigurasi tambahan dari tim TI. Kepuasan pengguna berada di tingkat menengah karena peningkatan yang diberikan bersifat bertahap, bukan transformatif.

Bersambung ke halaman berikutnya

Tabel III.6 – Analisis *Balanced Scorecard* untuk BI Tradisional (lanjutan)

Perspektif	Penilaian
<i>Internal Business Process</i>	Dari perspektif proses bisnis, solusi ini memberikan peningkatan yang sedang hingga tinggi dalam efisiensi operasional. Pengguna yang memiliki keahlian teknis dapat melakukan analisis sendiri tanpa selalu bergantung pada tim TI, mengurangi beban kerja analis. Fitur analitik layanan mandiri memungkinkan eksplorasi data yang lebih fleksibel untuk pengguna yang terlatih. Namun, untuk pengguna nonteknis atau pertanyaan yang sangat spesifik dan kompleks, sistem masih memerlukan intervensi manual dari tim analitik. Tidak ada dukungan untuk analisis prediktif otomatis sehingga organisasi tidak dapat memanfaatkan kemampuan peramalan untuk perencanaan strategis yang lebih baik. Proses tetap tidak dapat diperluas untuk kebutuhan bisnis yang sangat dinamis dan peka waktu.
<i>Learning and Growth</i>	Solusi ini memberikan kesempatan sedang untuk pembelajaran dan pertumbuhan. Organisasi dapat meningkatkan literasi data tim melalui pelatihan penggunaan alat BI dan fitur analitik layanan mandiri. Penguasaan alat BI populer seperti Tableau atau Power BI dapat menjadi keahlian yang berharga bagi karyawan. Namun, solusi ini tidak mendorong inovasi teknologi yang signifikan atau pengembangan kapabilitas dalam bidang kecerdasan buatan dan pembelajaran mesin. Organisasi tidak membangun pembeda teknologi yang kuat dan tetap bergantung pada vendor eksternal untuk sebagian besar fitur dan inovasi. Platform ini juga terbatas dalam hal kemampuan perluasan untuk pengembangan solusi khusus atau integrasi dengan teknologi yang lebih canggih di masa depan.

III.3.2.4 Solusi 4: Chatbot BI Berbasis Model Bahasa Besar (*Large Language Model*)

Tabel III.7 merangkum analisis untuk Solusi 4 yang sepenuhnya mengandalkan model bahasa besar pra-latih. Pendekatan ini menawarkan kewajaran bahasa yang sangat tinggi namun membawa tantangan dalam hal determinisme dan infrastruktur.

Tabel III.7 Analisis *Balanced Scorecard* untuk LLM

Perspektif	Penilaian
<i>Financial</i>	Solusi ini memerlukan investasi awal yang sangat tinggi, mencakup biaya lisensi atau akses API untuk model bahasa besar komersial (seperti GPT-4 atau Claude), pengadaan infrastruktur komputasi dengan GPU berkinerja tinggi untuk inferensi cepat, dan biaya pengembangan untuk integrasi sistem yang kompleks. Biaya operasional juga sangat signifikan karena setiap kueri memerlukan sumber daya komputasi yang besar, terutama untuk model dengan miliaran parameter. Dalam model berbasis API, biaya per token dapat terakumulasi dengan cepat pada skala organisasi besar. Pengembalian investasi berada pada tingkat sedang hingga tinggi dalam jangka panjang, bergantung pada seberapa baik organisasi dapat mengelola risiko halusinasi dan memastikan akurasi respons. Nilai tambah utama berasal dari kemampuan pemahaman bahasa yang sangat canggih dan fleksibilitas dalam menangani kueri kompleks yang tidak terstruktur. Namun, ketidakpastian dalam kontrol keluaran dan risiko kesalahan dapat membatasi pengembalian investasi jika tidak dikelola dengan baik. Biaya peluang juga perlu dipertimbangkan jika organisasi mengalami insiden kebocoran data atau respons yang tidak akurat yang berdampak pada keputusan bisnis.

Bersambung ke halaman berikutnya

Tabel III.7 – Analisis *Balanced Scorecard* untuk LLM (lanjutan)

Perspektif	Penilaian
<i>Customer</i> (Pengguna)	Solusi ini menawarkan pengalaman pengguna yang sangat unggul dalam hal kewajaran interaksi dan fleksibilitas komunikasi. Pengguna dapat mengajukan pertanyaan dengan cara yang sangat wajar, termasuk kueri yang kompleks, ambigu, atau memerlukan pemahaman konteks mendalam yang sulit ditangani sistem konvensional. Model bahasa besar dapat memahami nuansa, konteks percakapan multiturn, dan bahkan inferensi implisit dari pertanyaan pengguna. Respons yang dihasilkan sangat naratif, koheren, dan menyerupai komunikasi manusia, yang meningkatkan kepuasan pengguna secara signifikan. Namun, terdapat risiko bahwa sistem dapat menghasilkan respons yang terdengar meyakinkan tetapi faktanya tidak akurat (halusinasi), yang dapat menyesatkan pengguna dan menurunkan kepercayaan terhadap sistem. Pengguna nonteknis mungkin tidak dapat membedakan respons yang akurat dari yang dihasilkan secara spekulatif. Dalam mempertahankan kepuasan tinggi, sistem memerlukan mekanisme validasi dan verifikasi yang ketat, serta transparansi mengenai tingkat keyakinan respons.

Bersambung ke halaman berikutnya

Tabel III.7 – Analisis *Balanced Scorecard* untuk LLM (lanjutan)

Perspektif	Penilaian
<i>Internal Business Process</i>	Dari perspektif proses bisnis, solusi ini memberikan fleksibilitas tertinggi dalam menangani berbagai jenis kueri analitik, termasuk yang sangat kompleks, tidak terstruktur, atau belum pernah ditemui sebelumnya. Kemampuan model untuk memahami konteks yang dalam dan melakukan inferensi dapat mengurangi kebutuhan untuk konfigurasi manual atau pemrograman khusus untuk kasus penggunaan baru. Sistem dapat beradaptasi dengan perubahan kebutuhan bisnis dengan lebih organik. Namun, ketidakdeterministikan keluaran model bahasa besar menimbulkan tantangan dalam proses bisnis yang memerlukan konsistensi dan akurasi tinggi. Risiko halusinasi dapat menyebabkan keputusan bisnis yang salah jika tidak ada mekanisme validasi yang memadai. Latensi respons yang lebih tinggi dibandingkan solusi berbasis pola juga dapat menjadi hambatan untuk proses bisnis yang sangat sensitif terhadap waktu. Integrasi dengan sistem keamanan dan tata kelola data memerlukan perhatian khusus untuk memastikan bahwa model tidak secara tidak sengaja mengekspos informasi sensitif atau melanggar kebijakan privasi.

Bersambung ke halaman berikutnya

Tabel III.7 – Analisis *Balanced Scorecard* untuk LLM (lanjutan)

Perspektif	Penilaian
<i>Learning and Growth</i>	Solusi ini memberikan kesempatan sangat tinggi untuk pembelajaran dan pertumbuhan organisasi dalam bidang teknologi modern. Implementasi model bahasa besar memungkinkan tim untuk mengembangkan keahlian dalam pembelajaran mendalam, arsitektur Transformer, penyetelan-halus model, dan teknik prompt engineering yang merupakan kompetensi sangat relevan di era kecerdasan buatan generatif. Organisasi dapat memposisikan diri sebagai pelopor dalam adopsi teknologi kecerdasan buatan paling canggih. Namun, ketergantungan pada model dan infrastruktur dari penyedia eksternal (seperti OpenAI atau Anthropic) dapat membatasi kontrol organisasi terhadap teknologi inti dan menimbulkan risiko vendor <i>lock-in</i> . Jika menggunakan model sumber terbuka, organisasi memerlukan investasi signifikan dalam keahlian spesialisasi untuk pelatihan, penyetelan, dan pemeliharaan model. Platform ini membuka peluang untuk inovasi masa depan seperti asisten virtual multidomain, sistem rekomendasi kontekstual, atau analitik prediktif yang sangat canggih, tetapi memerlukan komitmen jangka panjang dalam pengembangan kapabilitas dan manajemen risiko.

III.3.2.5 Matriks Perbandingan *Balanced Scorecard*

Dalam memberikan gambaran yang lebih komprehensif, Tabel III.8 menyajikan matriks perbandingan keempat solusi berdasarkan keempat perspektif *Balanced Scorecard*, beserta karakteristik pengguna yang paling sesuai untuk masing-masing solusi:

Tabel III.8 Perbandingan *Balanced Scorecard* Alternatif Solusi

Solusi	<i>Financial</i>	<i>Customer</i>	<i>Process</i>	<i>L&G</i>	Digunakan oleh
<i>Chatbot</i> Berbasis Aturan Sederhana	Rendah- Sedang	Rendah- Sedang	Rendah	Rendah	Organisasi kecil dengan kebu- tuhan analitik sangat terbatas dan kueri yang sangat terstruktur
<i>Chatbot</i> BI dengan Klasifikasi Maksud, Pembang- kitan Bahasa Alami, dan Peramal- an Deret Waktu	Sedang- Tinggi (ROI Tinggi)	Sangat Tinggi	Sangat Tinggi	Sangat Tinggi	Organisasi me- nengah hingga besar dengan volume data tinggi, kebutuhan analitik kom- pleks, dan fokus pada transformasi digital berbasis AI
Dasbor BI Interaktif Tradisional dengan Pe- ningkatan	Sedang	Sedang	Sedang- Tinggi	Sedang	Organisasi yang sudah memiliki investasi besar dalam alat BI tra- disional dan ingin peningkatan bertahap

Bersambung ke halaman berikutnya

Tabel III.8 – Perbandingan *Balanced Scorecard* Alternatif Solusi (lanjutan)

Solusi	<i>Financial</i>	<i>Customer</i>	<i>Process</i>	<i>L&G</i>	Digunakan oleh
Chatbot BI Berbasis Model Bahasa Besar (LLM)	Sedang-Tinggi (Biaya Tinggi)	Sangat Tinggi (dengan Risiko)	Tinggi (dengan Tantangan)	Sangat Tinggi	Organisasi besar dengan anggaran signifikan, infrastruktur AI matang, kebutuhan pemahaman bahasa sangat kompleks, dan kapabilitas manajemen risiko AI yang kuat

III.3.2.6 Kesimpulan Pemilihan Solusi

Berdasarkan analisis komprehensif menggunakan metode *Balanced Scorecard* pada keempat perspektif (*Financial*, *Customer*, *Internal Business Process*, dan *Learning and Growth*), **Solusi 2: Chatbot BI dengan Klasifikasi Maksud Berbasis Pola, Pembangkitan Bahasa Alami Berbasis Templat, dan Peramalan Deret Waktu** adalah solusi yang paling optimal dan direkomendasikan untuk diimplementasikan.

Perlu dicatat bahwa Solusi 4 (Chatbot BI Berbasis Model Bahasa Besar) menawarkan kemampuan pemahaman bahasa alami yang paling canggih dan pengalaman pengguna yang sangat unggul. Namun, solusi ini memiliki beberapa kelemahan kritis yang membuatnya kurang optimal untuk konteks penelitian ini, yaitu biaya implementasi dan operasional yang sangat tinggi yang dapat tidak proporsional dengan kebutuhan organisasi menengah, risiko halusinasi dan respons tidak akurat yang dapat berdampak serius pada keputusan bisnis berbasis data, dan kesulitan dalam mengontrol keluaran secara deterministik yang penting untuk sistem BI dengan keperluan konsistensi dan akurabilitas, potensi kebocoran data sensitif melalui model yang tidak sepenuhnya dikontrol organisasi, dan ketergantungan pada penyedia model eksternal yang menimbulkan risiko keberlanjutan jangka panjang. Meskipun teknologi ini sangat menjanjikan untuk masa depan, untuk implementasi praktis dalam konteks organisasi yang memerlukan keseimbangan antara inovasi dan stabilitas, Solusi 2 tetap menjadi pilihan yang paling optimal.

Berikut alasan utama pemilihan Solusi 2 adalah sebagai berikut.

1. Keselarasan dengan Kebutuhan

Solusi 2 secara langsung mengatasi semua masalah pengguna yang telah diidentifikasi, termasuk keterlambatan respons, kesulitan akses analisis khusus, ketiadaan kemampuan prediksi otomatis, dan akses yang tidak ramah pengguna nonteknis. Solusi ini memenuhi seluruh kebutuhan fungsional dan non-fungsional yang telah disusun secara komprehensif.

2. Skalabilitas dan Adaptabilitas

Sistem yang diusulkan dirancang dengan arsitektur modular dan dapat diperluas yang dapat diadaptasi terhadap perubahan kebutuhan bisnis di masa depan tanpa memerlukan perancangan ulang besar. Kemampuan untuk menambahkan maksud baru, aturan baru, atau model peramalan baru secara mudah memberikan fleksibilitas jangka panjang.

3. Tahan Masa Depan dan Platform untuk Inovasi

Platform yang dibangun membuka pintu untuk inovasi-inovasi masa depan seperti ekspansi ke domain lain (*chatbot* layanan pelanggan, sistem rekomendasi, deteksi penipuan), integrasi dengan sistem eksternal (ERP, CRM), atau pengembangan kemampuan analitik lanjutan lainnya. Investasi dalam platform ini tidak hanya memberikan nilai untuk kebutuhan saat ini, tetapi juga menjadi fondasi untuk transformasi digital organisasi secara keseluruhan.

4. Pengembalian Investasi dan Justifikasi Finansial

Meskipun investasi awal lebih tinggi dibandingkan alternatif lain, pengembalian investasi jangka panjang sangat menarik karena penghematan biaya tenaga kerja yang signifikan (analisis dapat fokus pada tugas strategis), pengambilan keputusan yang lebih cepat dan akurat (yang dapat berdampak langsung pada pendapatan atau penghematan biaya), dan peningkatan daya saing organisasi. Berdasarkan studi dari berbagai industri, implementasi sistem analitik prediktif berbasis kecerdasan buatan dapat meningkatkan efisiensi operasional hingga 30% dan mempercepat pengambilan keputusan hingga 85% (Shah, 2025).

5. Keunggulan Kompetitif dan Diferensiasi

Implementasi *chatbot* BI canggih dengan kemampuan kecerdasan buatan dan pembelajaran mesin memberikan keunggulan kompetitif bagi organisasi, meningkatkan kelincahan dan kecepatan pengambilan keputusan dibandingkan kompetitor yang masih menggunakan sistem konvensional. Organisasi yang mampu menganalisis data dan merespons tren pasar lebih cepat memiliki posisi yang lebih kuat dalam persaingan bisnis.

6. Adopsi Pengguna dan Kepuasan

Antarmuka percakapan berbasis bahasa wajar memiliki tingkat adopsi yang jauh lebih tinggi dibandingkan dasbor tradisional karena lebih intuitif dan tidak memerlukan pelatihan ekstensif. Penelitian menunjukkan bahwa *chatbot* berbasis AI mampu menangani sebagian besar pertanyaan rutin secara otomatis, yang secara signifikan mengurangi beban kerja tim dan meningkatkan kepuasan pengguna (Adam, Wessel, dan Benlian 2021).

7. Keamanan dan Kontrol Data

Pendekatan pembangkitan bahasa alami berbasis templat memberikan kontrol penuh atas respons yang dihasilkan sistem, memastikan bahwa tidak ada kebocoran data sensitif atau informasi yang tidak seharusnya diungkapkan. Hal ini sangat penting untuk sistem yang beroperasi dengan data internal perusahaan yang bersifat rahasia.

8. Pembelajaran dan Pertumbuhan Organisasi

Implementasi solusi ini memungkinkan organisasi untuk membangun kapabilitas internal dalam bidang kecerdasan buatan, pembelajaran mesin, dan analitik lanjutan, yang merupakan keahlian kritis di era digital. Tim akan mengembangkan pengetahuan dan pengalaman yang berharga yang dapat diterapkan pada proyek-proyek inovasi lainnya di masa depan.

Dengan pemilihan Solusi 2, organisasi akan dapat mencapai transformasi digital yang signifikan dalam domain *Business Intelligence* dan analitik, meningkatkan efisiensi operasional, kecepatan pengambilan keputusan, dan memposisikan diri sebagai pemimpin dalam pemanfaatan teknologi kecerdasan buatan untuk keunggulan kompetitif di pasar yang semakin berbasis data.

Solusi yang dipilih juga sejalan dengan tren global dengan pasar kecerdasan buatan percakapan diproyeksikan mencapai USD 49,7 miliar pada tahun 2025 (Qaltivate, 2025), pasar pemrosesan bahasa alami tumbuh dengan CAGR 28,6% mencapai USD 438,08 miliar pada tahun 2034 (Precedence Research, 2025), dan pasar peramalan deret waktu diperkirakan mencapai USD 36,9 miliar pada tahun 2032 (WiseGuy Reports, 2024). Pertumbuhan pasar yang eksponensial ini menunjukkan bahwa investasi dalam teknologi-teknologi ini bukan hanya relevan untuk saat ini, tetapi juga strategis untuk jangka panjang.

III.4 Pemahaman dan Analisis Data (*Data Understanding*)

Tahap pemahaman data (*data understanding*) merupakan fase kedua dalam metodologi CRISP-DM yang bertujuan untuk mengumpulkan data awal, mengidentifikasi karakteristik data, mendeteksi permasalahan kualitas data, serta menemukan wawasan awal yang dapat membentuk hipotesis terhadap informasi tersembunyi dalam

data. Pada konteks pengembangan sistem *Business Intelligence* berbasis *chatbot*, tahap ini berfokus pada eksplorasi komprehensif terhadap lima domain data utama yang tersimpan dalam skema DWH_MOIS pada *Enterprise Data Warehouse*.

III.4.1 Sumber Data dan Arsitektur Penyimpanan

Sistem peramalan dan analisis performa berbasis *chatbot* terhubung secara langsung dengan sumber data utama berupa *Enterprise Data Warehouse* (EDW) yang menggunakan basis data Oracle pada server dengan skema DWH_MOIS. Koneksi yang diatur menggunakan metode *connection pooling* serta *parameter binding* untuk menjamin efisiensi dan keamanan saat eksekusi kueri. Skema DWH_MOIS berisi lima tabel domain utama dengan prefiks BRIGHTAI_ yang masing-masing memiliki fokus bisnis dan struktur data berbeda.

III.4.1.1 Asal-USul Data dan Izin Pemakaian

Seluruh data yang digunakan dalam penelitian ini merupakan data operasional internal perusahaan yang tersimpan pada *Enterprise Data Warehouse* milik PT Telkom Indonesia (Persero) Tbk, khususnya pada skema DWH_MOIS. Akses terhadap data diperoleh melalui mekanisme resmi kerja praktik yang diselenggarakan di Divisi *Digital Business and Technology* pada periode kerja praktik penulis. Penggunaan data untuk keperluan penelitian dan pengembangan prototipe sistem telah mendapat persetujuan dari pembimbing lapangan selaku perwakilan pihak perusahaan.


Data yang diproses oleh sistem bersifat agregat dan tidak mengandung informasi identitas pribadi pelanggan secara langsung. Atribut pelanggan seperti NCLI, ND, dan NOTEL yang terdapat dalam tabel sumber digunakan semata-mata sebagai kunci penghitungan agregasi (misalnya COUNT(DISTINCT NCLI) untuk menghitung jumlah pelanggan unik) dan tidak ditampilkan maupun disimpan dalam keluaran sistem. Seluruh respons *chatbot* dan hasil peramalan disajikan dalam bentuk metrik agregat pada level wilayah (regional, witel) dan periode waktu (bulanan) sehingga tidak memungkinkan identifikasi pelanggan individual. Sistem juga dirancang dengan akses baca saja (*read-only*) terhadap basis data, tanpa kemampuan untuk mengubah, menghapus, atau mengeksport data mentah dari *data warehouse*.

Kelima kategori strategi bisnis utama yang tercermin dalam 38 aturan tersebut secara komprehensif menggambarkan berbagai aspek analisis yang mendukung pengambilan keputusan berbasis data (lihat rekapitulasi pada Gambar III.1). Kategori pertama, yaitu *Churn Analysis*, terdiri dari enam aturan yang secara khusus menganalisis pola perpindahan pelanggan, tingkat retensi di tingkat regional, serta strategi mitigasi *churn* yang efektif untuk mempertahankan pelanggan dan mengurangi potensi ke-

Tabel III.9 Ringkasan Domain Data pada Skema DWH_MOIS

Domain Data	Jumlah Aturan Bisnis	Fokus Bisnis
SALES	12	Analisis volume pesanan, kinerja kanal penjualan, dan penetrasi layanan pada berbagai wilayah operasional
REVENUE	8	Evaluasi pendapatan, profitabilitas pelanggan, dan distribusi pendapatan per wilayah dan segmen
DATA_PROSES	7	Segmentasi dan profiling pelanggan berbasis data pemasangan, keaktifan digital, dan program loyalitas
TARGET	5	Pemantauan pencapaian target kinerja dan analisis kesenjangan terhadap target periode
CTO	6	Identifikasi potensi <i>churn</i> pelanggan dan strategi retensi melalui analisis siklus hidup layanan

hilangan pelanggan strategis. Selanjutnya, kategori kedua, *Customer Intelligence*, mencakup tujuh aturan yang berfokus pada analisis loyalitas pelanggan, segmentasi profil berdasarkan karakteristik demografis maupun perilaku, serta proses transformasi digital yang mendukung personalisasi layanan dan peningkatan pengalaman pelanggan secara keseluruhan. Kategori ketiga, *Revenue Analytics*, terdiri dari delapan aturan yang menitikberatkan pada analisis pendapatan lintas wilayah geografis, perilaku pelanggan terhadap pendapatan, siklus hidup pelanggan, serta strategi penetrasi pasar yang optimal untuk meningkatkan profitabilitas. Pada kategori keempat, *Order and Operations*, terdapat dua belas aturan yang mengkaji performa kanal penjualan, tingkat pemenuhan pesanan, tren pertumbuhan volume penjualan, serta efisiensi operasional yang berkontribusi terhadap peningkatan layanan dan penguatan proses bisnis. Terakhir, kategori kelima, *Performance and Target*, mencakup lima aturan yang memberikan evaluasi terhadap KPI dan melakukan benchmarking secara kompetitif terhadap target kinerja di tingkat regional maupun segmentasi pelanggan sehingga memungkinkan pengawasan dan pengendalian yang lebih efektif terhadap pencapaian strategi bisnis secara menyeluruh.



Gambar III.1 Detail *Rule-Based* yang Telah Ada

Kategori-kategori tersebut dirancang berdasarkan analisis kebutuhan komprehensif terhadap kueri-kueri esensial yang secara rutin diajukan oleh tingkat manajerial.

III.4.1.2 Domain SALES

Domain SALES merupakan domain utama yang merepresentasikan informasi terkait volume permintaan, performa penjualan, serta penetrasi layanan pada berbagai tingkatan wilayah operasional. Tabel ini menyajikan struktur data yang komprehensif, mencakup dimensi geografis, waktu, produk, serta atribut pelanggan dan metrik performa layanan. Tabel III.10 menyajikan spesifikasi lengkap domain ini.

Tabel III.10 Spesifikasi Domain Data Sales

Komponen	Deskripsi dan Atribut
Tabel	DWH_MOIS.BRIGHTAI_SALES
Fokus Bisnis	Analisis volume pesanan, kinerja kanal penjualan, serta penetrasi layanan pada tiap wilayah operasional
Hierarki Wilayah	REGIONAL, WITEL, DATEL, CSTO, LSTO, STO
Dimensi Waktu	YEAR_ID, MONTH_ID, PERIODE
Metrik Pemesanan	ORDER_ID, TOTAL_ORDER, ORDER_STATUS
Produk dan Pelanggan	PRODTYPE, BANDWIDTH, PACKAGE_TYPE, SERVICE_TYPE, CUSTOMER_ID, CUSTOMER_TYPE, SEGMENT
Metrik Performa	COMPLETION_RATE, FULFILLMENT_STATUS

Pemetaan parameter penjualan pada tabel di atas berfungsi mengisolasi informasi performa aktivasi layanan secara akurat.

III.4.1.3 Domain REVENUE

Domain REVENUE dirancang untuk mendukung analisis pendapatan, profitabilitas, serta distribusi pendapatan pada berbagai lapisan wilayah operasional. Domain ini memuat data yang mencakup identitas pelanggan, dimensi geografis, periode waktu, serta metrik utama terkait pendapatan yang dihasilkan per pelanggan maupun per layanan. Tabel III.11 menyajikan spesifikasi lengkap domain ini.

Tabel III.11 Spesifikasi Domain Data Revenue

Komponen	Deskripsi dan Atribut
Tabel	DWH_MOIS.BRIGHTAI_REVENUE
Fokus Bisnis	Evaluasi pendapatan, profitabilitas pelanggan, dan distribusi pendapatan per wilayah dan segmen bisnis
Identitas Pelanggan	NIP_NAS, NCLI, ND
Wilayah Tagihan	REGIONAL_BILL, WITEL_BILL, DATEL, CSTO, LSTO
Dimensi Waktu	YEAR_ID, MONTH_ID
Metrik Pendapatan	REVENUE, TOTAL_REVENUE, MONTHLY_REVENUE
Hierarki Layanan	SERVICE_HIERARCHY, GL_ACCOUNT, PRODUCT_TYPE
Metrik Kinerja	REVENUE_PER_PELANGGAN, REVENUE_PER_NCLI

Struktur *revenue* yang dipaparkan dalam tabel ini memfasilitasi pelacakan pertumbuhan moneter berbasis waktu.

III.4.1.4 Domain DATA_PROSES

Domain DATA_PROSES secara khusus dikembangkan untuk mendukung proses profiling dan segmentasi pelanggan secara komprehensif. Domain ini dirancang untuk mengidentifikasi atribut pelanggan, tingkat digitalisasi, serta segmentasi berdasarkan

an perilaku dan karakteristik layanan. Melalui data yang diperbarui secara berkala, DATA_PROSES memungkinkan analisis longitudinal terkait penetrasi produk digital, partisipasi dalam program loyalitas, dan atribut layanan pelanggan secara geografis maupun demografis. Tabel III.12 menyajikan spesifikasi lengkap domain ini.

Tabel III.12 Spesifikasi Domain Data Proses

Komponen	Deskripsi dan Atribut
Tabel	DWH_MOIS.BRIGHTAI_DAPROS
Fokus Bisnis	Segmentasi dan profiling pelanggan berbasis data pemasangan, keaktifan digital, dan status loyalitas
Identitas Pelanggan	NOTEL, ND_REFERENCE, NCLI, PERIOD
Atribut Produk	PRODTYPE, PLBLCL, SPEED, PACK_NAME
Hierarki Wilayah	REGIONAL, WITEL, TELDA, STO
Atribut Pelanggan	IS_DINAS, IS_POTS, IS_IPTV, CGEST, LGEST
Indikator Digital dan Loyalitas	LOY_PROGRAM, P_DIGITAL, KW_IH
Metrik Pendapatan	TREMS_REV_P, TREMS_REV_REF, ADDON_PRICE

Melalui atribut segmentasi pelanggan tersebut, manajer wilayah dapat membedah penyebaran konsumen dan status kepemilikan jaringan.

III.4.1.5 Domain TARGET

Domain TARGET difokuskan pada evaluasi target kinerja, analisis kesenjangan (*gap analysis*), serta pemantauan pencapaian strategi penjualan dan layanan. Domain ini memungkinkan manajemen untuk membandingkan antara nilai target dan realisasi, sekaligus mengukur tingkat pencapaian dalam berbagai konteks wilayah, produk, dan waktu. Tabel III.13 menyajikan spesifikasi lengkap domain ini.

Tabel III.13 Spesifikasi Domain Data Target

Komponen	Deskripsi dan Atribut
Tabel	DWH_MOIS.BRIGHTAI_TARGET
Fokus Bisnis	Pemantauan pencapaian target unit dan analisis kesenjangan terhadap target periode bulanan dan tahunan
Target dan Capaian	TARGET_VALUE, REALISASI, ACHIEVEMENT_RATE
Hierarki Wilayah	REGIONAL, WITEL, TREG, SEGMENT
Dimensi Waktu	PERIODE, BULAN, TAHUN
Klasifikasi Produk	PRODUCT_TYPE, SERVICE_TYPE
Metrik Evaluasi	GAP_ANALYSIS, PERFORMANCE_SCORE

Metrik capaian target di atas digunakan sebagai tolok ukur utama guna memastikan bahwa ekspansi bisnis tetap berada di jalur operasional yang direncanakan.

III.4.1.6 Domain CT0

Domain CT0 dirancang untuk menganalisis perilaku *churn* pelanggan serta strategi retensi yang berkaitan dengan siklus hidup layanan. Domain ini memungkinkan pengukuran tingkat *churn*, identifikasi pelanggan dengan risiko tinggi, serta pelacakan masa aktif layanan pelanggan. Struktur data dalam CT0 mencakup status pelanggan, metrik *churn*, alasan perpindahan layanan, serta parameter durasi berlangganan. Tabel III.14 menyajikan spesifikasi lengkap domain ini.

Tabel III.14 Spesifikasi Domain Data Churn

Komponen	Deskripsi dan Atribut
Tabel	DWH_MOIS.BRIGHTAI_CT0_NAL
Fokus Bisnis	Identifikasi pelanggan dengan potensi <i>churn</i> dan perumusan strategi retensi berbasis analisis siklus hidup
Status Pelanggan	CUSTOMER_ID, STATUS_LAYANAN, CHURN_FLAG
Metrik <i>Churn</i>	CHURN_RATE, CHURN_DATE, RETENTION_RATE
Hierarki Wilayah	REGIONAL, WITEL, DATEL
Atribut Layanan	BANDWIDTH, SERVICE_TYPE, TENURE
Dimensi Siklus Hidup	MASA_LAYANAN, PERIODE_CHURN, REASON_CODE

Parameter atrisi (CT0) melengkapi wawasan dengan indikator retensi, memungkinkan para pengambil keputusan untuk merancang mitigasi kepergian pelanggan (*churn*) dengan lebih efektif.

III.4.2 Analisis Kualitas Data

Evaluasi kualitas data untuk peramalan deret waktu (*time series forecasting*) meliputi tiga aspek utama, yaitu kelengkapan dan konsistensi data, struktur temporal, serta relevansi fitur. Proses evaluasi ini bertujuan untuk memastikan bahwa data yang digunakan memenuhi standar kualitas yang diperlukan untuk menghasilkan model peramalan yang akurat dan andal.

III.4.2.1 Kelengkapan dan Konsistensi Data

Pemeriksaan kelengkapan data dilakukan untuk mengidentifikasi nilai yang hilang (*missing values*) atau ketidakkonsistenan dalam interval pengambilan sampel. Data deret waktu sangat bergantung pada observasi sekuensial sehingga *timestamp* yang hilang atau interval pengambilan sampel yang tidak konsisten dapat menyebabkan asumsi model menjadi tidak valid.

Profiling dilakukan melalui kueri SELECT langsung ke skema DWH_MOIS pada *Enterprise Data Warehouse* selama periode pelatihan model (Mei–Juni 2026). Setiap metrik diagregasi pada level bulanan sehingga satu baris mewakili satu bulan ob-

servasi. Proses penarikan data menerapkan filter IS NOT NULL pada kolom kunci masing-masing tabel guna memastikan hanya baris yang memiliki nilai valid yang diproses. Tabel III.15 menyajikan hasil profiling nyata berdasarkan jumlah titik data (*data points*) bulanan yang berhasil ditarik untuk setiap metrik pada level nasional.

Tabel III.15 Hasil Profiling Data Deret Waktu per Metrik (Level Nasional)

Metrik	Tabel Sumber	Titik Data (Bulan)	Rentang	Filter NULL
order_hsi	BRIGHTAI_SALES	55	41–55	ORDER_DATE IS NOT NULL
fulfillment_rate	BRIGHTAI_SALES	55	41–55	ORDER_DATE IS NOT NULL
avg_install_days	BRIGHTAI_SALES	50	41–50	ORDER_DATE, TGL_PS IS NOT NULL
churn_hsi	BRIGHTAI_CTO_NAL	40	20–40	PERIODE IS NOT NULL
realisasi_hsi	BRIGHTAI_TARGET	25	24–25	REALISASI, TREG IS NOT NULL

Kolom *Rentang* menunjukkan variasi jumlah titik data pada level regional dan witel karena beberapa wilayah memiliki data historis yang lebih pendek. Secara keseluruhan, 185 seri waktu dilatih per model ($5 \text{ metrik} \times 37 \text{ entitas}$: 1 nasional + 5 regional + 31 witel), dengan 169 seri (91,4%) memenuhi ambang batas kelulusan KPI. Metrik *churn_hsi* dan *realisasi_hsi* memiliki titik data yang lebih sedikit karena tabel sumber mulai dipopulasi pada periode yang lebih akhir dibandingkan tabel BRIGHTAI_SALES.

III.4.2.2 Analisis Struktur Temporal

Analisis struktur temporal bertujuan untuk mengidentifikasi pola yang dapat dipelajari oleh model, seperti tren (*trend*), musiman (*seasonality*), dan siklus (*cycle*). Pengujian statistik seperti *Augmented Dickey-Fuller test* digunakan untuk memeriksa stasioneritas data. Data non-stasioner mungkin memerlukan transformasi differensiasi (*differencing*) atau transformasi lainnya sebelum dapat digunakan untuk pemodelan.

Hasil pengujian stasioneritas menunjukkan bahwa:

1. Domain SALES menunjukkan pola musiman yang jelas dengan siklus tahunan
2. Domain REVENUE memiliki tren pertumbuhan yang stabil dengan volatilitas

sedang

3. Domain CT0 menunjukkan fluktuasi musiman terkait periode kontrak pelanggan

III.4.2.3 Analisis Relevansi Fitur

Dalam peramalan multivariat, fitur-fitur yang digunakan harus memiliki hubungan logis dengan variabel target. Analisis korelasi dan pengetahuan domain digunakan untuk menyaring fitur-fitur yang relevan. Pemeriksaan terhadap potensi *data leakage* (fitur yang mengandung informasi masa depan) juga dilakukan untuk mencegah bias dalam model.

III.4.3 Atribut Relasional Antar-Domain

Dalam menjamin interoperabilitas antar-domain, sistem memanfaatkan sejumlah atribut utama yang bersifat relasional. Atribut-atribut ini digunakan sebagai parameter utama dalam penyusunan aturan (*rules*) pada masing-masing domain data, memungkinkan sistem untuk membentuk kondisi logika yang terstruktur dan presisi. Tabel III.16 menyajikan atribut utama relasional yang menghubungkan kelima domain data.

Tabel III.16 Atribut Utama Relasional Antar-Domain

Dimensi Relasional	Atribut Kunci
Dimensi Waktu	YEAR_ID, MONTH_ID, PERIODE, BULAN, TAHUN
Hierarki Wilayah	REGIONAL, WITEL, DATEL, STO, CSTO
Identitas Pelanggan	CUSTOMER_ID, NCLI, ND, NOTEL, NIP_NAS
Klasifikasi Produk	PRODTYPE, PRODUCT_TYPE, SERVICE_TYPE, PACKAGE_TYPE
Alur Analitik Utama	ORDER_ID, CHURN_FLAG, REVENUE, TARGET_VALUE

Kolom-kolom relasional tersebut memungkinkan sistem untuk membentuk kondisi logika yang terstruktur dan presisi, seperti:

1. Segmentasi pelanggan berdasarkan hierarki wilayah dan klasifikasi produk
2. Evaluasi performa layanan dalam rentang waktu tertentu per regional atau *witel*
3. Identifikasi potensi *churn* pada produk dan paket layanan tertentu per segmen pelanggan
4. Analisis tren pendapatan lintas wilayah dengan dimensi waktu yang konsisten

Dengan memanfaatkan atribut-atribut ini dalam definisi aturan, sistem dapat menghasilkan *insight* yang relevan dan dapat ditindaklanjuti, sesuai dengan konteks bisnis yang sedang dianalisis.

III.5 Persiapan Data (*Data Preparation*)

Tahap persiapan data (*data preparation*) merupakan fase ketiga dalam metodologi CRISP-DM yang mencakup seluruh aktivitas untuk membangun dataset final yang akan digunakan dalam proses pemodelan. Tahap ini meliputi pembersihan data (*data cleaning*), transformasi data (*data transformation*), reduksi data (*data reduction*), serta rekayasa fitur (*feature engineering*) untuk menghasilkan data berkualitas tinggi yang siap diproses oleh algoritma peramalan deret waktu.

III.5.1 Pembersihan Data

Proses pembersihan data bertujuan untuk menangani permasalahan kualitas data yang teridentifikasi pada tahap pemahaman data. Aktivitas pembersihan data mencakup penanganan nilai hilang, penghapusan duplikasi, serta deteksi dan penanganan *outlier*.

III.5.1.1 Penanganan Nilai Hilang

Data deret waktu sering kali mengandung nilai yang hilang (*missing values*) yang dapat ditangani menggunakan beberapa teknik. Teknik *forward fill* mempropagasi nilai observasi terakhir ke depan hingga ditemukan nilai baru, sedangkan *backward fill* melakukan sebaliknya. Teknik interpolasi memperkirakan nilai yang hilang berdasarkan titik data di sekitarnya. Pemilihan teknik penanganan nilai hilang disesuaikan dengan karakteristik data dan konteks bisnis. Tabel III.17 menyajikan teknik penanganan nilai hilang yang digunakan untuk setiap jenis atribut.

Tabel III.17 Teknik Penanganan Nilai Hilang per Jenis Atribut

Jenis Atribut	Teknik Imputasi	Justifikasi
Metrik Numerik Kontinu	Interpolasi Linear	Mempertahankan kontinuitas dan tren temporal
Atribut Kategorikal	Modus (Nilai Paling Sering)	Menggunakan nilai yang paling representatif
Identitas Pelanggan	Penghapusan Rekaman	Rekaman tanpa identitas tidak dapat digunakan
Dimensi Waktu	<i>Forward Fill</i>	Mempertahankan konsistensi periode waktu
Variabel Target	Tidak Diimputasi	Menghindari bias pada variabel target prediksi

Inventarisasi kualitas di atas menunjukkan bahwa meskipun sebagian besar atribut memiliki keutuhan informasi yang layak, beberapa anomali memerlukan prapemrosesan agar terhindar dari distorsi kalkulasi analitik.

III.5.1.2 Penghapusan Duplikasi

Rekaman duplikat diidentifikasi berdasarkan kombinasi kunci unik yang terdiri dari CUSTOMER_ID, PERIODE, dan PRODUCT_TYPE. Rekaman duplikat dihapus dengan mempertahankan rekaman terbaru berdasarkan *timestamp* pembaruan. Proses ini memastikan bahwa setiap kombinasi pelanggan, periode, dan produk hanya memiliki satu rekaman yang valid dan tidak ada redundansi data yang dapat menyebabkan bias dalam model.

III.5.1.3 Deteksi dan Penanganan *Outlier*

Deteksi *outlier* dilakukan menggunakan metode *Modified Z-Score* yang diusulkan oleh Iglewicz dan Hoaglin. Nilai dengan skor modifikasi $|M_i| > 3.5$ dikategorikan sebagai *outlier*. Penanganan *outlier* dilakukan dengan pendekatan *winsorization*, yaitu mengganti nilai ekstrem dengan batas persentil tertentu (persentil ke-1 dan ke-99) untuk mempertahankan informasi temporal tanpa menghapus rekaman secara keseluruhan.

III.5.2 Transformasi Data

Transformasi data dilakukan untuk menyesuaikan format dan skala data agar sesuai dengan kebutuhan algoritma pemodelan. Proses transformasi mencakup normalisasi, standardisasi, transformasi logaritmik, serta pengkodean fitur kategorikal.

III.5.2.1 Normalisasi dan Standardisasi

Normalisasi dan standardisasi merupakan teknik penskalaan data yang kritis untuk model *deep learning* guna mencegah ketidakstabilan pembelajaran dan meningkatkan performa model. Tabel III.18 menyajikan teknik penskalaan yang digunakan untuk setiap kategori fitur dalam sistem.

Tabel III.18 Teknik Penskalaan per Kategori Fitur

Kategori Fitur	Teknik Penskalaan		Justifikasi
Metrik Pendapatan	Standardisasi	Z-Score	Distribusi mendekati normal dengan rentang lebar
Volume Pesanan	Normalisasi	Min-Max	Distribusi seragam dengan batas jelas (0–1)
Tingkat <i>Churn</i>	Normalisasi	Min-Max	Nilai terbatas pada rentang 0–1
Pencapaian Target	Standardisasi	Z-Score	Memungkinkan representasi nilai negatif (di bawah target)
Fitur Temporal	Normalisasi	Min-Max	Mempertahankan skala relatif antar periode

Setelah langkah pembersihan ini, keandalan kumpulan data dapat dijamin, menihilk-

an peluang munculnya duplikasi sinyal yang merugikan akurasi inferensi di tahap berikutnya.

III.5.2.2 Transformasi Logaritmik

Dalam fitur dengan distribusi *skewed* (miring), transformasi logaritmik diterapkan untuk mengurangi kemiripan dan membuat distribusi lebih mendekati normal. Transformasi ini meningkatkan performa model dengan memastikan data terdistribusi lebih simetris. Penambahan konstanta 1 dilakukan untuk menangani nilai nol dalam data.

III.5.2.3 Pengkodean Fitur Kategorikal

Fitur kategorikal dikonversi menjadi representasi numerik menggunakan teknik *one-hot encoding* untuk kategori dengan kardinalitas rendah (kurang dari 10 nilai unik) dan *label encoding* untuk kategori dengan kardinalitas tinggi. Tabel III.19 menyajikan teknik pengkodean yang digunakan untuk setiap fitur kategorikal utama.

Tabel III.19 Teknik Pengkodean Fitur Kategorikal

Fitur Kategorikal	Kardinalitas	Teknik Pengkodean	Dimensi Hasil
REGIONAL	7	<i>One-Hot Encoding</i>	7 fitur biner
WITEL	>50	<i>Label Encoding</i>	1 fitur integer
SEGMENT	5	<i>One-Hot Encoding</i>	5 fitur biner
PRODTYPE	>20	<i>Label Encoding</i>	1 fitur integer
SERVICE_TYPE	8	<i>One-Hot Encoding</i>	8 fitur biner

Transformasi logaritmik ini secara matematis meredam rentang deviasi (*variance*) deret waktu yang bersifat eksponensial sehingga data berada pada distribusi berskala lebih seragam dan mempermudah konvergensi model komputasi.

III.5.3 Rekayasa Fitur untuk Peramalan Deret Waktu

Rekayasa fitur (*feature engineering*) merupakan proses pembuatan fitur baru dari data mentah untuk meningkatkan akurasi model prediksi. Dalam konteks peramalan deret waktu, rekayasa fitur mencakup pembuatan fitur temporal, fitur *lag*, fitur agregat, dan fitur interaksi.

III.5.3.1 Fitur Temporal

Fitur temporal diekstraksi dari dimensi waktu untuk menangkap pola musiman dan siklus dalam data. Tabel III.20 menyajikan fitur temporal yang dihasilkan.

Tabel III.20 Fitur Temporal yang Dihasilkan

Fitur Temporal	Deskripsi dan Formula
MONTH_SIN, MONTH_COS	Representasi siklis bulan menggunakan transformasi sinus dan kosinus untuk menangkap periodisitas musiman
QUARTER	Klasifikasi kuartal tahun (Q1, Q2, Q3, Q4) untuk mengidentifikasi pola per kuartal
IS_YEAR_END	Indikator biner akhir tahun (November–Desember) untuk pengaruh periode puncak
IS_QUARTER_END	Indikator biner akhir kuartal untuk mendeteksi efek pembatasan periode
DAYS_IN_MONTH	Jumlah hari dalam bulan bersangkutan untuk normalisasi berdasarkan durasi periode

Konstruksi data temporal di atas menyediakan konteks kronologis fundamental untuk memosisikan setiap observasi data dalam aliran peristiwa yang berkesinambungan.

III.5.3.2 Fitur *Lag* dan *Rolling Statistics*

Fitur *lag* dibuat dengan menggeser nilai variabel target ke periode sebelumnya untuk menangkap dependensi temporal. Selain itu, statistik bergulir (*rolling statistics*) dihitung untuk menangkap tren dan volatilitas. Tabel III.21 menyajikan fitur *lag* dan statistik bergulir yang dihasilkan.

Tabel III.21 Fitur Lag dan Statistik Bergulir

Fitur	Deskripsi
LAG_1, LAG_3, LAG_6, LAG_12	Nilai variabel target pada 1, 3, 6, dan 12 periode sebelumnya untuk menangkap dependensi
ROLLING_MEAN_3, ROLLING_MEAN_6	Rata-rata bergerak 3 dan 6 periode untuk mengidentifikasi tren jangka pendek dan menengah
ROLLING_STD_3, ROLLING_STD_6	Simpangan baku bergerak untuk mengukur volatilitas data
ROLLING_MIN_6, ROLLING_MAX_6	Nilai minimum dan maksimum bergerak 6 periode untuk mendeteksi rentang variasi
DIFF_1, DIFF_12	Diferensiasi orde 1 dan 12 untuk menangani non-stasioneritas dan pola musiman

Variabel-variabel retrospektif ini memainkan peran krusial dalam mengungkap pola autokorelasi, dengan performa pada bulan-bulan sebelumnya berfungsi sebagai prediktor kuat bagi tren di periode yang akan datang.

III.5.3.3 Fitur Agregat per Entitas

Fitur agregat dihitung untuk setiap entitas (pelanggan, wilayah, produk) guna menangkap karakteristik historis yang dapat memengaruhi nilai target. Tabel III.22 menyajikan fitur agregat yang dihasilkan.

Tabel III.22 Fitur Agregat per Entitas

Fitur Agregat	Deskripsi dan Perhitungan
CUSTOMER_AVG_REVENUE	Rata-rata pendapatan historis per pelanggan dihitung dari semua periode sebelumnya
REGION_TOTAL_ORDER	Total pesanan historis per regional untuk mengukur skala operasional regional
PRODUCT_CHURN_RATE	Tingkat <i>churn</i> historis per jenis produk untuk mengidentifikasi produk berisiko tinggi
SEGMENT_TARGET_ACHIEVEMENT	Rata-rata pencapaian target per segmen pelanggan untuk konteks pencapaian relatif
WITEL_REVENUE_GROWTH	Pertumbuhan pendapatan per wilayah telekomunikasi untuk menangkap tren pertumbuhan regional

Sebagai pelengkap aspek waktu, agregasi lintas entitas (nasional maupun regional) memberikan kerangka referensi hierarkis yang memungkinkan model untuk mengenali dinamika proporsional wilayah tertentu terhadap konstelasi bisnis secara keseluruhan.

III.5.4 Pembagian Data untuk Pelatihan dan Evaluasi

Pembagian data untuk model peramalan deret waktu menggunakan pendekatan *time-based split* untuk mencegah *data leakage* dan memastikan evaluasi yang realistis. Data dibagi berdasarkan urutan waktu dengan proporsi yang disajikan pada Tabel III.23.

Tabel III.23 Pembagian Data untuk Pelatihan dan Evaluasi

Dataset	Proporsi	Keterangan dan Tujuan
<i>Training Set</i>	70%	Data historis terlama untuk melatih model dan pembelajaran parameter
<i>Validation Set</i>	15%	Data periode tengah untuk <i>hyperparameter tuning</i> dan evaluasi intermediat
<i>Test Set</i>	15%	Data periode terbaru untuk evaluasi akhir model pada data yang belum pernah dilihat

Selain pembagian statis, sistem juga mengimplementasikan *rolling-origin cross-validation* untuk evaluasi yang lebih robust, dengan jendela pelatihan bergerak maju secara bertahap dan model dievaluasi pada beberapa horizon prediksi.

III.5.5 Penyimpanan *Dataset* Final

Dataset yang telah melalui proses persiapan disimpan dalam format yang terstruktur untuk memudahkan akses oleh modul pemodelan. Setiap dataset disimpan dengan metadata yang mencakup *timestamp* pembuatan, versi skema, statistik deskriptif, dan parameter transformasi yang digunakan. Penyimpanan parameter transformasi (*scaler*, *encoder*) memungkinkan transformasi yang konsisten pada data baru saat inferensi sistem.

III.6 Pemodelan Data (*Data Modelling*)

Tahap pemodelan data (*modeling*) merupakan fase keempat dalam metodologi CRISP-DM yang berfokus pada pemilihan teknik pemodelan, perancangan arsitektur model, konfigurasi *hyperparameter*, serta pelatihan model menggunakan dataset yang telah dipersiapkan. Pada penelitian ini, pemodelan data mencakup tiga komponen utama, yaitu model peramalan deret waktu berbasis pembelajaran mendalam, model klasifikasi *intent* berbasis pola, dan model pembangkitan bahasa alami berbasis templat.

III.6.1 Arsitektur Model Peramalan Deret Waktu

Sistem peramalan dalam penelitian ini mengadopsi pendekatan bertahap yang dimulai dari model statistik sebagai *baseline*, kemudian dibandingkan dengan model berbasis pembelajaran mendalam (*deep learning*). Evaluasi perbandingan ini bertujuan untuk memastikan bahwa kompleksitas tambahan model *deep learning* memberikan peningkatan akurasi yang signifikan dan terukur. Sistem menggunakan empat model yang dikategorikan sebagai berikut: (1) model statistik *baseline* berupa ARIMA dan Prophet, serta (2) model *deep learning* utama berupa LSTM (*Long Short-Term Memory*) dan GRU (*Gated Recurrent Unit*).

III.6.1.1 Model *Baseline* Statistik: ARIMA dan Prophet

Model ARIMA (*Autoregressive Integrated Moving Average*) dan Prophet digunakan sebagai *baseline* pembanding dalam evaluasi sistem peramalan. Penggunaan *baseline* statistik ini penting untuk memberikan konteks kuantitatif bagi penilaian performa model *deep learning*: apabila model *deep learning* tidak secara konsisten mengungguli *baseline* statistik, maka penggunaan model yang lebih kompleks tidak dapat dibenarkan secara teknis dan praktis.

ARIMA diimplementasikan untuk setiap seri waktu secara individual menggunakan seleksi parameter otomatis berdasarkan kriteria informasi AIC (*Akaike Information Criterion*). Data yang menunjukkan pola musiman yang signifikan secara statistik (berdasarkan uji Augmented Dickey-Fuller) menggunakan varian SARIMA dengan

parameter musiman (P, D, Q, m).

Prophet diimplementasikan dengan konfigurasi standar yang mencakup deteksi titik perubahan tren secara otomatis dan komponen musiman tahunan. Prophet dipilih sebagai *baseline* kedua karena kemampuannya menangani data bisnis dengan tren dan musiman yang kompleks tanpa memerlukan pra-pemrosesan manual yang ekstensif.

Hasil evaluasi *baseline* statistik ini kemudian dibandingkan dengan model *deep learning* menggunakan metrik sMAPE, MASE, dan *Skill Score* pada protokol *walk-forward validation* yang sama, untuk memastikan perbandingan yang adil dan representatif.

III.6.1.2 Model LSTM (*Long Short-Term Memory*)

LSTM merupakan jenis jaringan saraf berulang (*Recurrent Neural Network*, RNN) yang dirancang untuk mengatasi masalah gradien menghilang (*vanishing gradient*) pada RNN tradisional dan mampu mempelajari dependensi jangka panjang dalam data sekuens. Arsitektur LSTM terdiri dari sel memori dan tiga gerbang utama yang diuraikan pada Tabel III.24.

Tabel III.24 Komponen Gerbang pada Arsitektur LSTM

Gerbang	Formula Umum	Fungsi dalam Arsitektur
<i>Forget Gate</i>	$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$	Menentukan informasi dari sel memori periode sebelumnya yang harus diabaikan
<i>Input Gate</i>	$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$	Menentukan informasi baru dari input periode saat ini yang akan disimpan
<i>Output Gate</i>	$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$	Menentukan bagian sel memori yang menjadi keluaran tersembunyi

Keunggulan LSTM terletak pada kemampuannya untuk mempelajari dependensi jangka panjang dengan stabil dan menangani data deret waktu yang memiliki pola kompleks. Struktur gerbang memungkinkan model untuk secara selektif menyimpan, melupakan, dan menggunakan informasi dari periode-periode sebelumnya.

III.6.1.3 Model GRU (*Gated Recurrent Unit*)

GRU merupakan varian yang lebih sederhana dari LSTM dengan jumlah parameter yang lebih sedikit sehingga lebih efisien dalam menangkap dan mempertahankan dependensi jangka pendek dan jangka panjang dalam data deret waktu. GRU menggunakan dua gerbang utama, yaitu *update gate* dan *reset gate*. Tabel III.25 menyajikan komponen gerbang pada arsitektur GRU.

Tabel III.25 Komponen Gerbang pada Arsitektur GRU

Gerbang	Formula Umum	Fungsi dalam Arsitektur
<i>Update Gate</i>	$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z)$	Mengontrol seberapa banyak informasi dari <i>hidden state</i> lama yang dipertahankan
<i>Reset Gate</i>	$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r)$	Mengontrol seberapa banyak informasi dari <i>hidden state</i> lama yang diabaikan

Dibandingkan dengan LSTM, GRU memiliki struktur yang lebih sederhana dengan lebih sedikit parameter sehingga dapat meningkatkan kecepatan pelatihan sebesar 20–30% tanpa mengorbankan akurasi secara signifikan pada banyak kasus penggunaan.

III.6.1.4 Perbandingan Karakteristik Model

Tabel III.26 menyajikan perbandingan karakteristik seluruh model peramalan yang diimplementasikan dalam penelitian ini, mencakup model statistik *baseline* (ARIMA/SARIMA dan Prophet) serta model *deep learning* utama (LSTM dan GRU).

Tabel III.26 Perbandingan Karakteristik Model Peramalan

Aspek Perbandingan	ARIMA	Prophet	LSTM	GRU
Kompleksitas Arsitektur	Rendah	Rendah	Tinggi	Sedang
Jumlah Parameter	Sedikit (p, d, q)	Sedikit	Banyak	Lebih sedikit
Kecepatan Pelatihan	Sangat Cepat	Cepat	Lambat	Cepat
Dependensi Jangka Panjang	Terbatas	Sedang	Baik	Baik
Kemampuan Nonlinear	Tidak	Sebagian	Baik	Baik
Interpretabilitas	Sangat Tinggi	Tinggi	Rendah	Rendah
Kemampuan Multivariat	Terbatas	Terbatas	Baik	Baik
Kebutuhan Volume Data	Rendah	Rendah	Sedang	Sedang
Peran dalam Penelitian	<i>Baseline</i>	<i>Baseline</i>	Model Utama	Model Utama

Pemisahan partisi antara porsi historis, periode validasi, dan pengujian pamungkas mengamankan protokol pengujian yang objektif, mencegah terjadinya asimilasi informasi (*data leakage*) yang sering menjadi jebakan pemodelan deret waktu.

III.6.2 Konfigurasi *Hyperparameter*

Konfigurasi *hyperparameter* untuk model LSTM dan GRU ditetapkan sebagai nilai tetap pada berkas `config.py` berdasarkan praktik terbaik dari literatur. Tabel III.27 menyajikan konfigurasi *hyperparameter* yang digunakan dalam pelatihan.

Tabel III.27 Konfigurasi *Hyperparameter* Model (Berkas `config.py`)

<i>Hyperparameter</i>	LSTM	GRU	Keterangan
Jumlah Lapisan Berulang (NUM_LAYERS)	2	2	Kedalaman arsitektur <i>re-current</i>
Ukuran <i>Hidden State</i> (HIDDEN_SIZE)	64	64	Dimensi representasi internal
Tingkat <i>Dropout</i> (DROPOUT)	0,2	0,2	Regularisasi antar-lapisan
<i>Learning Rate</i> (LEARNING_RATE)	10^{-3}	10^{-3}	Laju pembelajaran Adam
Ukuran <i>Batch</i> (BATCH_SIZE)	32	32	Jumlah sampel per iterasi
Jumlah <i>Epoch</i> Maksimum (EPOCHS)	100	100	Batas iterasi pelatihan
<i>Early Stopping Patience</i>	20	20	<i>Epoch</i> tanpa perbaikan sebelum berhenti
Panjang Sekuens Masukan (WINDOW_SIZE)	12	12	Jumlah bulan historis sebagai input
Horizon Prediksi (HORIZON)	1	1	Jumlah bulan yang diprediksi

Matriks nilai di atas mendefinisikan ruang pencarian (*search space*) algoritma untuk menemukan takaran interaksi parameter yang optimal, menyeimbangkan kompleksitas komputasional dengan kapasitas generalisasi masing-masing model.

III.6.3 Strategi Pelatihan Model

Strategi pelatihan model dirancang untuk mengoptimalkan akurasi prediksi sekaligus mencegah *overfitting*. Beberapa teknik yang diimplementasikan meliputi *early stopping*, regularisasi, serta pemilihan fungsi kerugian yang sesuai dengan karakteristik masalah.

III.6.3.1 *Early Stopping*

Mekanisme *early stopping* diimplementasikan untuk menghentikan pelatihan jika *validation loss* tidak mengalami perbaikan selama 10 *epoch* berturut-turut. Bobot model terbaik (*best weights*) dipulihkan setelah pelatihan dihentikan untuk memastikan model menggunakan konfigurasi parameter terbaik.

III.6.3.2 Regularisasi

Teknik regularisasi yang digunakan mencakup *dropout* untuk mencegah *overfitting* dengan secara acak menonaktifkan sebagian neuron selama pelatihan, serta regularisasi L2 (*weight decay*) untuk membatasi magnitude bobot model.

III.6.3.3 Fungsi Kerugian

Pemilihan fungsi kerugian disesuaikan dengan karakteristik masalah prediksi. Tabel III.28 menyajikan fungsi kerugian yang digunakan untuk setiap jenis prediksi.

Tabel III.28 Fungsi Kerugian untuk Setiap Jenis Prediksi

Jenis Prediksi	Fungsi Kerugian	Kegunaan dan Formula
Prediksi Titik Numerik	<i>Mean Squared Error</i> (MSE)	Mengukur rata-rata kuadrat kesalahan prediksi untuk nilai kontinu, termasuk seluruh metrik operasional (volume pesanan, jumlah <i>churn</i> , pendapatan, dan lainnya)
Prediksi Kuantil	<i>Quantile Loss</i> (<i>Pi-nball Loss</i>)	Menghasilkan interval kepercayaan untuk pengambilan keputusan berbasis risiko

Perlu ditekankan bahwa seluruh metrik yang diramalkan dalam sistem ini, termasuk *churn*, diperlakukan sebagai tugas peramalan deret waktu numerik (*numeric time series forecasting*), bukan sebagai tugas klasifikasi biner. Metrik *churn_hsi* merepresentasikan jumlah agregat pelanggan yang berhenti berlangganan (`COUNT(DISTINCT NCLI)`) pada level bulanan per wilayah sehingga fungsi kerugian yang digunakan adalah MSE, bukan *Binary Cross-Entropy*. Prediksi *churn* biner per pelanggan individual (apakah seorang pelanggan tertentu akan *churn* atau tidak) merupakan tugas klasifikasi yang memerlukan protokol evaluasi terpisah (akurasi, presisi, daya ingat, AUC-ROC) dan tidak diimplementasikan pada versi sistem ini.

III.6.4 Model Klasifikasi *Intent* Berbasis Pola

Pencocokan kueri pengguna ke aturan bisnis menggunakan pendekatan pencocokan pola (*pattern matching*) yang dikombinasikan dengan mekanisme *confidence scoring*. Sistem mengimplementasikan tujuh kategori *intent* (*quantity*, *trend*, *comparison*, *location*, *performance*, *detail*, *reason*) beserta satu *fallback* (*general*), yang dikombinasikan dengan delapan kategori fokus analisis untuk dipetakan ke 38 aturan bisnis pada lima domain data.

Dalam setiap *intent*, didefinisikan sekumpulan pola (*pattern*) yang mencakup variasi pertanyaan yang mungkin diajukan pengguna. Sistem menghitung skor kecocokan

(*matching score*) antara kueri pengguna dengan setiap pola dan menghasilkan *confidence score* dalam rentang 0–100 melalui formula $c = \min(100, \text{skor} \times 10)$. Ambang batas (*threshold*) ditetapkan pada nilai 40 (setara 0,40 pada skala 0–1); kueri dengan *confidence score* di atas ambang batas diteruskan ke modul pemrosesan kueri, sedangkan kueri di bawah ambang batas memicu permintaan klarifikasi kepada pengguna.

III.6.5 Model Pembangkitan Bahasa Alami Berbasis Templat

Model pembangkitan bahasa alami (*Natural Language Generation*, NLG) menggunakan pendekatan berbasis templat untuk menghasilkan respons naratif dari data terstruktur. Sistem memetakan setiap *intent* ke satu atau lebih templat respons yang berisi *placeholder* untuk diisi dengan data aktual hasil kueri.

Dalam meningkatkan variasi dan kealamian respons, sistem mengimplementasikan beberapa templat untuk setiap skenario dan memilih secara acak atau berdasarkan konteks. Selain itu, model *template rewriting* berbasis transformer (T5) dapat digunakan untuk memperbaiki koherensi dan kealamian teks yang dihasilkan tanpa mengorbankan akurasi faktual.

III.6.6 Integrasi Model dalam Arsitektur Sistem

Ketiga komponen model (peramalan deret waktu, klasifikasi *intent*, dan NLG) diintegrasikan dalam arsitektur sistem *chatbot* BI dalam alur berikut.

1. Kueri pengguna diterima oleh modul klasifikasi *intent*
2. *Intent* dan parameter entitas diekstraksi dari kueri
3. Berdasarkan *intent*, sistem mengarahkan ke modul yang sesuai:
 - (a) Analisis deskriptif: Eksekusi kueri ke *data warehouse*
 - (b) Analisis prediktif: Invokasi model peramalan deret waktu
4. Hasil diproses oleh modul NLG untuk menghasilkan respons naratif yang mudah dipahami
5. Respons ditampilkan kepada pengguna melalui antarmuka *chatbot*

Tabel III.29 menyajikan ringkasan integrasi model dalam sistem.

Tabel III.29 Integrasi Model dalam Arsitektur Sistem

Komponen Sistem	Teknik/Model	Masukan	Keluaran
Klasifikasi <i>Intent</i>	<i>Pattern Matching + Confidence Scoring</i>	Kueri teks pengguna	<i>Intent</i> , entitas, confidence score
Peramalan Deret Waktu	LSTM / GRU (ARIMA & Prophet sebagai <i>baseline</i>)	Data historis bulanan	Prediksi nilai metrik
Pembangkitan Respons	<i>Template-based</i> NLG	Data hasil kueri / prediksi	Teks naratif bahasa Indonesia

BAB IV

PERANCANGAN SISTEM *BUSINESS INTELLIGENCE* *CHATBOT*

Berdasarkan analisis komprehensif terhadap permasalahan yang dihadapi dan kebutuhan pengguna yang telah diuraikan pada bab-bab sebelumnya, penelitian ini mengajukan solusi terintegrasi berupa *Business Intelligence Chatbot System* berbasis teknologi pembelajaran mendalam (*deep learning*) yang menggabungkan tiga komponen utama, yaitu mekanisme pencocokan pola (*pattern-based intent classification*) untuk pemahaman maksud pengguna, mesin kueri berbasis aturan (*rule-based query engine*) untuk pengambilan data terstruktur, serta model peramalan deret waktu (*time series forecasting*) untuk analisis prediktif. Solusi yang diajukan dirancang dengan visi untuk menghilangkan hambatan aksesibilitas data analitik bagi pengguna nonteknis melalui antarmuka percakapan yang intuitif dan responsif dalam bahasa alami, sekaligus meningkatkan kecepatan pengambilan keputusan melalui otomatisasi proses analisis dan pelaporan. Sistem ini mengintegrasikan kemampuan deskriptif, diagnostik, dan prediktif dalam satu *platform* terpadu yang memanfaatkan infrastruktur *Enterprise Data Warehouse* yang telah ada sehingga meminimalkan disrupti terhadap operasional bisnis yang sedang berjalan dan mengurangi kebutuhan perubahan drastis pada lanskap teknologi eksisting.

Transformasi dari kondisi *status quo* menuju solusi yang diusulkan melibatkan perubahan yang bersifat fundamental pada tiga aspek utama, yaitu arsitektur sistem yang bergeser dari pelaporan manual dan *dashboard* statis menuju sistem otomatis berbasis percakapan dengan kemampuan pemrosesan mendekati *real-time*, kemampuan analitik yang berkembang dari analisis retrospektif menjadi analisis prediktif yang bersifat proaktif, serta pengalaman pengguna yang beralih dari ketergantungan pada pengguna teknis yang memahami SQL menjadi kemudahan akses bagi pengguna bisnis umum melalui interaksi berbasis bahasa alami. Dengan demikian, sistem diharapkan mampu menjembatani kesenjangan antara kebutuhan pengambilan keputusan yang cepat dan kompleksitas teknis yang selama ini menjadi penghalang utama dalam pemanfaatan penuh kapabilitas data dan analitik di lingkungan organi-


sasi.

Sistem analitik yang ada saat ini (*as-is*) masih mengikuti pola operasional tradisional yang berfokus pada pelaporan manual dan eksplorasi data yang terbatas. Proses dimulai dari identifikasi kebutuhan analitik oleh pengguna bisnis, dilanjutkan dengan penerjemahan kebutuhan tersebut menjadi kueri basis data oleh analis atau tim teknis, eksekusi kueri terhadap *Enterprise Data Warehouse*, pemrosesan dan transformasi data untuk memenuhi standar kualitas serta format analisis, kemudian diakhiri dengan penyajian hasil dalam bentuk laporan. Keterbatasan utama dari pola *as-is* ini mencakup waktu respons yang lama akibat proses multi-tahap dengan *multiple touchpoint* antardepartemen sebelum *insight* dapat dihasilkan, tingkat aksesibilitas yang rendah karena hanya pengguna dengan keahlian teknis yang mampu melakukan analisis secara mandiri, ketiadaan kemampuan prediktif karena sistem berfokus pada analisis historis tanpa dukungan *forecasting* untuk pengambilan keputusan proaktif, serta efisiensi operasional yang rendah karena tim teknis harus mengalokasikan waktu signifikan untuk mengonversi permintaan analitik menjadi *query* teknis alih-alih berfokus pada aktivitas bernilai tambah yang lebih strategis.

IV.1 Alur Proses Bisnis Sistem Analitik Saat Ini (*As-Is*)

Proses bisnis sistem analitik saat ini direpresentasikan dalam notasi BPMN (*Business Process Model and Notation*) yang menggambarkan interaksi antar aktor, keputusan-keputusan kritis, dan aliran data dalam organisasi. Proses dimulai dengan identifikasi kebutuhan analisis baru oleh pengguna bisnis, dilanjutkan dengan klarifikasi kebutuhan dan pengembangan *query* oleh tim teknis, eksekusi *query* pada *data warehouse*, pemrosesan data hasil *query*, pembangunan *dashboard* atau laporan, *review* dan validasi internal, iterasi perbaikan apabila diperlukan, serta diakhiri dengan publikasi hasil analisis kepada pengguna akhir. Di dalam alur tersebut terdapat beberapa titik keputusan (*decision point*) yang bersifat kritis, antara lain: apakah permintaan dapat dipenuhi dengan *dashboard existing* atau memerlukan *custom query*, apakah data hasil *query* sudah sesuai dengan ekspektasi pengguna atau memerlukan transformasi tambahan, serta apakah hasil analisis sudah valid untuk dipublikasikan atau masih memerlukan revisi. Proses *as-is* ini bersifat iteratif dengan siklus umpan balik yang panjang dan kurang efisien dalam memenuhi kebutuhan analitik yang dinamis dan beragam dari pengguna bisnis. Diagram BPMN yang menggambarkan proses *as-is* disajikan pada Gambar IV.1.

Visualisasi proses *as-is* menunjukkan kompleksitas dan iterasi yang terlibat dalam setiap siklus permintaan analitik. Pengguna bisnis harus menunggu beberapa tahap



Gambar IV.1 BPMN Sistem *As-Is*

pemrosesan, *review*, dan validasi sebelum hasil analisis dapat diakses. Aliran data bersifat linear dengan berbagai *handoff* antar departemen sehingga menciptakan *bottleneck* dan jeda yang signifikan. Pengalaman pengguna berpusat pada antarmuka *dashboard* statis, tanpa kemampuan untuk melakukan eksplorasi data secara interaktif maupun berinteraksi melalui dialog percakapan yang natural.

IV.2 Alur Proses Bisnis Sistem Analitik dengan Chatbot BI (*To-Be*)

Proses bisnis sistem analitik yang diusulkan (*to-be*) merepresentasikan tingkat otomatisasi dan optimasi yang signifikan dibandingkan proses *as-is*. Proses dimulai ketika pengguna mengajukan pertanyaan dalam bahasa alami kepada sistem *chatbot*, yang kemudian dilanjutkan dengan proses *login* ke sistem *BI chatbot* untuk keperluan autentikasi dan otorisasi pengguna. Setelah autentikasi berhasil, sistem membangun halaman dialog *chatbot* sebagai antarmuka utama interaksi antara pengguna dan sistem yang bersifat *AI-powered*. Tahap pemrosesan dimulai dengan klasifikasi maksud berbasis pola untuk mengidentifikasi jenis pertanyaan yang diajukan, apakah bersifat deskriptif, diagnostik, atau prediktif. Berdasarkan jenis *intent* tersebut, sistem melakukan perutean (*routing*) ke modul yang sesuai, yaitu untuk analisis deskriptif dan diagnostik, sistem menggunakan *rule-based query engine* untuk menghasilkan dan mengeksekusi kueri terstruktur terhadap *data warehouse*; sedangkan untuk analisis prediktif, sistem mengakses model *forecasting* yang telah di-


latih untuk menghasilkan prediksi sesuai dengan rentang waktu (*time horizon*) dan parameter yang relevan. Setelah hasil analisis diperoleh, sistem melakukan perhitungan KPI dan agregasi data, kemudian menerapkan *natural language generation* berbasis templat (*template-based NLG*) untuk mengonversi keluaran numerik menjadi narasi dalam bahasa alami yang koheren dan mudah dipahami. Respons yang telah diformat dalam Bahasa Indonesia kemudian ditampilkan kembali kepada pengguna melalui antarmuka *chatbot*, dan pada tahap akhir pengguna dapat mengakses *dashboard* untuk melakukan *ad-hoc analysis* atau pelacakan KPI tambahan apabila diperlukan, atau proses diakhiri ketika analisis dinyatakan selesai.

Keunggulan proses *to-be* dibandingkan proses *as-is* terletak pada beberapa aspek utama: **kecepatan eksekusi** yang jauh lebih tinggi (hitungan menit dibandingkan hari) berkat eksekusi kueri *real-time*, **aksesibilitas yang lebih luas** karena tidak lagi memerlukan keahlian teknis SQL untuk mengakses *insight*, **otomatisasi proses** yang mengurangi beban kerja manual tim teknis melalui pemanfaatan *rule-based query* dan penanganan *intent* otomatis, **kemampuan analitik yang diperluas** melalui integrasi komponen prediktif berbasis *machine learning*, serta **pengalaman pengguna** yang lebih baik melalui antarmuka percakapan yang natural dan responsif. Secara keseluruhan, rancangan *to-be* ini memungkinkan siklus permintaan hingga penyajian hasil analitik standar diselesaikan dalam waktu kurang dari satu menit untuk mayoritas kasus sehingga lebih selaras dengan kebutuhan pengambilan keputusan yang cepat dan berbasis data. Diagram BPMN yang menggambarkan proses *to-be* disajikan pada Gambar IV.2.

Visualisasi proses *to-be* menunjukkan peningkatan yang signifikan dalam efisiensi dan responsivitas sistem. Pengguna dapat secara langsung mengajukan pertanyaan melalui antarmuka *chatbot* tanpa perlu menunggu atau melibatkan tim teknis. Aliran data bersifat paralel dengan otomatisasi penuh pada tahap pemrosesan sehingga memungkinkan hasil analisis diterima dalam waktu yang sangat singkat. Pengalaman pengguna berpusat pada dialog percakapan yang interaktif, dengan kemampuan untuk melakukan eksplorasi data secara *real-time* serta mengajukan kueri lanjutan (*follow-up queries*) secara mulus.

IV.3 Perbandingan Sistem Saat Ini (*As-Is*) dan Sistem Baru (*To-Be*)

Berdasarkan analisis proses bisnis yang telah diuraikan pada bagian sebelumnya, terdapat perbedaan fundamental antara sistem analitik saat ini (*as-is*) dan sistem yang diusulkan (*to-be*). Sistem *as-is* mengandalkan pelaporan manual dengan keterlibatan tim teknis pada setiap tahap, sedangkan sistem *to-be* mengotomatisasi sebagian



Gambar IV.2 BPMN Sistem *To-Be*

besar proses melalui antarmuka percakapan berbasis *chatbot*. Perbandingan kedua sistem berdasarkan aspek-aspek kritis disajikan pada Tabel IV.1.

Tabel IV.1 Perbandingan Sistem *As-Is* dan *To-Be*

Aspek	Sistem <i>As-Is</i>	Sistem <i>To-Be</i>
Waktu Respons	2–5 hari untuk kueri kompleks	<2 menit untuk 95% kueri
Antarmuka Pengguna	<i>Dashboard</i> statis, laporan manual	Antarmuka percakapan (<i>chatbot</i>) dalam Bahasa Indonesia
Ketergantungan Teknis	Memerlukan tim TI/analisis data untuk setiap permintaan	Pengguna nonteknis dapat mengakses <i>insight</i> secara mandiri
Aksesibilitas	Terbatas pada pengguna dengan keahlian SQL	Seluruh pengguna internal dapat mengakses melalui bahasa alami
Kemampuan Analitik	Deskriptif dan diagnostik (historis)	Deskriptif, diagnostik, dan prediktif (<i>forecasting</i>)
Proses Pengambilan Data	Ekstraksi manual dari berbagai sistem, transformasi via <i>spreadsheet</i>	Otomatis melalui <i>rule-based query engine</i>

Bersambung ke halaman berikutnya

Tabel IV.1 – Lanjutan dari halaman sebelumnya

Aspek	Sistem <i>As-Is</i>	Sistem <i>To-Be</i>
Kemampuan Prediktif	Tidak tersedia atau dilakukan manual secara periodik	Terintegrasi dengan model <i>time series forecasting</i> (LSTM/GRU-/Prophet/ARIMA)
Format Respons	Tabel, grafik, laporan tertulis	Narasi bahasa alami (<i>template-based NLG</i>)
Siklus <i>Feedback</i>	Iteratif dan panjang dengan banyak <i>handoff</i>	<i>Real-time</i> dengan kemampuan kueri lanjutan
Skalabilitas	Terbatas oleh kapasitas tim teknis	Skala horizontal melalui arsitektur layanan mikro
Ketersediaan	Jam kerja (bergantung pada tim teknis)	Diakses setiap saat (<i>self-service</i>)

IV.4 Rancangan Solusi Keseluruhan

Rancangan solusi keseluruhan mengintegrasikan lima lapisan (*layer*) arsitektur yang saling terhubung, yakni lapisan presentasi (*presentation layer*), lapisan aplikasi (*application layer*), lapisan logika bisnis (*business logic layer*), lapisan data (*data layer*), dan lapisan infrastruktur (*infrastructure layer*). Integrasi kelima lapisan tersebut memastikan bahwa sistem memiliki tingkat fleksibilitas, skalabilitas, dan kemudahan pemeliharaan (*maintainability*) yang tinggi untuk mendukung pertumbuhan bisnis serta evolusi kebutuhan analitik di masa depan.

IV.4.1 Komponen-Komponen Utama Arsitektur

Lapisan presentasi mencakup antarmuka pengguna yang dibangun dengan teknologi *web* modern, dengan fokus pada antarmuka *chatbot* berbasis *web* yang mendukung interaksi waktu nyata (*real-time*) dengan *backend* sistem. Antarmuka ini diimplementasikan menggunakan kerangka kerja *frontend* modern dengan pemanfaatan komunikasi asinkronus yang memungkinkan percakapan dua arah tanpa penundaan yang signifikan. Lapisan ini juga mencakup komponen untuk menampilkan metrik interaktif dan laporan yang terintegrasi dengan hasil analisis yang dihasilkan oleh *backend*.

Lapisan aplikasi mengenkapsulasi logika inti sistem yang terdiri atas beberapa modul utama. Modul *Natural Language Understanding* (NLU) bertanggung jawab untuk melakukan penguraian (*parsing*) dan pemahaman terhadap masukan pengguna dalam bahasa alami. Modul manajemen dialog mengelola status percakapan dan

menjaga koherensi dalam dialog multigiliran (*multi-turn*). Modul pembangkitan respons menghasilkan tanggapan yang sesuai berdasarkan hasil analisis yang diterima dari lapisan logika bisnis. Di sisi lain, lapisan logika bisnis mencakup implementasi aturan bisnis yang telah didefinisikan, mesin klasifikasi maksud, mesin kueri berbasis aturan, model *machine learning* untuk peramalan, serta repositori templat untuk NLG. Lapisan ini merupakan jantung sistem yang mengonversi maksud pengguna menjadi aksi teknis yang konkret dan menghasilkan wawasan berbasis data.

Lapisan data mencakup koneksi dan interaksi dengan *Enterprise Data Warehouse* yang menyimpan data transaksional dan data utama, serta lapisan singgahan (*cache*) untuk menyimpan hasil kueri yang sering diakses guna meningkatkan performa. Lapisan ini juga mencakup repositori untuk menyimpan model *machine learning* yang telah dilatih, metadata mengenai sumber data, dan log audit untuk melacak seluruh interaksi pengguna dengan sistem. Lapisan infrastruktur mencakup komponen teknis yang mendukung operasional sistem secara keseluruhan, antara lain *web server* untuk aplikasi *chatbot*, infrastruktur API untuk penanganan permintaan, layanan pemantauan (*monitoring*) dan pencatatan (*logging*), serta komponen keamanan untuk autentikasi dan otorisasi pengguna.


IV.4.2 Arsitektur Sistem dan Aliran Data

Arsitektur sistem secara keseluruhan dirancang dengan pendekatan modular berbasis layanan, dengan setiap komponen fungsional (seperti layanan *chatbot*, layanan kueri, layanan peramalan, dan layanan NLG) diimplementasikan secara terpisah. Komunikasi antarkomponen dilakukan melalui API REST untuk memastikan keterikatan yang longgar (*loose coupling*) dan tingkat ketahanan (*resilience*) yang memadai terhadap gangguan.

Diagram arsitektur sistem yang lebih rinci disajikan pada Gambar IV.3, yang memperlihatkan integrasi kelima lapisan dan aliran data antarkomponen di dalam sistem. Arsitektur ini dirancang untuk mendukung:

1. Skalabilitas horizontal, dengan setiap layanan dapat diduplikasi sesuai dengan kebutuhan kapasitas.
2. Ketahanan (*Resilience*) sehingga kegagalan pada satu layanan tidak secara langsung menyebabkan kegagalan sistem secara keseluruhan.
3. Kemudahan Pemeliharaan karena setiap modul dapat dikembangkan, diuji, dan di-*deploy* secara independen.
4. Interoperabilitas, melalui kemampuan setiap layanan untuk berinteraksi menggunakan standar API.

5. Keamanan, dengan penerapan autentikasi berlapis dan enkripsi data.



Gambar IV.3 Diagram Arsitektur Sistem Baru Secara Keseluruhan

Diagram arsitektur ini menggunakan sistem pewarnaan aliran untuk membedakan jenis interaksi yang terjadi antar komponen sehingga pembacaan terhadap alur kerja sistem menjadi lebih jelas. Aliran berwarna biru menggambarkan proses internal dan komunikasi tingkat layanan, yaitu interaksi antarmodul di dalam *backend* seperti layanan autentikasi, modul klasifikasi maksud, manajemen dialog, mesin kueri berbasis aturan, serta layanan peramalan. Aliran berwarna oranye merepresentasikan proses pengambilan data dan eksekusi kueri analitik, khususnya komunikasi antara *backend* dan *Enterprise Data Warehouse* melalui sistem koneksi *Oracle* untuk memperoleh data historis maupun metrik operasional yang relevan. Sementara itu, aliran berwarna ungu menunjukkan aliran data lintas lapisan dan propagasi hasil, yaitu bagaimana keluaran analitik dikembalikan ke lapisan logika bisnis untuk diproses lebih lanjut melalui mekanisme templating NLG. Aliran berwarna abu-abu menggambarkan operasi infrastruktur (seperti *logging*, *rate limiting*, pemantauan) yang dikelola oleh unit infrastruktur API guna menjaga keandalan sistem secara menyeluruh. Aliran berwarna merah digunakan untuk menandakan jalur penanganan kesalahan (*error handling*). Melalui pemisahan aliran ini, diagram memberikan representasi yang lebih presisi mengenai bagaimana permintaan dari antarmuka diproses secara *end-to-end*, mulai dari autentikasi, analisis *intent*, eksekusi aturan, perhitungan prediktif, pengambilan data ke EDW, hingga penyusunan dan pengiriman kembali respons kepada pengguna.

Sebagai catatan komprehensif terhadap diagram arsitektur sistem di atas, komponen *Temporal Fusion Transformer* (TFT) dicantumkan pada desain layanan peramalan

sebagai bentuk rancangan sistem prediktif yang holistik. Akan tetapi, implementasi secara teknis pada penelitian ini difokuskan secara eksklusif pada pemodelan LSTM dan GRU. Model TFT diposisikan sebagai landasan teoretis untuk pengembangan iterasi sistem di masa mendatang mengingat tingginya kompleksitas komputasi serta besarnya kebutuhan volume data latih yang dipersyaratkan oleh arsitektur tersebut.

Dalam mencegah terjadinya latensi yang tinggi, aspek waktu respons ditetapkan sebagai salah satu metrik krusial dalam perancangan ini mengingat produk yang dikembangkan beroperasi pada level operasional dan harus mampu memberikan jawaban secara cepat terhadap permintaan analitik harian. Tantangan utama muncul dari karakteristik *Enterprise Data Warehouse* yang menyimpan data dalam volume besar sehingga eksekusi kueri kompleks berpotensi menimbulkan penundaan. Dalam mengatasi hal tersebut, sistem menerapkan mekanisme optimasi, termasuk tembolok tingkat aturan (*rule-level caching*) dengan pendekatan *Time To Live* (TTL) yang memastikan hasil kueri disimpan sementara dan digunakan kembali tanpa perlu mengakses EDW setiap kali pengguna mengajukan permintaan yang sama. Kombinasi dari strategi ini memungkinkan penurunan latensi secara konsisten dan memastikan bahwa sistem tetap responsif dalam konteks penggunaan operasional.

IV.5 Kebutuhan Perangkat dan Lingkungan Sistem

Dalam memastikan bahwa arsitektur yang dirancang dapat diimplementasikan dan direproduksi, sistem memerlukan spesifikasi perangkat lunak dan perangkat keras tertentu yang berfungsi sebagai fondasi dari pengembangan sistem (*environment setup*).

IV.5.1 Perangkat Lunak dan Teknologi

Dalam melakukan implementasi dan pembangunan sistem yang nyata (tidak hanya sekadar rancangan), dibutuhkan beberapa perangkat lunak, pustaka pemrograman (*libraries*), dan teknologi pendukung. Daftar teknologi pada Tabel IV.2 merincikan versi dan fungsi spesifik setiap perangkat dalam sistem *Business Intelligence Chatbot*. Penjabaran ini memastikan bahwa seluruh proses, dari akuisisi data, pelatihan model, hingga rekayasa fitur, dapat ditelusuri dan direproduksi secara akurat.

Tabel IV.2 Perangkat Lunak dan Teknologi Implementasi Sistem

No	Perangkat	Deskripsi
1	Node.js	<i>Runtime</i> JavaScript sisi pelayan yang digunakan sebagai <i>backend</i> utama sistem. Node.js menjalankan Express.js untuk menyediakan <i>RESTful API</i> , mengelola autentikasi pengguna, mengeksekusi mesin aturan (<i>rule engine</i>), serta menghasilkan respons naratif melalui modul NLG berbasis templat JavaScript.
2	Python	Bahasa pemrograman yang digunakan khusus untuk layanan <i>machine learning</i> (<i>ML Service</i>). Python menangani pelatihan dan inferensi model peramalan deret waktu berbasis GRU dan LSTM melalui <i>framework</i> FastAPI.
3	FastAPI	<i>Framework</i> Python untuk membangun <i>RESTful API</i> dengan performa tinggi dan dokumentasi otomatis (Swagger/OpenAPI). FastAPI digunakan khusus untuk layanan <i>machine learning</i> yang menangani permintaan pelatihan dan prediksi model peramalan deret waktu.
4	React.js	Pustaka JavaScript untuk membangun antarmuka pengguna yang interaktif dan responsif. React.js digunakan untuk mengembangkan <i>frontend chatbot</i> berbasis web dengan fitur percakapan, panel peramalan, dan alur terpandu (<i>guided flow</i>).
5	Oracle Database	Basis data relasional yang melayani dua skema terpisah: (1) skema DWH_MOIS sebagai <i>Enterprise Data Warehouse</i> (DWH) yang menyimpan lima tabel domain analitik dengan prefiks BRIGHTAI_ (penjualan, pendapatan, target, proses data pelanggan, dan <i>churn</i>); dan (2) skema USR_RPT yang menyimpan data operasional sistem (tabel pengguna, riwayat percakapan, dan sesi). Koneksi dikelola melalui <i>connection pooling</i> dengan pustaka node-oracledb.

Bersambung ke halaman berikutnya

Tabel IV.2 – Lanjutan dari halaman sebelumnya

No	Perangkat	Deskripsi
6	PyTorch	<i>Framework deep learning</i> utama yang digunakan untuk membangun dan melatih model peramalan deret waktu berbasis GRU dan LSTM. PyTorch dipilih karena fleksibilitas dalam pendefinisian arsitektur model kustom dan kemudahan <i>debugging</i> .
7	Express.js	<i>Framework</i> web minimalis untuk Node.js yang digunakan sebagai fondasi <i>backend</i> utama. Express.js menangani <i>routing</i> , <i>middleware</i> keamanan (Helmet, CORS, <i>rate limiter</i>), serta integrasi dengan mesin aturan dan modul NLG.
8	Pandas	Pustaka Python untuk manipulasi dan analisis data tabular. Pandas digunakan pada tahap <i>data preparation</i> , transformasi fitur, dan agregasi data sebelum proses pelatihan model maupun eksekusi kueri.
9	NumPy	Pustaka Python untuk komputasi numerik yang menjadi fondasi operasi matematika pada pemrosesan data dan perhitungan metrik evaluasi model.
10	Scikit-learn	Pustaka <i>machine learning</i> Python yang digunakan untuk praolah data, ekstraksi fitur, perhitungan metrik evaluasi, dan implementasi model <i>baseline</i> untuk perbandingan performa.
11	node-oracledb	Pustaka Node.js resmi dari Oracle untuk koneksi ke Oracle Database. Pustaka ini mengelola <i>connection pooling</i> , eksekusi kueri SQL, dan penanganan tipe data khusus Oracle seperti CLOB.
12	Regex (JavaScript)	Modul ekspresi reguler bawaan JavaScript yang digunakan untuk implementasi pencocokan pola (<i>pattern matching</i>) dalam klasifikasi maksud berbasis aturan dan ekstraksi konteks geografis dari kueri pengguna.
13	Pustaka Templat JavaScript	Modul templat kustom yang dibangun dalam JavaScript untuk implementasi <i>template-based Natural Language Generation</i> . Modul ini mendukung 38 aturan dengan variasi templat per <i>intent</i> yang diisi secara dinamis berdasarkan data hasil kueri Oracle.

Bersambung ke halaman berikutnya

Tabel IV.2 – Lanjutan dari halaman sebelumnya

No	Perangkat	Deskripsi
14	JWT / bcrypt	Pustaka keamanan yang digunakan untuk autentikasi berbasis <i>JSON Web Token</i> (JWT) dan enkripsi kata sandi menggunakan algoritma <i>bcrypt</i> dengan <i>salt rounds</i> .
15	Git / GitHub	Sistem kontrol versi dan platform kolaborasi yang digunakan untuk manajemen kode sumber, pelacakan perubahan, dan dokumentasi proyek tugas akhir.
16	Jupyter Notebook	Aplikasi <i>open-source</i> yang digunakan untuk eksplorasi data, eksperimen model, dan dokumentasi proses analisis dalam format dokumen interaktif yang menggabungkan kode, visualisasi, dan narasi.
17	Google Colaboratory	Platform <i>cloud</i> dari Google yang menyediakan akses gratis ke GPU untuk pelatihan model <i>deep learning</i> . Google Colab digunakan untuk melatih model peramalan deret waktu yang memerlukan komputasi intensif.
18	Postman	Aplikasi untuk pengujian dan dokumentasi API. Postman digunakan untuk menguji <i>endpoint API backend</i> sistem dan memvalidasi respons sebelum integrasi dengan <i>frontend</i> .
19	Visual Studio Code	<i>Integrated Development Environment</i> (IDE) yang digunakan untuk penulisan kode, <i>debugging</i> , dan manajemen proyek pengembangan sistem.

IV.5.2 Kebutuhan Sumber Daya Komputasi

Dalam mendukung proses pelatihan model *deep learning* dan pengujian arsitektur yang diusulkan, diperlukan sumber daya komputasi yang memadai. Pelatihan model peramalan deret waktu berbasis LSTM dan GRU memerlukan akselerasi GPU untuk mempercepat proses komputasi yang kompleks. Pengembangan sistem ini memanfaatkan Google Colaboratory yang menyediakan akses ke GPU NVIDIA T4 dengan kapasitas 15GB memori GPU.

Dalam tahap implementasi dan peluncuran produk secara langsung (*deployment*), infrastruktur peladen (*server*) dirancang untuk memiliki spesifikasi minimal 4 inti prosesor (*cores*), memori RAM sebesar 16GB, dan penyimpanan berbasis SSD mi-

nimal 100GB guna memastikan aliran data yang cepat tanpa *bottleneck* pada sistem berkas.

IV.6 Desain Pengujian dan Evaluasi

Dalam memastikan bahwa sistem yang dikembangkan memenuhi spesifikasi dari desain arsitektur yang diajukan dan menguji keberhasilan implementasi, dirancang strategi pengujian dan evaluasi. Evaluasi ini mencakup penyelesaian bagian-bagian inti yang paling menantang dari sistem: modul klasifikasi maksud berbasis pola, pembangkitan bahasa alami (NLG), dan performa prediksi deret waktu.

IV.6.1 Evaluasi Klasifikasi Maksud Berbasis Pola

Modul pencocokan kueri ke aturan bisnis dievaluasi menggunakan metrik standar klasifikasi multi-kelas. Sistem mengimplementasikan tujuh kategori *intent* yang dipetakan ke 38 aturan bisnis; evaluasi dilakukan pada level pencocokan aturan (38 kelas) dengan pendekatan *one-vs-all* dan agregasi metrik menggunakan strategi *macro-averaging*, *micro-averaging*, dan *weighted-averaging*.

IV.6.1.1 Metrik Evaluasi Klasifikasi *Intent*

Metrik evaluasi yang digunakan untuk mengukur performa klasifikasi maksud mencakup:

1. Akurasi (*Accuracy*): Proporsi prediksi yang benar dari keseluruhan prediksi. Target minimal adalah 85%.
2. Presisi (*Precision*): Proporsi prediksi positif yang benar dari seluruh prediksi positif. Dihitung per kelas kemudian diagregasi.
3. Daya Ingat (*Recall*): Proporsi sampel positif yang berhasil diprediksi benar dari seluruh sampel positif aktual.
4. Skor-F1 (*F1-Score*): Rata-rata harmonik dari presisi dan daya ingat, memberikan keseimbangan antara kedua metrik.

Formula perhitungan metrik agregasi adalah sebagai berikut.

$$\text{Presisi}_{\text{makro}} = \frac{1}{K} \sum_{i=1}^K \text{Presisi}_i \quad (\text{IV.1})$$

$$\text{Daya Ingat}_{\text{makro}} = \frac{1}{K} \sum_{i=1}^K \text{Daya Ingat}_i \quad (\text{IV.2})$$

$$\text{Skor-F1}_{\text{makro}} = \frac{1}{K} \sum_{i=1}^K \text{Skor-F1}_i \quad (\text{IV.3})$$

dengan K adalah jumlah kelas *intent* dalam sistem.

IV.6.1.2 Analisis Nilai Keyakinan (*Confidence Score*)

Sistem menggunakan mekanisme pemberian nilai keyakinan dalam rentang 0 hingga 100 untuk setiap prediksi klasifikasi maksud. Nilai dihitung melalui fungsi penjumlahan bobot kata kunci primer dan pendukung yang cocok ($c = \min(100, \text{skor} \times 10)$). Ambang batas (*threshold*) ditetapkan pada nilai 40 dengan ketentuan:

1. Jika nilai keyakinan ≥ 40 : Prediksi dianggap valid.
2. Jika nilai keyakinan < 40 : Sistem meminta klarifikasi (*fallback mechanism*).

IV.6.2 Evaluasi Pembangkitan Bahasa Alami Berbasis Templat

Modul *Natural Language Generation* (NLG) dievaluasi dari dua aspek: akurasi faktual dan evaluasi subjektif oleh pengguna internal.

IV.6.2.1 Akurasi Faktual

Akurasi faktual dievaluasi dengan memverifikasi apakah seluruh nilai numerik dan informasi bisnis dalam respons NLG sesuai dengan hasil kueri dari basis data. Karena pendekatan NLG berbasis templat bersifat deterministik dan menyisipkan data langsung dari hasil kueri tanpa proses generatif, akurasi faktual dijamin secara arsitektural (Target: 100%).

IV.6.2.2 Evaluasi Subjektif Berbasis Pengguna

Kualitas keluaran NLG dinilai secara subjektif oleh pengguna internal perusahaan menggunakan kuesioner berskala Likert 1–5 pada empat dimensi utama:

1. Ketepatan Respons: Menilai apakah jawaban yang diberikan sistem sesuai dengan data aktual.
2. Kejelasan Narasi: Menilai apakah narasi, tabel, dan penjelasan yang dihasilkan sistem mudah dipahami.
3. Relevansi Analisis: Menilai apakah *insight* atau analisis yang diberikan sistem relevan dengan konteks pertanyaan pengguna.
4. Kemudahan Penggunaan: Menilai apakah antarmuka dan alur interaksi sistem bersifat intuitif.

IV.6.3 Evaluasi Peramalan Deret Waktu

Model dievaluasi menggunakan protokol *rolling-origin backtesting* untuk mencegah *data leakage*. Evaluasi mencakup *baseline* (ARIMA, Prophet) dan model utama (LSTM, GRU).

1. MAE (*Mean Absolute Error*): Rata-rata nilai absolut selisih prediksi dan aktual.
2. RMSE (*Root Mean Squared Error*): Akar kuadrat rata-rata kuadrat selisih.
3. sMAPE (*Symmetric Mean Absolute Percentage Error*):

$$\text{sMAPE} = \frac{100\%}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \quad (\text{IV.4})$$

4. MASE (*Mean Absolute Scaled Error*):

$$\text{MASE} = \frac{\text{MAE}}{\frac{1}{n-1} \sum_{i=2}^n |y_i - y_{i-1}|} \quad (\text{IV.5})$$

Dalam mengukur peningkatan performa model terhadap garis dasar (*seasonal naive*), dihitung *skill score*:

$$\text{Skill Score} = 1 - \frac{\text{MAE}_{\text{model}}}{\text{MAE}_{\text{baseline}}} \quad (\text{IV.6})$$

BAB V

IMPLEMENTASI SISTEM *BUSINESS INTELLIGENCE* *CHATBOT*

Bab ini menyajikan implementasi sistem *Business Intelligence* berbasis *rule-based chatbot* yang telah dirancang pada bab sebelumnya. Pembahasan mencakup arsitektur sistem yang diimplementasikan, implementasi setiap komponen utama, serta integrasi antar-komponen menjadi satu kesatuan sistem yang fungsional.

V.1 Arsitektur Sistem Terimplementasi

Sistem BrightAI diimplementasikan dengan arsitektur tiga lapis (*three-tier architecture*) yang memisahkan tanggung jawab setiap komponen secara jelas. Ketiga lapis tersebut adalah sebagai berikut.

1. *Frontend (React.js)*: Antarmuka pengguna berbasis web yang menyediakan fitur percakapan *chatbot*, panel peramalan, dan manajemen profil pengguna. *Frontend* berjalan pada porta 3000 dan berkomunikasi dengan *backend* melalui *RESTful API*.
2. *Backend (Node.js/Express)*: Peladen utama yang menangani autentikasi, manajemen sesi, eksekusi mesin aturan (*rule engine*), klasifikasi maksud (*intent classification*), pembangkitan bahasa alami (NLG), serta komunikasi dengan basis data Oracle. *Backend* berjalan pada porta 3001.
3. Layanan *Machine Learning (FastAPI/PyTorch)*: Layanan terpisah yang menangani pelatihan dan inferensi model peramalan deret waktu berbasis GRU dan LSTM. Layanan ini berjalan pada porta 8000 dan diakses oleh *backend* melalui permintaan HTTP internal.

Ketiga lapis terhubung ke Oracle Database yang berfungsi ganda melalui dua skema terpisah: (1) skema DWH_MOIS sebagai *Enterprise Data Warehouse* (DWH) yang menyimpan lima tabel domain analitik dengan prefiks BRIGHTAI_ (BRIGHTAI_SALES, BRIGHTAI_REVENUE, BRIGHTAI_TARGET, BRIGHTAI_DAPROS, BRIGHTAI_CTO_NAL); dan (2) skema USR_RPT yang menyimpan data operasional sistem, meliputi tabel pengguna (BRIGHTAI_USER), riwayat percakapan (BRIGHTAI_CHAT), dan sesi (BRIGHTAI_SESSION).

V.2 Implementasi *Backend* (Node.js/Express)

Backend sistem diimplementasikan menggunakan Node.js dengan *framework* Express.js sebagai fondasi *RESTful API*. Berkas utama `server.js` menginisialisasi aplikasi Express, mengonfigurasi *middleware*, mendaftarkan rute API, serta mengelola siklus hidup koneksi basis data.

V.2.1 Struktur Proyek *Backend*

Proyek *backend* diorganisasi menggunakan pola arsitektur MVC (*Model-View-Controller*) yang dimodifikasi menjadi struktur berlapis. Tabel V.1 menyajikan struktur direktori utama.

Tabel V.1 Struktur Direktori Proyek *Backend*

Direktori/Berkas	Fungsi
<code>server.js</code>	Titik masuk utama aplikasi: inisialisasi Express, <i>middleware</i> , rute, dan koneksi basis data
<code>config/database.js</code>	Konfigurasi koneksi Oracle Database, <i>connection pooling</i> , dan eksekutor kueri
<code>src/controllers/</code>	Penangan permintaan (<i>request handler</i>): <code>authController.js</code> dan <code>chatController.js</code>
<code>src/models/</code>	Model data untuk pengguna, riwayat percakapan, dan sesi
<code>src/routes/</code>	Definisi rute API: autentikasi, <i>chat</i> , sesi, dan peramalan
<code>src/rules/engine/</code>	Mesin aturan, klasifikasi maksud, pemroses kueri, dan pembangkit bahasa alami
<code>src/rules/databases/</code>	Definisi aturan per domain basis data
<code>src/rules/config/</code>	Registri aturan dan konfigurasi pemetaan tabel
<code>src/middleware/</code>	<i>Middleware</i> autentikasi JWT dan penanganan kesalahan
<code>src/utils/</code>	Utilitas: <i>logger</i> , <i>cache</i> , dan fungsi pembantu

V.2.2 Konfigurasi *Middleware* Keamanan

Sistem mengimplementasikan beberapa lapisan *middleware* keamanan pada Express.js untuk melindungi API dari ancaman umum. Konfigurasi *middleware* yang diterapkan mencakup:

1. Helmet: Mengatur tajuk HTTP keamanan (*security headers*) untuk mencegah serangan seperti *Cross-Site Scripting* (XSS) dan *clickjacking*.

2. *CORS (Cross-Origin Resource Sharing)*: Mengizinkan permintaan lintas-asal dari *frontend* yang berjalan pada domain berbeda.
3. *Rate Limiter*: Membatasi jumlah permintaan per alamat IP menjadi maksimal 100 permintaan per 15 menit untuk mencegah serangan *brute force* dan *Denial of Service (DoS)*.
4. Pembatasan Ukuran *Payload*: Membatasi ukuran badan permintaan JSON menjadi maksimal 10 MB.

V.2.3 Koneksi Oracle Database

Koneksi ke Oracle Database dikelola melalui modul `config/database.js` menggunakan pustaka `node-oracledb`. Satu *connection pool* melayani akses ke kedua skema: DWH_MOIS untuk kueri analitik dan USR_RPT untuk operasi autentikasi serta manajemen sesi. Konfigurasi *pool* disajikan pada Tabel V.2.

Tabel V.2 Konfigurasi *Connection Pool* Oracle Database

Parameter	Nilai	Keterangan
poolMin	2	Jumlah koneksi minimum yang dipertahankan
poolMax	10	Jumlah koneksi maksimum yang diizinkan
poolIncrement	1	Penambahan koneksi per permintaan baru
connectTimeout	10 detik	Batas waktu koneksi awal

Modul ini juga menyediakan fungsi `executeQuery` yang menangani eksekusi kueri SQL dengan format keluaran objek (`OUT_FORMAT_OBJECT`), penanganan tipe data CLOB secara otomatis, serta penutupan koneksi yang aman melalui blok `finally`. Setiap baris hasil kueri yang mengandung CLOB diproses secara asinkron menggunakan *stream* untuk mencegah kebocoran memori.

V.2.4 Rute API (*API Routes*)

Backend menyediakan empat kelompok rute API utama yang disajikan pada Tabel V.3.

Tabel V.3 Rute API Sistem BrightAI

Metode	<i>Endpoint</i>	Fungsi
POST	<code>/api/auth/register</code>	Registrasi pengguna baru
POST	<code>/api/auth/login</code>	Autentikasi dan penerbitan token JWT
GET	<code>/api/auth/profile</code>	Mengambil profil pengguna (memerlukan token)

Metode	Endpoint	Fungsi
PUT	/api/auth/profile	Memperbarui profil pengguna
PUT	/api/auth/password	Mengubah kata sandi
POST	/api/chat/message	Mengirim pesan ke <i>chatbot</i> dan menerima respons
GET	/api/chat/history	Mengambil riwayat percakapan pengguna
GET	/api/chat/session/:id	Mengambil pesan dalam satu sesi percakapan
DELETE	/api/chat/history	Menghapus riwayat percakapan
GET	/api/chat/capabilities	Mengambil daftar kemampuan dan aturan yang tersedia
GET	/api/sessions	Mengambil daftar sesi percakapan
POST	/api/forecast/*	Meneruskan permintaan peramalan ke layanan ML
GET	/api/telkom/health	Pemeriksaan kesehatan (<i>health check</i>) sistem

V.3 Implementasi Mesin Aturan (*Rule Engine*)

Mesin aturan merupakan komponen inti yang menghubungkan pertanyaan pengguna dengan kueri basis data dan respons naratif. Implementasi mesin aturan terdiri dari empat modul utama yang bekerja secara berurutan.

V.3.1 Arsitektur Mesin Aturan

Alur pemrosesan kueri dalam mesin aturan mengikuti tahapan sebagai berikut.

1. Penerimaan Kueri: Modul `chatController.js` menerima pesan pengguna dan memeriksa apakah pesan tersebut merupakan sapaan, permintaan bantuan, atau kueri analitik.
2. Pencocokan Aturan: Modul `queryProcessor.js` mencocokkan kueri pengguna dengan aturan yang tersedia menggunakan pencocokan pola kata kunci.
3. Eksekusi Aturan: Modul `ruleEngine.js` mengeksekusi kueri SQL yang terkait dengan aturan yang cocok terhadap Oracle Database, dengan injeksi filter geografis secara dinamis.
4. Pembangunan Respons: Modul `responseBuilder.js` dan `nlgGenerator.js` mengonversi hasil kueri menjadi narasi dalam bahasa Indonesia.

V.3.2 Struktur Definisi Aturan

Setiap aturan didefinisikan sebagai objek JavaScript yang memiliki struktur terstandar. Komponen utama setiap aturan disajikan pada Tabel V.4.

Tabel V.4 Komponen Struktur Definisi Aturan

Komponen	Deskripsi
RULE_META	Metadata aturan: identifikasi (RULE_ID), nama, deskripsi, domain basis data, kategori, dan prioritas eksekusi
KEYWORDS	Daftar kata kunci dan pola yang digunakan untuk mencocokkan kueri pengguna dengan aturan
SQL_QUERY	Kueri SQL yang dieksekusi terhadap <i>Enterprise Data Warehouse</i> Oracle (skema DWH_MOIS)
DATABASE_CONFIG	Konfigurasi tabel dan koneksi basis data yang digunakan oleh aturan
BUSINESS_LOGIC	Fungsi pemrosesan logika bisnis, termasuk format <i>IndonesianResponse</i> untuk mengubah data mentah menjadi struktur terformat
CACHE_DURATION	Durasi penyimpanan hasil kueri dalam <i>cache</i> (dalam detik)

Sistem mendukung 38 aturan analitik yang tersebar di lima tabel domain pada skema DWH_MOIS, yaitu BRIGHTAI_SALES, BRIGHTAI_REVENUE, BRIGHTAI_TARGET, BRIGHTAI_DAPROS, dan BRIGHTAI_CTO_NAL. *Listing V.1* menyajikan contoh implementasi struktur definisi aturan secara lengkap.

Listing V.1 Contoh Struktur Definisi Aturan Analitik

```
1 module.exports = {
2   RULE_META: {
3     RULE_ID: 'ps_001',
4     RULE_NAME: 'total_order_hsi',
5     DESCRIPTION: 'Analisis total order HSI bisnis dan basic',
6     DATABASE: 'BRIGHTAI_SALES',
7     CATEGORY: 'order_analysis',
8     COMPLEXITY: 'MEDIUM',
9     EXECUTION_PRIORITY: 'HIGH'
10  },
11
12  DATABASE_CONFIG: loadRuleDatabase("BRIGHTAI_SALES"),
13
14  KEYWORD_PATTERNS: {
15    primary: [
16      'total order hsi', 'jumlah order', 'order hsi bisnis'
17    ],
18  },
19 }
```

```

18     supporting: [
19         'order', 'hsi', 'bisnis', 'basic', 'bulanan'
20     ],
21     calculateConfidence: function(input) {
22         const lowerInput = input.toLowerCase();
23         const primaryMatches = this.primary.filter(
24             kw => lowerInput.includes(kw)
25         ).length;
26         const supportingMatches = this.supporting.filter(
27             kw => lowerInput.includes(kw)
28         ).length;
29         if (primaryMatches > 0)
30             return Math.min(80 + primaryMatches*10
31                             + supportingMatches*3, 100);
32         if (supportingMatches >= 3)
33             return 65 + supportingMatches * 4;
34         return 0;
35     }
36 },
37
38 SQL_QUERY: `SELECT ... FROM DWH_MOIS.BRIGHTAI_SALES
39             WHERE GROUP4 = 'High Speed Internet' ...`,
40
41 BUSINESS_LOGIC: {
42     formatIndonesianResponse: function(data) {
43         // Mengubah data mentah menjadi struktur terformat
44         return { ringkasan: '...', metrik: {...} };
45     }
46 }
47 };

```

V.3.3 Injeksi Filter Geografis

Mesin aturan mengimplementasikan fitur injeksi filter geografis secara dinamis ke dalam kueri SQL pada saat eksekusi. Fitur ini memungkinkan pengguna menyaring data berdasarkan regional atau wilayah telekomunikasi (*witel*) tanpa memerlukan aturan terpisah untuk setiap wilayah. Mekanisme injeksi mendukung dua mode:

1. Mode Penampung (*placeholder*): Jika kueri SQL mengandung penanda `/* :GEO_FILTER: */`, penanda tersebut diganti dengan klausa filter yang sesuai.
2. Mode Injeksi Otomatis: Jika tidak ada penanda, sistem melakukan pemindaian baris demi baris untuk menemukan blok `FROM DWH_MOIS` dan menyisipkan klausa filter pada posisi yang tepat sebelum `GROUP BY` atau penutup subkueri.

Dalam membedah mekanisme tersebut, Algoritma V.1 merinci prosedur tahap awal

yang mengekstraksi intensi cakupan geografis dari pertanyaan pengguna. Proses ini diawali dengan pengecekan hierarkis mulai dari kata kunci tingkat nasional hingga pencocokan struktur *witel*.

Algoritma V.1 Injeksi Filter Geografis ke dalam Kueri SQL (Bagian 1)

Require: Masukan pengguna q , kueri SQL S , basis data D , pemetaan kolom C

Ensure: Kueri SQL dengan filter geografis S'

```

1:  $q_{\text{lower}} \leftarrow \text{toLowerCase}(q)$ 
2: // Tahap 1: Deteksi cakupan geografis
3: if  $q_{\text{lower}}$  mengandung kata kunci nasional then
4:   return  $S$  ▷ Tidak diperlukan filter — cakupan nasional
5: end if
6:  $\text{scope} \leftarrow \text{null}$ ,  $\text{dbValue} \leftarrow \text{null}$ 
7: for setiap pola  $p$  dalam REGIONAL_PATTERNS do
8:   if  $q_{\text{lower}}$  mengandung  $p.\text{pattern}$  then
9:      $\text{scope} \leftarrow \text{"regional"}$ ,  $\text{dbValue} \leftarrow p.\text{dbValue}$ 
10:    break
11:   end if
12: end for
13: if  $\text{scope} = \text{null}$  then
14:   for setiap pola  $p$  dalam WITEL_PATTERNS do
15:     if  $q_{\text{lower}}$  mengandung  $p.\text{pattern}$  then
16:        $\text{scope} \leftarrow \text{"witel"}$ ,  $\text{dbValue} \leftarrow p.\text{dbValue}$ 
17:       break
18:     end if
19:   end for
20: end if
21: if  $\text{scope} = \text{null}$  atau  $\text{dbValue} = \text{null}$  then
22:   return  $S$  ▷ Tidak ada entitas geografis yang terdeteksi
23: end if
24: // Tahap 2: Tentukan nama kolom sesuai basis data
25:  $\text{cols} \leftarrow C[D]$  ▷ Ambil pasangan {regional, witel} untuk  $D$ 
26:  $\text{colName} \leftarrow \text{cols}[\text{scope}]$ 
27:  $\text{filterClause} \leftarrow \text{"AND " || colName || " = " || dbValue || " "}$ 

```

Bagian pertama algoritma di atas mendemonstrasikan proses deteksi cakupan geografis dari teks masukan pengguna. Sistem melakukan pencocokan terhadap daftar referensi regional dan *witel* untuk mengonstruksi klausa filter secara dinamis.

Setelah klausa filter berhasil dibentuk, tahap berikutnya adalah mengimplementasikan penyisipan sintaks tersebut ke dalam badan SQL asli, yang diuraikan pada bagian kedua algoritma berikut ini.

Eksekusi modifikasi SQL pada algoritma di atas merepresentasikan kemampuan sis-

Algoritma V.2 Injeksi Filter Geografis ke dalam Kueri SQL (Bagian 2)

```
28: // Tahap 3: Injeksikan filter ke dalam SQL
29: if  $S$  mengandung /* :GEO_FILTER: */ then
30:    $S' \leftarrow S.replace("/* :GEO_FILTER: */", filterClause)$ 
31:   return  $S'$ 
32: end if
33: // Tahap 3b: Injeksi otomatis jika tidak ada placeholder
34: Cari indeks baris FROM DWH_MOIS pertama dalam  $S \rightarrow i_{from}$ 
35: if  $i_{from} = -1$  then
36:   return  $S$ 
37: end if
38: Cari indeks klausa WHERE setelah  $i_{from} \rightarrow i_{where}$ 
39: if  $i_{where} = -1$  then
40:   return  $S$ 
41: end if
42: Pindai baris dari  $i_{where}$ , lacak kedalaman tanda kurung  $d \leftarrow 0$ 
43: for setiap baris  $\ell$  dari  $i_{where}$  hingga akhir  $S$  do
44:   Perbarui  $d$  berdasarkan karakter ( dan ) dalam  $\ell$ 
45:   if  $d < 0$  atau ( $d = 0$  dan  $\ell$  dimulai dengan GROUP BY/ORDER BY/HAVING)
     then
46:     Sisipkan filterClause sebelum baris  $\ell$  dengan indentasi yang sama
47:     return  $S'$ 
48:   end if
49: end for
50: return  $S$ 
```

tem dalam menyisipkan klausa WHERE tambahan secara terprogram. Penggunaan pencarian *placeholder* serta pemindaian leksikal mendalam memastikan integritas logika basis data tetap terjaga. Melalui arsitektur ini, *dashboard* percakapan dijamin hanya menarik dan merender analisis agregat untuk geografi yang relevan dan memiliki hak akses, mewujudkan prinsip isolasi wilayah fungsional.

V.3.4 Mekanisme *Caching*

Hasil eksekusi aturan disimpan dalam *cache* memori menggunakan kunci yang dihasilkan dari *hash* MD5 kombinasi kueri pengguna dan konteks geografis. Setiap entri *cache* memiliki durasi kedaluwarsa yang ditentukan oleh konfigurasi aturan (nilai bawaan: 1800 detik atau 30 menit). Mekanisme ini mengurangi beban kueri terhadap Oracle Database untuk pertanyaan yang sering diajukan.

V.4 Implementasi Klasifikasi Maksud (*Intent Classification*)

Modul klasifikasi maksud diimplementasikan dalam berkas `intentClassifier.js` menggunakan pendekatan pencocokan pola kata kunci berbobot (*weighted keyword matching*). Pendekatan ini dipilih karena memberikan latensi rendah (kurang dari 1 milidetik per kueri), interpretabilitas tinggi, dan kemampuan untuk bekerja dengan baik pada domain yang terbatas dan terdefinisi.

V.4.1 Arsitektur Klasifikasi

Sistem mengklasifikasikan setiap kueri pengguna ke dalam dua dimensi: *intent* (maksud) dan *focus* (fokus analisis). Tabel V.5 menyajikan daftar *intent* yang diimplementasikan beserta contoh kata kunci.

Tabel V.5 Daftar *Intent* yang Diimplementasikan

<i>Intent</i>	Bobot	Contoh Kata Kunci
<i>quantity</i>	3	berapa, jumlah, total, volume, angka
<i>trend</i>	3	tren, pertumbuhan, naik, turun, MoM, YoY
<i>comparison</i>	3	bandingkan, vs, perbedaan, lebih tinggi
<i>location</i>	3	di mana, regional, witel, wilayah
<i>reason</i>	4	kenapa, mengapa, penyebab, faktor
<i>performance</i>	3	performa, kinerja, pencapaian, target
<i>detail</i>	2	rincian, <i>breakdown</i> , distribusi, segmentasi
<i>general</i>	–	<i>Fallback</i> jika tidak ada kata kunci yang cocok

V.4.2 Algoritma Perhitungan Skor

Dalam setiap kueri, sistem menghitung skor kecocokan terhadap setiap *intent* dengan mengiterasi daftar kata kunci. Jika sebuah kata kunci ditemukan dalam kueri (menggunakan fungsi `String.includes`), skor *intent* tersebut ditambah sebesar nilai bobot. *Intent* dengan skor tertinggi dipilih sebagai hasil klasifikasi, dengan nilai keyakinan (*confidence*) dihitung sebagai $\min(100, \text{skor} \times 10)$. Jika seluruh skor bernilai nol, sistem mengembalikan *intent* general sebagai *fallback*.

Selain *intent*, sistem juga mengklasifikasikan fokus analisis ke dalam delapan kategori: *order*, *revenue*, *churn*, *fulfillment*, *subscriber*, *bundling*, *digital*, dan *target*. Kombinasi *intent* dan fokus analisis ini digunakan secara sinergis oleh modul pembangkitan bahasa alami (NLG) untuk memilih templat respons yang paling sesuai dengan konteks percakapan. Listing V.2 menunjukkan secara nyata implementasi inti dari proses pencocokan aturan pada kelas *query processor*.

Listing V.2 Pencocokan Aturan pada *Query Processor*

```
1 class QueryProcessor {
2   async findMatchingRule(userInput, rulesMap) {
3     const rules = Array.from(rulesMap.values());
4     const matches = [];
5
6     for (const rule of rules) {
7       if (rule.PATTERN_MATCHING && rule.PATTERN_MATCHING.
8         checkMatch) {
9         const matchResult = rule.PATTERN_MATCHING.checkMatch(
10          userInput);
11         if (matchResult.matches && matchResult.confidence >= 40) {
12           matches.push({
13             rule: rule,
14             confidence: matchResult.confidence,
15             focus_area: matchResult.focus_area
16           });
17         }
18       }
19     }
20
21     if (matches.length === 0) {
22       return { success: false, reason: 'no_matching_rule' };
23     }
24
25     // Pilih aturan dengan tingkat keyakinan tertinggi
26     matches.sort((a, b) => b.confidence - a.confidence);
```

```

25     const bestMatch = matches[0];
26
27     return {
28         success: true,
29         rule: bestMatch.rule,
30         confidence: bestMatch.confidence,
31         focus_area: bestMatch.focus_area,
32         alternatives: matches.slice(1, 3)
33     };
34 }
35 }

```

Dalam mengikat seluruh alur komputasi di atas, diperlukan sebuah algoritma sekuensial yang merangkum keseluruhan mekanisme klasifikasi. Algoritma V.3 mendeskripsikan prosedur tersebut secara formal, mulai dari penerimaan masukan, iterasi pencocokan pola, hingga penentuan maksud dan fokus akhir.

Dengan adanya algoritma yang terstruktur ini, modul pemroses kueri dapat membedakan berbagai bentuk pertanyaan pengguna dan memetakannya secara akurat ke dalam format yang dimengerti oleh sistem basis data dan mesin analitik.

V.5 Implementasi Pembangkitan Bahasa Alami (NLG)

Modul pembangkitan bahasa alami (NLG) diimplementasikan dalam dua berkas utama: `nlgGenerator.js` untuk orkestrasi proses dan `templateLibrary.js` untuk penyimpanan templat respons. Modul ini menghasilkan narasi dalam bahasa Indonesia berformat *Markdown* yang siap ditampilkan pada antarmuka *chatbot*.

V.5.1 Alur Pembangkitan Respons

Proses pembangkitan respons NLG mengikuti empat tahapan berurutan:

1. Ekstraksi Konteks: Fungsi `extractCtx` mengekstraksi informasi kontekstual dari data terstruktur hasil kueri, meliputi periode analisis, nilai utama, pertumbuhan MoM/YoY, distribusi produk, metrik pelanggan, dan wawasan bisnis.
2. Klasifikasi *Intent*: Modul `intentClassifier` mengklasifikasikan *intent* dan fokus dari pertanyaan asli pengguna.
3. Pemilihan Templat: Fungsi `getTemplate` dari `templateLibrary` memilih templat yang sesuai berdasarkan *intent* yang teridentifikasi. Setiap *intent* memiliki minimal tiga variasi templat.
4. Pengisian Data: Templat yang terpilih diisi dengan data faktual dari konteks. Seluruh angka diformat menggunakan *locale* Indonesia (`id-ID`).

Algoritma V.3 Klasifikasi Maksud Berbasis Pencocokan Pola Kata Kunci
Berbobot

Require: Kueri pengguna q , himpunan intent $\mathcal{I}$ dengan kata kunci dan bobot w_i , himpunan fokus $\mathcal{F}$

Ensure: Intent terpilih $\hat{i}$, nilai keyakinan c , fokus analisis $\hat{f}$

```
1:  $q_{\text{lower}} \leftarrow \text{toLowerCase}(q)$ 
2: Inisialisasi skor  $s_i \leftarrow 0$  untuk setiap  $i \in \mathcal{I}$ 
3: for setiap intent  $i \in \mathcal{I}$  do
4:   for setiap kata kunci  $kw \in \text{keywords}(i)$  do
5:     if  $kw \subseteq q_{\text{lower}}$  then
6:        $s_i \leftarrow s_i + w_i$ 
7:     end if
8:   end for
9: end for
10:  $\hat{i} \leftarrow \arg \max_{i \in \mathcal{I}} s_i$ 
11: if  $\max_i s_i = 0$  then
12:    $\hat{i} \leftarrow \text{general}$   $\triangleright$  Fallback jika tidak ada kata kunci yang cocok
13: end if
14:  $c \leftarrow \min(100, \max_i s_i \times 10)$ 
15: Inisialisasi skor fokus  $f_j \leftarrow 0$  untuk setiap  $j \in \mathcal{F}$ 
16: for setiap fokus  $j \in \mathcal{F}$  do
17:   for setiap kata kunci  $kw \in \text{keywords}(j)$  do
18:     if  $kw \subseteq q_{\text{lower}}$  then
19:        $f_j \leftarrow f_j + 1$ 
20:     end if
21:   end for
22: end for
23:  $\hat{f} \leftarrow \arg \max_{j \in \mathcal{F}} f_j$ 
24: return  $\hat{i}, c, \hat{f}$ 
```

V.5.2 Peta Subjek Aturan

Modul NLG mendefinisikan peta subjek (RULE_SUBJEK) yang memetakan setiap RULE_ID ke deskripsi subjek dalam bahasa Indonesia. Tabel V.6 menyajikan sebagian contoh pemetaan subjek.

Tabel V.6 Contoh Pemetaan Subjek Aturan

RULE_ID	Subjek dalam Bahasa Indonesia
ps_001	Total <i>order</i> HSI (Bisnis dan Basic)
ps_002	<i>Order</i> HSI berdasarkan distribusi regional
mart_001	Tren <i>revenue</i> layanan HSI
target_001	Realisasi HSI terhadap target
ct0_001	<i>Churn</i> pelanggan HSI (CT0)
dapros_001	Distribusi geografis pelanggan HSI

Kode templat di atas memastikan keseragaman penyajian laporan bisnis, dengan format respons telah dibakukan agar selaras dengan kebutuhan baca pengguna operasional di berbagai domain.

V.5.3 Format Keluaran

Respons NLG dihasilkan dalam format *Markdown* yang mendukung:

1. Judul dan subjudul hierarkis (##, ###)
2. Tabel data dengan tajuk kolom dan pemisah
3. Poin-poin (*bullet points*) untuk wawasan bisnis dan rekomendasi
4. Angka diformat sesuai konvensi Indonesia (titik sebagai pemisah ribuan, koma sebagai pemisah desimal)
5. Penanda sumber data, jumlah rekaman, dan waktu pemrosesan pada bagian akhir respons

Akurasi faktual dijamin sebesar 100% karena seluruh angka dalam respons berasal langsung dari hasil kueri Oracle Database tanpa melalui proses halusinasi teks generatif. *Listing* V.3 secara teknis menyajikan implementasi kelas dan fungsi utama yang bertanggung jawab merajut data basis data menjadi laporan *Markdown* yang komprehensif.

Listing V.3 Fungsi Pembangkitan Respons NLG

```
1 async generateResponse(ruleResult, rule, userInput, geoCtx) {
2   // 1. Ekstraksi konteks dari data terstruktur
3   const data = ruleResult.processed_data || ruleResult.data;
4   const ctx  = this.extractCtx(data, rule.RULE_META);
5
6   // 2. Klasifikasi intent dan fokus analisis
```

```

7  const intent = intentClassifier.classifyIntent(userInput);
8  ctx.intent = intent.intent;
9  ctx.focus = intent.focus;
10 ctx.subjek = RULE_SUBJEK[rule.RULE_META.RULE_ID]
11           || 'analisis data HSI';
12
13 // 3. Pemilihan templat berdasarkan intent
14 const template = templateLibrary.getTemplate(
15   ctx.intent, ctx
16 );
17
18 // 4. Pengisian data ke dalam templat
19 let response = template
20   .replace(/{\subjek}/g, ctx.subjek)
21   .replace(/{\periode}/g, ctx.periode)
22   .replace(/{\mainValue}/g, ctx.mainValue)
23   .replace(/{\mainLabel}/g, ctx.mainLabel)
24   .replace(/{\geo}/g, ctx.geoLabel);
25
26 // Tambahkan tabel data jika tersedia
27 if (ctx.breakdown) {
28   response += this.buildMarkdownTable(ctx.breakdown);
29 }
30
31 return response;
32 }

```

Dalam memberikan gambaran operasional yang holistik, prosedur dari pembentukan konteks hingga pemilihan frasa dijelaskan secara formal melalui sebuah algoritma deterministik. Algoritma V.4 mendeskripsikan prosedur lengkap pembangkitan respons mulai dari ekstraksi konteks terstruktur hingga produksi narasi akhir berbahasa Indonesia.

Dengan penerapan algoritma tersebut, sistem terbukti mampu menyajikan narasi bisnis yang bervariasi tanpa mengorbankan akurasi data analitik maupun konsistensi format pelaporan.

V.6 Implementasi Layanan *Machine Learning*

Layanan *machine learning* diimplementasikan sebagai layanan mikro (*microservice*) terpisah menggunakan Python dengan *framework* FastAPI dan pustaka PyTorch untuk pemodelan.

Algoritma V.4 Pembangkitan Respons Berbasis Templat (*Template-Based NLG*)

Require: Kueri pengguna q , data hasil kueri R , aturan r , jumlah rekaman n , waktu eksekusi t

Ensure: Respons naratif dalam bahasa Indonesia $\hat{T}$

```
1: // Tahap 1: Ekstraksi konteks terstruktur
2:  $ctx \leftarrow \text{extractCtx}(R, r, n, t)$   $\triangleright$  Populasi bidang: periode, mainValue,
   breakdown, growth, insights, dll.
3: // Tahap 2: Klasifikasi maksud kueri
4:  $(\hat{i}, c, \hat{f}) \leftarrow \text{classify}(q)$   $\triangleright$  Lihat Algoritma V.3
5: // Tahap 3: Pemilihan varian templat secara deterministik
6:  $\mathcal{V} \leftarrow \text{TEMPLATES}[\hat{i}]$   $\triangleright$  Ambil daftar varian untuk intent  $\hat{i}$ 
7: if  $\mathcal{V} = \emptyset$  then
8:    $\mathcal{V} \leftarrow \text{TEMPLATES}["\text{general}"]$ 
9: end if
10:  $h \leftarrow \sum_{c_j \in q} \text{charCode}(c_j)$   $\triangleright$  Hash aditif karakter kueri
11:  $k \leftarrow h \bmod |\mathcal{V}|$ 
12:  $\varphi \leftarrow \mathcal{V}[k]$   $\triangleright$  Varian terpilih — deterministik untuk masukan yang sama
13: // Tahap 4: Rendering templat
14:  $\hat{T} \leftarrow \varphi(ctx)$   $\triangleright$  Panggil fungsi templat dengan konteks terstruktur
15: return  $\hat{T}$ 
```

V.6.1 Struktur Proyek Layanan ML

Tabel V.7 menyajikan struktur direktori layanan *machine learning*.

Struktur *endpoints* yang tersusun rapi tersebut tidak hanya menjamin abstraksi layanan, tetapi juga memisahkan tanggung jawab antara lapisan aplikasi antarmuka dan lapisan komputasi analitik, sejalan dengan prinsip mikroservis.

V.6.2 Implementasi Model GRU dan LSTM

Model GRU dan LSTM diimplementasikan sebagai kelas Python yang mewarisi `torch.nn.Module`. Kedua model memiliki arsitektur yang serupa dengan perbedaan utama pada jenis sel berulang (*recurrent cell*) yang digunakan. Arsitektur setiap model terdiri dari:

1. Lapisan Berulang: GRU menggunakan `nn.GRU` dan LSTM menggunakan `nn.LSTM`, masing-masing dengan 2 lapisan bertumpuk (*stacked layers*) dan ukuran *hidden state* sebesar 64 unit.
2. Lapisan *Dropout*: Regularisasi dengan tingkat *dropout* 0,2 diterapkan setelah lapisan berulang untuk mencegah *overfitting*.
3. Lapisan Linear Keluaran: Lapisan `nn.Linear` yang memetakan *hidden state* terakhir ke dimensi horizon prediksi.

Tabel V.7 Struktur Direktori Layanan *Machine Learning*

Direktori/Berkas	Fungsi
main.py	Titik masuk FastAPI: konfigurasi aplikasi, CORS, dan siklus hidup
config.py	Konfigurasi: kredensial Oracle, <i>hyperparameter</i> bawaan, jalur penyimpanan model
routers/forecast.py	Rute API untuk pelatihan dan prediksi
models/gru_model.py	Definisi arsitektur GRU menggunakan <code>torch.nn</code>
models/lstm_model.py	Definisi arsitektur LSTM menggunakan <code>torch.nn</code>
training/trainer.py	<i>Pipeline</i> pelatihan dengan <i>walk-forward validation</i>
inference/predictor.py	<i>Pipeline</i> inferensi untuk prediksi waktu nyata
utils/preprocessing.py	Normalisasi data, pembuatan <i>sliding window</i> , dan pembagian data
utils/metrics.py	Perhitungan metrik evaluasi: MAE, RMSE, sMAPE, MASE, <i>Skill Score</i>
saved_models/	Penyimpanan model terlatih (.pth) dan <i>scaler</i> (.pkl)

Kedua model dirancang untuk menerima matriks masukan berdimensi (*batch*, *window_size*, 1) dan mereduksinya menjadi representasi peramalan berukuran (*batch*, *horizon*). Sebagai representasi pertama dari rancangan tersebut, *Listing V.4* menyajikan implementasi kode dari arsitektur GRU. Komponen ini menitikberatkan pada efisiensi komputasi dengan memanfaatkan gerbang pembaruan (*update gate*) dan gerbang atur ulang (*reset gate*) secara terintegrasi untuk mengendalikan aliran memori sekuensial.

Listing V.4 Implementasi Arsitektur Model GRU

```

1 import torch
2 import torch.nn as nn
3
4 class GRUForecaster(nn.Module):
5     def __init__(
6         self,
7         input_size: int = 1,
8         hidden_size: int = 64,
9         num_layers: int = 2,
10        dropout: float = 0.2,
11        horizon: int = 1,
12    ):
13        super().__init__()
14        self.gru = nn.GRU(
15            input_size=input_size,
16            hidden_size=hidden_size,

```

```

17         num_layers=num_layers,
18         batch_first=True,
19         dropout=dropout if num_layers > 1 else 0.0,
20     )
21     self.dropout = nn.Dropout(dropout)
22     self.fc = nn.Linear(hidden_size, horizon)
23
24     def forward(self, x: torch.Tensor) -> torch.Tensor:
25         out, _ = self.gru(x)                # (batch, seq, hidden)
26         out = self.dropout(out[:, -1, :])    # timestep terakhir
27         return self.fc(out)                  # (batch, horizon)

```

Berbeda dengan kesederhanaan struktural yang ditawarkan oleh mekanisme pembaruan GRU, arsitektur LSTM menghadirkan tingkat kendali memori yang lebih presisi melalui tambahan status sel (*cell state*) yang beroperasi secara berdampingan dengan status tersembunyi (*hidden state*). Konstruksi lapisan ini secara spesifik diuraikan pada *Listing V.5*, menunjukkan inisialisasi memori ganda yang krusial untuk mitigasi peluruhan gradien (*vanishing gradient*) pada deret waktu berdurasi panjang.

Listing V.5 Implementasi Arsitektur Model LSTM

```

1 import torch
2 import torch.nn as nn
3
4 class LSTMForecaster(nn.Module):
5     def __init__(
6         self,
7         input_size: int = 1,
8         hidden_size: int = 64,
9         num_layers: int = 2,
10        dropout: float = 0.2,
11        horizon: int = 1,
12    ):
13        super().__init__()
14        self.lstm = nn.LSTM(
15            input_size=input_size,
16            hidden_size=hidden_size,
17            num_layers=num_layers,
18            batch_first=True,
19            dropout=dropout if num_layers > 1 else 0.0,
20        )
21        self.dropout = nn.Dropout(dropout)
22        self.fc = nn.Linear(hidden_size, horizon)

```

```

23
24     def forward(self, x: torch.Tensor) -> torch.Tensor:
25         out, _ = self.lstm(x)                # (batch, seq, hidden)
26         out = self.dropout(out[:, -1, :])    # timestep terakhir
27         return self.fc(out)                  # (batch, horizon)

```

Selain arsitektur dasar, kinerja model sangat dipengaruhi oleh konfigurasi *hyperparameter* yang ditetapkan sebelum proses pelatihan dimulai. Konfigurasi bawaan yang diterapkan dalam layanan ini disajikan secara rinci pada Tabel V.8. Pengaturan tersebut dirancang untuk mencapai keseimbangan optimal antara kapasitas pembelajaran model dan risiko terjadinya *overfitting*.

Tabel V.8 Konfigurasi *Hyperparameter* Model Terimplementasi

<i>Hyperparameter</i>	Nilai	Keterangan
<i>Window Size</i>	12	Jumlah bulan historis sebagai masukan
<i>Horizon</i>	1	Jumlah bulan yang diprediksi
<i>Hidden Size</i>	64	Dimensi <i>hidden state</i> pada lapisan berulang
<i>Num Layers</i>	2	Jumlah lapisan berulang bertumpuk
<i>Dropout</i>	0,2	Tingkat <i>dropout</i> untuk regularisasi
<i>Learning Rate</i>	10^{-3}	Laju pembelajaran awal untuk pengoptimal Adam
<i>Batch Size</i>	32	Ukuran <i>mini-batch</i> untuk pelatihan
<i>Epochs</i>	100–300	Jumlah <i>epoch</i> maksimum
<i>Early Stopping</i>	25	Jumlah <i>epoch</i> tanpa perbaikan sebelum penghentian dini

Setelah seluruh konfigurasi ditetapkan, model dilatih menggunakan algoritma pembelajaran standar. Algoritma V.5 mendeskripsikan prosedur pelatihan GRU dan LSTM secara formal, termasuk integrasi mekanisme penghentian dini (*early stopping*) dan penjadwalan laju pembelajaran (*learning rate scheduling*). Langkah-langkah tersebut memastikan bahwa pelatihan akan dihentikan secara otomatis apabila model telah mencapai titik konvergensi.

Penerapan algoritma di atas secara efektif memastikan efisiensi komputasi, mencegah penggunaan sumber daya yang berlebihan, serta mengamankan model akhir agar memiliki tingkat generalisasi terbaik terhadap data validasi.

V.6.3 *Pipeline* Pelatihan

Pipeline pelatihan diimplementasikan dalam modul `training/trainer.py` dengan beberapa fitur utama:

Algoritma V.5 Pelatihan GRU/LSTM dengan *Early Stopping* dan *Learning Rate Scheduling*

Require: Data pelatihan $(X_{\text{train}}, y_{\text{train}})$, data validasi $(X_{\text{val}}, y_{\text{val}})$, model $\mathcal{M}(\cdot; \theta)$, jumlah *epoch* maksimum E , *patience* P

Ensure: Parameter model terbaik θ^*

```

1: Inisialisasi parameter  $\theta \leftarrow \theta_0$ , pengoptimal Adam dengan  $\eta = 10^{-3}$ 
2: Inisialisasi ReduceLRonPlateau (patience= 10, factor= 0,5)
3:  $\ell^* \leftarrow \infty$ ,  $\theta^* \leftarrow \theta_0$ ,  $p \leftarrow 0$ 
4: for  $e = 1$  hingga  $E$  do
5:   for setiap mini-batch  $(x_b, y_b)$  dari  $X_{\text{train}}$  do
6:      $\hat{y}_b \leftarrow \mathcal{M}(x_b; \theta)$ 
7:      $\mathcal{L}_{\text{train}} \leftarrow \frac{1}{|x_b|} \sum (\hat{y}_b - y_b)^2$ 
8:     Hitung  $\nabla_{\theta} \mathcal{L}_{\text{train}}$  melalui backpropagation
9:     Kliping gradien:  $\nabla_{\theta} \leftarrow \nabla_{\theta} \cdot \min\left(1, \frac{1}{\|\nabla_{\theta}\|}\right)$ 
10:    Perbarui  $\theta$  menggunakan Adam
11:  end for
12:   $\mathcal{L}_{\text{val}} \leftarrow \frac{1}{|X_{\text{val}}|} \sum (\mathcal{M}(X_{\text{val}}; \theta) - y_{\text{val}})^2$ 
13:  Perbarui scheduler: kurangi  $\eta$  jika  $\mathcal{L}_{\text{val}}$  tidak membaik selama 10 epoch
14:  if  $\mathcal{L}_{\text{val}} < \ell^*$  then
15:     $\ell^* \leftarrow \mathcal{L}_{\text{val}}$ ,  $\theta^* \leftarrow \theta$ ,  $p \leftarrow 0$ 
16:  else
17:     $p \leftarrow p + 1$ 
18:    if  $p \geq P$  then
19:      break ▷ Hentikan pelatihan, cegah overfitting
20:    end if
21:  end if
22: end for
23: Muat kembali  $\theta^*$  ke dalam  $\mathcal{M}$ 
24: return  $\theta^*$ 

```

V.6.3.1 Penyesuaian Otomatis Ukuran Jendela (*Auto-Tune Window Size*)

Pemilihan ukuran jendela historis (*window size*) merupakan faktor krusial dalam peramalan deret waktu. Ketika pengguna tidak menentukan ukuran jendela secara spesifik ($\text{window_size} = 0$), sistem akan mengevaluasi sejumlah kandidat, yaitu 3, 6, 9, dan 12 bulan. Kandidat tersebut dibatasi hingga maksimal 50% dari total data pra-pengujian untuk memastikan model memiliki cukup data observasi laten. Algoritma V.6 mendeskripsikan prosedur pemilihan ukuran jendela optimal tersebut secara formal.

Algoritma V.6 Penyesuaian Otomatis Ukuran Jendela (*Auto-Tune Window Size*)

Require: Deret waktu $Y = [y_1, \dots, y_T]$, jumlah langkah pengujian n_{test} ,
kandidat $\mathcal{W} = \{3, 6, 9, 12\}$

Ensure: Ukuran jendela optimal w^*

```
1:  $n_{\text{pretrain}} \leftarrow T - n_{\text{test}}$ 
2:  $w_{\text{max}} \leftarrow \max(3, \lfloor 0,5 \times n_{\text{pretrain}} \rfloor)$ 
3:  $\mathcal{W}' \leftarrow \{w \in \mathcal{W} \mid w \leq w_{\text{max}}\}$ 
4: if  $\mathcal{W}' = \emptyset$  then
5:    $\mathcal{W}' \leftarrow \{3\}$  ▷ Jendela minimum jika data terlalu sedikit
6: end if
7:  $\ell^* \leftarrow \infty, w^* \leftarrow \min \mathcal{W}'$ 
8: for setiap  $w \in \mathcal{W}'$  do
9:   Latih model sementara pada  $Y[1 \dots n_{\text{pretrain}}]$  dengan jendela  $w$  selama 150
     epoch
10:   $\ell_w \leftarrow \text{validation loss MSE pada 20\% data akhir pretrain}$ 
11:  if  $\ell_w < \ell^*$  then
12:     $\ell^* \leftarrow \ell_w$ 
13:     $w^* \leftarrow w$ 
14:  end if
15: end for
16: return  $w^*$ 
```

Melalui pendekatan adaptif ini, sistem dapat mengakomodasi berbagai karakteristik deret waktu yang berbeda pada setiap wilayah atau layanan sehingga proses penyediaan parameter secara manual yang memakan waktu lama tidak lagi diperlukan.

V.6.3.2 Validasi *Walk-Forward*

Teknik *k-fold cross-validation* standar tidak dapat digunakan untuk evaluasi kinerja model karena teknik tersebut mengabaikan urutan temporal dari data deret waktu. Sebagai gantinya, evaluasi model ini menggunakan protokol *walk-forward validation* yang merupakan validasi silang khusus deret waktu. Pada setiap tahapan iterasi, model dilatih secara kumulatif pada seluruh data historis hingga bulan ke- t , lalu digunakan untuk memprediksi data bulan ke- $t + 1$. Proses pengujian ini diulang untuk

n bulan terakhir (minimum 3 bulan, maksimum 6 bulan) guna menghasilkan estimasi metrik evaluasi yang jauh lebih realistis dalam skenario produksi. Algoritma V.7 mendeskripsikan prosedur operasional dari *walk-forward validation* tersebut secara formal.

Algoritma V.7 *Walk-Forward Validation* untuk Evaluasi Model Peramalan

Require: Deret waktu $Y = [y_1, y_2, \dots, y_T]$, model $\mathcal{M}$, jumlah langkah uji n

Ensure: Metrik evaluasi: MAE, RMSE, sMAPE, MASE, *Skill Score*

```

1:  $T_{\text{train}} \leftarrow T - n$ 
2: Inisialisasi daftar prediksi  $\hat{Y} \leftarrow []$ , nilai aktual  $Y_{\text{test}} \leftarrow []$ 
3: for  $t = T_{\text{train}}$  hingga  $T - 1$  do
4:   Latih  $\mathcal{M}$  menggunakan data  $Y[1 \dots t]$ 
5:    $\hat{y}_{t+1} \leftarrow \mathcal{M}.\text{predict}(Y[t - w + 1 \dots t])$ 
6:   Tambahkan  $\hat{y}_{t+1}$  ke  $\hat{Y}$ 
7:   Tambahkan  $y_{t+1}$  ke  $Y_{\text{test}}$ 
8: end for
9:  $\text{MAE} \leftarrow \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$ 
10:  $\text{RMSE} \leftarrow \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$ 
11:  $\text{sMAPE} \leftarrow \frac{100\%}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2 + \epsilon}$ 
12:  $\text{MASE} \leftarrow \frac{\text{MAE}}{\frac{1}{T-1} \sum_{t=2}^T |y_t - y_{t-1}|}$ 
13:  $\text{MAE}_{\text{naive}} \leftarrow \frac{1}{n} \sum_{i=1}^n |y_i - y_{i-1}|$ 
14:  $\text{Skill Score} \leftarrow 1 - \frac{\text{MAE}}{\text{MAE}_{\text{naive}}}$ 
15: return MAE, RMSE, sMAPE, MASE, Skill Score

```

Implementasi dari prosedur validasi tersebut menjamin bahwa metrik kesalahan seperti MAE, RMSE, sMAPE, MASE, dan *Skill Score* tidak bias terhadap bocoran data masa depan (*data leakage*) sehingga merepresentasikan ketangguhan model yang sebenarnya.

V.6.3.3 Mekanisme *Benchmark* terhadap Model Sebelumnya

Setelah pelatihan selesai, sistem membandingkan metrik model baru dengan model terbaik yang tersimpan sebelumnya untuk kombinasi metrik, tipe model, regional, dan *witel* yang sama. Model baru hanya disimpan jika memiliki sMAPE lebih rendah atau *Skill Score* lebih tinggi. Mekanisme ini mencegah regresi performa akibat pelatihan ulang.

V.6.3.4 Deteksi Data Parsial

Sistem mendeteksi apakah bulan terakhir dalam data berisi data parsial (belum lengkap) dengan membandingkan nilainya terhadap median bulan-bulan sebelumnya. Jika nilai bulan terakhir kurang dari 30% median, bulan tersebut dikecualikan dari evaluasi *walk-forward* untuk mencegah metrik yang menyesatkan.

V.6.3.5 Tata Kelola Reprodusibilitas

Dalam mendukung reprodusibilitas hasil eksperimen, sistem mengimplementasikan beberapa mekanisme berikut.

1. Penyimpanan artefak model: Setiap model terbaik disimpan sebagai berkas `.pth` (PyTorch) atau `.pkl` (ARIMA/*Prophet*) di direktori `saved_models/`. Berkas *checkpoint* menyimpan tidak hanya `state_dict` model, tetapi juga seluruh *hyperparameter* yang digunakan (`window_size`, `hidden_size`, `num_layers`, `dropout`), jenis model, metrik, regional, dan *witel*. Parameter normalisasi (`MinMaxScaler`) disimpan terpisah dalam berkas `.pkl` sehingga inferensi dapat menggunakan *scaler* yang identik dengan saat pelatihan.
2. Pelacakan riwayat pelatihan: Seluruh hasil pelatihan dicatat dalam berkas `training_history.json` yang menyimpan metadata lengkap setiap eksperimen, meliputi tipe model, metrik target, cakupan geografis, jumlah titik data, ukuran jendela, metode evaluasi (*walk-forward*), seluruh metrik evaluasi (`MAE`, `RMSE`, `sMAPE`, `MASE`, *Skill Score*), hasil *benchmark* terhadap model sebelumnya, serta stempel waktu pelatihan.
3. Versi pustaka terkunci: Berkas `requirements.txt` menetapkan versi eksak untuk setiap dependensi (misalnya `torch==2.1.1`, `fastapi==0.104.1`, `scikit-learn==1.3.2`) sehingga lingkungan pelatihan dapat direkonstruksi secara konsisten.
4. Pencegahan regresi: Mekanisme *benchmark* (Subbab V.6.3) memastikan bahwa model baru hanya menggantikan model lama jika memiliki `sMAPE` lebih rendah atau *Skill Score* lebih tinggi sehingga setiap artefak yang tersimpan merupakan model terbaik yang pernah dilatih untuk kombinasi metrik dan wilayah tertentu.

V.6.3.5.1 Keterbatasan. Implementasi saat ini belum menetapkan *random seed* secara eksplisit (misalnya `torch.manual_seed`) sehingga hasil pelatihan tidak dapat direproduksi secara numerik identik di antara dua sesi pelatihan berbeda. Namun, reprodusibilitas fungsional tetap terjaga melalui penyimpanan artefak model terbaik dan riwayat pelatihan yang lengkap sehingga model terlatih dapat dimuat ulang dan menghasilkan inferensi yang deterministik.

V.6.4 Praolah Data

Praolah data diimplementasikan dalam modul `utils/preprocessing.py` dengan tahapan berikut.

1. Normalisasi: Data dinormalisasi menggunakan `MinMaxScaler` dari Scikit-

learn ke rentang $[0, 1]$. Parameter *scaler* disimpan ke berkas `.pkl` untuk digunakan kembali saat inferensi.

2. Pembuatan *Sliding Window*: Data yang telah dinormalisasi diubah menjadi pasangan masukan-keluaran (X, y) menggunakan jendela geser (*sliding window*). Masukan X berukuran $(n_samples, window_size, 1)$ dan keluaran y berukuran $(n_samples, horizon)$.
3. Pembagian Data: Data dibagi menjadi *training set* (80%) dan *validation set* (20%) secara kronologis tanpa pengacakan untuk mempertahankan urutan temporal.

V.6.5 Implementasi Model *Baseline* Statistik (ARIMA dan *Prophet*)

Selain model *deep learning* GRU dan LSTM, layanan *machine learning* juga mengimplementasikan dua model statistik sebagai *baseline* pembandingan, yaitu ARIMA dan *Prophet*. Kedua model ini digunakan untuk mengevaluasi seberapa besar keunggulan model berbasis jaringan saraf berulang dibandingkan pendekatan statistik klasik pada data deret waktu operasional perusahaan.

V.6.5.1 ARIMA (*Auto-Regressive Integrated Moving Average*)

Model ARIMA diimplementasikan menggunakan pendekatan *auto-ARIMA*, yaitu pemilihan parameter (p, d, q) secara otomatis berdasarkan kriteria informasi AIC (*Akaike Information Criterion*). Sistem mencari kombinasi parameter terbaik pada ruang pencarian terbatas sehingga model yang dipilih merupakan model dengan tingkat kompleksitas-keseimbangan kesalahan yang optimal untuk setiap deret waktu. Pendekatan ini menghilangkan kebutuhan penalaan parameter secara manual untuk setiap kombinasi metrik dan wilayah.

V.6.5.2 *Prophet*

Model *Prophet* dari Meta diimplementasikan menggunakan konfigurasi bawaan dengan komponen musiman tahunan (*annual seasonality*) yang diaktifkan. *Prophet* menggunakan model aditif yang menguraikan deret waktu menjadi komponen tren, musiman, dan hari libur. Pada implementasi ini, komponen hari libur tidak diaktifkan mengingat data operasional bersifat bulanan dan tidak memiliki pola hari libur yang dominan. Hasil keluaran *Prophet* dikembalikan dalam format yang seragam dengan model lain untuk memungkinkan perbandingan metrik secara langsung.

V.6.6 Metrik Evaluasi Terimplementasi

Modul `utils/metrics.py` mengimplementasikan seluruh metrik evaluasi yang dirancang pada Bab IV. Fungsi `all_metrics` menghitung seluruh metrik dalam satu pemanggilan dan menghasilkan status KPI (*pass/fail*) untuk setiap target performa.

Tabel V.9 menyajikan target KPI yang diimplementasikan.

Tabel V.9 Target KPI Metrik Evaluasi Terimplementasi

Metrik	Target KPI	Interpretasi
MASE	$< 1,0$	Model lebih baik dari <i>seasonal naive forecast</i>
sMAPE (jangka pendek)	$< 30\%$	Kesalahan persentase simetris yang dapat diterima
<i>Skill Score</i>	$> -0,5$ (LDC) atau $> -0,1$ (LULUS)	Tiga kategori: LULUS ($> -0,1$), Lulus Dengan Catatan ($-0,5$ s.d. $-0,1$), GAGAL ($\leq -0,5$)

Implementasi metrik dengan konfigurasi **threshold** KPI secara langsung pada tahap kalkulasi ini memungkinkan komponen analitik sistem untuk mengategorikan model seketika menjadi tiga status operasional: LULUS, Lulus Dengan Catatan (LDC), atau GAGAL. Integrasi evaluasi bawaan ini menghilangkan kebutuhan akan pemrosesan data pasca-prediksi secara manual dan mengotomatiskan seleksi pemodelan **forecasting**.

V.7 Implementasi *Frontend* (React.js)

Frontend sistem diimplementasikan menggunakan React.js 18 dengan Tailwind CSS untuk penataan gaya (*styling*). Tabel V.10 menyajikan komponen utama yang diimplementasikan.

Tabel V.10 Komponen Utama *Frontend*

Komponen	Fungsi
App.jsx	Komponen utama yang mengelola navigasi, autentikasi, antarmuka <i>chatbot</i> , profil, dan pengaturan
Login.jsx	Halaman autentikasi: formulir masuk dan registrasi pengguna baru
ChatHistory.jsx	Panel riwayat percakapan: daftar sesi, pencarian, dan penghapusan
ForecastPanel.jsx	Panel peramalan: pemilihan metrik, model, cakupan wilayah, dan penjelasan hasil prediksi
GuidedFlow.jsx	Alur terpandu yang memandu pengguna memilih domain analisis, wilayah, dan metrik secara bertahap

Antarmuka *chatbot* menyediakan area percakapan dengan dukungan render *Markdown* untuk menampilkan tabel, format teks, dan poin-poin yang dihasilkan oleh modul NLG. Pengguna dapat mengetik pertanyaan dalam bahasa Indonesia alami atau menggunakan alur terpandu (*guided flow*) untuk memilih jenis analisis secara interaktif.

V.8 Implementasi Autentikasi dan Keamanan

Sistem mengimplementasikan mekanisme autentikasi dan keamanan berbasis standar industri web.

V.8.1 Autentikasi Berbasis JWT

Autentikasi pengguna menggunakan *JSON Web Token* (JWT) dengan konfigurasi berikut.

1. Registrasi: Kata sandi pengguna di-*hash* menggunakan algoritma *bcrypt* dengan 10 putaran *salt* sebelum disimpan ke basis data.
2. Masuk (*Login*): Kredensial divalidasi terhadap basis data. Jika valid, peladen menerbitkan token JWT dengan masa berlaku 24 jam dan penerbit (*issuer*) “brightai-backend”.
3. Otorisasi: Setiap permintaan ke rute yang dilindungi harus menyertakan token JWT pada tajuk *Authorization*. *Middleware* autentikasi memverifikasi dan mendekode token untuk mengidentifikasi pengguna.

V.8.2 Validasi Masukan

Validasi masukan pengguna diimplementasikan menggunakan pustaka *express-validator* dengan aturan yang mencakup validasi format surel, panjang minimal kata sandi (6 karakter), keharusan kombinasi huruf besar, huruf kecil, dan angka pada kata sandi, serta sanitasi terhadap serangan injeksi.

V.9 Ringkasan Implementasi

Implementasi sistem BrightAI telah berhasil mewujudkan seluruh komponen yang dirancang pada bab sebelumnya menjadi sistem yang terintegrasi dan fungsional. Tabel V.11 merangkum komponen-komponen utama yang telah diimplementasikan beserta statusnya.

Secara keseluruhan, sistem BrightAI telah diimplementasikan sebagai aplikasi tiga lapis yang mencakup: (1) *frontend* berbasis React.js pada porta 3000 yang menyediakan antarmuka percakapan, panel peramalan interaktif, dan alur terpandu; (2) *backend* berbasis Node.js/Express pada porta 3001 yang mengelola autentikasi, mesin aturan dengan 38 aturan analitik pada 5 domain, klasifikasi maksud, dan pengembangan bahasa alami.

V.9.1 Antarmuka Pengguna

Bagian ini menyajikan antarmuka pengguna (*user interface*) yang telah diimplementasikan sebagai realisasi tujuan perancangan antarmuka percakapan berbasis web. Setiap halaman dirancang untuk mendukung alur kerja analisis data yang intuitif

Tabel V.11 Ringkasan Komponen Sistem yang Terimplementasi

Komponen	Teknologi	Status
<i>Frontend</i> antarmuka pengguna	React.js 18, Tailwind CSS	Terimplementasi
<i>Backend</i> RESTful API	Node.js, Express.js	Terimplementasi
Mesin aturan (<i>rule engine</i>)	JavaScript, Oracle SQL	Terimplementasi (38 aturan, 5 domain)
Klasifikasi maksud (<i>intent</i>)	Pencocokan kata kunci berbobot	Terimplementasi (7 <i>intent</i>)
Pembangkitan bahasa alami (NLG)	Berbasis templat, Bahasa Indonesia	Terimplementasi (>30 subjek)
Model peramalan GRU	PyTorch, FastAPI	Terimplementasi
Model peramalan LSTM	PyTorch, FastAPI	Terimplementasi
Model <i>baseline</i> ARIMA	<i>Auto-ARIMA</i> berbasis AIC	Terimplementasi
Model <i>baseline</i> Prophet	<i>Prophet</i> (Meta), musiman tahunan	Terimplementasi
Autentikasi pengguna	JWT, <i>bcrypt</i>	Terimplementasi
Koneksi basis data	Oracle Database, <i>connection pool</i>	Terimplementasi (skema DWH_MOIS dan USR_RPT)

bagi pengguna internal perusahaan.


V.9.1.1 Halaman Masuk (*Login*)

Halaman masuk merupakan titik masuk pengguna ke dalam sistem BrightAI. Panel kiri menampilkan *branding* perusahaan dengan latar foto gedung Telkom beserta deskripsi singkat tiga fitur utama sistem, sedangkan panel kanan menyajikan formulir masuk yang meminta kredensial berupa alamat surel dan kata sandi. Formulir dilengkapi validasi masukan secara *real-time* serta umpan balik kesalahan apabila kredensial tidak valid. Gambar V.1 menunjukkan tampilan halaman masuk.

Antarmuka ini dirancang secara minimalis dengan memusatkan form masukan di tengah layar untuk mengurangi disonansi kognitif, mengizinkan pengguna untuk langsung berfokus pada autentikasi dasar yang aman.


V.9.1.2 Halaman Registrasi

Halaman registrasi memungkinkan pengguna internal baru untuk membuat akun pada sistem BrightAI. Formulir registrasi meminta empat isian, yaitu *username*, alamat surel, nama lengkap, dan kata sandi dengan persyaratan minimal enam karakter yang terdiri dari kombinasi huruf besar, huruf kecil, dan angka. Halaman ini dapat diakses melalui tautan “Daftar sekarang” pada halaman masuk, dan sebaliknya pengguna yang telah memiliki akun dapat kembali ke halaman masuk melalui tautan



Gambar V.1 Halaman Masuk (*Login*) Sistem BrightAI

“Masuk”. Gambar V.2 menunjukkan tampilan halaman registrasi.




Gambar V.2 Halaman Registrasi Pengguna Baru

Serupa dengan antarmuka *login*, halaman registrasi memastikan konsistensi visual sekaligus menyediakan fungsionalitas pembuatan kredensial baru sebelum pengguna dapat mengakses kapabilitas kecerdasan buatan sistem.

V.9.1.3 Halaman Utama *Chatbot*

Halaman utama *chatbot* merupakan antarmuka inti sistem yang terdiri dari tiga area: (1) bilah navigasi vertikal di sisi kiri yang menyediakan akses ke modul *chatbot*, profil, dan pengaturan; (2) panel riwayat percakapan yang memungkinkan pengguna mengelola sesi percakapan, termasuk pencarian, penggantian nama, penyematan (*pin*), dan penghapusan sesi; serta (3) area percakapan utama yang menampilkan pesan pengguna dan respons sistem. Di bagian bawah, alur terpandu (*guided flow*) menyediakan mekanisme interaksi terstruktur melalui pemilihan jenis analisis, kate-

gori domain, dan pertanyaan yang telah dikurasi. Bilah tajuk di bagian atas menampilkan status koneksi server, pengalih tema, dan informasi pengguna. Gambar V.3 menunjukkan tampilan halaman utama *chatbot*.




Gambar V.3 Halaman Utama *Chatbot* BrightAI

Sebagai pusat kendali utama (*centerpiece*) aplikasi, halaman ini mendedikasikan sebagian besar area layar untuk riwayat percakapan. Susunan pesan yang asinkron menegaskan sifat percakapan berbalas dengan jawaban sistem dirender dengan membedakan warna kotak teks.

V.9.1.4 Halaman Profil

Halaman profil menampilkan informasi akun pengguna yang sedang masuk, meliputi nama lengkap, *username*, alamat surel, dan peran (*role*) dalam sistem. Halaman ini dapat diakses melalui ikon pengguna pada bilah navigasi vertikal. Gambar V.4 menunjukkan tampilan halaman profil.




Gambar V.4 Halaman Profil Pengguna

Halaman profil memungkinkan pengguna mempersonalisasikan konfigurasi pribadinya, yang pada saat ini menampilkan rangkuman data personal sebagai konfirmasi akses sesi pengguna yang sedang aktif.

V.9.1.5 Halaman Pengaturan

Halaman pengaturan menyediakan opsi konfigurasi antarmuka bagi pengguna, termasuk pengalihan tema tampilan dan preferensi notifikasi. Halaman ini dapat diakses melalui ikon pengaturan pada bilah navigasi vertikal. Gambar V.5 menunjukkan tampilan halaman pengaturan.




Gambar V.5 Halaman Pengaturan Sistem

Aksesibilitas sistem turut disematkan melalui preferensi tema antarmuka pada halaman ini, mengizinkan penyesuaian kontras demi kenyamanan pemakaian jangka panjang dalam kondisi iluminasi lingkungan yang berbeda-beda.

V.9.1.6 Tampilan Tema Terang (*Light Mode*)

Sistem mendukung dua tema tampilan, yaitu tema gelap (*dark mode*) sebagai tema bawaan dan tema terang (*light mode*). Pengguna dapat beralih antara kedua tema melalui tombol pengalih pada bilah tajuk. Seluruh komponen antarmuka, termasuk area percakapan, panel riwayat, dan alur terpandu, menyesuaikan skema warna secara konsisten sesuai tema yang dipilih. Gambar V.6 menunjukkan tampilan sistem dalam tema terang.


Penggunaan *light mode* sangat cocok bagi pengguna yang lebih menyukai tata ruang dokumen putih standar, dengan seluruh komponen *React* diwarnai ulang melalui kelas utilitas *Tailwind* (*dark mode inversion*).



Gambar V.6 Tampilan Antarmuka *Chatbot* dalam Tema Terang (*Light Mode*)

V.9.1.7 Detail Respons *Rule-Based Query*

Ketika pengguna mengajukan pertanyaan analitik melalui antarmuka percakapan, sistem mencocokkan kueri tersebut dengan salah satu dari 38 aturan bisnis yang tersedia, mengeksekusi kueri SQL terhadap *Enterprise Data Warehouse*, dan menghasilkan respons naratif dalam bahasa Indonesia menggunakan modul NLG berbasis templat. Respons ditampilkan dalam format *Markdown* yang mencakup judul analisis, tabel data dengan angka terformat sesuai konvensi Indonesia, poin-poin wawasan bisnis, serta metadata sumber data dan waktu pemrosesan. Gambar V.7 menunjukkan contoh respons sistem terhadap pertanyaan analitik berbasis aturan.




Gambar V.7 Contoh Respons *Rule-Based Query* dengan Narasi NLG dan Tabel Data

Respons berbasis aturan dikemas secara terstruktur menggunakan fitur *Markdown*. Penyorotan tabel sintaks, ukuran fon hierarkis, serta pemformatan tebal (*bolding*) menghasilkan kejelasan tingkat tinggi bagi pembaca analisis bisnis pada eksekutif

regional.

V.9.1.8 Detail Respons Peramalan Deret Waktu

Fitur peramalan dapat diakses melalui panel peramalan pada alur terpandu, dengan pengguna memilih metrik yang hendak diramalkan, jenis model (GRU, LSTM, ARIMA, atau *Prophet*), serta cakupan wilayah (nasional, regional, atau *witel*). Hasil peramalan ditampilkan dalam format naratif yang mencakup nilai prediksi untuk periode berikutnya, perbandingan terhadap nilai aktual terakhir, serta metrik evaluasi model (MAE, RMSE, sMAPE, *Skill Score*). Panel ini merupakan realisasi langsung dari tujuan integrasi dan perbandingan model peramalan deret waktu ke dalam antarmuka *chatbot*. Gambar V.8 menunjukkan contoh hasil peramalan.



Gambar V.8 Contoh Hasil Peramalan Deret Waktu melalui Panel *Forecast*

Sistem terhubung ke Oracle Database melalui dua skema: DWH_MOIS untuk data analitik dan USR_RPT untuk data operasional. Sistem menggunakan mekanisme *caching* memori untuk mengoptimalkan waktu respons. Injeksi filter geografis secara dinamis memungkinkan sistem menyajikan analisis pada tingkat nasional, regional, maupun *witel* tanpa duplikasi definisi aturan.

V.9.2 Selisih antara Rancangan dan Implementasi

Demi transparansi, bagian ini menyatakan secara eksplisit selisih antara komponen yang dirancang pada Bab IV dan komponen yang berhasil diimplementasikan. Tabel V.12 merangkum selisih tersebut.

Selain ketiga komponen di atas, seluruh rancangan yang ditetapkan pada Bab IV telah berhasil diwujudkan dalam implementasi, meliputi mesin aturan (38 aturan, 5 domain), klasifikasi maksud (7 kategori *intent* dan 1 *fallback*), pembangkitan bahasa alami berbasis templat, model peramalan GRU dan LSTM beserta *baseline* ARIMA

Tabel V.12 Selisih antara Rancangan dan Implementasi

Komponen	Status	Keterangan
<i>Temporal Fusion Transformer</i> (TFT)	Tidak diimplementasikan	Dikaji dalam studi literatur (Subbab II.5.3.3) sebagai arsitektur lanjutan, namun tidak termasuk dalam lingkup implementasi penelitian ini karena keterbatasan volume data dan biaya komputasi. TFT tetap menjadi kandidat pengembangan di masa depan.
Model <i>ensemble</i> (gabungan keluaran beberapa model)	Tidak diimplementasikan	Dibahas secara teoretis pada kajian literatur, namun implementasi saat ini menjalankan setiap model secara independen tanpa mekanisme penggabungan prediksi.
Komponen hari libur pada <i>Prophet</i>	Diimplementasikan sebagian	Daftar hari libur Indonesia telah didefinisikan dalam kode, namun dampaknya terbatas karena data bersifat bulanan sehingga efek hari libur tidak dominan.

dan *Prophet*, autentikasi berbasis JWT, serta antarmuka percakapan interaktif.

BAB VI

EVALUASI

Bab ini menyajikan hasil evaluasi terhadap sistem *Business Intelligence* berbasis *rule-based chatbot* yang telah diimplementasikan. Evaluasi dilakukan terhadap setiap komponen utama sistem sesuai dengan desain pengujian yang dirancang pada Bab IV, yaitu evaluasi klasifikasi maksud, evaluasi pembangkitan bahasa alami, evaluasi peramalan deret waktu, serta evaluasi sistem secara terintegrasi.

VI.1 Evaluasi Klasifikasi Maksud (*Intent Classification*)

Modul klasifikasi maksud dievaluasi berdasarkan kemampuannya dalam mengenali *intent* pengguna dari kueri bahasa alami dalam bahasa Indonesia. Pengujian dilakukan dengan menggunakan sekumpulan kueri uji yang mewakili variasi pertanyaan untuk setiap *intent* yang didukung.

VI.1.1 Cakupan *Intent*

Sistem mengimplementasikan tujuh *intent* utama dan satu *intent* cadangan (*fallback*). Setiap *intent* didukung oleh sejumlah kata kunci berbobot yang digunakan untuk menghitung skor kecocokan. Tabel VI.1 menyajikan ringkasan cakupan kata kunci per *intent*.

Tabel di atas mengilustrasikan berbagai kombinasi masukan kueri yang harus mampu ditangani oleh sistem, mencerminkan kompleksitas bahasa alami yang sering dijumpai di lingkungan operasional. Dapat diamati bahwa setiap jenis *intent* memiliki karakteristik leksikal yang unik, yang menuntut sistem klasifikasi untuk tidak sekadar melakukan pencocokan kata kunci dasar, melainkan juga mengurai *part-of-speech* serta memahami konteks struktural dari kalimat pengguna. Tabel ini sekaligus menjadi landasan bagi penetapan *ground truth* pada saat proses evaluasi tingkat akurasi model klasifikasi yang diimplementasikan.

VI.1.2 Metodologi Evaluasi Klasifikasi

Evaluasi kuantitatif dilakukan menggunakan 100 kueri uji berlabel yang mencakup seluruh tujuh *intent* utama, satu kelas cadangan (*general*), serta 38 aturan bisnis. Se-

Tabel VI.1 Cakupan Kata Kunci per *Intent*

<i>Intent</i>	Bobot	Jumlah Kata Kunci	Contoh Kueri
<i>quantity</i>	3	12	“Berapa total <i>order</i> HSI bulan ini?”
<i>trend</i>	3	23	“Bagaimana tren pertumbuhan <i>revenue</i> ?”
<i>comparison</i>	3	13	“Bandingkan <i>order</i> regional 1 vs 2”
<i>location</i>	3	14	“Dengan <i>witel</i> dengan <i>order</i> tertinggi?”
<i>reason</i>	4	11	“Mengapa <i>churn</i> meningkat?”
<i>performance</i>	4	14	“Bagaimana pencapaian target HSI?”
<i>detail</i>	3	37	“Tampilkan rincian distribusi <i>order</i> ”
<i>general</i>	—	—	Kueri tanpa kata kunci yang dikenali

tiap kueri diberi label kebenaran dasar (*ground truth*) berupa *intent* yang diharapkan dan aturan yang diharapkan. Evaluasi dilakukan pada level pencocokan aturan, yaitu pencocokan kueri ke 38 aturan bisnis ditambah 1 kelas *no_match*. Metrik yang dihitung meliputi presisi, daya ingat, dan skor-F1 per kelas, serta agregasi makro (*macro*), mikro (*micro*), dan tertimbang (*weighted*).

VI.1.3 Cakupan Evaluasi Klasifikasi

Evaluasi klasifikasi pada penelitian ini difokuskan pada level pencocokan aturan (*rule matching*) dengan 38 kelas, bukan pada level klasifikasi *intent* (7+1 kategori). Keputusan ini didasarkan pada pertimbangan bahwa ketujuh kategori *intent* — *quantity*, *trend*, *comparison*, *location*, *performance*, *detail*, dan *reason* — dirancang sejak awal sebagai taksonomi yang bersifat saling eksklusif secara semantik, dengan penanda leksikal yang secara inheren tidak tumpang tindih (misalnya, “berapa” secara unik menandai *quantity*, “tren” secara unik menandai *trend*). Dataset uji yang digunakan pun sudah terkategori berdasarkan *intent* sesuai dengan taksonomi yang didefinisikan sehingga evaluasi pada level ini bersifat deterministik dan tidak menghadirkan tantangan klasifikasi yang bermakna.

Tantangan sesungguhnya dalam sistem ini terletak pada level pencocokan aturan: setelah *intent* teridentifikasi, sistem harus menentukan satu dari 38 aturan bisnis spesifik yang paling relevan berdasarkan kombinasi kata kunci lintas-domain yang sering kali tumpang tindih. Oleh karena itu, evaluasi kuantitatif berikut difokuskan

pada level pencocokan aturan sebagai ukuran kemampuan diskriminatif sistem yang sesungguhnya.

VI.1.4 Hasil Evaluasi Pencocokan Aturan

Tabel VI.2 menyajikan distribusi 38 aturan bisnis yang dievaluasi beserta jumlah aturan yang mencapai skor-F1 sempurna (1,0000) per domain basis data. Rekapitulasi ini penting untuk menyoroti seberapa merata tingkat keberhasilan model dalam mengklasifikasikan kueri ke berbagai penjuru domain analitik, dari area yang relatif lugas seperti data operasional hingga area yang kompleks secara semantik seperti kualitas performa (QoS/QoE). Pencapaian skor sempurna pada suatu domain secara spesifik merepresentasikan bahwa sistem tidak memiliki satu pun kesalahan dalam menginterpretasikan pola kalimat pada konteks domain terkait.

Tabel VI.2 Distribusi Aturan Bisnis per Domain Basis Data

Domain	Kode	Jumlah	F1 = 1,0	Cakupan Analisis
Penjualan (<i>Sales</i>)	ps	12	12	Order, bandwidth, penetras, STO, <i>fulfillment</i> , <i>channel</i> , tren
Proses Data Pelanggan (<i>Dapros</i>)	dapros	7	7	Segmentasi, <i>bundle</i> , profil digital, <i>revenue</i> , distribusi geografis
Pendapatan (<i>Revenue</i>)	mart	8	8	Tren pendapatan, performa regional, siklus hidup, <i>GL account</i>
Target	target	5	5	Realisasi target, segmentasi, performa regional, tren pertumbuhan
<i>Churn</i>	ct0	6	6	<i>Churn rate</i> , pola masa layanan, bandwidth, witel, pola temporal
Total		38	38	

Seluruh 38 aturan pada kelima domain mencapai skor-F1 sempurna (1,0000). Hasil ini dicapai melalui penerapan mekanisme *penalty* kontekstual pada fungsi *calculateConfidence*, yaitu pengurangan skor keyakinan ketika konteks kueri tidak sesuai dengan domain aturan. Sebagai contoh, aturan pada domain Proses Data Pelanggan mendapat *penalty* ketika kueri mengandung kata kunci *order*, *target*, atau *penetrasi* yang merupakan konteks domain lain sehingga aturan dari domain yang lebih tepat dapat menang dalam kompetisi skor.

Secara keseluruhan, evaluasi pada level pencocokan aturan (38 kelas + *no_match*) menghasilkan akurasi **100%** (100 dari 100 kueri) dengan metrik agregasi yang di-

sajikan pada Tabel VI.3. Agregasi ini memberikan gambaran ringkas namun komprehensif mengenai stabilitas model, memastikan bahwa tidak ada satu pun kelas minoritas yang performanya tertutup oleh performa kelas mayoritas, sebagaimana ditunjukkan oleh keseimbangan sempurna antara presisi makro dan mikro.

Tabel VI.3 Ringkasan Metrik Evaluasi Pencocokan Aturan

Strategi Agregasi	Presisi	Recall	Skor-F1
Makro (<i>macro</i>)	1,0000	1,0000	1,0000
Tertimbang (<i>weighted</i>)	1,0000	1,0000	1,0000
Mikro (<i>micro</i>)	1,0000	1,0000	1,0000

Seluruh 38 aturan yang dievaluasi mencapai skor-F1 sempurna (1,0000), menunjukkan bahwa setiap aturan memiliki kata kunci yang cukup spesifik dan mekanisme *penalty* kontekstual yang efektif dalam mencegah tumpang tindih antar-domain.

VI.1.5 Analisis Keyakinan dan Cakupan

Analisis terhadap nilai keyakinan (*confidence score*) dan tingkat cakupan (*coverage rate*) memberikan perspektif tambahan terhadap seberapa mantap dan efisien sistem dalam mengeksekusi proses klasifikasi. Tabel VI.4 menyajikan secara kuantitatif metrik-metrik tersebut, yang tidak hanya mengukur kebenaran prediksi, tetapi juga tingkat determinasi algoritma (*degree of certainty*) dalam mengambil keputusan serta latensi waktu komputasinya. Analisis ini krusial untuk memastikan bahwa sistem beroperasi dengan performa **real-time** dan tidak sekadar menghasilkan tebakan acak.

Tabel VI.4 Statistik Keyakinan dan Cakupan Klasifikasi

Metrik	Nilai
<i>Coverage Rate</i> (keyakinan ≥ 40)	93,0%
Rata-rata keyakinan (seluruh kueri)	83,2
Rata-rata keyakinan (prediksi benar)	83,2
Median keyakinan (prediksi benar)	90,0
Waktu rata-rata per kueri	0,14 ms

Coverage rate sebesar 93% menunjukkan bahwa mayoritas kueri uji berhasil melewati ambang batas keyakinan 40 dan memperoleh respons analitik. Rata-rata keyakinan sebesar 83,2 dengan median 90,0 menunjukkan bahwa sebagian besar prediksi memiliki tingkat kepastian yang tinggi. Tujuh kueri yang tidak melewati ambang keyakinan merupakan kueri umum (*general*) yang memang dirancang untuk ditangani oleh mekanisme *fallback*. Waktu klasifikasi rata-rata 0,14 milidetik jauh melampaui target 100 milidetik yang ditetapkan pada desain evaluasi.

VI.1.6 Analisis Mekanisme Disambiguasi

Evaluasi pencocokan aturan menghasilkan akurasi sempurna (100%) berkat penerapan tiga mekanisme disambiguasi pada fungsi *calculateConfidence* setiap aturan.

1. *Hard gate kontekstual*: Beberapa aturan mensyaratkan kehadiran kata kunci konteks tertentu sebelum menghitung skor. Sebagai contoh, aturan *dapros_006* (distribusi kecepatan) mensyaratkan kehadiran kata kunci *speed/kecepatan/bandwidth* sehingga kueri tentang penetrasi wilayah tidak terserap oleh aturan tersebut.
2. *Penalty lintas-domain*: Aturan yang memiliki kata kunci pendukung generik (seperti *regional*, *wilayah*, *pelanggan*) mendapat pengurangan skor ketika kueri mengandung konteks domain lain. Sebagai contoh, aturan pada domain Proses Data Pelanggan mendapat *penalty* ketika kueri mengandung kata *order*, *target*, atau *penetrasi* sehingga aturan dari domain Penjualan atau Target yang lebih relevan dapat menang.
3. Bonus frasa spesifik: Aturan memberikan bonus skor untuk frasa multi-kata yang sangat spesifik, seperti “*per speed*” pada *ps_003* dan kombinasi “*bisnis*” + “*basic*” pada *ps_001* sehingga aturan yang paling tepat memperoleh skor tertinggi meskipun terdapat kompetisi dari aturan yang lebih umum.

VI.1.7 Evaluasi terhadap Target Performa

Tabel VI.5 membandingkan hasil evaluasi pencocokan aturan dengan target yang ditetapkan pada Bab IV.

Tabel VI.5 Perbandingan Hasil Evaluasi Pencocokan Aturan dengan Target Performa

Metrik	Target	Hasil	Status
Akurasi Pencocokan Aturan	$\geq 0,85$	1,0000	Tercapai
Skor-F1 Makro (aturan)	$\geq 0,85$	1,0000	Tercapai
<i>Coverage Rate</i>	$\geq 80\%$	93%	Tercapai
Waktu Respons (p95)	< 100 ms	0,14 ms	Tercapai

Seluruh target performa berhasil tercapai dan melampaui ambang batas yang ditetapkan. Akurasi pencocokan aturan dan skor-F1 makro mencapai nilai sempurna (1,0000), jauh melampaui target minimal 0,85. *Coverage rate* sebesar 93% menunjukkan bahwa mayoritas kueri berhasil melewati ambang keyakinan dan memperoleh respons analitik. Waktu respons rata-rata 0,14 milidetik jauh melampaui target 100 milidetik, menunjukkan latensi yang sangat rendah. Akurasi sempurna ini dicapai melalui kombinasi *hard gate* kontekstual, *penalty* lintas-domain, dan bonus frasa spesifik yang memastikan setiap kueri diarahkan ke aturan yang paling relevan.

VI.1.8 Mekanisme *Fallback*

Jika klasifikasi maksud tidak menghasilkan kecocokan aturan atau nilai keyakinan rendah, sistem memicu mekanisme *fallback* yang memberikan respons berupa panduan penggunaan dan contoh pertanyaan yang dapat diajukan. Mekanisme ini memastikan bahwa pengguna selalu menerima respons yang informatif, meskipun kueri tidak dapat diproses secara analitik.

VI.2 Evaluasi Pembangkitan Bahasa Alami (NLG)

Modul pembangkitan bahasa alami (NLG) dievaluasi berdasarkan dua aspek sesuai dengan desain evaluasi pada Bab IV: akurasi faktual dan evaluasi subjektif berbasis pengguna internal.

VI.2.1 Akurasi Faktual

Akurasi faktual modul NLG secara arsitektural terjamin karena seluruh angka dan data numerik dalam respons berasal langsung dari hasil kueri *Enterprise Data Warehouse* Oracle tanpa proses generatif atau interpolasi. Modul NLG berperan sebagai penerjemah (*translator*) data terstruktur menjadi narasi, bukan sebagai penghasil (*generator*) data baru. Mekanisme ini mengeliminasi risiko halusinasi data (*data hallucination*) yang umum terjadi pada sistem berbasis model bahasa besar (*Large Language Model*).

Verifikasi akurasi faktual dilakukan oleh pengguna internal dari tim *Data Management* dengan membandingkan nilai numerik dalam respons sistem terhadap data sumber pada *Enterprise Data Warehouse*. Seluruh angka yang ditampilkan dalam respons terverifikasi sesuai dengan data sumber sehingga target akurasi faktual sebesar 100% berhasil tercapai.

VI.2.2 Evaluasi Subjektif oleh Pengguna Internal

Kualitas bahasa dan keluaran NLG dinilai secara subjektif oleh pengguna internal menggunakan kuesioner berskala Likert 1–5 pada empat dimensi: ketepatan respons, kejelasan narasi, relevansi analisis, dan kemudahan penggunaan. Hasil penilaian secara lengkap disajikan pada Subbab VI.6. Secara ringkas, rata-rata skor penilaian sebesar **4,75 dari 5,00** (95%) menunjukkan tingkat kepuasan yang tinggi terhadap kualitas keluaran NLG. Aspek ketepatan respons, kejelasan narasi, dan kemudahan penggunaan memperoleh skor sempurna (5/5), sedangkan aspek relevansi analisis memperoleh skor 4/5 yang mengindikasikan ruang peningkatan pada cakupan *insight*.

VI.2.3 Karakteristik Teknis Modul NLG

Sebagai pelengkap evaluasi, berikut adalah karakteristik teknis modul NLG yang mendukung kualitas keluaran.

1. Variasi Templat. Setiap *intent* didukung oleh minimal tiga variasi templat respons untuk menghindari kesan monoton. Variasi mencakup perbedaan struktur kalimat pembuka, susunan penyajian data, dan penekanan pada aspek analisis yang berbeda.
2. Cakupan Subjek. Modul NLG mendukung 38 subjek aturan yang mencakup lima domain basis data (penjualan, pendapatan, target, proses data pelanggan, dan *churn*). Setiap subjek memiliki pemetaan deskripsi dalam bahasa Indonesia yang digunakan sebagai judul dan konteks narasi.
3. Format Keluaran. Respons dihasilkan dalam format *Markdown* yang mendukung tabel, poin-poin, dan format teks terstruktur sehingga efektif untuk menyajikan data analitik dalam antarmuka percakapan.

VI.3 Evaluasi Peramalan Deret Waktu (*Time Series Forecasting*)

Model peramalan deret waktu dievaluasi menggunakan protokol *walk-forward validation* yang merupakan pendekatan validasi silang khusus deret waktu. Evaluasi mencakup empat model, yaitu GRU, LSTM, ARIMA, dan *Prophet*, pada empat metrik bisnis utama: *order_hsi* (volume pesanan), *churn_hsi* (volume *churn* pelanggan), *realisasi_hsi* (pencapaian target penjualan), dan *avg_install_days* (rata-rata hari instalasi). Keempat metrik ini mencakup seluruh indikator bisnis pelanggan yang dijanjikan pada tujuan penelitian (Bab I).

Klarifikasi Cakupan: Peramalan Numerik vs. Klasifikasi Biner

Sistem meramalkan empat metrik utama, yaitu *order_hsi*, *churn_hsi*, *realisasi_hsi*, dan *avg_install_days*. Seluruhnya merupakan **deret waktu numerik**: setiap titik data adalah nilai agregat bulanan (misalnya jumlah pesanan, total pendapatan, atau jumlah pelanggan *churn*). Oleh karena itu, seluruh evaluasi peramalan menggunakan metrik regresi (MAE, RMSE, sMAPE, MASE, dan *Skill Score*), bukan metrik klasifikasi.

Secara khusus, metrik *churn_hsi* didefinisikan sebagai `COUNT(DISTINCT NCLI)` per bulan per wilayah, yakni jumlah agregat pelanggan yang berhenti berlangganan. Ini berbeda dari tugas *churn prediction* biner yang lazim dijumpai dalam literatur, dengan setiap pelanggan individual diklasifikasikan sebagai *churn* atau *non-churn* dan dievaluasi menggunakan metrik klasifikasi (akurasi, presisi, daya ingat, AUC-ROC). Prediksi *churn* biner per pelanggan individual **tidak diimplementasikan** pada versi

sistem ini dan direkomendasikan sebagai pengembangan di masa mendatang (lihat Bab VII).

VI.3.1 Protokol Evaluasi

Evaluasi menggunakan *walk-forward validation* dengan langkah-langkah berikut.

1. Data deret waktu diurutkan secara kronologis.
2. Sejumlah n bulan terakhir (3–6 bulan, tergantung ketersediaan data) disisihkan sebagai data pengujian.
3. Pada setiap langkah pengujian, model dilatih pada seluruh data hingga bulan ke- t , kemudian memprediksi bulan ke- $t + 1$.
4. Proses diulang untuk setiap bulan pengujian.
5. Metrik evaluasi dihitung pada skala asli (setelah *inverse scaling*).

Pendekatan ini memastikan bahwa evaluasi bersifat realistis dan tidak menggunakan data masa depan (*data leakage*). Penilaian KPI menggunakan tiga kategori bertingkat berdasarkan kombinasi sMAPE dan *Skill Score* sebagai berikut.

1. LULUS: $\text{sMAPE} < 30\%$ dan $\text{Skill Score} > -0,1$. Model memenuhi ambang batas kesalahan absolut dan mampu mengungguli atau mendekati *naive forecast*.
2. Lulus Dengan Catatan (LDC): Model memenuhi sebagian ambang batas KPI. Terdapat dua skenario:
 - (a) $\text{sMAPE} < 30\%$ dan $\text{Skill Score} \in (-0,5; -0,1]$. Kesalahan absolut masih dalam toleransi bisnis, namun model kalah dari *naive forecast* akibat karakteristik data yang sangat stabil atau volumenya terbatas.
 - (b) $\text{sMAPE} \in [30\%; 32\%)$ dan $\text{Skill Score} > -0,1$. Kesalahan absolut marjinal melebihi ambang batas, namun model tetap mengungguli *naive forecast*. Kondisi ini lazim terjadi pada deret waktu dengan volatilitas tinggi dan jumlah titik uji yang terbatas.Hasil prediksi dengan status LDC dapat digunakan secara operasional dengan pemahaman atas keterbatasan yang menyertainya.
3. GAGAL: $\text{sMAPE} \geq 32\%$ atau $\text{Skill Score} \leq -0,5$, atau $\text{sMAPE} \geq 30\%$ dan $\text{Skill Score} \leq -0,1$. Model tidak memenuhi standar minimum akurasi atau menyimpang jauh dari *naive forecast*.

VI.3.2 Metrik Evaluasi

Pengukuran performa akurasi model dilakukan dengan menggunakan sejumlah metrik kuantitatif baku untuk analisis deret waktu, yang sebelumnya telah dikonseptualisasi pada tahap perancangan (Bab IV). Tabel VI.6 secara terstruktur menyajikan kelima metrik yang diimplementasikan beserta penjelasan formulasi matematis yang

melandasinya. Kelima metrik ini dievaluasi secara serentak guna memberikan penilaian performa yang komprehensif, mulai dari skala kesalahan absolut, persentase deviasi, hingga tingkat performa relatif terhadap model basis (*baseline*).

Tabel VI.6 Metrik Evaluasi yang Digunakan

Metrik	Deskripsi
MAE	Rata-rata nilai absolut selisih antara prediksi dan aktual
RMSE	Akar kuadrat rata-rata kuadrat selisih
sMAPE	Persentase kesalahan absolut simetris (rentang 0–200%)
MASE	Kesalahan rata-rata yang diskalakan terhadap <i>seasonal naive</i> ($m = 12$)
<i>Skill Score</i>	$1 - \text{MAE}_{\text{model}} / \text{MAE}_{\text{baseline}}$

Implementasi metrik-metrik tersebut menjadi landasan objektif dalam menilai tingkat simpangan prediksi model (*forecast errors*). Penilaian holistik atas metrik-metrik ini pada akhirnya bermuara pada keputusan deterministik pengklasifikasian kelayakan model ke dalam tiga tingkat status KPI: LULUS, Lulus Dengan Catatan (LDC), atau GAGAL.

VI.3.3 Hasil Evaluasi per Metrik Bisnis

Evaluasi dilakukan pada keempat metrik bisnis utama secara setara menggunakan protokol *walk-forward validation* dengan empat model (GRU, LSTM, ARIMA, *Prophet*) pada enam tingkat wilayah (Nasional, REG-1 hingga REG-5).

VI.3.3.1 Peramalan Rata-rata Hari Instalasi (*Avg Install Days*)

Tabel VI.7 menyajikan hasil evaluasi keempat model untuk metrik *avg_install_days* pada seluruh tingkat wilayah. Nilai sMAPE dan MASE yang lebih rendah menunjukkan akurasi yang lebih baik, sedangkan *Skill Score* yang lebih tinggi (positif) menunjukkan model lebih unggul dari *baseline seasonal naive*.

GRU menunjukkan kinerja terbaik di antara keempat model pada metrik ini, dengan lima wilayah berstatus LULUS dan satu wilayah (REG-4) berstatus Lulus Dengan Catatan (sMAPE = 24,61%, *Skill Score* = −0,396). Keunggulan GRU atas LSTM disebabkan oleh arsitektur yang lebih ringkas dengan jumlah parameter lebih sedikit sehingga lebih tahan terhadap *overfitting* pada data deret waktu yang relatif pendek. LSTM gagal memenuhi KPI pada REG-3 (*Skill Score* = −0,958) dan REG-4 (sMAPE = 31,32%). ARIMA memberikan performa kompetitif pada wilayah dengan pola data stabil — bahkan sedikit lebih baik dari GRU pada tingkat Nasional (sMAPE = 10,75% vs. 10,86%) dan REG-2 (sMAPE = 10,30% vs. 13,16%) — namun

Tabel VI.7 Perbandingan Hasil Evaluasi Model Peramalan pada Metrik *Avg Install Days*

Wilayah	Model	sMAPE (%)	MASE	<i>Skill Score</i>	KPI
Nasional	GRU	10,86	0,020	0,400	LULUS
	LSTM	12,18	0,023	0,350	LULUS
	ARIMA	10,75	0,018	0,480	LULUS
	<i>Prophet</i>	176,92	1,124	−10,00	GAGAL
REG-1	GRU	6,74	0,009	0,497	LULUS
	LSTM	11,77	0,016	0,149	LULUS
	ARIMA	10,51	0,014	0,232	LULUS
	<i>Prophet</i>	130,22	0,116	−5,253	GAGAL
REG-2	GRU	13,16	0,027	0,259	LULUS
	LSTM	13,45	0,027	0,252	LULUS
	ARIMA	10,30	0,020	0,434	LULUS
	<i>Prophet</i>	146,76	0,170	−3,725	GAGAL
REG-3	GRU	8,96	0,016	0,373	LULUS
	LSTM	24,61	0,051	−0,958	GAGAL
	ARIMA	41,27	0,060	−1,328	GAGAL
	<i>Prophet</i>	183,97	1,649	−10,00	GAGAL
REG-4	GRU	24,61	0,164	−0,396	LDC
	LSTM	31,32	0,215	−0,825	GAGAL
	ARIMA	35,40	0,267	−1,269	GAGAL
	<i>Prophet</i>	191,81	1,682	−10,00	GAGAL
REG-5	GRU	18,50	0,019	0,508	LULUS
	LSTM	24,39	0,027	0,323	LULUS
	ARIMA	20,41	0,019	0,516	LULUS
	<i>Prophet</i>	153,09	0,091	−1,315	GAGAL

Keterangan: LDC = Lulus Dengan Catatan (sMAPE < 30% namun *Skill Score* $\in (-0,5; -0,1]$).

gagal signifikan pada REG-3 (sMAPE = 41,27%) dan REG-4 (sMAPE = 35,40%). *Prophet* gagal menyeluruh pada seluruh wilayah dengan sMAPE berkisar 130%–192%, disebabkan oleh ketidakcocokan antara asumsi dekomposisi aditif *Prophet* dengan data operasional yang tidak memiliki pola musiman dominan.

VI.3.3.2 Peramalan Volume Pesanan (*Order HSI*)

Tabel VI.8 menyajikan hasil evaluasi keempat model pada metrik *order_hsi* yang merepresentasikan volume pesanan layanan internet.

Tabel VI.8 Perbandingan Hasil Evaluasi Model Peramalan pada Metrik *Order HSI*

Wilayah	Model	sMAPE (%)	MASE	<i>Skill Score</i>	KPI
Nasional	GRU	13,09	0,418	0,247	LULUS
	LSTM	16,50	0,521	0,063	LULUS
	ARIMA	16,74	0,538	0,032	LULUS
	<i>Prophet</i>	15,27	0,534	0,039	LULUS
REG-1	GRU	16,43	0,617	0,103	LULUS
	LSTM	14,84	0,561	0,215	LULUS
	ARIMA	16,38	0,588	0,176	LULUS
	<i>Prophet</i>	10,91	0,388	0,456	LULUS
REG-2	GRU	10,77	0,422	0,307	LULUS
	LSTM	12,60	0,493	0,165	LULUS
	ARIMA	13,55	0,524	0,112	LULUS
	<i>Prophet</i>	19,63	0,845	−0,434	LDC
REG-3	GRU	15,54	0,414	0,167	LULUS
	LSTM	15,49	0,410	0,158	LULUS
	ARIMA	16,85	0,458	0,060	LULUS
	<i>Prophet</i>	22,93	0,711	−0,460	LDC
REG-4	GRU	20,76	0,823	0,228	LULUS
	LSTM	21,27	0,838	0,223	LULUS
	ARIMA	16,09	0,645	0,402	LULUS
	<i>Prophet</i>	27,29	1,013	0,061	LULUS
REG-5	GRU	13,16	0,495	0,211	LULUS
	LSTM	13,34	0,501	0,236	LULUS
	ARIMA	18,29	0,661	−0,009	LULUS
	<i>Prophet</i>	14,83	0,547	0,166	LULUS

Keterangan: LDC = Lulus Dengan Catatan (sMAPE < 30% namun *Skill Score* ∈ (−0,5; −0,1]).

Seluruh model berhasil memenuhi KPI pada tingkat nasional untuk metrik volume pesanan, dengan GRU mencatat sMAPE terendah (13,09%) dan *Skill Score* tertinggi (0,247). Berbeda dengan metrik *avg_install_days*, *Prophet* menunjukkan kinerja yang kompetitif pada metrik ini. Pada REG-1, *Prophet* bahkan mencatat sMAPE terendah (10,91%) dan *Skill Score* tertinggi (0,456), yang mengindikasikan bahwa data pesanan memiliki pola musiman yang lebih kuat dibandingkan data operasional.

Seluruh model GRU, LSTM, dan ARIMA berstatus LULUS pada semua tingkat wilayah, sementara *Prophet* memperoleh status Lulus Dengan Catatan pada REG-2 dan REG-3.

VI.3.3.3 Peramalan Volume *Churn* (*Churn HSI*)

Tabel VI.9 menyajikan hasil evaluasi keempat model pada metrik *churn_hsi* yang merepresentasikan jumlah agregat pelanggan yang berhenti berlangganan per bulan.

Tabel VI.9 Perbandingan Hasil Evaluasi Model Peramalan pada Metrik *Churn HSI*

Wilayah	Model	sMAPE (%)	MASE	<i>Skill Score</i>	KPI
Nasional	GRU	22,29	0,504	0,169	LULUS
	LSTM	22,97	0,516	0,149	LULUS
	ARIMA	26,53	0,596	0,017	LULUS
	<i>Prophet</i>	45,15	1,592	−1,627	GAGAL
REG-1	GRU	30,95	0,713	0,013	LDC
	LSTM	30,83	0,717	0,008	LDC
	ARIMA	40,56	0,938	−0,196	GAGAL
	<i>Prophet</i>	74,71	1,856	−1,365	GAGAL
REG-2	GRU	14,30	0,295	0,160	LULUS
	LSTM	14,67	0,302	0,140	LULUS
	ARIMA	12,42	0,255	0,276	LULUS
	<i>Prophet</i>	54,21	1,794	−4,099	GAGAL
REG-3	GRU	22,10	0,496	−0,169	LDC
	LSTM	21,08	0,477	−0,124	LDC
	ARIMA	16,35	0,374	0,120	LULUS
	<i>Prophet</i>	55,49	1,992	−3,692	GAGAL
REG-4	GRU	27,67	0,616	0,239	LULUS
	LSTM	30,06	0,664	0,180	LDC
	ARIMA	27,63	0,609	0,248	LULUS
	<i>Prophet</i>	60,96	2,046	−1,530	GAGAL
REG-5	GRU	28,19	0,660	0,097	LULUS
	LSTM	27,28	0,643	0,121	LULUS
	ARIMA	31,47	0,679	0,160	LDC
	<i>Prophet</i>	46,23	1,207	−0,492	GAGAL

Keterangan: LDC = Lulus Dengan Catatan (*sMAPE* < 30% namun *Skill Score* $\in (-0,5; -0,1]$, atau *sMAPE* marjinal melebihi ambang batas (30%–32%) namun *Skill Score* > −0,1).

Peramalan *churn* merupakan tugas yang paling menantang di antara seluruh metrik yang dievaluasi. Pada tingkat nasional, GRU dan LSTM berhasil memenuhi KPI dengan *sMAPE* masing-masing 22,29% dan 22,97%, sedangkan *Prophet* gagal secara menyeluruh di seluruh wilayah. Pada REG-5 (Sulawesi–Papua–Maluku), GRU dan LSTM berhasil memenuhi ambang batas setelah dilakukan *hyperparameter tuning* dengan *sMAPE* masing-masing 28,19% dan 27,28%. GRU tetap menjadi model paling *robust* dengan lima wilayah berstatus LULUS atau Lulus Dengan Catatan dari

enam wilayah. ARIMA menunjukkan keunggulan pada REG-3 (LULUS vs. LDC pada GRU) dan REG-4 (LULUS dengan sMAPE sebanding).

Kinerja *Prophet* yang kurang memuaskan pada metrik *churn* semakin menegaskan bahwa metode dekomposisi berbasis tren dan musiman klasik kesulitan menangkap sinyal-sinyal fluktuatif yang tidak linier. Pola pelanggan yang berhenti berlangganan sering kali tidak mengikuti kalender musiman yang ketat, melainkan lebih dipengaruhi oleh dinamika promosi kompetitor, kualitas layanan jaringan pada bulan tertentu, atau faktor makroekonomi regional. Sebaliknya, model *deep learning* membuktikan kemampuannya dalam memodelkan interaksi kompleks antar variabel tanpa bergantung pada asumsi stasioneritas maupun periodisitas yang kaku. Hal ini sangat krusial mengingat data *churn* pada industri telekomunikasi sering kali dipenuhi oleh lonjakan seketika (*sudden spikes*) yang dapat menjerumuskan model statistik tradisional ke dalam kesalahan peramalan yang fatal.

Tantangan utama terletak pada REG-1 (Sumatera) yang merupakan satu-satunya wilayah tanpa model yang memenuhi ambang batas sMAPE 30% secara penuh. Model terbaik pada wilayah ini — LSTM dengan sMAPE 30,83% dan GRU dengan sMAPE 30,95% — memperoleh status Lulus Dengan Catatan (LDC) karena *Skill Score* yang tetap positif (0,008 dan 0,013) menunjukkan bahwa kedua model masih mengungguli *naive forecast*. Kondisi marginal ini disebabkan oleh tiga faktor: (1) volatilitas tinggi pada data *churn* REG-1 yang dipengaruhi oleh faktor nonperiodik seperti perubahan regulasi, program retensi ad-hoc, dan kondisi infrastruktur lokal di wilayah Sumatera; (2) keterbatasan jumlah titik data (41 bulan) yang menyulitkan model untuk mempelajari pola jangka panjang; dan (3) jumlah titik uji *walk-forward* yang terbatas (5 bulan) sehingga satu titik kesalahan besar dapat menaikkan rata-rata sMAPE secara signifikan. Meskipun demikian, hasil prediksi pada REG-1 tetap dapat digunakan secara operasional dengan pemahaman bahwa ketidakpastian estimasi pada wilayah tersebut lebih tinggi dibandingkan wilayah lain.

VI.3.3.4 Peramalan Realisasi Target (*Realisasi HSI*)

Tabel VI.10 menyajikan hasil evaluasi keempat model pada metrik *realisasi_hsi* yang merepresentasikan tingkat pencapaian target penjualan layanan internet secara agregat. Metrik ini sangat esensial secara bisnis karena merefleksikan performa komersial perusahaan dibandingkan dengan kuota yang dicanangkan. Oleh karena itu, kemampuan model untuk memprediksi metrik ini secara akurat akan sangat membantu jajaran manajemen dalam merumuskan manuver strategis di sisa periode berjalan.

Tabel VI.10 Perbandingan Hasil Evaluasi Model Peramalan pada Metrik *Realisasi HSI*

Wilayah	Model	sMAPE (%)	MASE	<i>Skill Score</i>	KPI
Nasional	GRU	8,27	0,101	0,481	LULUS
	LSTM	6,48	0,079	0,593	LULUS
	ARIMA	20,29	0,251	−0,080	LULUS
	<i>Prophet</i>	12,36	0,157	0,193	LULUS
REG-1	GRU	11,01	0,136	0,224	LULUS
	LSTM	11,62	0,143	0,179	LULUS
	ARIMA	15,97	0,202	0,214	LULUS
	<i>Prophet</i>	47,01	0,499	−1,855	GAGAL
REG-2	GRU	8,12	0,083	0,548	LULUS
	LSTM	6,56	0,067	0,635	LULUS
	ARIMA	11,91	0,122	0,163	LULUS
	<i>Prophet</i>	25,48	0,218	−0,190	LDC
REG-3	GRU	10,44	0,111	0,387	LULUS
	LSTM	9,84	0,105	0,417	LULUS
	ARIMA	13,41	0,148	0,579	LULUS
	<i>Prophet</i>	24,22	0,306	−0,698	GAGAL
REG-4	GRU	7,09	0,237	0,689	LULUS
	LSTM	6,26	0,209	0,726	LULUS
	ARIMA	11,09	0,463	0,037	LULUS
	<i>Prophet</i>	50,45	1,239	−0,626	GAGAL
REG-5	GRU	9,28	0,157	0,529	LULUS
	LSTM	9,33	0,158	0,526	LULUS
	ARIMA	21,22	0,334	−0,316	LDC
	<i>Prophet</i>	21,33	0,310	0,072	LULUS

Keterangan: LDC = Lulus Dengan Catatan (sMAPE < 30% namun *Skill Score* $\in (-0,5; -0,1]$).

Metrik realisasi target menunjukkan hasil evaluasi terbaik di antara seluruh metrik bisnis. LSTM mencatat kinerja tertinggi secara keseluruhan dengan sMAPE 6,48% pada tingkat nasional dan seluruh enam wilayah berstatus LULUS. GRU menunjukkan kinerja yang sebanding, juga dengan seluruh wilayah berstatus LULUS. Keunggulan LSTM atas GRU pada metrik ini disebabkan oleh data realisasi target yang cenderung memiliki tren jangka menengah yang lebih jelas sehingga arsitektur *memory cell* LSTM yang lebih kompleks mampu menangkap dependensi temporal lebih baik tanpa risiko *overfitting*. ARIMA memperoleh status LDC pada REG-5, sementara *Prophet* gagal pada tiga wilayah (REG-1, REG-3, REG-4). Hasil ini menunjukkan bahwa model *deep learning* (GRU dan LSTM) secara konsisten lebih unggul untuk peramalan pencapaian target penjualan.

VI.3.3.5 Ringkasan Lintas Metrik

Untuk memberikan gambaran akhir yang utuh mengenai keunggulan kompetitif masing-masing algoritma, Tabel VI.11 merangkum kinerja model terbaik untuk setiap metrik bisnis pada tingkat agregasi nasional. Sintesis ini krusial sebagai landasan pemilihan model *default* yang akan tertanam dalam layanan *backend* untuk melayani kueri-kueri prediktif pengguna.

Tabel VI.11 Ringkasan Kinerja Model Terbaik per Metrik Bisnis (Tingkat Nasional)

Metrik	Model Terbaik	sMAPE (%)	MASE	<i>Skill Score</i>	KPI
Order HSI	GRU	13,09	0,418	0,247	LULUS
Churn HSI	GRU	22,29	0,504	0,169	LULUS
Realisasi HSI	LSTM	6,48	0,079	0,593	LULUS
Avg Install Days	GRU	10,86	0,020	0,400	LULUS

Seluruh metrik bisnis utama yang dijanjikan pada tujuan penelitian berhasil diramalkan dengan status LULUS pada tingkat nasional. GRU menjadi model terbaik pada tiga dari empat metrik (*order_hsi*, *churn_hsi*, dan *avg_install_days*), sedangkan LSTM unggul pada *realisasi_hsi*. Temuan ini mengkonfirmasi bahwa arsitektur *recurrent neural network* (GRU dan LSTM) secara konsisten lebih unggul dibandingkan model statistik (ARIMA) dan model dekomposisi (*Prophet*) untuk peramalan deret waktu multimetrik pada konteks bisnis telekomunikasi.

VI.3.4 Analisis Komparatif Antar-Model

Berdasarkan hasil evaluasi pada keempat metrik bisnis, berikut adalah analisis karakteristik kinerja masing-masing model secara lintas-metrik.

VI.3.4.1 Kinerja Model GRU

Model GRU menunjukkan kinerja terbaik secara keseluruhan di antara keempat model yang diuji. Pada metrik `avg_install_days`, GRU berhasil memenuhi ambang batas KPI pada lima dari enam wilayah dengan status LULUS, dan menjadi satu-satunya model tanpa status GAGAL pada metrik tersebut. Pada metrik `order_hsi`, GRU mencatat sMAPE terendah pada tingkat nasional (13,09%). Pada metrik `churn_hsi` yang merupakan tugas paling menantang, GRU tetap menjadi model paling *robust* dengan lima wilayah berstatus LULUS atau Lulus Dengan Catatan dari enam wilayah. Keunggulan GRU secara konsisten disebabkan oleh arsitektur yang lebih ringkas dengan jumlah parameter lebih sedikit dibandingkan LSTM sehingga lebih tahan terhadap *overfitting* pada data deret waktu yang relatif pendek (20–55 titik data).

VI.3.4.2 Kinerja Model LSTM

Model LSTM menunjukkan keunggulan spesifik pada metrik `realisasi_hsi`, dengan seluruh enam wilayah berstatus LULUS dan sMAPE terendah pada tingkat nasional (6,48%). Keunggulan ini disebabkan oleh data realisasi target yang memiliki tren jangka menengah yang lebih jelas sehingga arsitektur *memory cell* LSTM yang lebih kompleks mampu menangkap dependensi temporal lebih baik. Namun, pada metrik lain — terutama `avg_install_days` dan `churn_hsi` — LSTM memiliki kinerja yang lebih rendah dibandingkan GRU akibat kecenderungan *overfitting* pada data pelatihan yang terbatas.

VI.3.4.3 Kinerja Model ARIMA

Model ARIMA memberikan performa yang kompetitif pada deret waktu yang relatif stabil. Pada metrik `avg_install_days`, ARIMA bahkan sedikit lebih baik dari GRU pada tingkat Nasional (sMAPE = 10,75% vs. 10,86%) dan REG-2 (sMAPE = 10,30% vs. 13,16%). Pada metrik `order_hsi`, seluruh wilayah ARIMA berstatus LULUS. Namun, ARIMA gagal secara signifikan pada wilayah dengan volatilitas tinggi, terutama pada metrik `avg_install_days` di REG-3 dan REG-4. Hasil ini mengkonfirmasi bahwa ARIMA efektif untuk deret waktu stasioner tetapi kurang *robust* terhadap pola non-linier dan perubahan mendadak.

VI.3.4.4 Kegagalan Model *Prophet*

Model *Prophet* menunjukkan kinerja yang sangat bervariasi antar-metrik. Pada metrik `avg_install_days` dan `churn_hsi`, *Prophet* gagal menyeluruh di seluruh wilayah karena data operasional dan *churn* tidak memiliki pola musiman dominan yang menjadi asumsi utama model. Sebaliknya, pada metrik `order_hsi`, *Prophet* me-

nunjukkan kinerja kompetitif — bahkan mencatat sMAPE terendah pada REG-1 (10,91%) — yang mengindikasikan bahwa data pesanan memiliki pola musiman yang lebih kuat dan sesuai dengan asumsi dekomposisi aditif *Prophet*. Pada metrik *realisasi_hsi*, *Prophet* gagal pada tiga wilayah. Temuan ini menunjukkan bahwa kecocokan *Prophet* sangat bergantung pada keberadaan pola musiman dalam data, dan model ini tidak direkomendasikan sebagai pilihan utama untuk metrik operasional.

VI.3.4.5 Kesimpulan Perbandingan Model

GRU merupakan model yang paling *robust* secara keseluruhan, menjadi model terbaik pada tiga dari empat metrik (*order_hsi*, *churn_hsi*, dan *avg_install_days*). LSTM unggul secara spesifik pada metrik *realisasi_hsi* yang memiliki tren jangka menengah yang jelas. ARIMA menjadi alternatif yang baik untuk wilayah dengan pola data stabil, tetapi kurang andal pada wilayah dengan volatilitas tinggi. *Prophet* hanya kompetitif pada metrik dengan pola musiman kuat (*order_hsi*) dan tidak digunakan sebagai model produksi utama pada sistem BrightAI.

VI.3.4.6 Catatan Metodologis: Sifat Perbandingan

Perbandingan antar-model pada evaluasi ini bersifat **deskriptif**, bukan inferensial. Uji signifikansi statistik seperti Diebold-Mariano (Python Package Index 2025) tidak diterapkan karena keterbatasan jumlah observasi pengujian. Protokol *walk-forward validation* yang digunakan menghasilkan hanya 3–6 titik kesalahan peramalan (*forecast errors*) per model per wilayah, yang tidak memenuhi syarat ukuran sampel minimum untuk uji hipotesis berpasangan yang bermakna secara statistik. Dengan jumlah titik uji yang sangat terbatas, uji signifikansi akan memiliki *statistical power* yang terlalu rendah untuk menghasilkan kesimpulan yang dapat diandalkan.

Oleh karena itu, pemilihan model terbaik didasarkan pada kriteria KPI bertingkat (LULUS / Lulus Dengan Catatan / GAGAL) yang mengevaluasi setiap model secara independen terhadap ambang batas sMAPE dan *Skill Score* yang telah ditetapkan sebelumnya, bukan pada perbandingan berpasangan antar-model. Pendekatan ini sesuai dengan konteks sistem produksi dengan keputusan utama adalah apakah suatu model memenuhi standar minimum performa bisnis, bukan apakah satu model secara statistik lebih unggul dari model lain pada tingkat signifikansi tertentu. Keterbatasan ini dapat dimitigasi pada pengembangan selanjutnya dengan mengakumulasi lebih banyak periode evaluasi seiring waktu sehingga memungkinkan penerapan uji formal seperti Diebold-Mariano atau *Model Confidence Set* (Arch Library Doc-

umentation 2025).

VI.3.5 Mekanisme Pembandingan Model

Sistem mengimplementasikan mekanisme pembandingan otomatis yang membandingkan model yang baru dilatih dengan model terbaik sebelumnya. Model baru hanya disimpan jika: (1) nilai sMAPE model baru lebih rendah dari model sebelumnya, atau (2) nilai sMAPE sama tetapi *Skill Score* model baru lebih tinggi. Riwayat pelatihan seluruh model disimpan dalam berkas `training_history.json` untuk keperluan pelacakan dan audit. Mekanisme ini mencegah regresi performa yang dapat terjadi akibat variasi stokastik pada proses pelatihan.

VI.4 Evaluasi Sistem Terintegrasi

Evaluasi sistem secara terintegrasi dilakukan untuk memverifikasi bahwa seluruh komponen dapat bekerja sama dengan baik dalam alur *end-to-end*.

VI.4.1 Pengujian Alur Lengkap

Pengujian alur lengkap mencakup skenario dari penerimaan kueri pengguna hingga penampilan respons pada antarmuka *chatbot*. Alur yang diuji meliputi:

1. Kueri Analitik: Pengguna mengajukan pertanyaan tentang data bisnis → klasifikasi *intent* → pencocokan aturan → eksekusi kueri SQL → pemrosesan logika bisnis → pembangkitan narasi NLG → penyimpanan riwayat percakapan → penampilan respons.
2. Kueri Peramalan: Pengguna memilih metrik dan cakupan wilayah pada panel peramalan → permintaan diteruskan ke layanan ML → pelatihan/inferensi model → hasil prediksi dikembalikan → pembangkitan narasi peramalan → penampilan respons.
3. Mekanisme *Fallback*: Pengguna mengajukan pertanyaan di luar cakupan → klasifikasi gagal → respons panduan penggunaan ditampilkan.

VI.4.2 Pengujian Waktu Respons

Waktu respons sistem diukur dari penerimaan kueri oleh *backend* hingga pengiriman respons ke *frontend*. Komponen waktu respons *end-to-end* terdiri dari:

1. Waktu klasifikasi *intent*: < 1 milidetik
2. Waktu pencocokan aturan: < 10 milidetik
3. Waktu eksekusi kueri SQL (terhadap Oracle): bervariasi tergantung kompleksitas kueri dan volume data
4. Waktu pemrosesan logika bisnis dan NLG: < 50 milidetik
5. Waktu inferensi model peramalan: < 500 milidetik

Dalam kueri analitik yang telah di-*cache*, waktu respons dapat mencapai kurang dari 10 milidetik karena hasil kueri diambil langsung dari *cache* memori.

VI.4.3 Pengujian Manajemen Sesi dan Riwayat

Sistem berhasil mengelola sesi percakapan dan riwayat pesan dengan fitur-fitur berikut:

1. Pembuatan sesi otomatis ketika pengguna memulai percakapan baru
2. Penyimpanan setiap pesan pengguna dan respons sistem ke basis data
3. Penghitungan jumlah pesan per sesi secara inkremental
4. Pengambilan riwayat percakapan per sesi atau keseluruhan
5. Penghapusan riwayat per sesi atau keseluruhan dengan verifikasi kepemilikan

VI.5 Validasi oleh Pengguna Internal

Sebagai pelengkap pengujian teknis, sistem BrightAI divalidasi secara langsung oleh pengguna internal dari tim *Data Management*. Validasi ini berfokus pada aspek relevansi analitik, keterbacaan respons, dan kesesuaian hasil dengan kebutuhan operasional pengguna.

VI.5.1 Ruang Lingkup Validasi

Validasi mencakup tiga aspek utama berikut.

1. Relevansi Kueri: Kemampuan sistem dalam memahami dan merespons pertanyaan yang berkaitan dengan metrik operasional seperti *order* HSI, *churn*, *fulfillment rate*, realisasi terhadap target, dan rata-rata hari instalasi.
2. Akurasi Hasil Analitik: Kesesuaian angka dan data yang disajikan dalam respons sistem dengan data aktual yang tersedia pada *Enterprise Data Warehouse* Oracle.
3. Keterbacaan Respons NLG: Kemudahan pengguna dalam memahami narasi, tabel, dan *insight* yang dihasilkan oleh modul pembangkitan bahasa alami.

VI.5.2 Temuan Validasi

Berdasarkan proses validasi yang dilakukan oleh tim *Data Management*, diperoleh temuan sebagai berikut.

1. Sistem secara konsisten menghasilkan respons yang benar dan relevan untuk pertanyaan-pertanyaan yang mencakup domain penjualan, pendapatan, target, proses data pelanggan, dan *churn*.
2. Seluruh angka yang ditampilkan dalam respons terverifikasi sesuai dengan data sumber. Konsistensi ini merupakan jaminan arsitektural dari pendekatan NLG berbasis templat yang menyisipkan nilai langsung dari hasil kueri, bukan

temuan pengukuran empiris independen.

3. Format narasi dalam bahasa Indonesia yang dihasilkan dinilai informatif dan mudah dipahami, termasuk penggunaan tabel untuk data tabular dan poin-poin untuk wawasan bisnis.
4. Fitur injeksi filter geografis berfungsi dengan benar, menghasilkan analisis yang spesifik sesuai cakupan wilayah yang ditanyakan pengguna.

VI.6 Umpan Balik Pengguna Internal

Bagian ini menyajikan umpan balik yang diperoleh dari pengguna internal perusahaan telekomunikasi dalam proses validasi sistem BrightAI. Umpan balik dikumpulkan melalui kuesioner yang diisi oleh anggota tim *Data Management* setelah menggunakan sistem secara langsung untuk kegiatan analitik operasional.

VI.6.1 Profil Responden dan Metodologi

Umpan balik diperoleh dari seorang *Officer Data Mining & Processing* pada unit *Data Management*. Responden memiliki pengalaman langsung dalam pengolahan dan analisis data operasional perusahaan sehingga penilaian yang diberikan mencerminkan perspektif pengguna aktual yang memahami konteks bisnis dan kualitas data yang mendasari sistem.

Penilaian dilakukan menggunakan skala Likert 1–5, dengan deskripsi sebagai berikut: 1 = Sangat Buruk, 2 = Buruk, 3 = Cukup, 4 = Baik, dan 5 = Sangat Baik. Empat aspek kualitas yang dinilai meliputi ketepatan respons, kejelasan narasi, relevansi analisis, dan kemudahan penggunaan.

VI.6.2 Hasil Penilaian Kuantitatif

Tabel VI.12 menyajikan skor penilaian untuk setiap aspek kualitas sistem.

Rata-rata skor penilaian sebesar **4,75 dari 5,00 (95%)** menunjukkan tingkat kepuasan pengguna yang tinggi terhadap kualitas keluaran sistem secara keseluruhan. Aspek ketepatan respons, kejelasan narasi, dan kemudahan penggunaan memperoleh skor sempurna (5/5), sedangkan relevansi analisis memperoleh skor 4/5 yang mengindikasikan adanya ruang peningkatan pada cakupan dan kedalaman *insight* yang dihasilkan.

VI.6.3 Umpan Balik Kualitatif

Responden memberikan penjelasan naratif dan umpan balik kualitatif secara menyeluruh terkait pengalaman interaksi dengan sistem, sebagaimana disarikan dalam kutipan otentik berikut:

Tabel VI.12 Skor Penilaian Kualitas Sistem BrightAI oleh Pengguna Internal

Aspek Penilaian	Skor	Kategori	Deskripsi Aspek
Ketepatan Respons	5/5	Sangat Baik	Kesesuaian jawaban sistem dengan data aktual pada <i>Enterprise Data Warehouse</i> .
Kejelasan Narasi	5/5	Sangat Baik	Kemudahan memahami narasi, tabel, dan penjelasan yang dihasilkan oleh modul NLG.
Relevansi Analisis	4/5	Baik	Kesesuaian <i>insight</i> dan analisis yang diberikan dengan kebutuhan operasional.
Kemudahan Penggunaan	5/5	Sangat Baik	Kemudahan alur interaksi, <i>layout</i> menu, dan tombol navigasi.
Rata-Rata	4,75/5	Sangat Baik	

Keterangan skala: 1 = Sangat Buruk, 2 = Buruk, 3 = Cukup, 4 = Baik, 5 = Sangat Baik.

“Secara umum semua sudah sesuai. Respons tepat sesuai data, narasi cukup jelas dan mudah dipahami, analisis relevan sesuai dengan konteks pertanyaan, layout menu dan button cukup intuitif sehingga mudah digunakan.”

Kutipan di atas mengonfirmasi bahwa aspek fungsionalitas utama, ketepatan penyajian data analitik, kejelasan narasi, serta keramahan antarmuka pengguna (*user experience*) telah berhasil diwujudkan dengan sangat baik oleh sistem.

VI.6.4 Masukan dan Saran Perbaikan

Di sisi lain, responden juga memberikan evaluasi kritis dan masukan substansial spesifik terkait ketepatan leksikal terminologi operasional yang digunakan di dalam sistem:

“Sebagai masukan, terminologi ‘order’ dalam konteks penjualan yang sudah complete disarankan untuk diganti dengan ‘sales’. Karena order adalah permintaan pelanggan terhadap layanan, jenis order sebenarnya ada banyak: AO/activation order (order untuk pasang layanan, ini dihitung sebagai sales), MO/modify order (order untuk modifikasi layanan eksisting), DO/disconnect order (order untuk cabut layanan atau churn), dsb sehingga penggunaan kata ‘sales’ lebih tepat untuk menyatakan penjualan/pasang layanan.”

Masukan mendalam ini merefleksikan bahwa, meskipun sistem telah terbukti secara mutlak mampu menyajikan agregasi data yang akurat dan nirkekeliruan perhitungan, masih terbuka ruang perbaikan yang signifikan pada ranah kesesuaian leksikon bisnis (*business terminology alignment*). Penyesuaian frasa tersebut sangat krusial agar hasil narasi dari sistem sepenuhnya selaras dengan dialek dan konvensi internal yang dipahami di tingkat operasional perusahaan secara harfiah.

VI.6.5 Rekap Umpan Balik per Aspek

Dalam memfasilitasi evaluasi yang terstruktur terhadap kualitas respons sistem, umpan balik kualitatif dari responden dikelompokkan ke dalam empat aspek utama: Ketepatan Respons, Kejelasan Narasi, Relevansi Analisis, dan Kemudahan Penggunaan. Setiap aspek dinilai menggunakan skala 1 hingga 5, disertai dengan pencatatan temuan positif maupun saran perbaikan. Tabel VI.13 menyajikan rekapitulasi sintesis dari penilaian aspek-aspek kualitatif tersebut.

Tabel VI.13 Rekap Umpan Balik Kualitatif Pengguna Internal

Aspek	Skor	Temuan Positif	Catatan / Saran
Ketepatan Respons	5/5	Respons tepat sesuai data pada <i>Enterprise Data Warehouse</i> .	Terminologi “ <i>order</i> ” disarankan diganti “ <i>sales</i> ” untuk konteks penjualan yang sudah <i>complete</i> .
Kejelasan Narasi	5/5	Narasi cukup jelas dan mudah dipahami; format tabel dan poin-poin informatif.	Penambahan visualisasi grafik dapat memperkaya penyajian data.
Relevansi Analisis	4/5	Analisis relevan sesuai konteks pertanyaan operasional.	Perluasan cakupan domain dan kedalaman <i>insight</i> dapat meningkatkan nilai analitik.
Kemudahan Penggunaan	5/5	<i>Layout</i> menu dan tombol cukup intuitif sehingga mudah digunakan.	Fitur saran otomatis (<i>auto-suggest</i>) dapat mempercepat interaksi.

Berdasarkan rekapitulasi pada tabel di atas, terbukti bahwa sistem secara umum mampu menjawab ekspektasi pengguna secara fungsional. Peningkatan pada aspek-aspek rekomendasi, seperti penyesuaian istilah, dapat diakomodasi pada iterasi pengembangan sistem selanjutnya untuk terus menyempurnakan pengalaman dan nilai analitik yang disajikan.

VI.6.6 Contoh Kueri yang Diujikan

Tabel VI.14 menyajikan contoh kueri analitik yang diajukan selama sesi validasi beserta kualitas respons yang dievaluasi.

Tabel VI.14 Contoh Kueri Uji dan Evaluasi Respons Sistem (Data Ilustratif)

Kueri Pengguna	Ringkasan Respons Sistem	Catatan Validator
“Berapa total order HSI bisnis dan basic bulan ini di Witel X?” (Domain: Sales)	Menampilkan total order beserta distribusi layanan (HSI Bisnis & Basic), pertumbuhan MoM dan YoY, tingkat <i>bundling</i> , serta tren tiga bulan terakhir.	Respons lengkap dan akurat; distribusi layanan dan analisis <i>bundling</i> sesuai kebutuhan operasional.
“Segmentasi pelanggan HSI berdasarkan <i>speed</i> dan <i>revenue</i> di Regional 1” (Domain: Data Proses)	Menampilkan pemetaan segmentasi pelanggan per kategori (korporat, UKM, konsumen, pemerintah) beserta jumlah pelanggan per segmen.	Segmentasi sesuai dengan data profil pelanggan; membantu perencanaan strategi <i>targeting</i> .
“Tren pendapatan HSI enam bulan terakhir” (Domain: Revenue)	Menampilkan tren pendapatan bulanan, rata-rata pendapatan per pelanggan, perubahan MoM, serta klasifikasi pertumbuhan per periode.	Analisis tren relevan untuk evaluasi kinerja pendapatan; format tabel mudah dibandingkan antar-bulan.
“Analisis <i>churn</i> HSI per regional” (Domain: Churn/CT0)	Menampilkan jumlah pelanggan <i>churn</i> per regional, tingkat <i>churn rate</i> , pola masa layanan, serta distribusi bandwidth pelanggan yang <i>churn</i> .	Data <i>churn</i> per wilayah sesuai laporan internal; identifikasi pola masa layanan berguna untuk strategi retensi.
“Pencapaian target HSI bulan ini” (Domain: Target)	Menampilkan realisasi terhadap target penjualan, persentase pencapaian, perbandingan per regional, serta status pencapaian (tercapai/belum).	Persentase pencapaian sesuai data target; perbandingan antar-regional membantu identifikasi wilayah yang perlu perhatian.

Catatan: Seluruh nilai numerik dalam tabel ini bersifat ilustratif dan tidak merepresentasikan data aktual perusahaan demi menjaga kerahasiaan informasi bisnis.

Penyajian contoh kueri operasional di atas mengilustrasikan kemampuan *end-to-end* dari sistem dalam menafsirkan permintaan pengguna, mengagregasi data sesuai parameter yang dikehendaki, serta memberikan ringkasan interpretatif yang bermanfaat untuk konteks pengambilan keputusan nyata di tingkat regional.

VI.7 Pembahasan Hasil Evaluasi

Berdasarkan hasil evaluasi terhadap seluruh komponen sistem, beberapa temuan dan pembahasan utama adalah sebagai berikut.

1. Klasifikasi Maksud: Evaluasi kuantitatif terhadap 100 kueri uji berlabel menunjukkan akurasi pencocokan aturan sebesar **100%** dengan skor-F1 makro 1,0000 pada 38 kelas aturan. Evaluasi difokuskan pada level pencocokan aturan karena taksonomi *intent* dirancang bersifat saling eksklusif secara semantik sehingga klasifikasi pada level tersebut bersifat deterministik. Seluruh target performa berhasil tercapai, termasuk *coverage rate* 93% dan waktu respons rata-rata 0,14 ms. Akurasi sempurna dicapai melalui penerapan mekanisme *penalty* kontekstual yang mencegah tumpang tindih kata kunci antar-domain. Pendekatan *rule-based* memberikan keunggulan latensi sangat rendah (<1 ms), interpretabilitas penuh, dan determinisme yang menjamin konsistensi hasil klasifikasi.
2. Pembangkitan Bahasa Alami: Pendekatan berbasis templat secara arsitektural menjamin akurasi faktual 100% karena seluruh nilai numerik dalam narasi disisipkan langsung dari hasil kueri basis data tanpa proses generasi bebas sehingga mengeliminasi risiko halusinasi (*hallucination*). Evaluasi subjektif oleh pengguna internal menghasilkan rata-rata skor **4,75 dari 5,00** (95%) pada empat dimensi kualitas (ketepatan respons, kejelasan narasi, relevansi analisis, dan kemudahan penggunaan). Skor 4/5 pada dimensi relevansi analisis mengindikasikan ruang peningkatan pada cakupan dan kedalaman *insight*.
3. Peramalan Deret Waktu: Evaluasi kuantitatif terhadap empat model pada empat metrik bisnis utama (*order_hsi*, *churn_hsi*, *realisasi_hsi*, dan *avg_install_days*) menunjukkan bahwa seluruh indikator bisnis yang dijanjikan pada tujuan penelitian berhasil diramalkan dengan status LULUS pada tingkat nasional. GRU merupakan model yang paling *robust* secara keseluruhan, menjadi model terbaik pada tiga dari empat metrik, sedangkan LSTM unggul pada metrik realisasi target. Peramalan volume pesanan menunjukkan hasil terbaik dengan seluruh model berstatus LULUS pada semua wilayah. Peramalan *churn* menjadi tugas yang paling menantang; setelah dilakukan *hyperparameter tuning*, REG-5 berhasil ditingkatkan dari status GAGAL menjadi LULUS, sedangkan REG-1 (Sumatera) memperoleh status Lulus Dengan

Catatan karena sMAPE marjinal melebihi ambang batas (30,83%–30,95%) meskipun model tetap mengungguli *naive forecast*. Kondisi pada REG-1 disebabkan oleh volatilitas tinggi data *churn* di wilayah Sumatera yang dipengaruhi faktor nonperiodik. *Prophet* tidak sesuai untuk data operasional dan *churn* tetapi menunjukkan kinerja yang kompetitif pada data pesanan yang memiliki pola musiman lebih kuat. Protokol *walk-forward validation* memberikan estimasi performa yang realistis, dan mekanisme *benchmark* otomatis memastikan bahwa model yang disimpan selalu merupakan model terbaik yang tersedia.

4. Arsitektur Sistem: Arsitektur tiga lapis dengan layanan ML terpisah memberikan fleksibilitas dalam pengembangan dan skalabilitas. Pemisahan ini memungkinkan pelatihan model yang intensif secara komputasi tanpa mengganggu kinerja *backend* utama.
5. Validasi Pengguna Internal: Penilaian oleh *Officer Data Mining & Processing* dari tim *Data Management* menghasilkan rata-rata skor **4,75 dari 5,00** (95%) pada empat aspek kualitas: ketepatan respons (5/5), kejelasan narasi (5/5), relevansi analisis (4/5), dan kemudahan penggunaan (5/5). Skor ini mengkonfirmasi bahwa sistem mampu memproses kueri operasional dengan benar, menghasilkan analitik yang akurat, dan menyajikan respons yang informatif serta mudah dipahami. Masukan yang diperoleh menyoroti perlunya penyesuaian terminologi bisnis, yaitu penggunaan istilah “*sales*” sebagai pengganti “*order*” untuk konteks penjualan layanan yang sudah *complete*, guna meningkatkan kesesuaian dengan konvensi operasional perusahaan.

VI.7.1 Ancaman terhadap Validitas

Beberapa ancaman terhadap validitas hasil evaluasi perlu diakui agar temuan dapat diinterpretasikan secara proporsional.

1. Ukuran sampel deret waktu yang terbatas. Data historis yang tersedia berkisar antara 20 hingga 55 titik data bulanan per metrik per wilayah. Jumlah ini cukup untuk pelatihan model univariat, tetapi membatasi kapasitas model *deep learning* untuk mempelajari pola jangka panjang yang kompleks. Protokol *walk-forward validation* menghasilkan hanya 3–6 titik kesalahan peramalan per model per wilayah sehingga varians estimasi metrik evaluasi (sMAPE, *Skill Score*) cukup tinggi. Temuan bahwa suatu model berstatus LULUS atau GAGAL pada wilayah tertentu harus diinterpretasikan dengan mempertimbangkan keterbatasan ini; akumulasi data lebih lanjut seiring waktu akan meningkatkan keandalan estimasi.
2. Generalisasi lintas metrik. Meskipun evaluasi telah mencakup empat metrik

bisnis utama (*order_hsi*, *churn_hsi*, *realisasi_hsi*, dan *avg_install_days*), setiap metrik memiliki karakteristik statistik yang berbeda (tingkat volatilitas, keberadaan pola musiman, jumlah titik data). Superioritas GRU pada metrik operasional dan *churn* tidak serta-merta berlaku pada metrik lain yang belum dievaluasi, seperti pendapatan (*revenue*) per pelanggan. Demikian pula, keunggulan LSTM pada metrik realisasi target bersifat spesifik terhadap karakteristik data yang memiliki tren jangka menengah yang jelas.

3. Evaluasi klasifikasi oleh pengembang. Pelabelan 100 kueri uji untuk evaluasi klasifikasi *intent* dan pencocokan aturan dilakukan oleh pengembang sistem. Meskipun label telah disesuaikan agar konsisten dengan definisi aturan bisnis, terdapat risiko bias konfirmasi dengan label kueri ambigu cenderung diselaraskan dengan perilaku sistem. Mitigasi yang dilakukan meliputi penggunaan definisi *intent* yang eksplisit dan dokumentasi setiap penyesuaian label beserta justifikasinya. Akurasi sempurna (100%) yang dicapai pada dataset uji tidak menjamin kinerja yang sama pada kueri di luar dataset tersebut sehingga evaluasi berkelanjutan dengan kueri pengguna nyata tetap diperlukan.
4. Cakupan data satu perusahaan. Seluruh evaluasi dilakukan pada data historis dari satu perusahaan telekomunikasi. Hasil evaluasi, termasuk superioritas GRU atas model lain dan tingkat keberhasilan klasifikasi *intent*, bersifat spesifik terhadap distribusi data dan pola bisnis perusahaan tersebut. Generalisasi ke perusahaan atau industri lain memerlukan evaluasi ulang dengan data yang sesuai.

BAB VII

PENUTUP

Bab ini menyajikan kesimpulan dari pelaksanaan tugas akhir berdasarkan tujuan yang telah ditetapkan, serta saran untuk pengembangan sistem di masa mendatang.

VII.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan evaluasi yang telah dilakukan, diperoleh kesimpulan sebagai berikut.

1. Arsitektur sistem *Business Intelligence* berbasis *chatbot* telah berhasil dirancang dan diimplementasikan menggunakan arsitektur tiga lapis yang terdiri dari *frontend* React.js, *backend* Node.js/Express, dan layanan *machine learning* FastAPI/PyTorch. Sistem mampu memproses permintaan analisis data dan memberikan *insight* berbasis data kepada pengguna internal perusahaan secara otomatis melalui antarmuka percakapan berbasis web.
2. Modul pemrosesan bahasa alami telah diimplementasikan menggunakan pendekatan pencocokan pola kata kunci berbobot (*weighted keyword matching*) yang mendukung tujuh *intent* utama dan delapan fokus analisis. Evaluasi kuantitatif terhadap 100 kueri uji berlabel menunjukkan akurasi pencocokan aturan sebesar **100%** dengan skor-F1 makro 1,0000 pada 38 kelas aturan. Seluruh target performa berhasil tercapai, termasuk *coverage rate* 93% dan waktu respons rata-rata 0,14 milidetik. Evaluasi difokuskan pada level pencocokan aturan karena taksonomi *intent* dirancang bersifat saling eksklusif secara semantik sehingga klasifikasi pada level tersebut bersifat deterministik. Akurasi sempurna dicapai melalui penerapan mekanisme *penalty* kontekstual pada fungsi penghitungan keyakinan yang mencegah tumpang tindih kata kunci antar-domain.
3. Mekanisme *rule-based query* telah diimplementasikan melalui mesin aturan (*rule engine*) yang mendukung 38 aturan analitik, mencakup lima domain basis data bisnis (penjualan, pendapatan, target, proses data pelanggan, dan *churn*). Mesin aturan dilengkapi fitur injeksi filter geografis secara dinamis dan mekanisme *caching* untuk menghasilkan respons yang cepat dan konsis-

ten.

4. Model peramalan deret waktu terpilih telah diintegrasikan ke dalam sistem dengan membandingkan model *deep learning* (GRU dan LSTM) terhadap *baseline* statistik (ARIMA dan *Prophet*) pada empat metrik bisnis utama: volume pesanan (*order_hsi*), volume *churn* (*churn_hsi*), pencapaian target penjualan (*realisasi_hsi*), dan kualitas layanan operasional (*avg_install_days*). Seluruh metrik berhasil diramalkan dengan status LULUS pada tingkat nasional. Model GRU memberikan kinerja paling *robust* secara keseluruhan, menjadi model terbaik pada tiga dari empat metrik (sMAPE nasional: *order* 13,09%, *churn* 22,29%, *avg_install_days* 10,86%), sedangkan LSTM unggul pada metrik realisasi target (sMAPE 6,48%). Model ARIMA kompetitif pada deret waktu stabil namun gagal pada wilayah bervolatilitas tinggi, sementara *Prophet* tidak sesuai untuk data operasional dan *churn* tetapi menunjukkan kinerja kompetitif pada data pesanan yang memiliki pola musiman lebih kuat.
5. Modul pembangkitan bahasa alami berbasis templat (*template-based Natural Language Generation*) telah diintegrasikan untuk menghasilkan narasi dalam bahasa Indonesia dari data terstruktur hasil kueri *Enterprise Data Warehouse Oracle*. Pendekatan berbasis templat secara arsitektural menjamin akurasi faktual karena seluruh nilai numerik dalam narasi disisipkan langsung dari hasil kueri basis data tanpa melalui proses generasi bebas sehingga tidak terdapat risiko halusinasi (*hallucination*) yang lazim dijumpai pada model generatif.
6. Antarmuka percakapan berbasis web telah dirancang dan diimplementasikan menggunakan React.js dengan dukungan *render Markdown* untuk menampilkan tabel dan format teks, panel peramalan interaktif, alur terpandu (*guided flow*), serta manajemen riwayat percakapan. Penilaian oleh pengguna internal dari tim *Data Management* menghasilkan rata-rata skor 4,75 dari 5,00 (95%) pada empat aspek kualitas (ketepatan respons, kejelasan narasi, relevansi analisis, dan kemudahan penggunaan), yang mengkonfirmasi bahwa sistem dapat memenuhi kebutuhan analitik operasional pengguna.

VII.2 Saran

Berdasarkan hasil evaluasi dan keterbatasan yang diidentifikasi selama pelaksanaan tugas akhir, berikut adalah saran untuk pengembangan sistem di masa mendatang.

1. Integrasi Model Bahasa Besar (*Large Language Model/LLM*): Pendekatan klasifikasi maksud berbasis pencocokan pola kata kunci memiliki keterbatasan dalam menangani variasi bahasa alami yang kompleks. Integrasi dengan LLM seperti GPT atau Gemini dapat meningkatkan kemampuan pemaham-

an bahasa alami secara signifikan, khususnya untuk menangani kueri ambigu, parafrase, dan pertanyaan di luar cakupan aturan yang telah didefinisikan.

2. Implementasi Model *Temporal Fusion Transformer (TFT)*: Model TFT yang telah dirancang pada tahap perancangan belum diimplementasikan secara penuh. Implementasi TFT menggunakan pustaka `pytorch-forecasting` diharapkan dapat meningkatkan akurasi peramalan melalui mekanisme perhatian multi-kepala (*multi-head attention*) dan kemampuan menangkap pola temporal jangka panjang.
3. Implementasi Prediksi *Churn Biner per Pelanggan*: Sistem saat ini meramalkan jumlah agregat *churn* bulanan (`COUNT(DISTINCT NCLI)`) sebagai deret waktu numerik. Pengembangan selanjutnya dapat menambahkan modul klasifikasi biner yang memprediksi probabilitas *churn* untuk setiap pelanggan individual berdasarkan fitur perilaku (tenur, pendapatan, penggunaan layanan). Modul ini memerlukan protokol evaluasi klasifikasi terpisah (akurasi, presisi, daya ingat, skor-F1, AUC-ROC) dan tidak boleh dicampurkan dengan metrik regresi yang digunakan untuk peramalan deret waktu.
4. Integrasi dengan Sistem ERP/CRM Perusahaan: Sistem yang dikembangkan saat ini merupakan purwarupa mandiri (*standalone*). Integrasi dengan sistem ERP (*Enterprise Resource Planning*) atau CRM (*Customer Relationship Management*) yang ada di perusahaan dapat memperluas cakupan data dan fungsionalitas, serta mendukung alur kerja bisnis yang lebih komprehensif.
5. Peningkatan Keamanan ke Standar *Enterprise*: Implementasi keamanan saat ini berada pada tingkat dasar (autentikasi JWT dan enkripsi *bcrypt*). Peningkatan ke standar keamanan *enterprise* seperti ISO 27001, implementasi *OAuth 2.0*, *audit logging*, dan enkripsi data *at-rest* diperlukan untuk penerapan pada lingkungan produksi.
6. Perluasan Cakupan *Intent dan Domain Data*: Cakupan *intent* saat ini dibatasi pada tujuh kategori utama. Perluasan cakupan *intent* dapat dilakukan melalui analisis log percakapan pengguna secara berkala untuk mengidentifikasi pola pertanyaan baru yang belum tercakup. Selain itu, penambahan domain data baru di luar lima domain yang ada dapat meningkatkan nilai analitik sistem.
7. Kontainerisasi dan *Deployment Otomatis*: Implementasi kontainerisasi menggunakan Docker dan orkestrasi dengan Kubernetes atau Docker Compose dapat meningkatkan konsistensi lingkungan *deployment*, skalabilitas, dan kemudahan pemeliharaan sistem pada lingkungan produksi.
8. Perluasan Validasi ke Kelompok Pengguna yang Lebih Luas: Validasi sistem saat ini telah dilakukan oleh pengguna internal dari tim *Data Management*.

Ke depannya, validasi perlu diperluas kepada kelompok pengguna yang lebih beragam di luar tim *Data Management*, mencakup pengguna dari fungsi bisnis lain seperti tim penjualan, tim perencanaan, dan manajemen operasional. Perluasan ini bertujuan untuk mengukur efektivitas sistem dalam mendukung pengambilan keputusan pada berbagai konteks bisnis, mengidentifikasi kebutuhan analitik baru yang belum tercakup, serta memperoleh umpan balik yang lebih representatif mengenai kemudahan penggunaan dan relevansi respons sistem.

DAFTAR PUSTAKA

- Adam, Martin, Michael Wessel, dan Alexander Benlian. 2021. "AI-based Chatbots in Customer Service and Their Effects on User Compliance". *Electronic Markets* 31 (2): 427–445. <https://doi.org/10.1007/s12525-020-00414-7>.
- Amazon Web Services. 2024. "Securing Generative AI: Data, Compliance, and Privacy Considerations". Diakses pada November 4, 2025. <https://aws.amazon.com/blogs/security/securing-generative-ai-data-compliance-and-privacy-considerations/>.
- Ananta, Y. E., dkk. 2025. "Pengembangan Aplikasi Sido Chatbot sebagai Layanan Informasi Menggunakan Pendekatan Pencocokan Pola Berbasis Aturan". *Jurnal Sistem Cerdas dan Aplikasi X (Y)*: 1–12.
- Arch Library Documentation. 2025. "Model Confidence Set (MCS) for Time Series Evaluation". Diakses pada November 4, 2025. <https://arch.readthedocs.io/en/latest/bootstrap/mcs.html>.
- AtScale. 2025. "Why Semantic Layers? A Key Technical Architecture". Diakses pada November 4, 2025. <https://www.atscale.com/blog/semantic-layers-key-technical-architecture/>.
- Bamurange, Daniel. 2025. "Designing a Hybrid AI Chatbot Framework for Student Support: Integrating NLP and Human Oversight in African Universities". *Edinburgh Journals - Journal of Information Technology* 5 (4): 41–52. <https://doi.org/10.70619/vol5iss4pp41-52>.
- Celikyilmaz, Asli, Elizabeth Clark, dan Jianfeng Gao. 2020. "Evaluation of Text Generation: A Survey". *arXiv preprint arXiv:2006.14799*.
- Cheng, Yu, dkk. 2025. "Multivariate Time Series Forecasting Through Automated Feature Extraction and Transformer-Based Modeling". *Journal of Computer Science and Software Applications* 5 (5): 1–25.

- Cherednichenko, O., dkk. 2023. "Reference Model for Collaborative Business Intelligence Virtual Assistants". Dalam *CEUR Workshop Proceedings*, 3403:77–88.
- Cyara. 2024. "What's the Optimum Confidence Threshold for My Chatbot". Diakses pada November 4, 2025. <https://cyara.com/blog/optimum-chatbot-confidence-threshold/>.
- Databricks. 2025a. "An Introduction to Time Series Forecasting with Generative AI". Diakses pada December 4, 2025. <https://www.databricks.com/blog/introduction-time-series-forecasting-generative-ai>.
- . 2025b. "The Role of Semantic Layers in Modern Data Analytics". Diakses pada November 4, 2025. <https://www.databricks.com/glossary/semantic-layer>.
- Diqi, M., dkk. 2023. "Multi-Step Vector Output Prediction of Time Series Using EMA LSTM and GRU-LSTM Hybrid Model". *JOIN X (Y)*: 1–20.
- East Ventures. July 2025. *AI-first: Decoding Southeast Asia Trends*. White Paper. Diakses: 4 November 2025. Jakarta, Indonesia: East Ventures. <https://east.vc/press-release-3/east-ventures-launched-a-white-paper-focusing-on-ai>.
- Elangovan, Ashwin, dkk. 2023. "ConSiDERS: The Human Evaluation Framework". Dalam *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*.
- European Data Protection Board. 2025. "AI Privacy Risks & Mitigations: Large Language Models (LLMs)". Diakses pada November 4, 2025. <https://www.edpb.europa.eu/>.
- Evidently AI. 2025. "Accuracy, Precision, and Recall in Multi-Class Classification". Diakses pada December 2, 2025. <https://www.evidentlyai.com/classification-metrics/multi-class-metrics>.
- Feyisetan, Oluwaseyi, Borja Balle, Thomas Drake, dan Tom Diethe. 2022. "Privacy- and Utility-Preserving Textual Analysis via Calibrated Multivariate Perturbations". *Proceedings of the 13th ACM International Conference on Web Search and Data Mining*, 178–186. <https://doi.org/10.1145/3336191.3371856>.
- Fujitsu - PostgreSQL Fastware. 2024. "Generative AI and Data: Protecting Organizational Data". Diakses pada November 4, 2025. <https://www.postgresql.fastware.com/blog/generative-ai-and-data>.

- Gao, Mingqi, Xinyu Hu, Jie Yin, Xiao Ruan, dan Xiaojun Wan. 2025. “LLM-based NLG Evaluation: Current Status and Challenges”. ArXiv:2402.01383, *Computational Linguistics*.
- Gehweiler, Christian. 2024. “Classification of Intent in Moderating Online Discussions”. *Expert Systems with Applications* 239:122234.
- Gehweiler, Christian, dkk. 2025. “Intent Detection for Task-Oriented Conversational Agents: A Survey”. *Expert Systems* 42 (3).
- Genesys. 2023. “Set Bot Confidence Thresholds”. Diakses pada November 4, 2025. <https://www.genesys.com/blog/post/set-bot-confidence-thresholds>.
- Grandini, Margherita, Enrico Bagli, dan Giorgio Visani. 2020. “Metrics for Multi-Class Classification: An Overview”. *arXiv preprint arXiv:2008.05756*, arXiv: 2008.05756 [cs.LG].
- Gul, Raazia, dan Mamdouh Abdulaziz Saleh Al-Faryan. 2023. “From insights to impact: leveraging data analytics for data-driven decision-making and productivity in banking sector”. *Humanities and Social Sciences Communications* 10:1–12. <https://doi.org/10.1057/s41599-023-02122-x>.
- Hartanto, Sigit, dkk. 2024. “Temporal Fusion Transformers for Enhanced Multivariate Time Series Stock Market Prediction”. *The Science and Information Organization* X (Y).
- Hengst, Floris, dkk. 2024. “Conformal Intent Classification and Clarification for Fast and Accurate Intent Recognition”. Dalam *Findings of the Association for Computational Linguistics: NAACL 2024*, 2410–2418. <https://aclanthology.org/2024.findings-naacl.156.pdf>.
- Hsu, Chin-Lung, dan Judy Chuan-Chuan Lin. 2023. “Understanding the User Satisfaction and Loyalty of Customer Service Chatbots”. *Journal of Retailing and Consumer Services* 71:103211. <https://doi.org/10.1016/j.jretconser.2022.103211>.
- Huang, Xufei. 2021. “Chatbot: Design, Architecture, and Applications”. PhD thesis, University of Pennsylvania. <https://www.cis.upenn.edu/wp-content/uploads/2021/10/Xufei-Huang-thesis.pdf>.
- IBM. 2025. “Types of Chatbots”. Diakses pada December 4, 2025. <https://www.ibm.com/think/topics/chatbot-types>.

- Iqbal, Muhammad, Rashid Ahmad, dan Saif Ur Rehman Khan. 2021. “Combined Support Vector Machine and Pattern Matching for Arabic Question Classification”. *International Journal of Pattern Recognition and Artificial Intelligence* 35 (8): 287–299. https://doi.org/10.1007/978-3-319-99007-1_27.
- IT Convergence. 2024. “Generative AI Data Security: Key Considerations”. Diakses pada November 4, 2025. <https://www.itconvergence.com/blog/data-security-considerations-for-generative-ai/>.
- Jeaab, K., dkk. 2024. “A Comparison of LSTM, GRU, and XGBoost for Forecasting Morocco’s Yield Curve”. *Eastern-European Journal of Enterprise Technologies X (Y)*.
- Kale, Mihir, dan Abhinav Rastogi. 2020. “Template Guided Text Generation for Task-Oriented Dialogue”. Dalam *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 6505–6520. Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.emnlp-main.527>.
- Kapoor, Ankit, dan Sujala Shetty. 2023. “Implementing Natural Language Generation Through Industry-Specific Chatbots”. *Data Science and Intelligent Computing Techniques*, 55–67. <https://doi.org/10.56155/978-81-955020-2-8-6>.
- Khaddam, Ibrahim, dan Mohammad Alzghoul. 2025. “Artificial Intelligence-Driven Business Intelligence: Systematic Literature Review”. *International Journal of Energy Economics and Policy* 15 (1): 45–54. <https://doi.org/10.32479/ijeep.19820>.
- Khosla, Sopan, Chenwei Xu, Shikhar Toshniwal, Dinesh Manocha, Markus Dreyer, Lambert Mathias, Jing Gao, dan Asli Celikyilmaz. 2022. “Evaluating the Practical Utility of Confidence-score based Techniques for Unsupervised Open-World Classification”. Dalam *Proceedings of the Third Workshop on Insights from Negative Results in NLP*, 20–28. <https://doi.org/10.18653/v1/2022.insights-1.3>.
- Kuligowska, Karolina, dan Zdzislaw Kowalczyk. 2024. “Enhancing Chatbot Intent Classification Using Active Learning Pipeline”. *Journal of Applied Economic Sciences* 19 (2): 290–300.
- Labs, dbt. 2024. “Understanding Semantic Layer Architecture”. Diakses pada November 4, 2025. <https://www.getdbt.com/blog/semantic-layer-architecture>.

- Lee, Chris van der, dkk. 2021. “Human Evaluation of Automatically Generated Text: Current Trends and Best Practices”. *Natural Language Engineering* 27 (4): 1–27.
- Lim, Bryan, Sercan O. Arik, Nicolas Loeff, dan Tomas Pfister. 2021. “Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting”. *International Journal of Forecasting* 37 (4): 1748–1764. <https://doi.org/10.1016/j.ijforecast.2021.03.012>.
- Lubis, J. H., dkk. 2025. “Performance Optimization of ERD Designs Using Cost-Based and Rule-Based Query Optimization”. *JUTEI X (Y)*: 1–10.
- Luo, Yuanshuai, dan Guiran Liu. 2024. “Data Security Strategies in Natural Language Processing Applications”. *arXiv preprint arXiv:2410.08553*, arXiv: 2410.08553.
- Masini, Ricardo P., Marcelo C. Medeiros, dan Eduardo F. Mendes. 2023. “Machine learning advances for time series forecasting”. *Journal of Economic Surveys* 37 (1): 76–111. <https://doi.org/10.1111/joes.12429>.
- Mena, Gary, Kristof Coussement, Koen W. De Bock, Arno De Caigny, dan Stefan Lessmann. 2024. “Exploiting Time-Varying RFM Measures for Customer Churn Prediction with Deep Neural Networks”. *Annals of Operations Research* 339 (1-2): 765–787. <https://doi.org/10.1007/s10479-023-05259-9>.
- Merugu, Srujana, dkk. 2024. “Intent Detection in the Age of LLMs”. Dalam *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track*, 1–12.
- Miresghallah, Fatemehsadat, Kartik Goyal, Shrimai Upadhyay, dan Taylor Berg-Kirkpatrick. 2022. “Differentially Private Methods in Natural Language Processing”. *Proceedings of the Fourth Workshop on Privacy in Natural Language Processing*, 1–11. <https://doi.org/10.18653/v1/2022.privatenlp-1.1>.
- Morrison, Mark, dkk. 2021. “Reproducible Subjective Evaluation”. Dalam *Proceedings of the Neural Information Processing Systems Workshop on ML Evaluation Standards*.

- Mulyatun, Dedi Kurniawan, dan Agus Hudaya. 2021. "Pendekatan Natural Language Processing pada Aplikasi Chatbot sebagai Alat Bantu Customer Service". *Journal of Information System Management (JOISM)* 2 (2): 12–17. <https://doi.org/10.24076/joism.2021v3i1.404>. <https://jurnal.amikom.ac.id/index.php/joism/article/view/404>.
- Nabiilah, Sarah, Adiwijaya, dan Widi Maharani. 2025. "Comparative Analysis of SVM and IndoBERT for Intent Classification in E-LEMBUR Chatbot". *Journal of Software and Computer Engineering* 6 (3): 258–267. <https://doi.org/10.61628/jsce.v6i3.2058>.
- Ouaddi, Charaf, Fatima Benabbou, dan Nawal Sael. 2025. "Assessing the Effectiveness of Large Language Models for Intent Detection in Tourism Chatbots: A Comparative Analysis and Performance Evaluation". *Scientific African* 28:e02649. <https://doi.org/10.1016/j.sciaf.2025.e02649>.
- Ouali, S., dkk. 2024. "Arabic Chatbots Challenges and Solutions: A Systematic Review". *International Journal of Computer Science and Mobile Computing X* (Y): 1–20.
- Ozerova, Daria. 2022. "Intent Detection Module for a Conversational Assistant". Master's thesis, Czech Technical University in Prague.
- Petropoulos, Fotios, dkk. 2023. "Forecast Evaluation for Data Scientists: Common Pitfalls and Best Practices". *International Journal of Forecasting* 39 (4): 1500–1518.
- Petropoulos, Fotios, Daniele Apiletti, Vassilios Assimakopoulos, Mohamed Zied Babai, Devon K. Barrow, Souhaib Ben Taieb, dkk. 2022. "Forecasting: theory and practice". *International Journal of Forecasting* 38 (3): 705–871. <https://doi.org/10.1016/j.ijforecast.2021.11.001>.
- Prasetyo, Budi, dan Dhanan Kusuma. 2024. "Customer Churn Prediction using Histogram Augmentation Technique and XGBoost". *Procedia Computer Science* 227:456–465.
- Precedence Research. 2025. "Natural Language Processing Market Size to Hit USD 438.08 Bn by 2034". Diakses pada November 4, 2025. <https://www.precedenceresearch.com/natural-language-processing-market>.

- Priadinata, Rendra, dan Kusuma Wijaya. 2025. "Comparative Analysis of LSTM, GRU, and Bi-LSTM Deep Learning Models for Time Series Forecasting". *Jurnal Sinkron* 10 (1): 78–95.
- Python Package Index. 2025. "Diebold-Mariano Test Implementation in Python". Diakses pada November 4, 2025. <https://pypi.org/project/dieboldmariano/>.
- Qaltivate. 2025. "Conversational AI Market Summary: 2025 Edition". Diakses pada November 4, 2025. <https://qaltivate.com/blog/conversational-ai-market/>.
- Querio AI. 2025. "Conversational AI Data Analyst Chatbot". Diakses pada Desember 4, 2025. <https://querio.ai/articles/conversational-ai-data-analyst-chatbot>.
- Rebuffel, Clément, Laure Soulier, Geoffrey Scoutheeten, dan Patrick Gallinari. 2020. "A Hierarchical Model for Data-to-Text Generation". *arXiv preprint arXiv:2004.15006*, arXiv: 2004.15006.
- Retresco. 2024. "GPT and Template-Based Text Models in NLG". Diakses pada Desember 4, 2025. <https://www.retresco.de/en/blog/gpt-template-based-text-models/>.
- Sabila, A., dkk. 2025. "Deep Learning, GRU (Gated Recurrent Unit), LSTM (Long Short-Term Memory) Stock Price Prediction". *Akademika X* (Y).
- Sahoo, Saumyaranjan, Satish Kumar, Naveen Donthu, dan Alok Kumar Singh. 2023. "Artificial intelligence capabilities, open innovation, and business performance – Empirical insights from multinational B2B companies". *Industrial Marketing Management* 114:1–15. <https://doi.org/10.1016/j.indmarman.2023.12.008>.
- Sai, Ananya B., Akash Kumar Mohankumar, dan Mitesh M. Khapra. 2020. "A Survey of Evaluation Metrics Used for NLG Systems". *arXiv preprint arXiv:2008.12009*.
- Sam, Erick, dan Charles Okonkwo. 2024. "Customer Churn Prediction using Machine Learning Models". *Journal of Educational Research and Reviews* 12 (3): 210–225.
- Santosa, Rahmad, Adetiya Bagus Nusantara, dan Syaiful Imron. 2025. "Comparative Analysis of SVM and IndoBERT for Intent Classification in Indonesian Overtime Chatbots". *JSCE* 6 (3): 258–270. <https://doi.org/10.61628/jsce.v6i3.2058>.

- Shah, Nisarg. 2025. "AI-Driven Autonomous Database Management: Self-Tuning Query Optimization, Predictive Maintenance, and Intelligent Workload Distribution". *World Journal of Advanced Research and Reviews* 24 (1): 1519–1533.
- Sharma, Priya, dan Rajesh Kumar. 2024. "Rule-based AI Chatbot". *International Journal of Innovative Research and Technology* 11 (1): 1–15.
- Singh, S. U., dkk. 2025. "A Survey on Chatbots and Large Language Models: Testing and Design Principles". *Journal of Decision Systems* X (Y): 1–25.
- Sorour, Mohamed K. 2020. "The Role of Business Intelligence and Analytics in Higher Education Decision Making". Dalam *2020 IEEE Global Engineering Education Conference (EDUCON)*, 1849–1856. IEEE. <https://doi.org/10.1109/EDUCON45650.2020.9194157>.
- Spiliotis, Evangelos, Spyros Makridakis, dan Fotios Petropoulos. 2020. "Comparison of Statistical and Machine Learning Methods for Time Series Forecasting". *International Journal of Forecasting* 36 (1): 1–15.
- Spot Intelligence. 2023. "Building a Dataset for Intent Classification in NLP: Evaluation and Model Performance". Diakses pada November 4, 2025. <https://spotintelligence.com/2023/11/03/intent-classification-nlp/>.
- Straits Research. 2024. "Business Intelligence Market Size & Outlook, 2025–2033". Diakses pada November 4, 2025. <https://straitsresearch.com/report/business-intelligence-market>.
- Sunendar, Nendi, dan Yan Rianto. 2025. "Comparison of ARIMA, LSTM, and GRU Models for Forecasting Sales of HIT Aerosol Products". *Jurnal Pilar Nusa Mandiri* X (Y).
- Syarifudin, Muhammad, dkk. 2024. "Modeling AI-Chatbot Service Quality and Purchase Intention". *JDMHI* X (Y).
- Talenggoran, R., dkk. 2025. "Implementation of Rasa Framework to Build FAQ Bot System on Messaging Platform". *JUTEI* X (Y): 1–10.
- Tuncer, İlker, dan Musa Peker. 2023. "Comparison of ARIMA, Prophet and LSTM Models for Time Series Forecasting in Business Intelligence Applications". *Engineering Science and Technology, an International Journal* 46:101513. <https://doi.org/10.1016/j.jestch.2023.101513>.

- Velotix. 2025. “Data Security in Generative AI Environments: 5 Steps”. Diakses pada November 4, 2025. <https://www.velotix.ai/resources/blog/data-security-in-generative-ai-environments/>.
- Wijaya, Bambang, dan Dianto Kusuma. 2024. “Multi-industry Stock Forecasting using GRU-LSTM Deep Learning”. *Jurnal Infotel* 16 (2): 145–162.
- WiseGuy Reports. 2024. “Time Series Forecasting Market”. Diakses pada November 4, 2025. <https://www.wiseguyreports.com/reports/time-series-forecasting-market>.
- Xiao, Ziang, dkk. 2023. “A Framework for Analyzing NLG Evaluation Metrics Using Measurement Theory”. *Transactions of the Association for Computational Linguistics*.
- Yang, X., dkk. 2024. “Machine Learning for Database Management and Query Optimization”. *International Journal of Computer Science and Management* X (Y): 1–12.
- Yellowfin BI. 2025. “What is Natural Language Generation? How NLG Works”. Diakses pada December 4, 2025. <https://www.yellowfinbi.com/blog/what-is-natural-language-generation>.
- Yunita, Anis, dkk. 2025. “Performance Analysis of Neural Network Architectures for Time Series Forecasting: A Comparative Study of RNN, LSTM, GRU, and Hybrid Models”. *Data Science and Engineering* X (Y): 1–25.
- Zhang, Yun, dkk. 2024. “A Comprehensive Survey of Time Series Forecasting: ARIMA, Deep Learning, Transformers, and Beyond”. *arXiv preprint*, eprint: 2411.05793.
- Zhang, Yutao, Yang Liu, Meng Zhang, dan Xiaoming Li. 2022. “Disentangling Confidence Score Distribution for Out-of-Domain Intent Detection”. *arXiv preprint arXiv:2210.08830*, arXiv: 2210.08830.

LAMPIRAN A

HASIL WAWANCARA

Wawancara terstruktur dilakukan untuk menggali kebutuhan fungsional dan non-fungsional sistem *Business Intelligence* berbasis *chatbot*. Wawancara melibatkan dua narasumber dari PT Telkom Indonesia yang merepresentasikan perspektif manajemen dan teknis.

Narasumber 1: Bapak Purwanto

Manager Regional Data Management

Tabel A.1 Hasil Wawancara dengan Bapak Purwanto

Pertanyaan	Jawaban
Bagaimana kondisi sistem analitik saat ini?	Saat ini kami masih mengandalkan dasbor statis dan pelaporan manual. Setiap permintaan analisis khusus harus diproses oleh tim TI atau analis data. Proses ekstraksi data dari berbagai sistem (CRM, billing, order management) memakan waktu 2–5 hari untuk ku-eri kompleks.
Apa tantangan utama yang dihadapi?	Tantangan utama adalah ketergantungan pada tim teknis yang terbatas. Hanya sekitar 10–15 dari 200 lebih pengguna internal yang memiliki kemampuan SQL. Selain itu, belum ada fitur prediktif yang mudah diakses, peramalan masih dilakukan manual dengan hasil berupa laporan bulanan, bukan real-time.

Bersambung ke halaman berikutnya

Tabel A.1 – *Lanjutan dari halaman sebelumnya*

Pertanyaan	Jawaban
Fitur apa yang diharapkan dari sistem baru?	Kami membutuhkan sistem yang dapat me-respons pertanyaan bisnis dalam hitungan menit melalui antarmuka percakapan Bahasa Indonesia. Fitur utama yang diharapkan: query on-demand, peramalan prediktif otomatis, dan respons naratif yang mudah dipahami pengguna nonteknis.
Bagaimana dengan aspek keamanan data?	Keamanan adalah prioritas. Sistem harus memiliki enkripsi, kontrol akses berbasis peran, dan audit trail lengkap. Data sensitif pelanggan tidak boleh ditampilkan langsung dalam respons chatbot.
Apa target keberhasilan sistem?	Target utama: 70% pengguna internal mengadopsi sistem dalam 6 bulan, waktu respons berkurang dari 2–5 hari menjadi kurang dari 2 menit, dan skor kepuasan pengguna (SUS) minimal 70.

Narasumber 2: Mas Renno Rifaldo

Officer Regional Data Mining and Processing

Tabel A.2 Hasil Wawancara dengan Mas Renno Rifaldo

Pertanyaan	Jawaban
Apa kendala teknis integrasi data saat ini?	Kami memiliki sistem database yang terpadu pada Oracle dan beberapa sistem legacy. Kualitas data antar-sistem tidak konsisten, dan data warehouse hanya di-update sekali sehari (batch malam).
Data apa saja yang tersedia untuk analisis?	Data historis pelanggan tersedia minimal 1 tahun, mencakup informasi pesanan (order), target penjualan, tingkat churn, dan pendapatan. Data disimpan di Oracle Data Warehouse.

Bersambung ke halaman berikutnya

Tabel A.2 – *Lanjutan dari halaman sebelumnya*

Pertanyaan	Jawaban
Pendekatan teknis apa yang direkomendasikan?	Kami merekomendasikan pendekatan yang aman untuk data, cepat, akurat, dan tidak membosankan dalam penyajian data pada percakapan AI. Backend menggunakan FastAPI dengan target response time di bawah 2 detik.
Apa batasan teknis yang perlu diperhatikan?	Sistem harus dapat menangani latency dan throughput yang memadai. Perlu caching strategy untuk kueri yang sering diakses. Arsitektur harus scalable untuk mengakomodasi pertumbuhan pengguna dan volume data.
Bagaimana rencana infrastruktur?	Gunakan Tools bebas untuk deployment. Oracle Database tetap sebagai single source of truth dengan tambahan Redis untuk caching.

Kesimpulan

Berdasarkan wawancara dengan kedua narasumber, teridentifikasi bahwa kondisi sistem saat ini masih mengandalkan pelaporan manual dan dasbor statis dengan waktu respons 2–5 hari untuk kueri kompleks. Tantangan utama mencakup ketergantungan pada tim teknis terbatas, fragmentasi sistem data, dan ketiadaan fitur prediktif yang mudah diakses.

Kedua narasumber mengkonfirmasi kebutuhan akan sistem Business Intelligence berbasis chatbot yang dapat mempercepat akses insight, mendukung antarmuka bahasa alami dalam Bahasa Indonesia, dan menyediakan kemampuan peramalan prediktif. Data historis pelanggan (pesanan, target, churn, pendapatan) tersedia minimal 1 tahun di Oracle Data Warehouse sebagai basis pengembangan sistem.

LAMPIRAN B

HASIL FORMULIR EVALUASI HASIL SISTEM BRIGHTAI (INTERNAL)

Evaluasi akhir dari fungsionalitas purwarupa sistem BrightAI dilakukan secara internal dengan melibatkan representasi pihak manajemen data perusahaan, yaitu seorang *Officer Data Management* yang bertindak secara langsung sebagai mentor dari proyek ini. Penilaian evaluasi difokuskan dan diwakilkan oleh satu orang *officer* tersebut mengingat manajer terkait sedang berada dalam masa transisi perpindahan tugas ke pihak lain sehingga sang *officer* merupakan individu yang paling komprehensif dalam memahami konteks, kebutuhan operasional, serta kondisi riil analitik perusahaan saat ini. Berdasarkan hasil pengisian formulir evaluasi yang dilampirkan, didapatkan umpan balik yang valid mengenai kesesuaian sistem dengan spesifikasi kebutuhan awal, keandalan antarmuka percakapan sistem, serta relevansi wawasan (*insight*) bisnis yang dihasilkan oleh model. Hal ini memverifikasi bahwa solusi kecerdasan buatan terintegrasi yang dibangun telah sejalan dengan standar internal perusahaan dan diproyeksikan mampu mempercepat proses pengambilan keputusan.

LAMPIRAN C

TAUTAN REPOSITORI KODE SUMBER

Seluruh kode sumber yang dikembangkan pada penelitian ini, mencakup arsitektur layanan *backend* (berbasis Node.js dan FastAPI), antarmuka *frontend* (berbasis React), *rule-based engine*, hingga modul peramalan berbasis pembelajaran mesin (LSTM, GRU, ARIMA, Prophet), telah didokumentasikan secara terpusat pada repositori GitHub.

Kode sumber sistem BrightAI dapat ditinjau lebih lanjut dan diakses secara daring melalui tautan berikut:

<https://github.com/thalitazhrr/BrightAIProject-Final>

Repositori tersebut juga memuat dokumentasi terkait struktur direktori proyek, instruksi pengaturan lingkungan pengembangan (*environment setup*), daftar dependensi perangkat lunak, serta skrip yang diperlukan untuk mereplikasi fungsionalitas sistem secara keseluruhan.

